DIPARTIMENTO DI
ECONOMIA E FINANZA

METODI E ANALISI STATISTICHE 2024

In ricordo di
Francesco Domenico d'Ovidio

UNIVERSITÀ
DEGLI STUDI DI BARI
ALDO MORO

DIPARTIMENTO DI
ECONOMIA E FINANZA

METODI E ANALISI STATISTICHE 2024

In ricordo di
Francesco Domenico d'Ovidio

UNIVERSITÀ
DEGLI STUDI DI BARI
ALDO MORO

Tutti i diritti di traduzione, riproduzione e adattamento,
totale o parziale, con qualsiasi mezzo (comprese le copie
fotostatiche e i microfilm) sono riservati

Toma E. (a cura di), *Metodi e Analisi Statistiche 2024*, Dipartimento di Economia e Finanza, Università degli studi di Bari Aldo Moro.

© Copyright 2024 by Università degli Studi di Bari Aldo Moro
www.uniba.it

Prima edizione: dicembre 2024

ISBN: 978-88-6629-053-7

I contributi presentati nel presente volume sono stati tutti oggetto di valutazione interna

Editing finale a cura di E. Toma

Sommario

Sommario ..... pag. III

Ernesto Toma
In ricordo di Francesco Domenico d'Ovidio ..... « V

Ernesto Toma
Presentazione ..... « IX

Francesco Domenico d'Ovidio
Sulle misure di concordanza e discordanza fra due distribuzioni statistiche ..... « 1

Antonella Massari, Vittoria Claudia De Nicolò, Eleonora Lionetti
La statistica per il calcio ..... « 65

Monica Carbonara, Sara Casacci
Analisi territoriale dei low-income earners in Italia ..... « 83

Domenico Viola, Carlo Cusatelli, Debora Cazzetta, Andrea Troisi
Evoluzione e prospettive dell'industria alimentare nella città metropolitana di Bari ..... « 99

Alessio Tafuni, Crescenza Calculli, Alessio Pollice
Analisi quantitativa dei dati del servizio Copernicus per la valutazione e la gestione degli incendi boschivi in Italia nella stagione estiva 2023 ..... « 113

Laura Antonucci, Antonia Cofano, Corrado Crocetta, Massimo Russo
Analisi della soddisfazione rispetto ai servizi erogati da Sanitaservice ASL Foggia s.r.l. ..... « 129

Barbara Nocca, Nunziata Ribecco, Alessandro Stella
L'impatto delle mutazioni del DNA sul processo di* splicing*: un'analisi statistica nel contesto del gene BRCA1 ..... « 143

Maurizio Gangemi
La manna del Mezzogiorno tra normativa e mercato (XVIII-XIX secc.) ..... « 155

Pietro Bianco, Angela Maria D'Uggento, Mariabeatrice Principi, Ernesto Toma
Real World Data: la nuova sfida nell'analisi dei dati sui percorsi di cura dei pazienti ..... « 171

Angela Maria D'Uggento, Claudia Marin, Albino Biafora, Margaret Antonicelli, Barbara Cafarelli
Misurare l'efficacia dei messaggi pubblicitari sui social media. Il caso della pandemia in Italia ..... « 193

Domenico Viola, Alessandro Rinaldi
Ramificazioni delle famiglie di curve di concentrazione L(p) ad una famiglia di archi di una Superellisse al variare dei parametri β e δ ..... « 205

Agata Maria Madia Carucci, Giovanni Vannella
Spese per i servizi sociali e Strategia per le Aree Interne ..... « 221

In ricordo di
Francesco Domenico d'Ovidio



Il volume *Metodi e analisi statistiche 2024* è dedicato al prof. Francesco Domenico d'Ovidio, l'amico Franco, che purtroppo ci ha prematuramente lasciato il 5 luglio scorso, a poco più di un anno da quella pensione a cui mentalmente si rifiutava di pensare.

"*Per la ricerca, finché posso scrivere un rigo non smetto*". Questo uno degli ultimi messaggi inviatimi da Franco a fine giugno scorso, quando mi aveva manifestato la sua volontà di andare in pensione in anticipo di un anno, aggiungendo che per lui la ricerca era il suo hobby. Credo che tali parole possano riassumere la sua reale immensa passione per il suo lavoro, in particolare per la ricerca scientifica.

Per il lettore che non abbia avuto la fortuna di conoscere il prof. d'Ovidio, Franco, provo a ripercorrere la sua vita accademica.

Laureatosi in Scienze Statistiche ed Economiche presso l'Università degli Studi di Bari, aveva inizialmente prestato servizio nei ruoli del personale tecnico presso lo stesso Ateneo, nell'allora Istituto di Scienze demografiche e sociali, per circa un decennio. La sua preparazione statistica, unita alle sue profonde conoscenze del mondo informatico, lo aveva spinto da subito a collaborare scientificamente con i docenti dell'Istituto (e successivamente con quelli del Dipartimento di Scienze Statistiche in cui l'Istituto era nel frattempo confluito), facendogli anche intraprendere attività di ricerca in maniera autonoma. Punto di riferimento scientifico, per lui come per tanti di noi, diviene il prof. Francesco Delvecchio, già ordinario di Statistica sociale e Decano italiano del settore scientifico disciplinare.

Grazie anche alla collaborazione scientifica con il prof. Delvecchio, che gli ha consentito di sviluppare sempre più la sua innata attenzione verso le tematiche proprie della Statostica sociale, dal 2001 diviene ricercatore del settore stesso presso la Facoltà di Economia dell'Università di Bari e, dopo circa un anno, vince il concorso da professore associato nella stessa sede, pur prendendo servizio con tale qualifica solo dal 2005, a causa del blocco delle assunzioni nazionale decretato a partire dal 1 gennaio 2003.

I suoi interessi di ricerca erano da lui stesso sintetizzati nella sua pagina web dipartimentale nelle seguenti parole: valutazione della ricerca; valutazione della didattica; valutazione dei servizi; analisi di fenomeni sociali e sanitari; indicatori sociali e culturali; analisi di sopravvivenza (e in genere epidemiologiche); modelli SEM; analisi di segmentazione; reti neurali; sostenibilità alimentare e ambientale.

Tali parole, però, non rendono assolutamente merito alla sua poliedricità e quindi non possono essere considerate esaustive di quelli che erano i suoi innumerevoli interessi che spaziavano a 360° su moltissime altre tematiche scientifiche, principalmente statistiche ma non solo.

Testimonianza ne sono i numerosissimi ambiti, universitari e non, ai quali, nel corso degli anni, ha dato il suo prezioso contributo di idee, non solo metodologiche.

Va menzionata, ad esempio, la sua partecipazione a progetti quali: FORMEZ su "Invecchiamento e stato di salute nel Mezzogiorno (1989); Regione Puglia sulla procedura di rilevazione e pubblicazione dei dati delle elezioni regionali (2005); A.R.T.I.-Regione Puglia per l'individuazione di indicatori per la valutazione delle università pugliesi (2009-2010).

In campo universitario, di assoluto rilievo il suo contributo in progetti scientifici quali: "Demografia e poteri locali" (E. Todisco, 1997-98), "La ricerca di determinanti del rischio mediante analisi di segmentazione di campioni" (L. Fabbris, 2000-01), "Transizioni università-lavoro e valorizzazione delle competenze professionali dei laureati: modelli e metodi di analisi multidimensionale delle determinanti" (L. Fabbris, 2002-03), Analisi di sensibilità e sostituibilità di indicatori rilevanti per la valutazione del sistema universitario" (E. Aureli, 2005), "Modelli e metodi per abbinare profili formativi e bisogno di professionalità di settori economici in rapida evoluzione" (L. Fabbris, 2005-07), "Modelli, indicatori e metodi per rappresentare l'efficacia formativa di corsi di laurea ai fini dell'accreditamento e del miglioramento organizzativo" (L. Fabbris, 2008-2010), "Indicatori di efficacia della formazione terziaria e riflessioni metodologiche dalla ricerca sui laureati dell'Università di Padova" (L. Fabbris, 2009), "The future of sustainability" (C. Crocetta, 2022).

Non da ultimo, va ricordato il suo impegno in gruppi di lavoro come quello del CRISP (Centro di Ricerca Interuniversitaria sui Servizi alla Persona), presso Università di Milano-Bicocca, o nel gruppo per lo studio della Valutazione dei Servizi (SIS - Società Italiana di

Statistica), o nel CIRPAS-Bari (Centro Interuniversitario di Ricerca “Popolazione, Ambiente e Salute"), per finire con il suo contributo in ambito internazionale con la sua partecipazione al Cedimes-Paris e allo IARC-Tirana.

Copiosa, negli anni, la sua produzione scientifica che peraltro testimonia la multidisciplinarietà e la validità della sua ricerca. Tra i suoi lavori, infatti, ritroviamo pubblicazioni su prestigiose riviste statistiche quali Quality & Quantity, Socio-Economic Planning Sciences, Social Indicators Research, ma anche su riviste di altri contesti quali quello medico, con contributi su Acta haematologica, Journal of Hepatology, Cancer, Dermato-endocrinology, International Journal of Trichology, Digestive And Liver Disease, Forensic Science International: Genetics, Journal of the Association of Physicians, o economico matematico con articoli su Applied Mathematics, Procedia Economics and Finance.

In ogni suo contributo scientifico, egli ha sempre messo in primo piano il rigore metodologico della ricerca e la sua profonda capacità di interpretare il dato statistico, che faceva di lui un fine statistico sociale.

Dal punto di vista didattico, numerose sono le discipline di cui ha tenuto corsi di lezioni: Statistica sociale e sanitaria, Statistica Giudiziaria, Statistica sociale, Statistica del Turismo, Statistica per la valutazione dei servizi, Indagini campionarie, Statistica per la programmazione socio-sanitaria, scrivendo anche molto materiale didattico a beneficio degli studenti (ma anche di molti di noi colleghi).

Per comprendere meglio il prof. D’Ovidio, il nostro Franco, non si può però non parlare del suo lato umano, che forse ancor di più lo rendeva unico. Pertanto, credo che qualche ricordo personale possa aiutare a immaginare chi sia stato Franco d’Ovidio, per chi non lo abbia conosciuto, o a ricordarlo, per chi invece abbia avuto il piacere di incontrarlo sulla propria strada.

Non ci sono dubbi nell’affermare come Franco non sia mai stato banale nello svolgere il suo ruolo di professore. Il suo rapporto con gli studenti era speciale, li chiamava quasi sempre per nome, anche a distanza di anni. Ogni esame, specie quelli in cui lo studente manifestava delle difficoltà, era una vera lotta, e vinceva Franco quando finalmente (talvolta dopo anche più di un’ora), lo studente superava l’esame. E quando si accorgeva che lo studente era impreparato sull’argomento richiesto, non lo rimproverava quasi mai, bensì iniziava pazientemente a spiegarglielo durante l’esame (e qui, lo confesso, aggiungerei un ahimé, perché in quel modo gli esami divenivano talvolta interminabili, anche se, adesso, daremmo qualsiasi cosa per vederlo immergersi in quelle spiegazioni…). E quanti tesisti, tanti, si sono rivolti a lui sapendo che avrebbero trovato sempre una porta aperta per imparare, e oltre quella porta hanno passato insieme a lui ore e ore a comprendere l’uso dello strumento statistico. Caro Franco, ancora oggi tutti i tuoi studenti ti pensano e ti sono grati per tutta la tua competenza e disponibilità.

Era un uomo curioso come pochi, sempre pronto a studiare ciò che non sapeva o ad approfondire quello che già sapeva; a indagare su fenomeni sociali sui quali piccolo era lo sforzo che faceva per “capirli” -essendo dotato di grande intuito- ma grande era la facilità di approcciarli da un punto di vista metodologico, per poi divulgare il suo sapere. Anche negli ultimi mesi della dura lotta contro la malattia che lo stava consumando, è sempre stato per il suo, il nostro, gruppo di ricerca, una sorta di help online, sempre pronto a venire in soccorso a chiunque glielo chiedesse, condividendo con gli altri le sue profonde conoscenze della materia e per questo motivo raramente colto in fallo su qualcosa di cui ignorava il

contenuto. La passione per la ricerca e l'abnegazione verso il lavoro, è certamente uno dei principali insegnamenti che ci ha lasciato.

Personalmente, a lui devo molto, sia dal punto di vista umano che da quello scientifico. Con lui sono cresciuto e grazie a lui sono migliorato nel corso degli anni. Come dimenticare quando io, studente che aveva da poco chiesto la tesi di laurea al prof. Delvecchio, mi rivolgevo sempre a Franco (allora tecnico) per qualsiasi dubbio, soprattutto di natura informatica ma anche di natura statistica. E da lui ho sempre ricevuto preziosi consigli, suggerimenti, indicazioni. E per lui, fino alla fine, forse sono sempre rimasto un po' lo studente "sbarbatello" di quegli anni iniziali, come mi chiamava talvolta quando eravamo soli, in alternanza al nomignolo "boss", che evidenziava come purtroppo non era riuscito ad ottenere quanto a detta di tutti avrebbe ampiamente meritato, l'ultimo step della carriera universitaria (pur avendo comunque conseguito negli ultimi anni l'abilitazione scientifica nazionale a professore ordinario). Ma molti di noi lo chiamavano Maestro, e questo conferma che spesso i titoli si conquistano sul campo, a prescindere dalle traiettorie accademiche della vita.

Franco mi manca, ci manca, in ogni momento, non solo accademico ma soprattutto della vita quotidiana, con la sua "intelligente ironia" che lo contraddistingeva, con quelle battute che spesso ci lasciavano inizialmente un po' così… quasi perplessi, ma che poi ti facevano sorridere dopo qualche secondo, quando le avevi finalmente comprese.

Ho chiesto alla famiglia di scrivere qualche parola su di lui, e la moglie Maria, che fino all'ultimo ha lottato insieme al suo compagno di una vita, mi ha scritto queste poche righe che però sintetizzano perfettamente il suo sentimento, il nostro sentimento:

Mi manchi, perché non ho mai smesso di pensarti perché affrontare la realtà mi fa sempre molto male, perché amarti è per me naturale e ciò che è accaduto è irreale. Tu vivi nel mio cuore, nei miei pensieri, nelle parole che dico quando ti penso e parlo di te e così sopravvivi e fai ancora parte della mia vita

Maria

Ciao amico mio, e grazie di tutto

Ernesto

Presentazione

Il volume *Metodi e analisi statistiche 2024*, nona edizione della serie di volumi che raccolgono contributi di autori, sia statistici che non statistici, questi ultimi però con la caratteristica di usare dati e metodi quantitativi per le proprie ricerche, come detto nel precedente breve scritto in suo ricordo, è quest'anno dedicato al prof. Francesco Domenico d'Ovidio.

E proprio per questo motivo, il volume inizia con quello che verosimilmente è stata l'ultima "fatica scientifica" di Franco d'Ovidio, "*Sulle misure di concordanza e discordanza fra due distribuzioni statistiche*" che ad alcuni di noi aveva voluto far pervenire in formato pdf *preprint* per condividere ciò su cui stava lavorando e per avere anche giudizi e eventuali suggerimenti. Come lui riporta nel breve abstract, il saggio costituisce una breve ma, per quanto possibile, completa dissertazione sulle principali tecniche statistiche per lo studio delle relazioni tra due variabili, con particolare attenzione alle tecniche non parametriche, In questo saggio, che esula dal format del presente volume sia in alcuni standard che nella sua lunghezza, si propongono anche alcuni sviluppi di tecniche non parametriche di misura della concordanza tra variabili. Il lettore noterà una leggere difformità nella veste grafica di tale contributo, ma ciò dipende dal fatto che non si è voluto alterare la prima impaginazione, peraltro assolutamente conforme alla maggior parte dello standard del presente volume.

Il secondo contributo, di Massari et al., si applica il metodo statistico allo sport, in particolare al gioco del calcio, per valutare la performance delle squadre. È applicato l'indice degli Expected Goals che, calcolando la probabilità che un tiro possa trasformarsi in un gol, diventa anche indicatore della qualità delle occasioni create da una squadra e quindi del gioco di quest'ultima. Ai fini della previsione dell'andamento delle partite sono applicati modelli Poissoniani, esponenziali, della distribuzione uniforme standard, per osservare il numero di eventi che avvengono in un dato periodo di tempo, il tempo tra gli stessi eventi e quando essi si verificano.

Nel successivo lavoro, di Carbonara e Casacci (Istat), è analizzato il fenomeno dei "lavoratori poveri" attraverso la proposizione di un'analisi delle caratteristiche dei lavoratori a basso reddito, mettendo a frutto l'elevato potenziale informativo degli archivi amministrativi integrati. In particolare, gli autori si soffermano sulla relazione tra la probabilità di essere un lavoratore dipendente a basso reddito in Italia e un set di variabili socio-demografiche e sulla relazione tra la probabilità di un lavoratore a basso reddito di vivere in una famiglia economicamente svantaggiata e un insieme di caratteristiche della famiglia di appartenenza. Il tutto viene proposto in un'ottica territoriale.

Nel quarto contributo Viola et al., attraverso l'analisi di dati ufficiali ISTAT, si soffermano sull'andamento delle unità locali attive del settore alimentare tra il 2012 e il 2022, per esplorare come l'industria abbia reagito alle problematiche socio-economiche del periodo e individuare le tendenze future.

Nel lavoro di Tafuni et al. viene affrontata la tematica degli incendi boschivi in Italia durante i mesi estivi del 2023, su fonte dati Copernicus. L'analisi è volta verso la valutazione preventiva del rischio di incendi e allo studio delle aree distrutte dal fuoco. Dai dati emerge una concentrazione maggiore di tali fenomeni nelle regioni meridionali italiane, in particolare nella Sicilia, con vaste aree di macchia mediterranea e foreste di sclerofille devastate dagli incendi.

Antonucci et al., in analogia a quanto fatto nelle precedenti edizioni del presente volume, in un'ottica di analisi della customer satisfaction, analizzano i servizi erogati da Sanitaservice ASL FG s.r.l. nell'anno 2023. Lo studio individua punti di forza e di debolezza di tali servizi, evidenziando un significativo miglioramento nella valutazione degli stessi e nella soddisfazione media complessiva, pur restando presenti determinate problematiche da affrontare per migliorare ulteriormente l'efficacia dei servizi stessi.

Dopo il contributo di Nocca et al. che, grazie ad un campione di 105 soggetti, studiano l'effetto delle mutazioni del DNA sul processo di *splicing*, con particolare riferimento al gene BRCA1 sito sul cromosoma 17, Gangemi affronta, in un'ottica storico-economica, l'utilizzo della manna da frassino nella farmacopea d'età moderna e contemporanea. Tale utilizzo, secondo l'autore, determinò un crescente interesse del governo napoletano per la tutela della qualità e per ragioni fiscali e nel contributo. Nell'articolo sono ripercorsi l'iter legislativo e alcuni degli aspetti economici più importanti inerenti tale singolare produzione nelle regioni meridionali d'Italia.

Bianco et al, nel successivo lavoro, discutono dei risultati di una ricerca condotta su un gruppo di pazienti, affetti da malattie infiammatorie croniche intestinali (IBD), la Rettocolite Ulcerosa (RCU) e il morbo di Crohn e sottoposti a trattamento medico con anticorpi monoclonali biologici (Infliximab e Vedolizumab). Gli studiosi, con dati provenienti da talune unità operative di Gastroenterologia della Regione Puglia, cercano di evidenziare analogie e differenze tra le due patologie, al fine di valutare l'efficacia delle cure e i miglioramenti nella qualità della vita dei pazienti. L'approccio della ricerca è quello dei Real World Data (RWD) che pone in luce come i dati del mondo reale e, in questo caso, le evidenze cliniche, possano essere utilizzati per generalizzazioni all'intera popolazione.

D'Uggento et al. affrontano successivamente un tema di estrema attualità, quello dell'efficacia dei messaggi pubblicitari sui social media. In un'ottica di analisi testuale, gli autori si concentrano su una misura dell'efficacia del cambiamento pubblicitario di grandi marchi, utilizzando un corpus di quasi 30.000 tweet e indicatori creati sulla base dei risultati ottenuti da una *sentiment analysis*.

Dopo il contributo di Viola e Rinaldi, che affrontano una tematica metodologica concernente le ramificazioni delle famiglie di curve di concentrazione L(p) ad una famiglia di archi di una Superellisse al variare dei parametri β e δ, completano il volume Carucci e Vannella che, attraverso l'utilizzo dei dati censuari a livello comunale e di quelli sulla spesa sociale dei comuni singoli o associati provenienti dalla "Rilevazione sugli interventi e servizi sociali dei comuni singoli o associati", studiano le diverse caratterizzazioni delle Aree Interne per comprendere le differenze territoriali e le dinamiche che possano impattare sui differenti sviluppi dei territori.

Certi che il volume riscontrerà il favore dei lettori, si ringraziano tutti gli Autori.

Bari, 28/12/2024 *Ernesto Toma*

Sulle misure di concordanza e discordanza fra due distribuzioni statistiche

Francesco Domenico d'Ovidio*

Università degli studi di Bari Aldo Moro

Riassunto: Il presente saggio costituisce una breve ma, per quanto possibile, compendiosa disamina delle principali tecniche per l'analisi descrittiva e inferenziale (ove ve ne siano le condizioni) delle relazioni tra due variabili statistiche, con particolare attenzione alle tecniche cosiddette "non parametriche", ossia che non prevedano ipotesi vincolanti sui parametri delle distribuzioni statistiche rilevate. Nel saggio si propongono anche alcuni sviluppi di tecniche non parametriche di misura della concordanza tra variabili.

Keywords: Concordanza, Correlazione, Correlazione non parametrica.

1. Premessa

Si vuole in questa nota proporre alcune note sulla misura della concordanza e della discordanza di una distribuzione statistica doppia, ossia due distribuzioni relative alle medesime n unità statistiche, siano esse espresse in scala di misura cardinale (c.d. "quantitativa") che in scala di misura ordinale (facente dunque parte, in genere, delle cosiddette misure "qualitative"), ma anche, in qualche caso, espresse su scala nominale.

L'analisi della concordanza/discordanza riguarda un aspetto limitato del concetto empirico di *co-variazione statistica* fra due o più variabili (intesa come correlazione, covarianza, cograduazione o associazione, a seconda del livello di misurazione delle variabili considerate); questo concetto peraltro non implica necessariamente un effettivo legame di dipendenza o di interdipendenza fra esse, ossia una vera e propria *relazione causale*, fenomeno

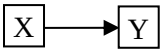
* francescodomenico.dovidio@uniba.it.

appartenente ad altro e più complesso campo di studi, il quale implica l'analisi e l'interpretazione dei legami logici e strutturali che sottendono una co-variazione statistica[1].

In tutti i casi, è opportuno definire preliminarmente i vari tipi di relazioni tra variabili che possono incontrarsi nell'analisi dei fenomeni statistici (schema sintetizzato da quello più dettagliato di Corbetta, 2005).

1.1. Relazione diretta (asimmetrica)

Questo tipo di relazione, ove il mutamento di una variabile X produce logicamente e *direttamente* un mutamento in un'altra variabile Y, è la più semplice che può essere identificata partendo da una co-variazione:

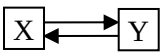


In questo tipo di relazione, elementi essenziali sono:

a) l'evidente *asimmetria* (direzionalità) e *gerarchia* della relazione descritta (ad es., un incremento del reddito familiare può certamente produrre un aumento dei consumi voluttuari della famiglia, mentre il contrario non è verosimile, e dunque non può esservi *reciprocità*);
b) l'*immediatezza* della relazione identificata.

1.2. Relazione reciproca (simmetrica)

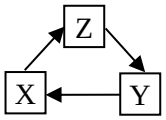
Questo tipo di relazione presenta il secondo degli elementi prima descritti (esistenza di una relazione *immediata*), ma non il primo: le variabili interessate hanno infatti la medesima gerarchia, ed il rapporto rilevato è simmetrico, ossia di *co-variazione* (si possono avere, a seconda dei casi, *retroazione* o *simultaneità*): un esempio classico di relazione reciproca con retroazione è quella fra domanda e prezzo in un regime di concorrenza perfetta e di elevata elasticità del mercato: un incremento della domanda di un bene ne fa alzare i prezzi, ma questo aumento porta a una diminuzione della domanda, che causa a propria volta una riduzione del prezzo, e a questo punto la domanda torna a crescere, e così via:



[1] Per riprendere un esempio notissimo (Johnston, 1972), si pensi alla forte correlazione rilevata nel Regno Unito di mezzo secolo fa fra il numero di televisori venduti ed il numero di suicidi registrati nel medesimo periodo di tempo: nonostante la scarsa qualità di certi programmi televisivi, nessuno potrebbe mai sostenere che la prima variabile influenzi la seconda, né tantomeno il contrario (è ancora più inverosimile, invero, che l'ultimo atto di chi ha deciso di suicidarsi sia l'acquisto di un televisore).

1.3. Relazione circolare

Si parla di relazione *circolare* (o *ciclica*) quando si osserva che i mutamenti di una variabile X causano mutamenti in una variabile Z, ma questi mutamenti inducono una variazione in una terza variabile (Y), la quale a sua volta causa un mutamento nella X, ed il ciclo ricomincia:



Si tratta di un legame ben più complesso della *relazione reciproca* descritta poc'anzi, e può interessare anche un numero maggiore di variabili, ma gli effetti sono sostanzialmente i medesimi, con l'aggravante della maggior difficoltà di calcolare il peso effettivo delle singole relazioni (fra X e Z, fra Z e Y e fra Y e X); possono aversi anche problemi di stima dei parametri.

1.4. Relazione indiretta

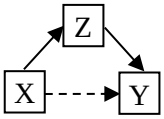
Una relazione fra due variabili X e Y è *indiretta* quando l'influenza della prima sulla seconda, pur se misurabile, non è ben definita e in realtà appare dovuta all'esistenza di una terza variabile Z, influenzata dalla prima, che a sua volta ha influenza sulla Y.

Un esempio potrebbe essere l'apparente influenza delle condizioni socio-economiche della famiglia di origine (X) sui risultati di un test per il calcolo del QI (quoziente di intelligenza) effettuato dai figli al compimento dei 18 anni (Y). Si presume ovviamente la *direzionalità* della relazione (non è certamente possibile che i risultati del test QI dei figli influenzino la condizione familiare), e sembrerebbe esservi anche un *nesso logico*, seppur aleatorio (in effetti, una condizione di disagio familiare *potrebbe* indurre uno stato psicologico in grado di influenzare i risultati del test, mentre una famiglia di buon livello socio-economico *potrebbe* indurre una maggiore serenità nei figli, e dunque risultati non distorti).

Se si inserisce nello schema la variabile "istruzione" (Z), però, appare un nesso molto più evidente: famiglie in stato di difficoltà socio-familiare, pur in costanza di altre caratteristiche culturali, in genere possono garantire ai figli una istruzione meno approfondita ed anche un ambiente meno adatto a fornire i migliori risultati, rispetto a famiglie più abbienti.

Poiché la maggior parte dei test QI per giovani e adulti implicano, in realtà, una certa familiarità con i numeri, con le parole e con le forme geometriche (competenze, queste, che si acquisiscono soprattutto con l'istruzione), appare evidente che a parità di effettive potenzialità intellettive i risultati del test

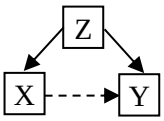
saranno tanto migliori quanto migliore è l'istruzione[2].

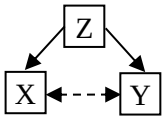


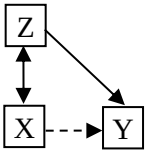
La variabile Z, in questo caso, viene detta "interveniente", perché il suo intervento chiarisce e specifica il nesso causale fra X e Y, che certamente esiste, ma è in massima parte *indiretto* (non si può escludere, invero, anche il citato *effetto diretto* sullo status psicologico del ragazzo al momento del test, ma tale effetto interesserà presumibilmente una parte minima, se non irrisoria, dei soggetti considerati).

1.5. Relazione spuria

Quando la relazione individuata (asimmetrica o simmetrica che sia) manca di un qualsiasi nesso logico, oppure quando questo nesso logico è solo apparente, si è *in presenza di una co-variazione senza causazione*. Oltre alla relazione fra numero di televisori venduti e numero di suicidi, un esempio classico è quello dell'incremento dei danni (Y) provocati da un incendio apparentemente legato al numero di pompieri (X) che sono intervenuti per spegnerlo (ove la causa comune di ambo gli elementi è la dimensione dell'incendio, indicata con "Z" nel primo degli schemi sottostanti, mentre la linea tratteggiata indica la relazione spuria, che svanisce quando si inserisce fra le variabili la vastità dell'incendio).







Può capitare che la relazione spuria non implichi un legame causale con una terza variabile, ma semplicemente una co-variazione o una relazione reciproca (secondo schema). Ad esempio, se in un campione si rileva una relazione imprevista (ad esempio, fra genere X e orientamento politico Y, come è capitato in una ricerca sociale fra gli studenti universitari di qualche decennio fa), è possibile che sia una terza variabile, in qualsiasi modo connessa con

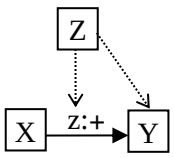
[2] Non va esclusa, inoltre, la possibilità (ipotizzata e verificata in vari studi) che un'istruzione stimolante e approfondita sia in grado di fare emergere abilità e potenzialità intellettive latenti, le quali in assenza di stimoli rimangono assopite, e dunque incrementare non solo la mera misura del QI, ma anche le manifestazioni empiriche dell'oggetto di tale misura, ossia, appunto, l'intelligenza.

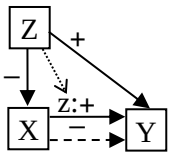
il genere, a causare la variazione (nel caso citato, la provenienza: in genere nelle città vi è una prevalenza di orientamento progressista e nelle zone rurali un orientamento maggiormente conservatore; ora, il subcampione di studentesse proveniva in maggioranza dalle città, ove le famiglie erano abbastanza progressiste da concedere alle figlie di avere una istruzione universitaria, mentre la provenienza del subcampione maschile era distribuito più equamente fra aree urbane e aree rurali: di conseguenza, la vera relazione causale urbanizzazione/orientamento politico veniva rilevata in modo spurio, oltre che in minor misura, anche dall'appartenenza di genere).

1.6. Relazione condizionata (o "di interazione")

A volte esiste (o si ritiene logicamente che esista) una effettiva influenza di una variabile X su una variabile Y, ma questa relazione può cambiare tenendo conto di una terza variabile (Z), risultando più o meno forte a seconda del valore assunto da Z.

Per esempio, indagando sulla spesa per abbigliamento di un campione rappresentativo di donne in base al reddito familiare, ci si attende di riscontrare la consueta relazione positiva tra reddito disponibile X e consumi Y. Alla prova dei fatti, invece, questa relazione non si evince dai dati, oppure esiste ma più debole del previsto, al limite della significatività statistica. Si potrebbe dunque ritenere che non è del tutto vero che un aumento del reddito disponibile possa *causare* un incremento della spesa per abbigliamento.





Tuttavia se, come descritto nel primo degli schemi su riportati, viene inserita come "filtro" all'azione della X una terza variabile (Z) che sia a sua volta logicamente legata alle decisioni d'acquisto in materia, come può essere la classe di età (essendo non omogenea né come tipo né come costi la moda femminile per le varie fasce di età), si può giungere a determinare che all'interno di ciascuna fascia di età il reddito disponibile influenza pesantemente gli acquisti di abbigliamento, molto più di quanto si potesse valutare prima, ma che tali effetti non erano ben definiti nel gruppo aggregato. Ciò perché, ad esempio, il reddito familiare delle donne anziane (in genere derivante da pensione) è ben diverso da quello delle donne in età meno avanzata (reddito da lavoro, proprio e/o del coniuge o convivente).

A volte la vera causa (e perfino il senso) di una relazione è difficile da identificare: ad esempio, come nello schema destro della figura, può capitare di identificare in un campione di intervistati in età lavorativa una relazione significativa inversa tra l'istruzione (X) e il reddito (Y): la qual cosa appare quantomeno bizzarra, dato che è opinione comune (suffragata da molte indagini nazionali) che un maggior livello di istruzione determini una maggiore possibilità di guadagno. Si tratta, dunque, di una relazione presumibilmente spuria.

Inserendo la variabile "età" (Z), il fenomeno appare più chiaro, anche tenendo conto dei motivi storici: ancora oggi, infatti, si riscontra una causazione inversa tra età ed istruzione (maggiore età, minore istruzione), legata ai diversi contesti socio-economici delle diverse generazioni ed alle diverse normative sull'obbligo scolastico, mentre è noto che nella maggior parte dei casi il reddito cresce al crescere dell'anzianità e dell'esperienza lavorativa, e dunque con l'età; invero, si rilevano numerosi sessantenni con bassa istruzione ma con redditi elevati (come molti bravissimi artigiani… di cui gli idraulici, spesso citati come categoria principe, costituiscono solo la "punta di diamante"), mentre la maggior parte dei giovani neolaureati deve accontentarsi di lavoretti precari o, nella migliore delle ipotesi, di posti da impiegato. A causa di questa interazione (o combinazione di relazioni), l'apparenza è che l'istruzione sia un fattore negativo per la riuscita professionale; suddividendo il campione per classi di età, invece, appare evidente che, fra i giovani come fra gli anziani, *a parità di età* un titolo di studio più elevato produce, nella maggior parte dei casi, un reddito più cospicuo. Dunque, la relazione negativa identificata nel complesso dei casi fra l'istruzione e il reddito è spuria (ed è quindi tratteggiata nel terzo schema), mentre la vera causa è una interazione *positiva* all'interno di ciascun gruppo di età.

Nell'insieme di relazioni fin qui descritto, che naturalmente può essere più o meno agevolmente esteso al caso di più variabili intervenienti, l'oggetto del presente lavoro si inquadra essenzialmente nello studio delle relazioni reciproche, cioè simmetriche, legate al concetto di *co-variazione*.

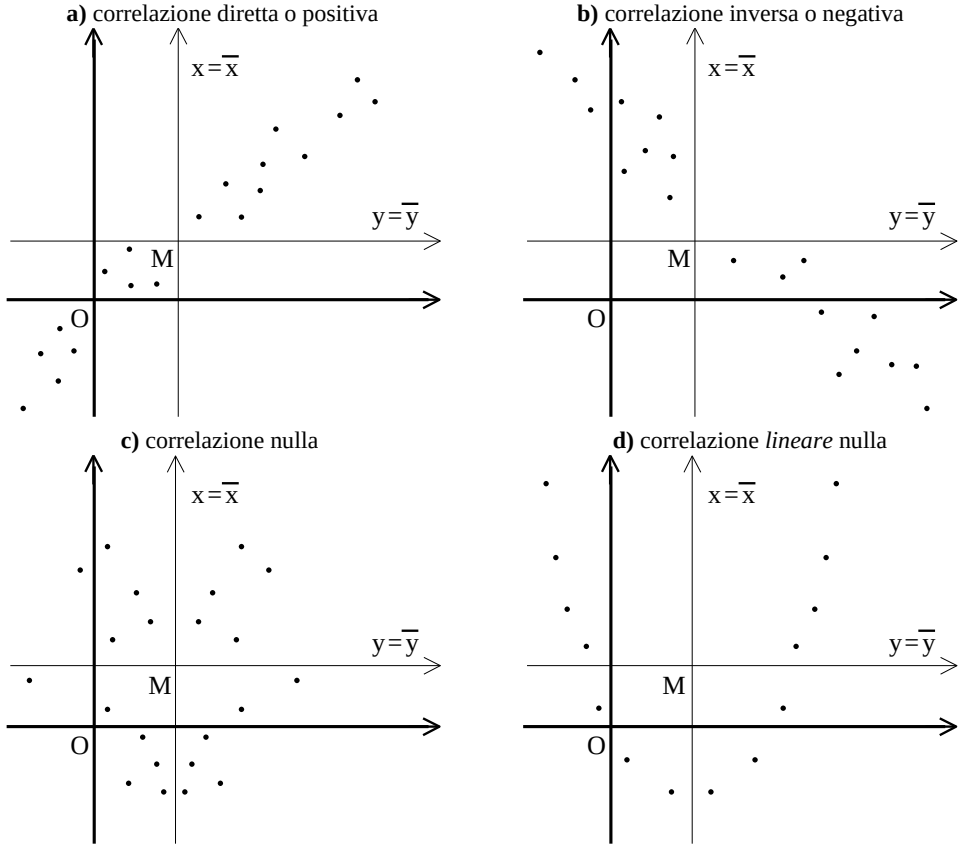
2. La co-variazione come misura delle relazioni tra due variabili

Per descrivere il ruolo della co-variazione nella misura del tipo e del grado di associazione tra due variabili, espresse almeno a livello di scala di intervalli, vengono riportati di seguito alcuni dei concetti più noti della Statistica (facendo esplicito riferimento a Delvecchio, 2024, cap XV, par. 2).

Avendo due distribuzioni di variabili X e Y relative alle medesime unità statistiche, la i-ma di tali unità (a cui è associata la coppia di valori x_i e y_i) può essere individuata su un diagramma cartesiano bidimensionale da un punto di coordinate (x_i, y_i); ivi, si identifichi con M il punto di coordinate $(\bar{x}, \bar{y})$ e si definisca un sistema di riferimento traslato con origine in M.

In Fig. 1 sono riportati i diagrammi cartesiani (con punti tracciati indipendentemente) riferiti a quattro diverse situazioni.

Figura 1. *Determinazioni di due variabili x e y definite come punti di coordinate (x_i, y_i) in un sistema cartesiano con origine traslata in M: $(\bar{x}, \bar{y})$.*



Fonte: Delvecchio, 2024

Se i punti così definiti sono localizzati tutti nel 1° e nel 3° quadrante del sistema traslato (Fig. 1.a), le distribuzioni X e Y, e quindi i fenomeni da esse identificati, sono *concordanti*, in quanto i valori $(x_i - \bar{x})$ e $(y_i - \bar{y})$ sono sempre entrambi non positivi o entrambi non negativi. Da ciò deriva che il prodotto $(x_i - \bar{x}) \cdot (y_i - \bar{y})$ è sempre positivo.

Se i punti identificati giacciono tutti nel 2° e nel 4° quadrante (Fig. 1.b), si tratta invece di distribuzioni (e fenomeni) *discordanti*, perché quando i valori $(x_i - \bar{x})$ sono positivi i valori $(y_i - \bar{y})$ sono negativi, e viceversa. Dunque, il prodotto $(x_i - \bar{x}) \cdot (y_i - \bar{y})$ è sempre negativo.

Vi sono poi situazioni in cui non si rileva né concordanza né discordanza: per esempio, nella distribuzione mostrata in Fig. 1.c, a ogni punto corrisponde un simmetrico rispetto all'asse delle ordinate: quindi, se per un punto il prodotto $(x_i - \bar{x}) \cdot (y_i - \bar{y})$ è positivo, per il punto simmetrico rispetto all'asse verticale tale prodotto è negativo, e viceversa. La somma o la media di tali prodotti sarà dunque pari a zero. Peraltro, *non vi è alcuna relazione riconoscibile* tra le variabili X e Y.

In Fig. 1.d, invece, pur essendovi ancora per ogni punto il suo simmetrico rispetto all'asse delle ordinate, con nullità della somma o media dei prodotti $(x_i - \bar{x}) \cdot (y_i - \bar{y})$, è evidente l'esistenza di una relazione parabolica (dunque, *non lineare*) fra i due fenomeni.

Nella maggior parte dei casi, tuttavia, le situazioni non sono tanto chiare e definite: non sempre vi è concordanza o discordanza perfetta tra i singoli punti, e dunque in una maggioranza di prodotti $(x_i - \bar{x}) \cdot (y_i - \bar{y})$ positivi (o negativi) possono essere identificati molti prodotti nulli o negativi (e viceversa, nulli o positivi); anche l'assenza di correlazione non sempre è verificata, e a fronte di una covarianza nulla possono aversi prodotti $(x_i - \bar{x}) \cdot (y_i - \bar{y})$ positivi o negativi per alcuni o per molti punti.

Per descrivere l'eventuale relazione lineare esistente tra X e Y è dunque opportuno fare riferimento non ai singoli prodotti ma alla loro somma, detta *Codevianza*, ossia $Cod(X,Y) = \sum (x_i - \bar{x})(y_i - \bar{y})$, o alla loro media

$$\frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n},$$

la quale, esprimendo la media del prodotto degli scarti delle x_i e y_i dalle rispettive medie, è denominata $Cov(X,Y)$, ossia *covarianza* tra X e Y.

In caso di fenomeni concordanti si ha $Cov(X,Y)>0$ (*correlazione diretta*), mentre per fenomeni discordanti $Cov(X,Y)<0$ (*correlazione inversa*); in caso di assenza di una relazione lineare, logicamente sarà $Cov(X,Y)=0$.

Tuttavia, la covarianza ha il difetto di dipendere anche dalla forma (linearità) della relazione e dall'unità di misura dei caratteri osservati, e non ha un limite inferiore né un limite superiore, e non sarebbe possibile valutare la *forza effettiva* della relazione stessa (anche a scopo di confronto con altre): meglio sarebbe, dunque, un indice di covariazione *relativo*.

3. Il coefficiente di correlazione lineare

Per quanto finora precisato, sotto la condizione di una *relazione lineare* tra due distribuzioni di caratteri misurati almeno a livello di scala di intervalli, la misura più adeguata (e nota) di una relazione reciproca tra due variabili X e Y è data dal *coefficiente di correlazione lineare di Bravais-Pearson*[3]

$$r=\frac{\mathrm{Cov}(X,Y)}{\sqrt{\mathrm{Var}(X)\,\mathrm{Var}(Y)}}=\frac{\mathrm{Codev}(X,Y)}{\sqrt{\mathrm{Dev}(X)\,\mathrm{Dev}(Y)}}=\frac{\sum_{i=1}^{n}(x_i-\bar{x})\,(y_i-\bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i-\bar{x})^2\sum_{i=1}^{n}(y_i-\bar{y})^2}}. \quad [1]$$

il quale, poiché la *disuguaglianza di Cauchy-Schwartz*[4] assicura che il denominatore è pari al massimo assoluto del numeratore, è un numero puro, invariante al variare dell'unità di misura dei caratteri x_i e y_i, e sempre compreso fra -1 e +1. Si ha il primo caso quando tra le due variabili (qui denotate, come d'uso comune, con X e Y, ma formulazioni più corrette utilizzano la notazione "generalizzata" X_1 e X_2) esiste una relazione perfettamente inversa, il secondo caso quando si ha una perfetta relazione diretta. In tutti gli altri casi il valore assoluto del coefficiente risulterà inferiore a 1, fino a essere pari a zero in caso di totale indipendenza tra le due variabili.

Si noti che non vale il discorso inverso: non è detto, infatti, che un coefficiente nullo implichi una perfetta indipendenza tra le due variabili osservate[5].

---

[3] Auguste Bravais, fisico, astronomo e mineralogista francese (1811-1863), è molto noto per la sua ipotesi sulla struttura reticolare dei cristalli, ma per gli statistici è soprattutto colui che per primo ha descritto e utilizzato, nel 1846, un indice di misura della concordanza fra due variabili, che, più tardi, fu approfondito e applicato a campi scientifici ben differenti prima da Francis Galton (1869 e 1888), che fu il primo a identificarne le relazioni matematiche con il coefficiente di regressione lineare, usando il simbolo "r" per indicare il rapporto di covarianza normalizzato (benché ancora tramite scarto interquartile dalle rispettive mediane) e poi dal suo seguace e amico Karl Pearson: questi modificò la normalizzazione del coefficiente di concordanza nella forma nota ed evidenziata nella [1], analizzandone approfonditamente le caratteristiche matematiche (1896) con la *teoria dei momenti statistici*, al punto che il mondo scientifico perse di vista il fondamentale contributo di Galton e, quindi, il coefficiente di correlazione lineare fu generalmente definito con i soli nomi del primo e dell'ultimo dei suoi "padri", appunto, Bravais e Pearson.

[4] In base alla *disuguaglianza di Cauchy-Schwarz*, qualunque siano X e Y, si ha

$$[E(XY)]^2 \le E(X^2)\cdot E(Y^2)\,,$$

per cui, fatto salvo il fattore posizionale (la media):

$$[\mathrm{Cov}(X,Y)]^2 \le \mathrm{Var}(X)\cdot\mathrm{Var}(Y):\quad \mathrm{Cov}_{xy}^2 \le \sigma_x^2\cdot\sigma_y^2 \;\rightarrow\; -\sigma_x\cdot\sigma_y \le \mathrm{Cov}_{xy} \le \sigma_x\cdot\sigma_y.$$

[5] Un caso classico è quello, già introdotto in Fig. 1.d, di due variabili legate tra loro da una relazione matematica del tipo $y = b_0 + b_1\cdot x + b_2\cdot x^2$, che rappresenta in effetti un *arco di*

Se e solo se i requisiti per l'inferenza[6] sono rispettati, allora r è una stima consistente, sufficiente ed efficiente della correlazione nella popolazione, e per verificare la semplice ipotesi di base che, pur se un campione abbia fatto registrare un coefficiente r > 0, l'effettiva correlazione nell'universo sia invece nulla (ossia H_0: $\rho=0$ contro H_1: $\rho>0$), si usa il test seguente, distribuito secondo una T_g di Student con $g=n-2$ gradi di libertà,

$$t = r\sqrt{(n-2)/(1-r^2)},$$

che fornisce il valore di soglia

$$|r_\alpha| = t_{g,\alpha}\sqrt{(1-r^2)/(n-2)}.$$

Tuttavia, r presenta una distorsione pari a $\rho(1-\rho^2)/2n$: il che, peraltro, implica che la stima è assolutamente corretta solo per $\rho=-1$, 0 oppure 1, e dunque i valori empirici $r=-1$, 0 e 1 sono le uniche stime di ρ a possedere le proprietà auspicabili in uno stimatore[7].

---

parabola: non per niente, l'indice di Bravais-Pearson sopra descritto si chiama "coefficiente di correlazione lineare". Va ricordato, peraltro, che anche coefficienti molto diversi da zero non implicano *automaticamente* una relazione di mutua dipendenza tra le variabili, ma solo una concordanza o discordanza nelle variazioni. Lo stesso vale, invero, nel caso del coefficiente di regressione lineare, che non misura di per sé la *dipendenza causale* dei fenomeni studiati, ma solo la loro "dipendenza in termini statistici", ossia una relazione asimmetrica di concordanza o discordanza delle misure di detti fenomeni: è infatti compito di studiosi esperti dei fenomeni medesimi, successivamente, comprendere la causa di tale concordanza/discordanza, escludendo sia le eventuali relazioni spurie ma anche relazioni indirette.

[6] Requisiti per l'inferenza su ρ: 1) le osservazioni di ciascuna serie devono essere estratte casualmente e indipendentemente fra loro; 2) inoltre la loro distribuzione campionaria deve approssimarsi, almeno asintoticamente, a una normale doppia con varianze costanti: in altri termini, ciascuna delle distribuzioni parziali $Y|x_i$ e $X|y_i$ deve distribuirsi normalmente e con varianza costante (cfr., per es. Delvecchio 2024, cap XV, par. 3). Si noti però che i test per la verifica della normalità di una variabile singola sono in genere poco adeguati a verificare la binormalità, che è una forma semplificata della multinormalità e dunque va verificata con test appropriati, come, per es., il criterio suggerito da Malkovich e Afifi (1973).

Detto criterio, in breve, consiste innanzitutto nel calcolare le trasformate scalari v_i del vettore di dati $\mathbf{x}_i$ tramite la forma quadratica $v_i = (\mathbf{x}_i - \overline{\mathbf{x}})' \hat{\mathbf{\Sigma}}^{-1} (\mathbf{x}_i - \overline{\mathbf{x}})$, ove, data la matrice ${}^*\mathbf{X}$ degli scarti delle osservazioni x_{ij} dalle rispettive medie $\overline{x}_j$, $\hat{\mathbf{\Sigma}}^{-1} = ({}^*\mathbf{X}' {}^*\mathbf{X})/(n-1)$. A questo punto, è possibile valutare con test di Kolmogorov se le quantità v_i si distribuiscono in modo statisticamente simile a un χ^2 con m gradi di libertà (nel caso presente, m=2), evento che si verifica se e solo se le osservazioni x_{ij} sono tratte da una popolazione multinormale (cfr., per es., Delvecchio 2010, cap. III, par. 2).

[7] Peraltro, ove si abbia l'ipotesi H_0: $\rho=\rho_j$ contro l'alternativa H_1: $\rho\neq\rho_j$, i valori campionari r si distribuiscono in modo asimmetrico intorno alla correlazione della popolazione (ρ), in modo tanto più accentuato quanto più essa si discosta da zero. Per tal motivo, l'ipotesi citata

Posta questa assunzione, fondamentale per l'inferenza statistica, il coefficiente di correlazione calcolato con il metodo del "prodotto dei momenti" di Pearson è una misura pienamente valida e adeguata fintanto che i caratteri siano entrambi quantitativi e la relazione sia effettivamente lineare.

La linearità o meno della relazione, laddove non siano applicabili tecniche inferenziali, spesso può essere determinata solo graficamente ma non matematicamente. Se invece è applicabile l'analisi inferenziale dei dati, poiché un buon modello di dipendenza deve avere residui distribuiti casualmente e in modo approssimativamente normale, si può fare riferimento appunto a test di casualità e di normalità dei residui della regressione della Y sulla X e viceversa: in particolare, si può utilizzare inizialmente il test delle sequenze di Wald-Wolfowitz per verificare la casualità della distribuzione dei residui, e poi il test di Shapiro-Wilks per verificarne la normalità. In caso di casualità e normalità dei residui, è possibile valutare inferenzialmente la linearità delle relazioni tra l'una e l'altra variabile utilizzando l'appropriato test (cfr., ad es., Delvecchio 2024, Cap. XIV, par. 5).

Come è noto, inoltre, elevando al quadrato il coefficiente di correlazione lineare si ottiene l'indice di determinazione

$$R^2 = \frac{[\mathrm{Codev}(X,Y)]^2}{\mathrm{Dev}(X)\,\mathrm{Dev}(Y)} = \frac{\left[\sum_{i=1}^{n}(x_i-\bar{x})\,(y_i-\bar{y})\right]^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2 \sum_{i=1}^{n}(y_i-\bar{y})^2} \quad ,$$

il quale, corrispondendo matematicamente sia al rapporto *Dev*(*R*)/*Dev*(*Y*) che a quello *Dev*(*R*)/*Dev*(*X*), indica quanta parte della devianza totale è spiegata (o *determinata*) dalla funzione di regressione lineare della Y dalla X, o viceversa dalla funzione di regressione della X dalla Y.

---

viene meglio verificata usando la trasformata *z* di Fisher (1915, 1921) di ogni coefficiente, allo scopo di correggerne adeguatamente sia asimmetria che eteroschedasticità:

$$z = 0{,}5 \times ln[(1+r)\,/\,(1-r)] = arctanh(r).$$

Tuttavia, tale trasformazione di r in z implica un piccolo ma sistematico errore in eccesso; una trasformazione più corretta (Hotelling, 1953) è invero

$$z' = arctanh(r) - [3 \cdot arctanh(r) + r]\,/\,(4 \cdot n - 4)\,.$$

Pertanto, il test corretto per la verifica di H_0 risulta essere:

$$Z = (z_1' - z_2')/\sqrt{1/(n_1-3) + 1/(n_2-3)}\,,$$

che per campioni abbastanza grandi risulta normalmente distribuito (quindi, fissato a α, l'ipotesi H_0 deve essere rifiutata se $Z > z_{\alpha/2}$).

4. Correlazioni non lineari

In caso di non linearità della relazione (per esempio, nel caso di relazioni paraboliche come quella, di ordine 2, mostrata nella sezione *d* della precedente Fig. 1), il coefficiente di correlazione di Pearson fornisce risultati molto meno corretti e affidabili rispetto al caso di relazione lineare.

Sono stati proposti nel corso del tempo alcuni indici statistici in grado di rendere giustizia anche di tali casi: appunto nel caso di relazioni paraboliche d'ordine *k*, Bonferroni (1939) propose un "coefficiente di correlazione" in grado di generalizzare la formulazione di Pearson anche a tali relazioni.

Detto coefficiente è abbastanza complesso da elaborare, essendo basato sul calcolo dei determinanti di alcune matrici (a cui Bonferroni arriva con un ragionamento progressivo di stringente rigore metodologico) rappresentanti in varie combinazioni le medie delle variabili interessate: precisamente, indicando con M_x e M_y tali medie, con M_{x^h} le medie delle potenze h-esime delle x e con $M_{x^h y}$ le medie dei prodotti fra le x^h e la y:

$$D(1,\ x,\ x^2,\ ...,\ x^k) = \begin{vmatrix} 1 & M_x & M_{x^2} & ... & M_{x^k} \\ M_x & M_{x^2} & M_{x^3} & ... & M_{x^{k+1}} \\ ... & ... & ... & ... & ... \\ M_{x^k} & M_{x^{k+1}} & M_{x^{k+2}} & ... & M_{x^{2k}} \end{vmatrix},$$

$$D(1,\ x,\ x^2,\ ...,\ x^k, y) = \begin{vmatrix} 1 & M_x & M_{x^2} & ... & M_{x^k} & M_y \\ M_x & M_{x^2} & M_{x^3} & ... & M_{x^{k+1}} & M_{xy} \\ M_{x^2} & M_{x^3} & M_{x^4} & ... & M_{x^{k+2}} & M_{x^2 y} \\ ... & ... & ... & ... & ... & ... \\ M_{x^k} & M_{x^{k+1}} & M_{x^{k+2}} & ... & M_{x^{2k}} & M_{x^k y} \\ M_y & M_{xy} & M_{x^2 y} & ... & M_{x^k y} & M_{y^2} \end{vmatrix}^2;$$

sostituendo l'ultima colonna della prima matrice con i primi k+1 elementi dell'ultima colonna della seconda matrice, si ottiene:

$$D(1,\ x,\ x^2,\ ...,\ x^k)_y = \begin{vmatrix} 1 & M_x & M_{x^2} & ... & M_y \\ M_x & M_{x^2} & M_{x^3} & ... & M_{xy} \\ ... & ... & ... & ... & ... \\ M_{x^{k-1}} & M_{x^k} & M_{x^{k+1}} & ... & M_{x^{k-1} y} \\ M_{x^k} & M_{x^{k+1}} & M_{x^{k+2}} & ... & M_{x^k y} \end{vmatrix}.$$

Bonferroni dimostra poi che, ponendo

$$D(1, x, ..., x^{k-1}, y) = \frac{D(1, x, ..., x^{k-1}) \cdot D(1, x, ..., x^{k}, y) + \left[D(1, x, ..., x^{k})_y \right]^2}{D(1, x, x^2, ..., x^k)} ,$$

il rapporto

$$r_k = \frac{D(1, x, x^2, ..., x^k)_y}{\sqrt{D(1, x, ..., x^k) \cdot D(1, x, ..., x^{k-1}, y)}} , \qquad [2]$$

varia tra -1 e $+1$, raggiungendo tali estremi solo se la distribuzione congiunta di x e y risulta esattamente parabolica d'ordine k, per cui Bonferroni lo denomina "coefficiente di correlazione parabolica di ordine k".

Se k=1, lo sviluppo dei determinanti della [2] porta r_k a coincidere con il coefficiente di correlazione lineare di Pearson, così come, del resto, l'equazione della parabola $y = b_0 + b_1x + b_2x^2 + \ldots + b_kx^k$ si riduce a quella della retta.

Tuttavia, solo nel caso di k=1 questo indice identifica una effettiva relazione simmetrica fra le due variabili: invero, nella parabola mostrata in Fig. 1 la forma della dipendenza di y da x si evidenzia molto diversa di quella della dipendenza di x da y. Di conseguenza, come evidenziò anche Bonferroni nell'articolo citato, per k>1 non abbiamo un vero e proprio coefficiente di correlazione, ma solo un indicatore dell'intensità della regressione parabolica di ordine k in grado di indicare (al contrario del relativo indice di determinazione R_k^2) anche che la parabola sia concava (quando $r_k<0$ e, dunque, il punto di flesso appare in basso nel grafico) oppure convessa (quando $r_k>0$ e quindi punto di flesso in alto).

Si tratta di una funzione con buona valenza esplorativa, ma non di uso comune, per cui questa tecnica è stata accolta dal mondo della ricerca statistica con meno interesse di tanti altri contributi di Bonferroni.

Di diverso tipo e più generale applicazione è la serie di soluzioni proposte da altri Autori, fra cui F. Giusti[8], il quale per il calcolo del coefficiente di correlazione in caso di connessioni non lineari (di qualsiasi forma) tra le variabili si basa sull'indice R^2 calcolato sulla base di una o entrambe le funzioni di regressione (di y da x e/o di x da y), di regola come rapporto tra devianza di regressione e devianza totale della variabile scelta come dipendente, estraendone la radice quadrata per approssimare almeno la distribuzione positiva dell'indice a quella del coefficiente r di Pearson (a cui, come è logico, esso corrisponde esattamente ove la relazione studiata sia lineare):

[8] Cfr. Giusti e Guerrieri, 1979.

$$I_{xy} = \sqrt{\frac{\sum(\hat{y}_i - \overline{y})^2}{\sum(y_i - \overline{y})^2}} \quad , \quad I_{yx} = \sqrt{\frac{\sum(\hat{x}_i - \overline{x})^2}{\sum(x_i - \overline{x})^2}} \quad , \quad I = \frac{I_{xy} + I_{yx}}{2} \ .$$

Questo indice, come R^2, varia tra 0 (nel caso di completa indipendenza tra le due distribuzioni) e 1 nel caso in cui fra X e Y vi sia una relazione matematica del tipo Per rendere giustizia alla eventuale relazione inversa non lineare fra le due variabili, si può moltiplicare l'indice così ricavato per −1 qualora le differenze tra il valore teorico dell'ultimo dato e quello del primo dato siano entrambe negative e per 0 se esse hanno segno opposto; in sintesi formale:

$$I_r = \frac{I_{xy} + I_{yx}}{2} \cdot \text{segno}(\hat{x}_n - \hat{x}_1) \cdot \text{segno}(\hat{y}_n - \hat{y}_1) \ . \qquad [3]$$

Questo stratagemma consente di ottenere un indice di correlazione non (necessariamente) lineare comparabile con il coefficiente di Pearson, con cui coincide esattamente in caso di linearità della relazione. Tuttavia, non è facilmente ricavabile la sua distribuzione campionaria, per cui il suo utilizzo risulta limitato alla semplice analisi descrittiva.

In conclusione, in caso di non linearità della relazione (oppure se almeno uno dei due caratteri è misurato su scala ordinale), generalmente sono considerati risultati più affidabili quelli forniti dagli *indici di correlazione non parametrica*, descritti nel seguito: questi in realtà non valutano le relazioni matematiche (lineari o meno) tra due variabili, ma solo la forza di una relazione *monotòna*: dunque non sono *misure* ma *indicatori*.

4. L'indice *rho* di Spearman

Tra le misure non parametriche di correlazione fra caratteri misurati su scala di livello superiore a quello nominale (e dunque, almeno ordinale, pur se talora una variabile dicotomica può essere trattata come una forma elementare di variabile ordinale), la più nota, e la prima studiata, è senz'altro l'*indice di cograduazione "rho" di Spearman* (1904). Esso deriva direttamente dal coefficiente di Bravais-Pearson applicato ai ranghi r_i e s_i: delle unità statistiche nelle due distribuzioni ordinate in senso non decrescente[9]:

[9] Ossia i numeri d'ordine che i caratteri x e y assumono, per ciascuna i-esima unità statistica, nelle rispettive graduatorie non decrescenti, e che quindi, in assenza di valori con pari rango (in inglese "ties"), sono dati dalla serie di tutti i numeri interi da 1 a n. In caso di parità in una distribuzione, generalmente agli elementi di pari rango viene assegnato il loro "rango medio": cioè, avendo per esempio due elementi uguali dopo il primo e il secondo in

$$\rho_s = \frac{\sum_{i=1}^{n}(r_i - \bar{r})(s_i - \bar{s})}{\sqrt[2]{\sum_{i=1}^{n}(r_i - \bar{r})^2 \cdot \sum_{i=1}^{n}(s_i - \bar{s})^2}} \,. \qquad [4]$$

Se e solo se tutte le osservazioni hanno ranghi distinti, allora la [4] (con una serie di passaggi aritmetici, non tutti intuitivi)[10] si semplifica nella

graduatoria, invece di assegnare i ranghi 3 e 4 si assegna a entrambi il rango 3,5. Questo criterio implica che, se, in un campione di 10 unità, dopo le prime due le altre hanno tutte lo stesso rango, a queste va assegnato lo stesso rango medio (3+4+5+6+7+8+9+10)/8=6,5.

[10] In breve: si tenga conto innanzitutto che (in virtù di una procedura sviluppata, tra gli altri, da Carl F. Gauss a 9 anni) la somma dei primi n numeri naturali in *progressione aritmetica* è pari a $n(n+1)/2$; dunque, in assenza di valori con pari posto graduatoria, per ambo le distribuzioni la media aritmetica dei ranghi è pari a $\mathbf{(n+1)/2}$. Da ciò deriva che le due quantità nella radice a denominatore della [2], formalmente *devianze*, sono entrambe equivalenti a

$$\sum(r_i-\bar{r})^2 = \sum(s_i-\bar{s})^2 = \sum(i-\bar{i})^2 = \sum i^2 - n\bar{i}^2 = \sum i^2 - n\left[(n+1)/2\right]^2 \,.$$

Ora, la somma dei quadrati dei primi n numeri naturali è sempre pari a $\boldsymbol{n(n+1)(2n+1)/6}$ (cfr., ad es., http://www.batmath.it/matematica/avista/somma_quadr/somma_quadr.htm).

Ognuna delle due quantità (o devianze) nella radice a denominatore è dunque pari a

$$\frac{n\cdot(n+1)(2n+1)}{6} - \frac{n\cdot(n+1)^2}{4} = n\cdot(n+1)\left[\frac{(2n+1)}{6} - \frac{(n+1)}{4}\right] = n(n+1)\frac{2(2n+1)-3(n+1)}{12} =$$

$$= n\cdot(n+1)\frac{4n+2-3n-3}{12} = n\cdot(n+1)\frac{n-1}{12} = \frac{n\cdot(n+1)\cdot(n-1)}{12} = \frac{n\cdot(n^2-1)}{12} \,,$$

ed essendo uguali le due sommatorie, la radice del loro prodotto sarà anch'essa $n(n^2–1)/12$.

Per quanto riguarda il numeratore (somma dei prodotti degli scarti dal rango medio), esso si semplifica partendo dalla formulazione alternativa della codevianza $\sum(r_i-\bar{r})(s_i-\bar{s})$:

$$\sum_{i=1}^{n} r_i\cdot s_i - n\,\bar{r}\,\bar{s} = \sum_{i=1}^{n} r_i\cdot s_i - n\frac{n+1}{2}\frac{n+1}{2} = \sum_{i=1}^{n} r_i\cdot s_i - n\frac{(n+1)(n+1)}{4}\frac{3}{3} = \sum_{i=1}^{n} r_i\cdot s_i - (3n+3)\frac{n(n+1)}{12} =$$

$$= \sum_{i=1}^{n} r_i\cdot s_i + \left[(n-1)-(4n-2)\right]\frac{n(n+1)}{12} = \sum_{i=1}^{n} r_i\cdot s_i + \frac{n(n+1)(n-1)}{12} - \frac{n(n+1)(4n+2)}{12} =$$

$$= \sum_{i=1}^{n} r_i\cdot s_i + \frac{n(n^2-1)}{12} - \frac{n(n+1)(2n+1)}{6} = \sum_{i=1}^{n} r_i\cdot s_i + \frac{n(n^2-1)}{12} - \sum_{i=1}^{n} i^2 = \sum_{i=1}^{n} r_i\cdot s_i + \frac{n(n^2-1)}{12} - \sum_{i=1}^{n}\frac{2i^2}{2} =$$

$$= \sum_{i=1}^{n} r_i\cdot s_i + \frac{n(n^2-1)}{12} - \frac{1}{2}\left(\sum_{i=1}^{n} i^2 + \sum_{i=1}^{n} i^2\right) = \sum_{i=1}^{n}\frac{2\cdot r_i\cdot s_i}{2} + \frac{n(n^2-1)}{12} - \frac{1}{2}\left(\sum_{i=1}^{n} r_i^2 + \sum_{i=1}^{n} s_i^2\right) =$$

$$= \sum_{i=1}^{n}\frac{2\cdot r_i\cdot s_i}{2} - \sum_{i=1}^{n}\frac{r_i^2+s_i^2}{2} + \frac{n(n^2-1)}{12} = \frac{n(n^2-1)}{12} - \sum_{i=1}^{n}\frac{r_i^2 - 2\cdot r_i\cdot s_i + s_i^2}{2} = \frac{n(n^2-1)}{12} - \sum_{i=1}^{n}\frac{(r_i-s_i)^2}{2} \,.$$

Dividendo questo risultato per il denominatore precedentemente identificato si ha, infine:

$$\frac{n(n^2-1)/12 - \sum_{i=1}^{n}(r_i-s_i)^2/2}{n(n^2-1)/12} = \frac{n(n^2-1)/12}{n(n^2-1)/12} - \frac{12\cdot\sum_{i=1}^{n}(r_i-s_i)^2/2}{n(n^2-1)} = 1 - \frac{6\cdot\sum_{i=1}^{n}(r_i-s_i)^2}{n(n^2-1)} \,.$$

seguente formulazione, ben più nota nell'ambiente statistico:

$$r_s = 1 - \frac{6 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{n(n^2 - 1)}. \qquad [5]$$

Si noti che la massima discordanza assoluta si ha quando r_i e s_i rappresentano i minimi e massimi valori delle rispettive distribuzioni, ossia $(|n|-1) + (|n-1|-2) + [|n-2|-3)\ldots$; in generale, $|r_i - s_i| = n + 1 - 2i$, per cui:

$$\mathrm{Max}\left[\sum_{i=1}^{n}(r_i - s_i)^2\right] = \sum_{i=1}^{n}(n + 1 - 2i)^2 = \sum_{i=1}^{n}\left[(n+1)^2 - 4i(n+1) + 4i^2\right] =$$

$$= n(n+1)^2 - 4(n+1)\sum_{i=1}^{n} i + 4\sum_{i=1}^{n} i^2 = \frac{n(n^2-1)}{3} \quad ,$$

da cui si evince facilmente la forma

$$r_s = 1 - \frac{2 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{\mathrm{Max}\left[\sum_{i=1}^{n} (r_i - s_i)^2\right]} .$$

Quest'ultima espressione evidenzia che anche r_s varia fra -1 (quando vi è massima discordanza) ed 1 (quando vi è massima concordanza): infatti in questo caso i termini nella sommatoria a numeratore sono tutti nulli, e di conseguenza si annulla l'intera frazione (per cui $\rho_s = 1-0 = 1$); in caso contrario, il termine a numeratore corrisponde chiaramente a 2 volte il denominatore (e in tal caso, dunque, vale $r_s = 1-2 = -1$).

Va da sé che, ove nella distribuzione di una o entrambe le variabili in esame vi siano pareggi di rango in numero sensibile, cioè per oltre il 20% dei casi (per alcuni studiosi, oltre il 30%, per altri anche il 10%), il coefficiente risulta distorto, e andrebbe corretto in base al numero di pareggi e a quanti valori uguali si contano in ciascun pareggio.

Indicando con ${}_xt_j$ il numero dei "pareggi" del gruppo j (j=1,...,u) della graduatoria X e con ${}_yt_h$, il numero dei "pareggi" del gruppo h (h=1,...,v) della graduatoria Y e ponendo (cfr., ad es., Delvecchio 2024, Cap. XV, par. 4):

$$T_x = \frac{1}{12 \cdot n} \sum_{j=1}^{u} {}_xt_j\,({}_xt_j^2 - 1) \qquad \text{e} \qquad T_y = \frac{1}{12 \cdot n} \sum_{h=1}^{v} {}_yt_h\,({}_yt_h^2 - 1),$$

si dimostra che l'indice di Spearman assume la forma

$$r_s^* = \frac{[(n^2-1)/12 - T_x] + [(n^2-1)/12 - T_y] - (1/n)\sum (r_i - s_i)^2}{2\sqrt{[(n^2-1)/12 - T_x][(n^2-1)/12 - T_y]}}. \qquad [6]$$

Tuttavia, la complicazione dei calcoli necessari per la correzione può scoraggiare l'uso dell'indice, per cui in tali casi converrebbe maggiormente utilizzare la [4], sempre corretta perché non vincolata alla condizione di progressione aritmetica dei ranghi, e dunque di valori tutti distinti fra loro.

Una seconda soluzione semplice e sempre corretta al problema dei pareggi nell'indice di cograduazione di Spearman è stata proposta negli anni Settanta del secolo passato da V. Amato (1970, 1977). Essa utilizza il semplice calcolo aggiuntivo dei ranghi r_i' e s_i' delle singole unità statistiche nelle graduatorie non crescenti[11], ed è espressa come:

$$r_s' = 1 - \frac{4 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{\sum_{i=1}^{n} (r_i - r_i')^2 + \sum_{i=1}^{n} (s_i - s_i')^2} . \qquad [7]$$

Logicamente, se (e solo se) in entrambe le distribuzioni poste a confronto ***non*** si osservano pareggi, si verifica l'equivalenza $r_s' = r_s$. Infatti, in tal caso ambo le graduatorie r_i e s_i risultano semplicemente permutazioni dei primi *n* numeri naturali, e per entrambe si avrà:

$$\sum_{i=1}^{n} (r_i - r_i')^2 = \sum_{i=1}^{n} (s_i - s_i')^2 = \frac{n \cdot (n^2 - 1)}{3} .$$

Ora, l'equivalenza è immediata sostituendo dette quantità nella [7], che dunque può essere assunta come forma generale dell'indice di Spearman:

$$r_s' = 1 - \frac{4 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{\frac{n \cdot (n^2 - 1)}{3} + \frac{n \cdot (n^2 - 1)}{3}} = 1 - \frac{4 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{\frac{2n \cdot (n^2 - 1)}{3}} = 1 - \frac{6 \cdot \sum_{i=1}^{n} (r_i - s_i)^2}{n \cdot (n^2 - 1)} = r_s .$$

Vedremo tra breve quale influenza sui risultati possa avere, in caso di pareggi di rango, la scelta dell'una o dell'altra formulazione dell'indice.

---

[11] Ovverossia, poniamo che nelle graduatorie non decrescenti dei caratteri *x* e *y* le unità presentino, per esempio, rispettivamente i ranghi [3, 6, 3, 5, 7, 1, 3] nella distribuzione X (si noti la situazione di pareggio di tre unità ai primi posti, che invece di spartirsi i ranghi 2, 3 e 4 condividono la media 3) e i ranghi [4, 3, 1, 6, 2, 5, 7] nella distribuzione Y. Le graduatorie *non crescenti* per le stesse unità saranno rispettivamente [5, 2, 5, 3, 1, 7, 5] per X, e [4, 5, 7, 2, 6, 3, 1] per Y. Com'è evidente, il rango dell'i-esima unità nella graduatorie non crescente si ricava per semplice differenza tra il numero di osservazioni incrementato di 1 e il rango nella rispettiva graduatoria non decrescente: $r_i' = n + 1 - r_i$, $s_i' = n + 1 - s_i$.

Contrariamente al coefficiente di Bravais-Pearson, il quale, come si è notato, richiede la normalità della distribuzione doppia dei dati posti in relazione, è *sempre* ammessa la verifica statistica della significatività per l'indice di Spearman. In letteratura (per es., Zar 1972; Maciak, 2009) sono tabulati, per vari livelli di significatività e varie numerosità campionarie, i valori soglia, esatti per $n \leq 25$ e approssimati per numerosità maggiori, sotto i quali considerare statisticamente prossimo a 0 un valore empirico $|r_s|$ con probabilità di errore α (detti valori soglia sono parzialmente riportati in Tab. 1).

Tabella 1. *Valori soglia $r_{s;\alpha}$ dell'indice di Spearman a due code.*

	$\alpha \geq P(R_s \geq r_{s;\alpha})$			
n	0,005	0,01	0,025	0,05
6	1	0,943	0,886	0,829
7	0,929	0,893	0,786	0,714
8	0,881	0,833	0,738	0,643
9	0,833	0,783	0,700	0,600
10	0,794	0,745	0,648	0,564
11	0,755	0,709	0,618	0,536
12	0,727	0,678	0,587	0,503
13	0,703	0,648	0,560	0,484
14	0,679	0,626	0,538	0,464
15	0,654	0,604	0,521	0,446
16	0,635	0,582	0,503	0,429
17	0,618	0,566	0,488	0,414
18	0,600	0,550	0,472	0,401
19	0,584	0,535	0,460	0,391
20	0,570	0,522	0,447	0,380
21	0,556	0,509	0,436	0,370
22	0,544	0,497	0,425	0,361
23	0,532	0,486	0,416	0,353
24	0,521	0,476	0,407	0,344
25	0,511	0,466	0,398	0,337

Fonte: Zar, 1972 ($n \leq 16$), Maciak, 2009 ($n > 16$).

Tenendo conto della buona approssimazione dell'indice di Spearman a una curva normale con media nulla e varianza pari a $1/(n-1)$, se $n > 100$ (ma l'approssimazione è abbastanza buona anche per $n > 50$, per cui il test risulta comunque affidabile) è opportuno effettuare la verifica di ipotesi $H_0: |\rho_s| = 0$ contro $H_1: |\rho_s| > 0$ facendo riferimento appunto alla standardizzazione z dell'indice stesso ($z = |r_s| \cdot \sqrt{n-1}$), da cui il valore soglia del test:

$$|r_{s,\alpha}| = z_\alpha / \sqrt{n-1} \ .$$

Se $25<n\leq 50$ (o 100, se si vuole andare sul sicuro) è invece possibile, per la medesima verifica di ipotesi, far riferimento al meno potente ma sempre corretto test basato sull'approssimazione $t=|r_s|\sqrt{(n-2)/(1-r_s^2)}$, che si distribuisce come un T_α di Student con $g = n-2$ gradi di libertà fornendo il seguente valore di soglia (sotto il quale l'indice di Spearman è statisticamente non differente da zero):

$$|r_{s,\alpha}| = t_{g,\alpha}\sqrt{(1-r_s^2)/(n-2)} \ .$$

Per concludere l'argomento, va tenuto presente che, a causa della presenza del quadrato delle differenze r_i-s_i, l'indice di Spearman tende a essere eccessivamente sensibile a grandi differenze di rango, cioè in presenza di variabili fortemente, seppur non totalmente, discordanti (Amato 1954).

Per quanto riguarda l'efficienza asintotica relativa dell'indice di Spearman rispetto al coefficiente di correlazione lineare di Bravais-Pearson, secondo Hotelling e Pabst (1936) sotto l'ipotesi di distribuzione normale bivariata dei dati essa è pari a $(3/\pi)^2 \approx 0{,}91189$. Tale risultato viene confermato dal il criterio di Pitman (1948), risultando inoltre pari esattamente a *1* in caso di distribuzione uniforme (rettangolare) ed a 1,266 se essa è di forma esponenziale.

In conclusione, detto indice può rivelarsi un ottimo succedaneo del coefficiente *r* di Pearson, però privo dei suoi vincoli distributivi.

Si noti che, talora, alla notazione r_s è preferita quella originale proposta da Spearman: ρ_s (la quale però, per rigore formale, non andrebbe riferita alla cograduazione rilevata fra due campioni, bensì esclusivamente *fra due popolazioni*).

5. Esempio di scelta tra correlazione parametrica e non parametrica

La Tab. 2 mostra, in associazione con le Figg. 2-3, la convenienza di utilizzare l'uno o l'altro degli indici di correlazione fin qui descritti laddove le variabili in esame siano tutte quantitative (dato che, ove anche una sola di esse sia misurata su scala ordinale, il problema non si pone).

Si abbiano dunque due variabili (presumibilmente non collineari ma correlate) misurate sugli stessi soggetti, ossia 12 alunni di una scuola del ciclo primario: *numero medio mensile di assenze scolastiche* fatte registrare dagli alunni nel corso dell'anno scolastico e *tempo di fruizione* di spettacoli televisivi, senza distinzione se cartoni animati, telefilm, programmi di intrattenimento e, ove ve ne siano, programmi educativi.

Supponendo che possa esservi una relazione tra le due variabili, la cui direzione al momento può essere considerata incerta[12], i dati della Tab. 2, in cui il campione di alunni è stato ordinato per numero di assenze registrate, sembrano fornire indicazioni contrastanti circa questa ipotesi. Infatti, mentre gli alunni con un minor numero di assenze mensili fanno effettivamente rilevare una minore fruizione di programmi TV, il maggior numero di ore di fruizione non sempre compete agli alunni più assenteisti.

Tabella 2. *Assenze scolastiche mensili registrate nell'anno scolastico da un campione di 12 alunni delle scuole primarie, ore medie settimanali di fruizione di spettacoli TV da parte degli stessi alunni, e rispettivi ranghi. Valori modificati della seconda variabile (per valutare gli effetti di una possibile relazione lineare).*

	x	*y*	Rango	Rango	***Fruizione TV modificata***	
Alunni	Assenze	Fruizione TV	Assenze	Fruizione TV	*y'*	*rango(y')*
H	1	10	1,5	3	*11*	*3*
D	1	12	1,5	4	*12*	*4*
B	2	9	3,5	2	*10*	*2*
L	2	6	3,5	1	*9*	*1*
F	3	22	5	8	*17*	*8*
I	4	33	6	11	*20*	*11*
J	5	32	7	10	*19*	*10*
A	6	20	8	6	*15*	*6*
G	7	21	9	7	*16*	*7*
C	8	34	10,5	12	*21*	*12*
E	8	13	10,5	5	*14*	*5*
K	11	23	12	9	*18*	*9*

Inoltre, rappresentando graficamente (Fig. 2) la relazione ipotizzata con limitazione della medesima a una dipendenza univoca dell'assenteismo scolastico (variabile conseguente) dalla fruizione TV (variabile antecedente), si pone in luce che, a causa del più che cospicuo numero di assenze scolastiche da parte di alunni con una fruizione intermedia di spettacoli televisivi, la forma della relazione medesima non è rettilinea, ma curvilinea, approssimandosi a un arco di parabola (tendenza bilineare):

$$y = -3{,}677 + 0{,}8185\, x - 0{,}016\, x^2.$$

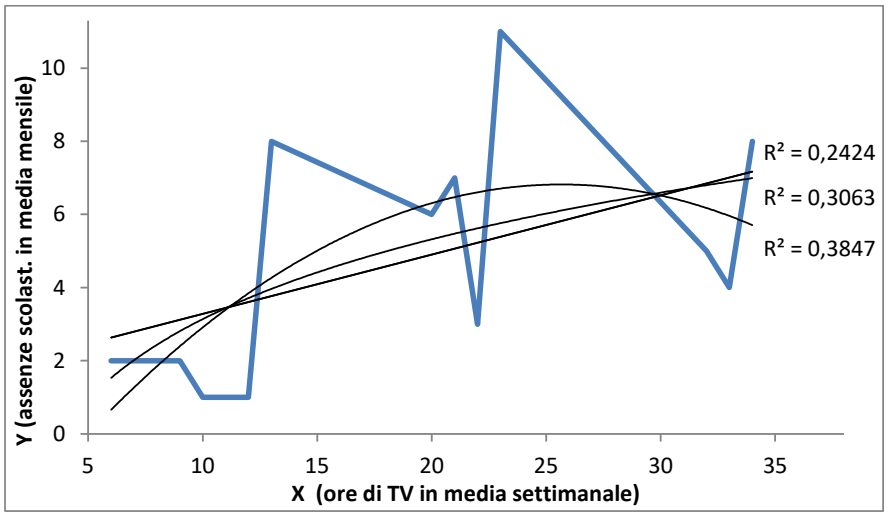
[12] In effetti, è certamente logico ritenere che una smodata passione per i programmi televisivi possa condurre i ragazzi a "marinare la scuola", ma non è possibile escludere a priori l'ipotesi opposta che tale assenteismo sia dovuto essenzialmente a uno scarso desiderio di frequentare le lezioni, e che la scelta di passare il tempo guardando la televisione sia una *conseguenza*, più o meno piacevole per gli interessati, e non una causa effettiva.

A tale funzione è associato un valore dell'indice di determinazione[13] interessante seppur non elevatissimo (R^2=0,3847, ossia poco meno del 38,5% della variabilità delle assenze sarebbe imputabile alla variabilità della fruizione di programmi televisivi). Essa è però irrealistica come tutte le funzioni paraboliche, portando a stimare numeri di assenze mensili (assurdamente) *minori di 0* per fruizioni televisive sia inferiori a 5 ore che superiori a 45.

Molto più adeguata, nei limiti dell'ipotesi unidirezionale considerata, risulta la funzione di tendenza logaritmica $y = 3{,}1484\ ln(x) - 4{,}1125$, a cui è associato un ancora rispettabile valore R^2=0,3063. Invece, alla funzione di tendenza lineare $y = 1{,}6624 + 0{,}1619\ x$ è associato un misero R^2=0,2424 (e un coefficiente di correlazione lineare pari a 0,492).

Di conseguenza, la migliore rappresentazione della relazione che fa dipendere il numero di assenze scolastiche dalla fruizione di programmi TV sarebbe (*cum grano salis*) una funzione logaritmica.

Figura 2. *Assenze scolastiche mensili registrate nell'anno scolastico da un campione di 12 alunni delle scuole primarie, assunte come* dipendenti *dalle ore medie settimanali di fruizione di spettacoli TV da parte degli stessi alunni. Linee di tendenza.*

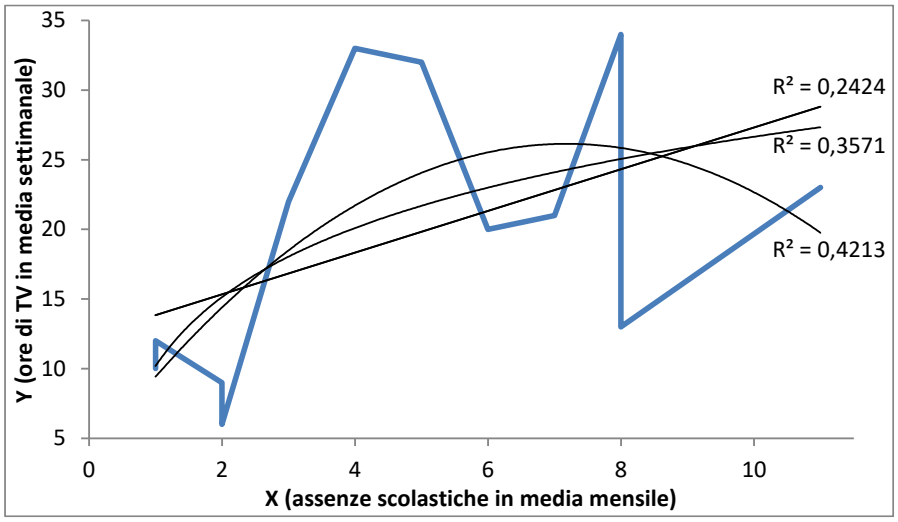


[13] Va detto che, per quanto riguarda la linea di tendenza rettilinea, l'indice di determinazione R^2 (che, com'è noto, esprime quanta parte della devianza totale è determinata dalla regressione di ciascuna variabile dall'altra), è calcolato a partire da *r*, essendo:

$$R^2 = [Cod(X,Y)]^2 / [Dev(X) \cdot Dev(Y)] = Dev(R_Y) / Dev(Y) = Dev(R_X) / Dev(X).$$

Per quanto riguarda invece le linee di tendenza di diversa forma, stimati i coefficienti della relativa funzione interpolante (calcolo che generalmente viene svolto tramite formulazioni linearizzanti), si fa riferimento all'indice di determinazione della funzione linearizzata. Per questo motivo l'indice di determinazione risultante non è molto adatto a fini inferenziali.

Figura 3. *Ore medie settimanali di fruizione di spettacoli TV da parte di un campione di 12 alunni delle scuole primarie, assunte come dipendenti dalle assenze scolastiche mensili fatte registrare dagli stessi alunni. Linee di tendenza.*



Tuttavia, come evidenzia la successiva Fig. 3, tale relazione (contrariamente a quella lineare) non presenta la medesima capacità esplicativa invertendo l'ordine delle variabili: infatti, assunta la dipendenza logaritmica della fruizione di programmi TV dal numero di assenze scolastiche (ipotesi poco usuale e ancor meno verosimile, ma in qualche modo possibile), si ha un indice di determinazione sensibilmente maggiore: R^2=0,3571. Lo stesso avviene, peraltro, per la relazione parabolica, la cui inverosimiglianza qui è ancora più evidente; in caso di relazione lineare l'indice di determinazione, così come il coefficiente di correlazione, è invece del tutto identico invertendo la direzione della relazione stessa, ma ciò è matematicamente ovvio.

Dunque, sarà compresa tra 0,553 e 0,598 la stima del coefficiente di correlazione lineare *relativo alla trasformazione logaritmica della variabile antecedente*, a seconda di quale sia, appunto, la variabile antecedente e quale la dipendente. La media dei due coefficienti, secondo la formulazione proposta nella [3] per le relazioni non lineari, risulta pari a 0,575.

Fin qui l'analisi grafica e dei coefficienti di determinazione.

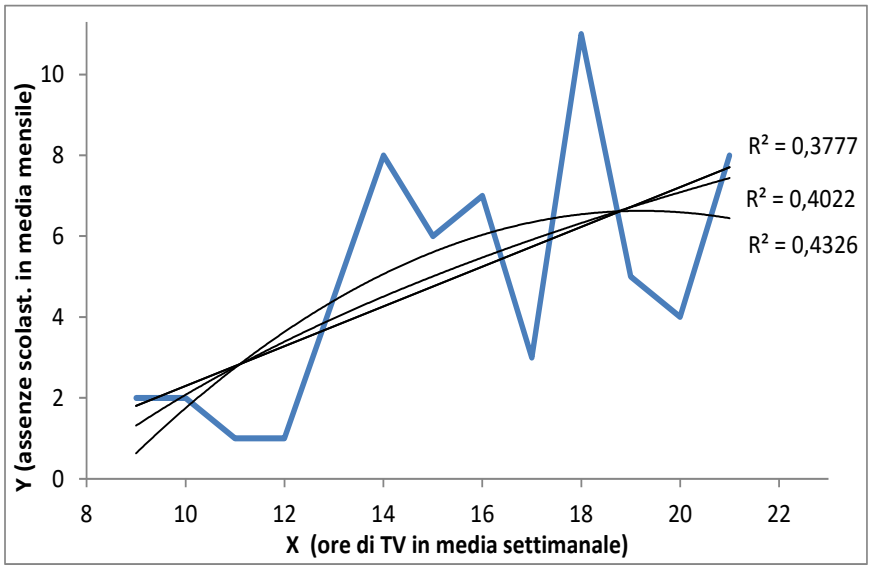
Ma un risultato ben più consistente può aversi utilizzando criteri inferenziali, premettendo comunque che ambo le distribuzioni dei dati risultano provenire da popolazioni normalmente distribuite (sia secondo il test di Kolmogorov-Smirnov, corretto secondo Lilliefors, che secondo il test di Shapiro-Wilk), e che anche la distribuzione congiunta risulta binormale secondo il criterio di Malkovich-Afifi.

Ipotizzando una dipendenza lineare del numero di assenze scolastiche dalla fruizione di programmi televisivi, i residui della regressione risultano normalmente distribuiti, così come i residui ottenuti facendo regredire linearmente le ore di fruizione televisiva dal numero di assenze. Tuttavia, in ambo i casi il modello lineare risultante non è statisticamente significativo in termini di adattamento ($F=3{,}20 < f_{0{,}05;1;10}=4{,}96$), e lo stesso si verifica per quanto riguarda la significatività del coefficiente di correlazione ($p>0{,}1$).

Indubbiamente, ciò è dovuto anche alla ridotta numerosità campionaria, ma soprattutto alla carenza di linearità della relazione tra le due variabili, evidenziata anche dall'indice di determinazione mostrato nella rappresentazione grafica, ben ridotto in confronto alle altre relazioni ipotizzate.

A dimostrazione di ciò, le ultime colonne della Tab. 2 riportano una simulazione operata modificando leggermente alcuni valori y al fine di ottenere una relazione lineare tra assenze scolastiche e tempo di fruizione della TV, linearità dimostrata statisticamente, com'è logico, dopo aver verificato la normalità della distribuzione doppia ottenuta con i dati modificati, nonché normalità e casualità dei residui di detta relazione (si noti che le modifiche effettuate non hanno influenzato affatto i ranghi delle osservazioni).

Figura 4. *Assenze scolastiche mensili registrate nell'anno scolastico da un campione di 12 alunni delle scuole primarie, assunte come* dipendenti *dalle ore medie settimanali di fruizione di spettacoli TV da parte degli stessi alunni (dato leggermente modificato per garantire la linearità della relazione). Linee di tendenza.*



In virtù di dette modifiche, che hanno ridotto il campo di variazione della variabile "Ore di fruizione settimanale di programmi televisivi", i modelli di

regressione si presentano come da Fig. 4. In particolare, la funzione di tendenza lineare $y = -2{,}662 + 0{,}4916\,x$ presenta finalmente un indice di determinazione abbastanza rilevante: $R^2=0{,}3777$, comparabile con quello della funzione logaritmica che quasi vi si sovrappone (essendo tuttora inverosimile la funzione di parabola, pur se presenta il miglior R^2). Il test di adattamento fornisce un risultato altrettanto valido ($F=6{,}07 > f_{0{,}05;1;10}=4{,}96$) confermando la relazione lineare, come è logico date le premesse.

In definitiva, il coefficiente di correlazione lineare qui risulta $r=0{,}6146$, decisamente rilevante e, soprattutto, statisticamente significativo ($p<0{,}035$).

Tuttavia, questo risultato ottimale è dovuto soltanto alla modifica dei dati effettuata appunto per garantire la linearità della relazione medesima[14].

Si può dunque affermare che per lo studio dell'interrelazione tra due caratteri, in assenza di linearità della medesima, anche in base a criteri inferenziali non è adeguato l'utilizzo del coefficiente di correlazione lineare.

A questo punto, diventa utile o addirittura indispensabile il ricorso a un metodo non parametrico come quello proposto da Spearman.

Facendo riferimento all'usuale formulazione [5], è immediato il calcolo dell'indice $r'_s=0{,}6171$. Tuttavia, i dati riportati in Tab. 2 evidenziano la presenza, per la variabile "Assenze", di ben 6 parità di rango (in tre gruppi), su un totale di 24 valori, ossia il 25%.

Sarebbe dunque opportuno correggere l'indice tramite la formulazione [6] o, più semplicemente, fare ricorso alla formulazione [3], la quale, basandosi su una media dei ranghi pari a $(12+1)/2=6{,}5$, conduce abbastanza agevolmente al calcolo corretto $r_s=0{,}6151$. Valore molto prossimo al precedente (e quasi identico al valore di r ottenuto nella distribuzione linearizzata!), la qual cosa lascia presumere che la soglia del 20% delle parità di rango sul totale dei valori sia, in questo caso, fin troppo prudente[15].

---

[14] Si noti, peraltro, che le uniche curve che forniscono, dopo opportuna trasformazione dei dati, un modello linearizzato con parametri statisticamente significativi sia per la regressione di Y su X che per quella di X su Y sono, con $F=6{,}87 > f_{0{,}05;1;10}$, la curva di potenza

$$Y = b_0 \cdot X^{b_1} \quad \rightarrow \quad \ln(Y) = \ln(b_0) + b_1 \cdot \ln(X) \quad \rightarrow \quad Y = 9{,}5923 \cdot X^{0{,}442}$$

e, con valori della statistica F leggermente diversi a seconda di quale sia la variabile dipendente, ma entrambi maggiori di 6 ($> f_{0{,}05;1;10}$), la curva sigmoide di equazione

$$Y = e^{b_0 + b_1/X} \quad \rightarrow \quad \ln(Y) = b_0 + b_1/X \quad \rightarrow \quad Y = e^{3{,}2346 - 1{,}064/X}.$$

Tuttavia, entrambe le curve fanno rilevare residui con distribuzione statisticamente non casuale, benché tendenzialmente normale, e dunque anch'esse non risultano essere pienamente adeguate per valutare la correlazione tra le due variabili X e Y.

[15] Ovviamente, il medesimo risultato si ottiene utilizzando la citata correzione per parità di rango [4]. Avendosi $T_x=(2\cdot3+2\cdot3+2\cdot3)/(12\cdot12)=0{,}125$ e $T_y=0$, ed essendo 109,5 la somma dei quadrati delle differenze $(r_i - s_i)$, il valore corretto del *rho* di Spearman risulta infatti:

Sulla scorta di tale risultato ed essendo n=12, posto il livello di significatività α=0,05, nella Tab. 1 si identifica un valore soglia di 0,564, per cui va senz'altro respinta l'ipotesi $H_0: |\rho_s| = 0$ (e quindi accettata la $H_1: |\rho_s| > 0$).

6. L'indice γ_a di Amato

Si è detto nel par. 4 che l'indice di cograduazione di Spearman presenta l'inconveniente di essere molto sensibile a forti discordanze tra le due serie.

Per tale motivo, Amato (1954) derivò dall'indice r_s un indice quadratico di cograduazione in grado di ridurre l'entità di questo inconveniente operando tramite la sua radice quadrata, allo stesso modo in cui lo scarto quadratico medio riduce il similare problema legato all'uso della varianza.

Sono abbastanza complessi i passaggi per trarre dall'indice di Spearman un indice quadratico in grado di esprimere adeguatamente valori anche negativi, richiedendo peraltro un approccio strutturale difficilmente sintetizzabile in questo saggio, per il quale si rimanda a testi specifici (Amato 1970).

La struttura finale dell'indice è comunque molto semplice:

$$\gamma_a = \sqrt{\frac{1+r_s}{2}} - \sqrt{\frac{1-r_s}{2}} \quad . \qquad [8]$$

Come è facilmente verificabile, l'indice γ_a è nullo se e solo se r_s=0 e produce valori negativi quando r_s<0, positivi ove r_s>0, con minimo -1 quando anche $r_s = -1$ e massimo pari a 1 quando anche $r_s = 1$.

In caso di distribuzioni di dati con pareggi, Amato (1954) suggerisce la seguente generalizzazione del proprio indice di cograduazione:

$$\gamma_a = \frac{\sqrt{\frac{1+r_s}{2}} - \sqrt{\frac{1-r_s}{2}}}{\sqrt{\frac{1+r_s}{2}} + \sqrt{\frac{1-r_s}{2}}}, \qquad [9]$$

$$r_s^* = \frac{(143/12 - 0{,}125) + 143/12 - 109{,}5/12}{2\sqrt{(143/12 - 0{,}125) \cdot 143/12}} = 0{,}6151,$$

che è appunto il risultato immediatamente ottenuto tramite la [2].

Anche l'utilizzo della formulazione [5] conduce a un risultato praticamente identico, come è semplice verificare. In realtà, sussiste una differenza quasi impercettibile a livello millesimale: mentre entrambe le formule [2] e [4] producono un calcolo pari a 0,6151228, la formula proposta da Amato fornisce r_s=0,6151142: differenza in genere irrilevante. La maggiore semplicità di calcolo rende comunque la procedura di Amato una valida alternativa alla [2] in caso di campioni numerosi, ove il ricorso alla [4] è molto disagevole.

ma, a parere dello scrivente, sarebbe molto più semplice ed efficace applicare la [8] non all'originale indice di Spearman, ma alla sua generalizzazione r_s' proposta da Amato stesso, descritta nella [7] del paragrafo 4.

Per quanto riguarda inferenze sull'indice di Amato, non ne è stata tabulata direttamente la distribuzione, tuttavia tra γ_a^2 e r_s^2 esiste la relazione, derivata semplicemente dal quadrato della precedente formulazione[16]:

$$\gamma_a^2 = 1 - \sqrt{1 - r_s^2} \quad ,$$

e dunque i valori di soglia per la verifica del sistema di ipotesi H_0: $r_s=0$ contro H_1: $r_s>0$ possono essere facilmente calcolati partendo da quelli della Tab. 1 per $n \leq 30$ (oppure, per $n \leq 100$, dalla tabella originale proposta da Zar, 1972); ancor più semplicemente, possono essere adottati direttamente i valori soglia della Tab. 1 in relazione ai valori empirici r_s utilizzati per il calcolo dell'indice di Amato: infatti, dalla [11] si ricava immediatamente:

$$1 - \gamma_a^2 = \sqrt{1 - r_s^2} \quad \rightarrow \quad 1 - r_s^2 = (1 - \gamma_a^2) \quad \rightarrow \quad r_s^2 = 1 - (1 - \gamma_a^2)$$

da cui

$$r_s = \pm\sqrt{1 - (1 - \gamma_a^2)} \quad .$$

Invero, l'indice di cograduazione di Amato si limita a quantificare diversamente la forza della relazione tra le due variabili a fini descrittivi e interpretativi, ma non influisce (fuorché apparentemente) sulla sua significatività statistica, che sarà dunque valutata sul valore originale r_s, eventualmente salvando il segno (coda sinistra o coda destra) che invece nella precedente relazione resta indeterminato.

Logicamente, per numerosità campionarie abbastanza consistenti si potranno ancora applicare al valore empirico dell'indice r_s i test statistici basati sulle distribuzioni normale e di Student per verificare che l'indice γ_a ad esso assimilato sia statisticamente significativo.

7. L'indice *Tau* di Kendall

Concettualmente molto differente rispetto all'indice di Spearman è l'*indice* $\boldsymbol{\tau}$ *di Kendall* (1938), anch'esso una misura simmetrica di *associazione direzionale*, relativa a coppie di caratteri qualitativi ordinali oppure quantitativi (ma

[16] Infatti: $\gamma_a^2 = \left[\sqrt{(1+r_s)/2} - \sqrt{(1-r_s)/2}\right]^2 = (1+r_s)/2 + (1-r_s)/2 - 2\sqrt{(1+r_s)/2}\sqrt{(1-r_s)/2} =$
$= 1 - \sqrt{(1+r_s)(1-r_s)} = 1 - \sqrt{1-r_s^2}$.

non necessariamente legati da relazione lineare o normalmente distribuiti). Esso è basato sul conteggio del numero di coppie di unità ordinate nello stesso modo su entrambi i caratteri (ossia *concordanti*) e del numero di coppie di unità ordinate in modo opposto (*discordanti*), che viene sottratto alle prime; il risultato viene poi diviso per il numero totale di combinazioni di coppie:

$$(C-D) / K \qquad [10]$$

dove:

- C: numero di coppie di unità la cui differenza di rango ha segno *concordante* nei due caratteri osservati (cioè se risulta $x_i-x_j>0$ sarà anche $y_i-y_j>0$, mentre se $x_i-x_j<0$ si avrà anche $y_i-y_j<0$);
- D: numero di coppie di unità la cui differenza di rango ha invece segno *discordante* (ossia, se abbiamo $x_i-x_j>0$ sarà $y_i-y_j<0$, mentre se $x_i-x_j<0$ avremo $y_i-y_j>0$);
- K: numero di possibili combinazioni di coppie di valori, dato, nella formulazione base dell'indice, detta $\boldsymbol{\tau}_a$, dal prodotto $n(n-1)/2$.

Il termine $C-D$ può essere calcolato come somma dei prodotti dei segni delle differenze tra i valori o i ranghi del primo carattere, ordinato in modo non decrescente, e quelli del secondo carattere relativi alle medesime unità:

$$\sum_{i=1}^{n-1}\sum_{j=i+1}^{n} \text{segno}(x_i - x_j)\cdot\text{segno}(y_i - y_j),$$

poiché ogni prodotto in sommatoria sarà pari a $+1$ se ambo le differenze sono positive oppure negative, mentre sarà pari a -1 se una è positiva e l'altra è negativa, e pari a 0 se almeno una delle differenze è nulla.

Esso può dunque essere interpretato come "codevianza tra i segni delle differenze", e poiché il termine K è pari al valore che avrebbe tale codevianza se *tutte* le coppie di differenze avessero concordanza di segno, il tau di Kendall:

$$\boldsymbol{\tau}_a = \frac{2\cdot\sum_{i=1}^{n-1}\sum_{j=i+1}^{n}\text{segno}(x_i - x_j)\cdot\text{segno}(y_i - y_j)}{n(n-1)} \qquad [11]$$

di fatto corrisponde al coefficiente di correlazione lineare applicato alla dicotomia negativo/positivo (−1, +1).

Tuttavia, ove siano presenti due o più valori identici nella successione delle X o delle Y, il confronto non determina né una concordanza né una discordanza[17] e dunque non contribuisce al calcolo di $\boldsymbol{\tau}$. La mancata correzione di tale problema comporterebbe, dunque, che il campo di variazione dell'indice

[17] In tal caso il segno della differenza di ranghi, infatti, non è né positivo né negativo, e dunque la dicotomia su cui si basa l'indice diventa una tricotomia (−1, 0, +1).

non sarebbe più compreso tra -1 e $+1$, ma meno ampio (causando una sensibile distorsione). Dunque, in presenza di parità in una o in entrambe le variabili, identificati g_x e g_y gruppi di valori identici tra loro, e definiti rispettivamente con t_{ix} e t_{iy} il numero di casi con uguale valore in ogni gruppo di pareggi di X e di Y rispettivamente, Kendall (1948) propose l'indice:

$$\boldsymbol{\tau_b} = \frac{2 \cdot \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)}{\sqrt[2]{n(n-1) - \sum_{i=1}^{g_x} t_{ix}(t_{ix} - 1)} \cdot \sqrt[2]{n(n-1) - \sum_{i=1}^{g_y} t_{iy}(t_{iy} - 1)}} \; . \qquad [12]$$

Come è immediato, in assenza di pareggi i due indici $\boldsymbol{\tau_a}$ e $\boldsymbol{\tau_b}$ sono del tutto identici, e in effetti la [12] si presenta come forma generale del $\boldsymbol{\tau}$ di Kendall, di cui la [11] è un caso particolare. Ai fini della successiva verifica statistica, dunque, si indicherà indifferentemente con $\boldsymbol{\tau}$ l'uno o l'altro, qualsiasi sia stato concretamente utilizzato.

Una volta calcolato opportunamente l'indice $\boldsymbol{\tau}$, per campioni minori di 25 casi è possibile verificarne la significatività tramite i valori-soglia puntuali identificati nella Tab. 3.

Tabella 3. *Valori soglia τ_α dell'indice di Kendall a una coda*.

	$\alpha \geq P(\tau \geq \tau_\alpha)$			
n	0,005	0,01	0,025	0,05
6	1	0,867	0,867	0,733
7	0,810	0,810	0,714	0,619
8	0,786	0,714	0,643	0,571
9	0,722	0,667	0,556	0,500
10	0,644	0,600	0,511	0,467
11	0,600	0,564	0,491	0,418
12	0,576	0,545	0,455	0,394
13	0,564	0,513	0,436	0,359
14	0,516	0,473	0,407	0,363
15	0,505	0,467	0,390	0,333
16	0,483	0,433	0,383	0,317
17	0,471	0,426	0,368	0,309
18	0,451	0,412	0,346	0,294
19	0,439	0,392	0,333	0,287
20	0,421	0,379	0,326	0,274
21	0,410	0,371	0,314	0,267
22	0,391	0,352	0,296	0,257
23	0,378	0,344	0,295	0,253
24	0,377	0,341	0,290	0,246

Fonte: Best, 1973.

Per numerosità campionarie maggiori, l'indice di Kendall si approssima tendenzialmente alla distribuzione normale con media nulla (essendo nulla la

somma totale delle sue concordanze e discordanze) e varianza

$$\hat{\sigma}_{\tau}^{2} = \frac{4n+10}{9n\cdot(n-1)} \quad ,$$

e si possono dunque identificarne i valori soglia a un prefissato livello di significatività α tramite la standardizzazione $z = \tau \cdot \sqrt{9n(n-1)/(4n+10)}$, da cui $\tau_{\alpha} = z_{\alpha} \cdot \sqrt{(4n+10)/9n(n-1)}$, qualsiasi sia α (per test a una coda o a due code).

I vantaggi dell'indice di cograduazione di Kendall, come si nota, non risiedono tanto nella semplicità di calcolo, che anzi può presentare aspetti di notevole complessità per campioni molto numerosi, ma nel fatto che, nonostante che la sua prima formulazione vi facesse riferimento, esso non richiede una preventiva trasformazione in ranghi delle variabili osservate (anche quelle espresse su scala cardinale) pur rimanendo svincolato dalla forma delle distribuzioni dei dati, per cui risulta più adeguato dell'indice di Spearman allo studio delle variabili continue.

In Appendice è riportato un facile esempio di calcolo dell'indice di Kendall con l'ausilio di fogli di calcolo informatico.

Va notato che, mentre i valori estremi dell'indice τ corrispondono a quelli di Spearman e di Bravais-Pearson, così come il valore che indica indipendenza statistica (lo zero), i valori intermedi sono sensibilmente differenti, come è evidente anche dal confronto della Tab. 3 con la Tab. 1.

Si calcoli, per esempio, l'indice τ_b relativo alla Tab. 2 (par. 5), i cui dati sono riportati in Tab. 4 (stavolta senza ordinamento perché superfluo).

Tabella 4. *Assenze scolastiche mensili registrate nell'anno scolastico da un campione di 12 alunni delle scuole primarie, ore medie settimanali di fruizione di spettacoli TV da parte degli stessi alunni: concordanze, discordanze e parità.*

	x	*y*			Parità	Parità
Alunni	Assenze	Fruizione TV	Concordanze	Discordanze	t_x	t_y
A	6	20	7	4	0	0
B	2	9	7	2	1	0
C	8	34	7	1	1	0
D	1	12	6	1	1	0
E	8	13	3	4	1	0
F	3	22	5	1	0	0
G	7	21	3	2	0	0
H	1	10	3	1	1	0
I	4	33	1	2	0	0
J	5	32	1	1	0	0
K	11	23	1	0	0	0
L	2	6	0	0	1	0
Somme			44	19	6	0

Essendo $n(n-1)=132$, $\Sigma\, t_x(t_x-1)=6$ e $\Sigma\, t_y(t_y-1)=0$, tramite la [12] è immediato calcolare l'indice $\boldsymbol{\tau}_b = 2\times(44-19)/\sqrt{126\times132} = 0{,}388$, valore che risulta inferiore, sia pur di poco, al valore soglia per α=0,05 e n=12: di conseguenza, andrebbe *accettata* l'ipotesi di base $H_0: |\boldsymbol{\tau}| = 0$, non potendosi ritenere, quindi, che vi sia una correlazione tra le variabili studiate.

Nonostante le notevoli differenze di principio, di struttura e, spesso, di valori risultanti dai calcoli, seguendo il criterio di Pitman l'indice di Kendall ha comunque un'efficienza asintotica del tutto simile a quella del *rho* di Spearman: circa *0,912* sotto l'ipotesi di distribuzione *normale bivariata*, esattamente pari a *1* in caso di *distribuzione uniforme*, e pari a *1,266* se si rileva una distribuzione *esponenziale doppia* dei dati.

7.1 L'indice $\boldsymbol{\tau}$ per grandi campioni

L'indice $\boldsymbol{\tau}_b$ di Kendall, per grandi campioni, può dare qualche problema computazionale (persino nei computer di ultima generazione) a causa della necessità di valutare l'ammontare di tutti i casi di parità, che indubbiamente possono essere numerosissimi. Stuart (1953) ne ha proposto una versione molto più adeguata a grandi volumi di dati, denominata "$\boldsymbol{\tau}_c$ di Kendall-Stuart", ma talora negli scritti scientifici il contributo di Stuart viene dimenticato, e l'indice attribuito al solo Kendall.

Detto indice, in effetti, si limita ad esprimere la [12] nei suoi concetti base di concordanza, discordanza e parità fra valori, facendo però riferimento a una tabella di cograduazione (ossia una tabella di contingenza in cui sia le modalità di riga che quelle di colonna sono ordinabili, e vengono ordinate generalmente in senso crescente), come quella che si può ricavare anche da una distribuzione numericamente irrisoria come quella della Tab. 4:

	x (rank)								
Y (rank)	1 (1)	2 (2)	3 (3)	4 (4)	5 (5)	6 (6)	7 (7)	8 (8)	11 (9)
6 (1)		1							
9 (2)		**1**							
10 (3)	1								
12 (4)	1								
13 (5)								1	
20 (6)						**1**			
21 (7)							**1**		
22 (8)			1						
23 (9)									**1**
32 (10)					1				
33 (11)				1					
34 (12)								1	

L'identificazione delle concordanze "C" e delle discordanze "D" appare abbastanza agevole, tenendo conto delle definizioni fornite per la [10]: infatti, dato l'ordinamento *concordemente crescente* dei ranghi delle due variabili studiate in una tabella, tali definizioni corrispondono alle seguenti:

- C = per ogni j.ma riga e k.ma colonna, partendo dal valore in alto a sinistra della tabella, somma dei dati relativi alle coppie che hanno *ambo gli indici di riga e di colonna maggiori* di quelli del valore dato, (il che corrisponde a sommare tutti i casi in cui si ha contemporaneamente $x_i>x_k$ e $y_i>y_j$, oppure $x_i<x_k$ e $y_i<y_j$);
- D = per ogni j.ma riga e k.ma colonna, partendo dal valore in alto a destra, somma dei dati relativi alle coppie per le quali risultano *di segno opposto* le differenze degli indici di riga e di colonna rispetto a quelli del valore dato (il che corrisponde a sommare tutti i casi in cui si ha contemporaneamente $x_i>x_k$ e $y_i<y_j$, oppure $x_i<x_k$ e $y_i>y_j$);.

e fanno rilevare nel medesimo ordine una semplificazione per il calcolo pratico di tali valori:

$$\boldsymbol{\tau_c}=\frac{2\cdot(C-D)}{\sqrt[2]{(C+D+T_x)}\cdot\sqrt[2]{(C+D+T_y)}}\ . \qquad [12]$$

La successiva Tab. 4 simula i risultati di un'indagine campionaria sul livello di alfabetizzazione funzionale, secondo i criteri previsti dalla classificazione dello statunitense *National Center for Education Statistics* (2014), nella lettura di testi e documenti[18].

[18] Benché 200 casi siano un carico computazionale considerevole ma non troppo gravoso in uno studio di correlazione non parametrica, la medesima analisi potrebbe essere effettuata sulla base non di un campione, ma di una popolazione di migliaia o milioni di unità: e, in tal caso, la complessità computazionale diventa rapidamente insostenibile.

È il caso, però, di fornire qualche informazione sull'argomento, ancorché irrilevante ai fini della trattazione statistica: nella definizione UNESCO (1984), l'analfabetismo funzionale è "la condizione di una persona incapace di comprendere, valutare, usare e farsi coinvolgere da testi scritti per intervenire attivamente nella società, per raggiungere i propri obiettivi e per sviluppare le proprie conoscenze e potenzialità". In pratica, un analfabeta funzionale sa generalmente leggere, scrivere ed esprimersi in modo sufficientemente corretto dal punto di vista formale, ma si distingue per almeno una delle seguenti caratteristiche, e la sua disfunzionalità è tanto più grave quante più insiemi di caratteristiche fa verificare:

- incapacità di comprendere in misura adeguata testi o materiali informativi pensati per essere compresi dalla persona comune (articoli di giornale, contratti legali, regolamenti, bollette, corrispondenza bancaria, orari di mezzi pubblici, cartine stradali, dizionari, enciclopedie, foglietti illustrativi di farmaci, istruzioni di apparecchiature);
- scarsa abilità nell'eseguire anche semplici calcoli matematici, ad esempio riguardanti la contabilità personale o il tasso di sconto su un bene in vendita;

Tabella 4. *Distribuzione di un campione di 200 soggetti >65 anni secondo il massimo titolo di studio conseguito e il loro livello di alfabetizzazione funzionale nella lettura di testi e documenti (classificazione* National Center for Education Statistics, *USA, 2014).*

	Livello di alfabetizzazione funzionale				
Titolo di studio	Inadeguato	Basilare	Sufficiente	Competente	Totale
Senza titolo	4	1	-	-	5
Licenza elementare	5	10	5	5	25
Licenza media	10	15	15	20	60
Maturità	5	15	25	30	75
Laurea	1	4	20	10	35
Totale	25	45	65	65	200

Per esempio, rispetto ai 4 soggetti *senza titolo di studio* e *inadeguati* in termini di alfabetizzazione funzionale, risultano avere rango maggiore per ambo le variabili tutti coloro che possiedono almeno la *licenza elementare* e un *basilare* livello di alfabetizzazione funzionale: dunque, essendo state rilevate **10+5+5+15+15+20+15+25+30+4+20+10=174 unità** appartenenti a tali celle, e posto che ognuno di questi presenta *concordanza* nella differenza di rango con tutti i 4 soggetti anzidetti, si rilevano ben 4×174=696 concordanze in questo primo passo. Occorre però effettuare i medesimi calcoli in riferimento a ciascuna delle celle (ad esclusione di quelle relative ai titolari di *Laurea* o con livello di alfabetizzazione "*Competente*", poiché non vi sono osservazioni con rango maggiore con cui confrontarle), e sommare tutte le concordanze così ricavate, ottenendo così il rispettabile valore **C = 6881**.

Per quanto riguarda invece le *discordanze*, partendo dalla cella in alto a destra (*senza titolo di studio* ma con livello *Competente* di alfabetizzazione) si ottiene un nulla di fatto in quanto non vi sono osservazioni, così come per la medesima riga al livello di alfabetizzazione *Sufficiente*. Rispetto all'unico soggetto senza titolo di studio ma con livello di alfabetizzazione basilare, vi sono quattro caselle in cui si ha discordanza nelle graduatorie (*inadeguata* alfabetizzazione funzionale, ma titoli di studio dalla licenza elementare alla laurea), e la somma delle unità rilevate in dette caselle è pari a **5+10+5-1=21**. Replicando l'operazione per ciascuna delle caselle chiave rimanenti (come

- scarse competenze nell'utilizzo degli strumenti informatici (sistemi operativi, uso della rete, software di videoscrittura, fogli di calcolo, ecc.);
- conoscenza superficiale dei fenomeni scientifici, politici, storici, sociali ed economici, legata prevalentemente alle esperienze personali o a quelle dei propri amici; tendenza a generalizzare sulla base di singoli episodi non rappresentativi; largo uso di pregiudizi;
- scarso senso critico, tendenza a credere ciecamente alle informazioni ricevute, incapacità di distinguere le notizie false da quelle vere e di distinguere fonti attendibili e inattendibili.

prima, escludendo la prima colonna, minore della quale non vi sono categorie, e l'ultima riga, oltre cui non vi è nulla) si ottiene il numero totale di discordanze nelle differenze di rango: nel caso esemplificato, **D = 3736**.

8. L'indice γ di Goodman e Kruskal

Altro indice non parametrico di correlazione molto noto è il γ di Goodman e Kruskal (1954, 1959, 1963), inizialmente nato per l'analisi di tabelle tetracoriche nel solco dell'indice Q di Yule (che sarà descritto in seguito, riguardando relazioni tra variabili dicotomiche), ma successivamente sviluppato estendendone l'uso anche alle variabili nominali con più di due modalità (anche con numero di modalità differente tra le due variabili) e, infine, alle variabili misurate almeno su scala ordinale:

$$\gamma = (C - D) / (C + D). \qquad [12]$$

Esso può essere inteso come una formulazione alternativa del τ di Kendall, poiché di questo mantiene il significato dei simboli *C=concordanze* e *D=discordanze*, pur sostituendone il denominatore.

Come tutti gli indici fin qui descritti, anche il γ di Goodman-Kruskal presenta un minimo pari a -1 nel caso in cui tutti i casi rilevati facciano osservare discordanze (perfetta contrograduazione), un massimo pari a $+1$ nel caso in cui tutti i casi rilevati facciano osservare concordanze (perfetta cograduazione), e logicamente il valore zero quando le concordanze e le discordanze sono in numero perfettamente uguale (mancanza di relazioni).

In pratica, il valore dell'indice γ può essere ottenuto tramite la formula

$$\gamma = \frac{\sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)}{\sum_{i=1}^{n-1} \sum_{j=i+1}^{n} |\text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)|}. \qquad [13]$$

Essa risulta senz'altro corretta dal punto di vista strutturale, facendo rilevare un minimo effettivo di -1 e un massimo di $+1$ anche in presenza di pareggi di rango o valore, dato che tali pareggi valgono zero sia nelle sommatorie poste a numeratore della frazione che in quelle a denominatore, mentre concordanze e discordanze, che a numeratore hanno segni differenti, a denominatore valgono ugualmente 1.

In pratica, se non vi sono parità di rango (o di valori) il denominatore vale $n(n-1)/2$, e quindi si ha l'equivalenza $\gamma = \tau_a$. In non pochi testi statistici viene

data per acquisita (erroneamente) anche l'equivalenza $\gamma = \tau_b$ ove vi sia parità di valori o di ranghi nell'una o nell'altra variabile: come è agevole verificare, invece, in tal caso risulta $\gamma \geq \tau_b$.

L'approssimazione per eccesso in questo secondo caso è legata al diverso peso che hanno, nel denominatore dei due indici, i casi in cui vi siano parità di valori o rango solo per una delle due variabili e non per l'altra, dato che esse azzerano l'intero termine di sommatoria $|\text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)|$ nello stesso modo dei casi in cui le parità di valori contigui si verifichino per entrambe le graduatorie, riducendo dunque, ciascuno, il denominatore medesimo di un intera unità; invece, la correzione del τ_b in caso di pareggi in un singola graduatoria risulta inferiore rispetto al caso di pareggi in entrambe: dunque si avrà $\gamma = \tau_b$ solo nel caso che valori uguali si presentino per entrambe le variabili *nelle medesime unità*.

In presenza di pareggi in unità differenti nelle due serie di dati questi casi, dunque, l'indice di Goodman-Kruskal tende a sovrastimare la forza dell'associazione tra le variabili, rispetto all'indice di Kendall.

Per ottenere una maggiore (seppur non perfetta) comparabilità con l'indice di Kendall, si può operare la seguente correzione:

$$\gamma' = \frac{2 \cdot \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)}{\frac{n \cdot (n-1)}{2} + \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} |\text{segno}(x_i - x_j) \cdot \text{segno}(y_i - y_j)|} = \frac{2 \cdot (C - D)}{\frac{n \cdot (n-1)}{2} + (C + D)} \quad [14]$$

In effetti, la formula [14] appare equivalente alla *media armonica* fra il τ_a di Kendall (formula [10] del paragrafo precedente) e l'indice γ , risultando esattamente pari al primo in assenza di pareggi e molto prossimo al τ_b quando, invece, si riscontrino valori uguali in una o entrambe le serie di dati (può quindi essere utilizzata in alternativa alla [11]); la differenza rispetto al τ_b diventa però abbastanza sensibile quando il numero di pareggi è molto elevato in rapporto al totale delle osservazioni.

Ciò implica che nella verifica delle ipotesi statistiche per piccoli campioni possono essere generalmente utilizzati i medesimi valori soglia dell'indice di Kendall, e, per numerosità sufficienti, anche gli adeguati test statistici per la verifica di ipotesi.

Invece, per grandi campioni (n>100), ove non solo è più difficoltoso effettuare il calcolo di K, ma è anche più probabile la presenza di numerosi pareggi di rango nell'una o nell'altra distribuzione di dati, e dunque la distorsione di γ' può essere apprezzabile, è opportuno utilizzare l'indice

originale[19], dato dalla [13], con la seguente standardizzazione:

$z = \frac{\gamma}{\sqrt{1-\gamma^2}}\sqrt{\frac{C+D}{n}}$, ovvero $z = \gamma \cdot \sqrt{\frac{(C+D)/n}{1-\gamma^2}}$,da cui si ricavano, con alcuni passaggi algebrici, i valori soglia:

$\gamma_\alpha = z_\alpha \cdot \sqrt{\frac{n}{z_\alpha^2 + n + C + D}}$. A scopo comparativo, in relazione al campione di alunni delle scuole primarie descritto nella Tab. 2 del Par. 5, dati non modificati e quindi con un numero di pareggi abbastanza ridotto (appena 3 su 12 casi, localizzati nella sola serie delle assenze), applicando ambo le formule [13] e [14], si ottengono γ=0,3968 e γ' = 0,3876, entrambi molto prossimi all'indice di Kendall τ_b = 0,3877: il primo, però, significativo in base ai valori soglia dell'indice stesso (Tab. 3), sia pur per una frazione di punto, il secondo no.

La successiva Tab. 5 ripropone invece il medesimo campione con alcune variazioni, all'unico scopo di *aumentare il numero di casi in parità in ambo le serie* (rispettivamente 10 su 12 in riferimento alle assenze, e ben 11 su 12 in riferimento alle ore di fruizione TV); i pareggi, utilizzati per il calcolo dell'indice τ_b di Kendall, sono riportati nelle ultime due colonne. Al centro, si notano le relative sommatorie dei casi di *concordanza* e di *discordanza* delle differenze tra i termini, da cui è immediato calcolare (tramite la [13] o la [12], indifferentemente come si vedrà in seguito): $\gamma = (39-8)/(39+8) =$ **0,66**.

Poiché τ_b = **0,5688** appare evidente che in tal caso la formulazione [12] non ottiene un risultato affidabile, come anche la [13]. Applicando la [14], invece, dal momento che $n\cdot(n-1)/2 = 12\cdot11/2 = 132/2 = 66$, si ricava immediatamente $\gamma' = 2\cdot(39-8)/(66+39+8) =$ **0,5487**, molto prossimo all'indice di Kendall, pur richiedendo molte meno informazioni dell'indice τ_b .

Tabella 5. *Assenze scolastiche registrate da un campione di 12 alunni delle scuole primarie e ore medie settimanali di fruizione di spettacoli TV da parte degli stessi.*

[19] Se si dispone di grandi volumi di dati e di insufficienti risorse computazionali (di natura *digitale* oppure *analogica* come carta e penna), il calcolo di γ' può essere molto arduo da effettuare, come anche quello di γ nella sua formulazione "pratica".

Come per l'indice di Spearman e quello di Kendall, invero, il numero di coppie di segni da confrontare e memorizzare in una tabella di comparazione (digitale o analogica) può diventare oneroso e persino improponibile; inoltre, come già affermato in precedenza, non sempre (o anche raramente) è metodologicamente adeguata la sostituzione di un qualsiasi indice non parametrico di correlazione con il coefficiente di correlazione lineare di Pearson, ben più parsimonioso in termini computazionali: *l'ipotesi di linearità della relazione è esiziale!*

	x	*y*	*C*	*D*	*Pareggi*	
Alunni	n. Assenze	Ore di fruizione TV	(concordanze)	(discordanze)	*x*	*y*
A	7	23	5	2	*3*	*2*
B	1	8	8	0	*2*	*1*
C	7	28	4	1	*3*	*3*
D	1	8	7	0	*2*	*1*
E	7	28	3	1	*3*	*3*
F	4	28	2	2	*2*	*3*
G	7	23	3	1	*3*	*2*
H	1	11	3	0	*2*	*1*
I	4	28	1	1	*2*	*3*
J	4	22	2	0	*2*	***0***
K	11	23	1	0	***0***	*2*
L	2	11	-	-	***0***	*1*
		Somme:	39	8	*12*	*11*

A titolo di informazione, la Tab. 6 mostra la tabella di contingenza relativa al campione di alunni dettagliato nella precedente Tab. 5.

Tabella 6. *Distribuzione di un campione di 12 alunni delle scuole primarie secondo il numero di assenze scolastiche ore medie settimanali di fruizione di spettacoli TV.*

Media settimanale	**Numero di assenze registrate**					
ore di fruizione TV	**1**	**2**	**4**	**7**	**11**	**Totale**
8	2					2
11	1	1				2
22			1			1
23				2	1	3
28			2	2		4
Totale	3	1	3	4	1	12

Vediamo ora il caso di distribuzioni ordinali con numerosità campionarie elevate.

La successiva Tab. 7 simula i risultati di un'indagine campionaria sul livello di alfabetizzazione funzionale, secondo i criteri previsti dalla classificazione dello statunitense *National Center for Education Statistics* (2014), nella lettura di testi e documenti[20].

[20] Benché 200 casi siano un carico computazionale considerevole ma non troppo gravoso in uno studio di correlazione non parametrica, la medesima analisi potrebbe essere effettuata sulla base non di un campione, ma di una popolazione di migliaia o milioni di unità: e, in tal caso, la complessità computazionale diventa rapidamente insostenibile.

È il caso, però, di fornire qualche informazione sull'argomento, ancorché irrilevante ai fini della trattazione statistica: nella definizione UNESCO (1984), l'analfabetismo funzionale è "la condizione di una persona incapace di comprendere, valutare, usare e farsi coinvolgere da testi scritti per intervenire attivamente nella società, per raggiungere i propri obiettivi e

Tabella 7. *Distribuzione di un campione di 200 soggetti >65 anni secondo il massimo titolo di studio conseguito e il loro livello di alfabetizzazione funzionale nella lettura di testi e documenti (classificazione* National Center for Education Statistics, *USA, 2014).*

	Livello di alfabetizzazione funzionale				
Titolo di studio	Inadeguato	Basilare	Sufficiente	Competente	Totale
Senza titolo	4	1	-	-	5
Licenza elementare	5	10	5	5	25
Licenza media	10	15	15	20	60
Maturità	5	15	25	30	75
Laurea	1	4	20	10	35
Totale	25	45	65	65	200

Facendo riferimento alla forma [12] dell'indice **γ** anziché alla [13], l'identificazione delle concordanze "C" e delle discordanze "D" appare abbastanza agevole secondo la definizione base del **τ** di Kendall:

- C: numero di coppie di unità la cui differenza di rango ha segno *concordante* nei due caratteri osservati (cioè se risulta $x_i - x_j > 0$ sarà anche $y_i - y_j > 0$, mentre se $x_i - x_j < 0$ si avrà anche $y_i - y_j < 0$);
- D: numero di coppie di unità la cui differenza di rango ha invece segno *discordante* (ossia, se abbiamo $x_i - x_j > 0$ sarà $y_i - y_j < 0$, mentre se $x_i - x_j < 0$ avremo $y_i - y_j > 0$).

Dato l'ordinamento *concordemente crescente* dei ranghi delle due variabili studiate, tali definizioni corrispondono alle seguenti:

- C = *somma delle coppie di dati, partendo dal valore in alto a sinistra della tabella*;

per sviluppare le proprie conoscenze e potenzialità". In pratica, un analfabeta funzionale sa generalmente leggere, scrivere ed esprimersi in modo sufficientemente corretto dal punto di vista formale, ma si distingue per almeno una delle seguenti caratteristiche, e la sua disfunzionalità è tanto più grave quante più insiemi di caratteristiche fa verificare:

- incapacità di comprendere in misura adeguata testi o materiali informativi pensati per essere compresi dalla persona comune (articoli di giornale, contratti legali, regolamenti, bollette, corrispondenza bancaria, orari di mezzi pubblici, cartine stradali, dizionari, enciclopedie, foglietti illustrativi di farmaci, istruzioni di apparecchiature);
- scarsa abilità nell'eseguire anche semplici calcoli matematici, ad esempio riguardanti la contabilità personale o il tasso di sconto su un bene in vendita;
- scarse competenze nell'utilizzo degli strumenti informatici (sistemi operativi, uso della rete, software di videoscrittura, fogli di calcolo, ecc.);
- conoscenza superficiale dei fenomeni scientifici, politici, storici, sociali ed economici, legata prevalentemente alle esperienze personali o a quelle dei propri amici; tendenza a generalizzare sulla base di singoli episodi non rappresentativi; largo uso di pregiudizi;
- scarso senso critico, tendenza a credere ciecamente alle informazioni ricevute, incapacità di distinguere le notizie false da quelle vere e di distinguere fonti attendibili e inattendibili.

- D = *somma delle coppie di dati, partendo dal valore in alto a destra*.

Per esempio, rispetto ai 4 soggetti *senza titolo di studio* e *inadeguati* in termini di alfabetizzazione funzionale, risultano avere rango maggiore per ambo le variabili tutti coloro che possiedono almeno la *licenza elementare* e un *basilare* livello di alfabetizzazione funzionale: dunque, essendo state rilevate **10+5+5+15+15+20+15+25+30+4+20+10=174 unità** appartenenti a tali celle, e posto che ognuno di questi presenta *concordanza* nella differenza di rango con tutti i 4 soggetti anzidetti, si rilevano ben 4×174=696 concordanze in questo primo passo. Occorre però effettuare i medesimi calcoli in riferimento a ciascuna delle celle (ad esclusione di quelle relative ai titolari di *Laurea* o con livello di alfabetizzazione "*Competente*", poiché non vi sono osservazioni con rango maggiore con cui confrontarle), e sommare tutte le concordanze così ricavate, ottenendo così il rispettabile valore **C = 6881**.

Per quanto riguarda invece le *discordanze*, partendo dalla cella in alto a destra (*senza titolo di studio* ma con livello *Competente* di alfabetizzazione) si ottiene un nulla di fatto in quanto non vi sono osservazioni, così come per la medesima riga al livello di alfabetizzazione *Sufficiente*. Rispetto all'unico soggetto senza titolo di studio ma con livello di alfabetizzazione basilare, vi sono quattro caselle in cui si ha discordanza nelle graduatorie (*inadeguata* alfabetizzazione funzionale, ma titoli di studio dalla licenza elementare alla laurea), e la somma delle unità rilevate in dette caselle è pari a **5+10+5-1=21**. Replicando l'operazione per ciascuna delle caselle chiave rimanenti (come prima, escludendo la prima colonna, minore della quale non vi sono categorie, e l'ultima riga, oltre cui non vi è nulla) si ottiene il numero totale di discordanze nelle differenze di rango: nel caso esemplificato, **D = 3736**.

La formulazione [12] fornirà dunque il risultato

$$\gamma = (6881\text{-}3736)/(6881+3736) = 0{,}296\ ,$$

superiore, pur se non in misura eccezionale, al valore soglia 0,224: per cui si può affermare che "la relazione tra istruzione formale e alfabetizzazione funzionale è statisticamente dimostrata", ma indubbiamente non con la forza che ci si sarebbe attesi e che sarebbe stata auspicabile per il buon "funzionamento" del collettivo sociale studiato, ossia con valori ben più distanti da zero.

$$\gamma' = \frac{2\cdot(C-D)}{\frac{n\cdot(n-1)}{2}+(C+D)} = 2\cdot(6881\text{-}3736)/[100*199+(6881+3736) = 0{,}206$$

Modalità della mutabile A	Modalità della mutabile B						Totale
	Modalità 1	Modalità 2	…	Modalità *j*	…	Modalità *c*	

Modalità 1	n_{11}	n_{21}	…	n_{j1}	…	n_{c1}	n_{01}
Modalità 2	n_{12}	n_{22}	…	n_{j2}	…	n_{c2}	n_{02}
…	…	…	…	…	…	…	…
Modalità *h*	n_{1h}	n_{2h}	…	n_{jh}	…	n_{ch}	n_{0h}
…	…	…	…	…	…	…	…
Modalità *r*	n_{1r}	n_{2r}	…	n_{jr}	…	n_{cr}	n_{0r}
Totale	n_{10}	n_{20}	…	n_{j0}	…	n_{c0}	n

In generale, facendo riferimento alla notazione del prospetto su riportato, il calcolo di concordanze e discordanze nella tabella cograduata è dato dalle seguenti sommatorie (apparentemente complicate, ma in realtà banali):

$$C = \sum_{j=1}^{c-1} \sum_{h=1}^{r-1} \left[n_{jh} \sum_{i=j+1}^{c} \sum_{k=h+1}^{r} n_{ik} \right] \quad \text{e} \quad D = \sum_{j=2}^{c} \sum_{h=1}^{r-1} \left[n_{jh} \sum_{i=1}^{j} \sum_{k=h+1}^{r} n_{ik} \right] .$$

9. L'indice di cograduazione di Gini

Concettualmente diverso dalle misure non parametriche di correlazione precedentemente descritte, è l'*indice di cograduazione di Gini* (1914), molto ben considerato in Italia ma poco noto all'estero:

$$G = \frac{\sum_{i=1}^{n} \left| r_i - s_i' \right| - \sum_{i=1}^{n} \left| r_i - s_i \right|}{K} , \qquad [15]$$

ove:

- r_i e s_i mantengono il già visto significato di *ranghi nelle due graduatorie non decrescenti* delle variabili X e Y,
- s_i' rappresenta il rango assunto dall'i-esima unità statistica nella *graduatoria non crescente* di Y (dunque *invertita* rispetto alla precedente),
- K rappresenta il massimo valore che può essere assunto dal numeratore del rapporto, e vale $(n^2-1)/2$ quando n è un numero dispari, $(n^2/2)$ quando n è pari: in pratica, si pone K=INTERO[$(n^2-1)/2$], ove "INTERO" è la funzione aritmetica che arrotonda un numero all'intero immediatamente inferiore.

Detto indice è positivo in caso di concordanza delle due variabili, valendo 1 in caso di perfetta concordanza, mentre in caso di discordanza esso è negativo, valendo -1 se la discordanza è a sua volta "perfetta" (ossia se ai ranghi $1, 2, \ldots, n$ delle determinazioni di X corrispondono ranghi $n, n-1, \ldots, 1$ delle determinazioni di Y).

Il calcolo del numeratore della [15] in caso di perfetta concordanza (e

ugualmente della quantità posta a denominatore dell'indice) è immediato se si tiene conto che in tal caso la seconda sommatoria a numeratore è nulla (infatti per ogni i, $r_i = s_i$), mentre nella prima sommatoria r_i e s'_i sono perfettamente contrograduati, ossia ai ranghi $r_1 = 1$, $r_2 = 2$, …, $r_i = i$ sono associati i ranghi $s'_1 = n$, $s'_2 = n-1$, ..., $s'_i = n-i+1$: ragion per cui si ha

$$\sum |\mathbf{r_i - s_i}| = \sum |\mathbf{i - (n-i+1)}| = \sum |\mathbf{(n-i+1) - i}| = \sum |\mathbf{n-2i+1}| \,\mathbf{.}$$

In caso di massima discordanza di r_i e s_i, invece, è la prima sommatoria a essere nulla (essendo sempre $r_i = s'_i$), mentre la seconda fornisce esattamente il medesimo risultato su descritto; in tal caso, però, il denominatore ha logicamente segno negativo.

È immediato constatare (ad es., sviluppando per $n = 2, 3, 4, 5$) che la quantità $\sum |n-2i+1|$ è data in pratica dalla doppia somma di tutti gli $n/2$ numeri dispari da 1 a $(n-1)$ se n è pari, e la somma di tutti gli $(n-1)/2$ numeri pari da 2 a $(n-1)$ se n è dispari.

Utilizzando la formula di Gauss per il calcolo della somma di una progressione aritmetica $a_1, a_2, \ldots, a_k$, ossia $k \cdot (a_1 + a_k)/2$, si ottiene dunque:

$$2 \cdot \left[\frac{n}{2} \cdot \frac{1 + (n-1)}{2} \right] = n \cdot \frac{1 + n - 1}{2} = \frac{n^2}{2} \qquad \text{per } n \text{ pari,}$$

$$2 \cdot \left[\frac{(n-1)}{2} \cdot \frac{2 + (n-1)}{2} \right] = (n-1) \cdot \frac{2 + n - 1}{2} = \frac{(n-1) \cdot (n+1)}{2} = \frac{(n^2 - 1)}{2} \quad \text{altrimenti.}$$

Va notato ancora che, mentre il valore che indica indipendenza statistica (lo zero) e i valori estremi dell'indice di Gini corrispondono a quelli degli altri indici di correlazione descritti (parametrici e non parametrici), come del resto è logico, i valori intermedi sono distribuiti in modo differente, pur se meno del τ di Kendall.

In caso di parità di rango, inoltre, il denominatore descritto nella [15] fornisce risultati distorti per difetto. Una forma *sempre corretta* dell'indice di Gini (dovuta ancora ad Amato 1970, 1977) è invece:

$$G' = \frac{\sum |r_i - s'_i| - \sum |r_i - s_i|}{\sum |r_i - s'_i| + \sum |r_i - s_i|} \,. \qquad [16]$$

Per quanto riguarda la verifica inferenziale dell'indice, non è nota la distribuzione statistica esatta della v.c. di cui l'indice G è determinazione, pur se nel corso degli anni, proseguendo l'evoluzione delle tecniche computazionali alcuni Autori (Cucconi 1964, Girone 1971, Otten 1973, Girone *et al.* 2010) hanno potuto calcolarne una porzione sufficiente alla maggior parte degli

scopi, fino a numerosità campionarie di 24 unità (Tab. 5).

Tabella 5. *Valori soglia g_α dell'indice di Gini a una coda*.

	$\alpha \geq P(G \geq G_\alpha)$					
n	0,005	0,01	0,02	*0,025**	0,04	0,05
6	1	1	0,889	*0,889*	0,889	0,778
7	0,917	0,917	0,833	*0,812*	0,750	0,750
8	0,875	0,813	0,750	*0,735*	0,688	0,688
9	0,800	0,750	0,700	*0,688*	0,650	0,600
10	0,760	0,720	0,640	*0,630*	0,600	0,560
11	0,700	0,667	0,600	*0,592*	0,567	0,533
12	0,667	0,639	0,583	*0,569*	0,528	0,500
13	0,643	0,595	0,548	*0,536*	0,500	0,476
14	0,612	0,571	0,531	*0,516*	0,469	0,449
15	0,607	0,554	0,518	*0,505*	0,464	0,446
16	0,578	0,531	0,484	*0,473*	0,438	0,422
17	0,569	0,528	0,486	*0,472*	0,431	0,417
18	0,543	0,506	0,457	*0,445*	0,407	0,395
19	0,533	0,489	0,444	*0,433*	0,400	0,389
20	0,510	0,480	0,440	*0,428*	0,390	0,370
21	0,509	0,473	0,427	*0,416*	0,382	0,364
22	0,496	0,455	0,413	*0,403*	0,372	0,355
23	0,485	0,447	0,409	*0,398*	0,364	0,349
24	0,472	0,438	0,396	*0,386*	0,354	0,340

Fonte: Girone et al.*, 2010.*

** I valori soglia per α=0,025 sono stimati come media non centrata dei valori contigui.*

Per numerosità campionarie da 25 unità in su, poi, l'indice di Gini presenta una distribuzione campionaria rapidamente prossima a una curva normale (cfr., per es., Amato 1954) con media nulla e varianza pari a

$$\hat{\sigma}_G^2 = \frac{2}{3 \cdot (n-1)} \cdot \frac{n^2+2}{n^2} \qquad \text{per } n \text{ pari,}$$

$$\hat{\sigma}_G^2 = \frac{2}{3 \cdot (n-1)} \cdot \frac{n^2+3}{n^2-1} \qquad \text{per } n \text{ dispari,}$$

per cui la standardizzazione $z = G/\hat{\sigma}_G$ consente di identificare i rispettivi valori soglia a un prefissato livello di significatività α, ossia $G_\alpha = z_\alpha \cdot \hat{\sigma}_G$.

Se n≤50, logicamente, valori soglia più precisi possono essere identificati tramite approssimazione alla distribuzione di Student:

$$t = G \frac{(n-2)(1-G^2)}{n-1 \cdot \hat{\sigma}_G}, \qquad \text{da cui} \qquad G_\alpha = t_{g,\alpha} \frac{(n-1)\hat{\sigma}_G}{(n-2)(1-G^2)}.$$

10. Concordanza tra variabili nominali

Oltre a quelli fin qui descritti (concordanza tra due variabili cardinali oppure ordinali), esiste un altro tipo di relazione statistica di grande interesse: la relazione tra modalità di due variabili nominali (dette anche "mutabili"), non necessariamente ordinabili[21]. Questo aspetto viene identificato, a seconda dei casi, con l'*associazione*, con l'*uguaglianza/disuguaglianza* delle variabili oppure con la loro *somiglianza/dissomiglianza*. Talora, questi indici possono essere utilizzati anche per valutare in qualche modo la *concordanza/discordanza* tra modalità di due variabili (o, specularmente, di una stessa variabile stimata in due popolazioni).

Va tuttavia premesso che il concetto di associazione statistica tra variabili misurate su scala nominale non coincide con quello di concordanza o discordanza (concetti peraltro difficili da definire in dette variabili), se non, appunto, in casi particolari.

Un caso particolare è, in effetti, quello delle tabelle 2×2 (2 righe × 2 colonne), descriventi cioè due caratteri dicotomici, come ad esempio le risposte fornite o gli esiti rilevati in due gruppi di unità (popolazioni o campioni che siano) per una stessa domanda o test con due modalità:

Modalità di risposta	Gruppi A	Gruppi B
1	100	100
2	0	0
Totale	100	100

Modalità di risposta	Gruppi A	Gruppi B
1	70	70
2	30	30
Totale	100	100

Modalità di risposta	Gruppi A	Gruppi B
1	100	0
2	0	100
Totale	100	100

Invero, i tre prospetti su riportati evidenziano, i primi, una chiara associazione tra i gruppi, espressa come *concordanza* delle risposte fornite (pur se nel primo prospetto la dicotomia è netta, non essendo fornita da alcuno la seconda modalità di risposta, e nel secondo un po' più sfumata), il terzo una

[21] Ove dette variabili siano entrambe *ordinabili*, risulta in genere più proficuo fare ricorso agli indici di correlazione non parametrica fin qui descritti; tuttavia, possono trarsi informazioni interessanti anche dalle tecniche di analisi descritte in questo paragrafo. Peraltro, va anche approfondita la differenza concettuale tra variabili *ordinali* e *ordinabili*: le prime sono variabili nativamente contraddistinte da una gerarchia (per es., gli anni di nascita, l'ordine in una classifica, o la gerarchia dei gradi militari, ma anche voti e punteggi, benché spesso trattati come espressioni discrete di variabili continue, possono rientrare tra le variabili ordinali), mentre le altre sono mutabili le cui modalità possono essere ordinate secondo criteri logici, anche se talora con un certo livello di arbitrarietà: per esempio, i giorni della settimana. Per maggiori approfondimenti su queste tematiche, cfr., per es., Agresti (2010), Delvecchio (2024).

"associazione" espressa però come *discordanza* delle risposte tra un gruppo di soggetti e l'altro. Anche nel caso di discordanza, logicamente, potremmo rilevare, una situazione più ambigua, se alcuni soggetti del gruppo A avessero fornito la risposta "2" e alcuni soggetti del gruppo B la risposta "1".

In modo analogo, si può valutare la concordanza/discordanza di risposte fornite da un *medesimo gruppo* di 100 soggetti a due domande diverse ma entrambe dicotomiche con le medesime modalità (per es., "Sì"/"No", "D'accordo"/"In disaccordo", "Rosso"/"Nero"), oppure a due test diagnostici con risultato binario ("Nella norma"/"Non nella norma"):

Modalità di risposta	Domande A	B
1	100	100
2	0	0
Totale	100	100

Modalità di risposta	Domande A	B
1	50	50
2	50	50
Totale	100	100

Modalità di risposta	Domande A	B
1	100	0
2	0	100
Totale	100	100

In questo caso, notiamo che il prospetto centrale definisce una situazione ambigua, poiché, se è vero che alla domanda B si osserva lo stesso numero (e quota) di risposte "1" fornite dai soggetti alla domanda A (e lo stesso numero di risposte "2"), nulla è noto sulla eventuale concordanza di tali risposte: ossia cosa abbiano risposto alla domanda B coloro che avevano fornito una risposta o l'altra alla domanda A. La stessa cosa si può dire, pur se con minore incertezza, per tutte le situazioni intermedie.

Una informazione più precisa si otterrebbe costruendo, sulla base dei dati osservati, le relative tabelle di cograduazione (in questo caso denominate "tabelle tetracoriche"), che nel primo e terzo caso darebbero i seguenti risultati, un po' banali (e statisticamente poco rilevanti):

a.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	100	0	100
2	0	0	0
Totale	100	0	100

b.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	0	100	100
2	0	0	0
Totale	0	100	100

Invece, il caso descritto nel prospetto centrale è molto più complesso, in quanto si può verificare, innanzitutto, che chi risponde "1" o "" alla domanda A risponda nell'identico modo alla domanda B, configurando così una perfetta *concordanza* (prospetto *c.*); ma potrebbe anche essere che chi risponde "1" alla domanda A risponda "2" alla domanda B, e viceversa, evidenziando in tal modo una totale *discordanza* (prospetto *d.*):

c.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	50	0	50
2	0	50	50
Totale	50	50	100

d.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	0	50	50
2	50	0	50
Totale	50	50	100

L'associazione tra le risposte fornite è molto meno evidente nei successivi prospetti, anzi, del tutto inesistente nell´ultimo, ove la perfetta equidistribuzione delle modalità impedisce di ipotizzare qualsiasi relazione (per cui, in tal caso, si intende verificata l'indipendenza delle due distribuzioni):

e.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	30	20	50
2	20	30	50
Totale	50	50	100

f.

Risposta dom. A	Risposta dom. B 1	2	Totale
1	25	25	50
2	25	25	50
Totale	50	50	100

In tutti i prospetti qui descritti la distribuzione marginale (ossia i totali dei casi rilevati nelle due modalità di risposta sia per la prima che nella seconda domanda) rimane identica, nonostante che i risultati incrociati siano diversi o del tutto opposti.

Si evidenzia qui una proprietà fondamentale delle distribuzioni doppie di variabili dicotomiche: *se si mantengono costanti le distribuzioni marginali (ossia i totali di riga e di colonna) basta fissare una sola frequenza in una qualunque cella affinché le altre tre siano determinate in modo univoco*. In altri termini, queste tabelle di contingenza hanno un solo *grado di libertà*.

Ma se in casi come quelli descritti è possibile rilevare empiricamente una concordanza o discordanza tra variabili dicotomiche, quando essa non risulta evidente si ravvisa la grande utilità di una statistica in grado di sintetizzare questa informazione così come possono fare i coefficienti di regressione o gli indici di cograduazione nel caso di variabili quantitative oppure ordinali.

Per proseguire, innanzitutto generalizziamo le precedenti tabelle di contingenza, esprimendole formalmente espresse come

h.

Risposta domanda A	Risposta domanda B Modalità 1	Modalità 2	Totale
Modalità 1	n_{11}	n_{21}	$n_{01}=n_{11}+n_{21}$
Modalità 2	n_{12}	n_{22}	$n_{02}=n_{12}+n_{22}$
Totale	$n_{10}=n_{11}+n_{12}$	$n_{20}=n_{21}+n_{22}$	$n=n_{01}+n_{02}=n_{10}+n_{20}$

Proseguendo nella formalizzazione, definiamo in modo simile una generica tabella di contingenza di r righe e c colonne:

g.

Risposta domanda A	Risposta domanda B: Modalità 1	…	Modalità *c*	Totale
Modalità 1	n_{11}	…	n_{c1}	$n_{01}=n_{11}+\ldots+n_{c1}$
…	…	…	…	…
Modalità *h*	n_{1h}	…	n_{ch}	$n_{0h}=n_{1h}+\ldots+n_{ch}$
…	…	…	…	…
Modalità *r*	n_{1r}	…	n_{cr}	$n_{0r}=n_{1r}+\ldots+n_{cr}$
Totale	$n_{10}=n_{11}+\ldots+n_{1r}$	…	$n_{c0}=n_{21}+\ldots+n_{2r}$	$n=n_{01}+\ldots+n_{0r}=n_{10}+\ldots+n_{c0}$

Tenendo presente i prospetti precedenti (in particolare il prospetto *f.*), si evince che fra i caratteri (o variabili categoriali) di una tabella a doppia entrata vi è *indipendenza* (o associazione nulla) quando, al variare delle modalità della prima, ogni modalità della seconda ha la medesima frequenza relativa in tutte le sue distribuzioni parziali e in quella marginale.

In altri termini, per tutte le caselle della *h.esima* riga della tabella di contingenza qui definita, $n_{1h}/n_{10} = \ldots = n_{ih}/n_{i0} = \ldots = n_{0h}/n$; allo stesso modo, per tutte le caselle della *i.esima* colonna, $n_{i1}/n_{01} = \ldots = n_{ih}/n_{0h} = \ldots = n_{i0}/n$.

Ciò implica che, affinché vi sia indipendenza, deve aversi

$$n_{ih} = \frac{n_{i0}\, n_{0h}}{n} \qquad \text{per qualsiasi } i\,,\, h. \qquad [17]$$

Se la condizione [17] non è verificata, si può affermare che ***non esiste*** indipendenza tra le due variabili.

11. L'indice *V* di Cramér e il coefficiente di contingenza

Gli indici di associazione sono in genere ottenuti da tabelle di contingenza misurate con varianti delle statistiche χ^2 di Pizzetti-Pearson e di "massima verosimiglianza" G^2; tali statistiche presentano valori nulli in caso di assenza di associazione e valori maggiori di zero ove tra le due variabili vi sia associazione, ma sono privi di un limite superiore *assoluto*, ossia indipendente dai dati rilevati.

Invero, il primo indice, che rappresenta essenzialmente il valore empirico della distribuzione χ^2 relativa ai dati osservati, può essere calcolato (per semplificare le successive discussioni, senza applicare la *correzione di Yates per la continuità*; cfr. Yates, 1934) come:

$$\chi^2 = \sum_{i=1}^{c}\sum_{h=1}^{r} \frac{(n_{ih} - n^*_{ih})^2}{n^*_{ih}}\,, \qquad [18]$$

ove n^*_{ih}, nella notazione usuale, rappresenta il valore teorico di ogni casella sotto l'ipotesi di indipendenza delle distribuzioni, dato dalla [17]:

$$n^{*}_{ih} = \frac{n_{i0}n_{0h}}{n} \quad .$$

Il valore empirico[22] del χ^2, nella condizione di massima associazione tra le due distribuzioni nella medesima tabella di contingenza (ossia con gli stessi totali marginali), assume un massimo dipendente dai dati rilevati, come si evince facilmente dal procedimento matematico esposto di seguito.

Posto che, logicamente, n_{ih} non può essere maggiore di n_{i0}, si evince subito (moltiplicando ambo i termini per n_{ih}) che $n^2_{ih} \le n_{ih}\, n_{i0}$, e quindi:

$$\chi^2 \le n\left(\sum_{h=1}^{r}\sum_{i=1}^{c}\frac{n_{ih}\cdot n_{i0}}{n_{0h}\cdot n_{i0}} - 1\right) = n\left(\sum_{h=1}^{r}\frac{1}{n_{0h}}\sum_{i=1}^{c} n_{ih} - 1\right) = n\left(\sum_{h=1}^{r}\frac{n_{0h}}{n_{0h}} - 1\right) = n(r-1)\,.$$

Analogamente, da $n_{ih} \le n_{0h}$ e $n^2_{ih} \le n_{ih}\, n_{0h}$ si evince che $\chi^2 \le n(c-1)$.

In altri termini, la statistica χ^2 non può superare il prodotto tra il totale n e il minore dei due valori forniti dal numero delle colonne e da quello delle righe della tabella di contingenza, diminuiti di 1.

Gli indici di associazione più utilizzati cercano di fissarne, dunque, il limite superiore: un caso fra tutti, molto noto e valido per coppie di variabili con qualsiasi numero di categorie da 2 in su (entro i limiti degli strumenti computazionali utilizzati), è l'*indice V* di Cramér (1946), ottenuto dividendo il valore empirico della statistica χ^2 per il suo massimo; per cui:

$$V = \frac{n\left(\sum_{i=1}^{c}\sum_{h=1}^{r}\frac{n^2_{ih}}{n_{i0}n_{0h}} - 1\right)}{n\cdot min\{c-1,\quad r-1\}} = \frac{\sum_{i=1}^{c}\sum_{h=1}^{r}\frac{n^2_{ih}}{n_{i0}n_{0h}} - 1}{min\{c-1,\, r-1\}} = \frac{\sum_{i=1}^{c}\sum_{h=1}^{r}\frac{n^2_{ih}}{n_{i0}n_{0h}} - 1}{min\{c,\, r\} - 1}\,. \qquad [18]$$

---

[22] Il valore empirico può essere anche calcolato come $\chi^2 = n\cdot\left(\sum_{i=1}^{c}\sum_{h=1}^{r}\frac{n^2_{ih}}{n_{i0}n_{0h}} - 1\right)$. Infatti, tenendo presente che il totale delle numerosità è dato da $n = \sum\sum n_{ih} = \sum\sum n^{*}_{ih}$, si ha:

$$\sum\sum\frac{(n_{ih}-n^{*}_{ih})^2}{n^{*}_{ih}} = \sum\sum\frac{(n_{ih}-n_{i0}n_{0h}/n)^2}{n_{i0}n_{0h}/n} = \sum\sum\frac{n^2_{ih} - 2n_{ih}(n_{i0}n_{0h}/n) + (n_{i0}n_{0h}/n)^2}{n_{i0}n_{0h}/n} =$$

$$= \sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}/n} - \sum\sum\frac{2n_{ih}(n_{i0}n_{0h}/n)}{n_{i0}n_{0h}/n} + \sum\sum\frac{(n_{i0}n_{0h}/n)^2}{n_{i0}n_{0h}/n} =$$

$$= n\cdot\sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}} - \sum\sum 2n_{ih} + \sum\sum n_{i0}n_{0h}/n = n\cdot\sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}} - 2n + \sum\sum n^{*}_{ih} =$$

$$= n\cdot\sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}} - 2n + n = n\cdot\sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}} - n = n\left(\sum\sum\frac{n^2_{ih}}{n_{i0}n_{0h}} - 1\right) \quad .$$

L'indice V assume, chiaramente, il valore **0** in caso di *perfetta indipendenza* e il valore **1** in caso di *associazione massima* tra le due distribuzioni osservate, ed è utilizzabile per variabili categoriali con qualsiasi numero di modalità.

È quasi immediata la verifica statistica della sua significatività facendo riferimento al χ^2, da cui deriva a meno della costante $(min\{c,r\}-1)$, con $g = (c-1)(r-1)$ gradi di libertà.

Tuttavia, esso non distingue tra relazioni di concordanza o discordanza: tutte le distribuzioni mostrate nei precedenti prospetti *a.*, *b.*, *c.*, *d.* producono infatti il medesimo indice *V*, massimo e dunque pari a 1, come del resto è logico considerando che la statistica utilizzata è sempre *non negativa*.

Identico problema fa rilevare il *coefficiente di contingenza*, dato da

$$C = \sqrt{\frac{\chi^2}{n+\chi^2} \Big/ k} \quad , \qquad [19]$$

ove k è una costante di correzione necessaria in quanto il massimo valore del rapporto tra χ^2 e $(n+\chi^2)$ è sempre minore di 1 e, come quello del χ^2 empirico, dipende dalla struttura della tabella di contingenza: di conseguenza, non può essere utilizzato per comparare tabelle con diverso numero di righe o colonne[23]. In caso di tabelle quadrate, k vale $(r-1)/r$, o, equivalentemente, $(c-1)/c$; in caso contrario, essa è data dalla media geometrica delle due quantità: $\sqrt{(r-1)/r \cdot (c-1)/c}$.

12. Il coefficiente di correlazione tetracorica

Talora, però, si ha il caso di due variabili generalmente misurate almeno su scala di intervalli e con distribuzione normale bivariata, che per motivi di studio o di rilevazione siano state dicotomizzate, per es., sopra e sotto la mediana: in tal caso, le variabili studiate A e B (dicotomiche) sono realizzazioni di una coppia di variabili latenti X e Y, continue con distribuzione normale standardizzata, che possono risultare correlate tra loro.

In tal caso, le tabelle di contingenza (2×2) relative alle variabili A e B

[23] Invero, per una tabella tetracorica Max(C)=0,707, mentre per una tabella 4×4 si ha Max(C)=0,870; il valore massimo di C, come è evidente, tende rapidamente ad avvicinarsi a 1 al crescere della complessità della tabella, ma non raggiunge mai tale limite ottimale. Alcuni studiosi, proprio per tale motivo, sconsigliano l'utilizzo di tale indice per tabelle di dimensione inferiore a 5×5.

descrivono semplici rappresentazioni delle variabili originali, e per determinare la correlazione (lineare) di dette variabili andrebbe utilizzato il *coefficiente di correlazione tetracorica* r_{tet} (Pearson, 1900), che in tali casi è strutturalmente (e talora numericamente) equivalente al coefficiente di correlazione lineare e ne viene considerato una adeguata approssimazione (Guilford, 1956). In altri casi, l'uso di tale coefficiente è senz'altro inappropriato (e persino illogico per vari motivi, a partire dalla sua complessità).

La descrizione più semplice della struttura formale del coefficiente r_{tet} (Ekström, 2011; Noyan and Gölbaşi Şimşek, 2012) parte dalla distribuzione tetracorica delle variabili X e Y, la cui manifestazione empirica è espressa dalla tabella di contingenza *h.*; ponendo P_A e P_B le probabilità marginali relative a n_{01}/n e n_{10}/n rispettivamente, si effettuino le trasformazioni in v.c. normali standardizzate[24] $z_A = F^{-1}(1-p_A)$ e $z_B = F^{-1}(1-p_B)$.

Con queste premesse, il coefficiente di correlazione tetracorica è quella quantità r_{tet} che soddisfa l'equazione

$$\frac{n_{11}}{n} = \int_{z_A}^{\infty}\int_{z_B}^{\infty} F_2(x_1, x_2, r_{tet})\,dx_1 dx_2 ,$$

ove $F_2(x_1,x_2,r_{tet})$ è la f.d.p. normale bivariata

$$F_2(x_1, x_2, r_{tet}) = \frac{1}{2\pi\sqrt{1-r_{tet}^2}} \exp\left[\frac{1}{2(1-r_{tet}^2)}(x_1^2 - 2r_{tet}x_1x_2, x_2^2)\right] .$$

Le linee $x_1 = z_A$ e $x_2 = z_B$ dividono questa normale bivariata in quattro quadranti le cui probabilità corrispondono alle frequenze relative nella tabella di contingenza 2×2.

Pearson considerava il coefficiente di correlazione tetracorica uno dei più importanti contributi da lui forniti alla teoria della statistica, affiancando il sistema organico di curve continue che da lui prende nome, il test del chi quadro e ai suoi contributi alle statistiche per piccoli campioni (Camp, 1933). Tuttavia, le considerevoli e riconosciute difficoltà di calcolo[25] hanno grandemente nuociuto alla popolarità di detto coefficiente.

---

[24] Ad ogni v.c. continua X può essere fatta corrispondere v.c. normale standardizzata tramite la trasformazione:

$$Z_X = F^{-1}[F_X(X)],$$

ove F^{-1} è la funzione inversa di ripartizione della v.c. normale standardizzata e F_X è la funzione di ripartizione della v.c. X.

[25] Per non parlare di vari problemi computazionali legati agli "zeri campionari", ancor non del tutto risolti nonostante i numerosi algoritmi di calcolo sviluppati nel corso degli anni.

Nell'articolo del 1900 è esaustivamente descritto da Pearson il procedimento con cui pervenire, tramite una serie di potenze di r_{tet}, alla stima approssimata di r_{tet} (essendo irrilevante ottenerne il valore esatto, posto che le variazioni del coefficiente diventano inavvertibili per potenze con esponente elevato), ma esso è decisamente complicato da calcolare.

Pearson stesso, nel medesimo articolo, propose quattro diverse semplificazioni di calcolo, con approssimazioni di minore affidabilità, e altre ancora vennero proposte da vari studiosi in seguito (molto più recentemente: Walker e Lev, 1953; Edwards, 1957; Lord e Novick, 1968; Digby, 1983; Becker e Clogg, 1988; Bonett and Price, 2005).

L'approssimazione utilizzata più frequentemente, anche perché abbastanza affidabile e semplice da risolvere, è

$$r_t = \cos\left[\pi \frac{\sqrt{n_{11}n_{22}}}{\sqrt{n_{11}n_{22}} + \sqrt{n_{12}n_{21}}}\right] \quad , \qquad [20]$$

più nota sotto la forma semplificata[26]

$$r_t = \cos\left[\frac{\pi}{1+\sqrt{(n_{12}n_{21})/(n_{11}n_{22})}}\right] \quad . \qquad [21]$$

La significatività statistica del coefficiente di correlazione tetracorica può essere agevolmente verificata tramite la standardizzazione $z = r_t/s_{r_t}$, con lo scarto standardizzato dato da

$$s_{r_t} = \frac{\sqrt{n_{10}/n \cdot n_{20}/n \cdot n_{01}/n \cdot n_{02}/n}}{h_X h_Y \sqrt{n}} \quad ,$$

ove h_X e h_Y rappresentano le ordinate dei punti identificati dalle proporzioni delle modalità di X e Y sulla distribuzione normale standardizzata.

Per chiarire il procedimento, si immagini di voler verificare la correlazione tra i redditi di coppie di coniugi entrambi occupati, ma registrati (per motivi di privacy) in termini di posizione entro e sopra la soglia di 1.500 € mensili. Il prospetto seguente riporta le numerosità n_{ij} e le proporzioni marginali delle due variabili dicotomizzate.

[26] Il ricorso alla quale, logicamente, sarebbe da evitare quando siano presenti "zeri campionari" anche solo in una casella della diagonale principale $n_{11}n_{22}$. Tuttavia, tale evento di per sé sarebbe un motivo per considerare errata la dicotomizzazione effettuata, oppure inverosimile la distribuzione normale di una o entrambe le variabili latenti a cui questa è riferita.

Reddito mogli	Reddito mariti ≤ 1.500 €	Reddito mariti > 1.500 €	Totale		Reddito mariti ≤ 1.500 €	Reddito mariti > 1.500 €	$p_j(y)$
≤ 1.500 €	100	230	330				0,31
> 1.500 €	90	630	720				0,69
Totale	190	860	1.050	$p_i(x)$	0,18	0,82	1,00

I dati della tabella di contingenza forniscono la stima del coefficiente

$$r_t = \cos\left[\frac{180°}{1+\sqrt{\frac{(100\cdot 630)}{(90\cdot 230)}}}\right] = \cos\left[\frac{180°}{1+\sqrt{6300/2070}}\right] = \cos(65,58°) = -0,925,$$

mentre per valutarne la significatività occorre fare riferimento alle proporzioni marginali

$$s_{r_t} = \frac{\sqrt{0,18\cdot 0,82\cdot 0,31\cdot 0,69}}{0,2613\cdot 0,3521\cdot\sqrt{105}} = \frac{0,1777}{0,9428} = 0,1885.$$

Essendo $z = r_t/s_{r_t} = -4,909$ (valore ben maggiore, in valore assoluto, del valore soglia z_α=2,326 per una significatività α=0,01), si respinge l'ipotesi che l'elevato valore del coefficiente valutato sia dovuto al caso.

13. L'indice φ di Pearson (indice di correlazione tetracorica)

Nel caso di tabelle di contingenza 2×2 in cui le variabili esaminate siano entrambe dicotomiche native (e non il risultato di una classificazione di variabili continue), è consigliabile utilizzare indici specifici per tale livello di misurazione: ad esempio, l'indice φ (ossia "phi"), detto anche *indice di correlazione tetracorica* (da non confondere con il precedente coefficiente) o *mean square contingency coefficient*, proposto anch'esso da Pearson fin dai tempi dell'elaborazione del test χ^2, seppure non sia stato mai stato oggetto di un suo scritto specifico ma solo di annotazioni e cenni (Pearson, 1900; Cramér, 1946, p. 282).

La sua formulazione ha qualche analogia con quella degli indici di cograduazione, in quanto cerca di valutare la differenza tra concordanze e discordanze di due variabili non quantitative, a patto che fra esse sia riconoscibile una qualsiasi relazione d'ordine (anche qualora non siano realmente misurate

su scala ordinale)[27]. Facendo riferimento alla tabella di contingenza *h.* descritta al par. 10, le concordanze (quando entrambe le variabili fanno rilevare la prima modalità o entrambe la seconda) sono identificate dalla diagonale principale della tabella (caselle n_{11} e n_{22}), mentre le discordanze sono quelle poste sulla diagonale secondaria (caselle n_{21} e n_{12}).

h.

Risposta domanda A	Risposta domanda B Modalità 1	Modalità 2	Totale
Modalità 1	n_{11}	n_{21}	$n_{01}=n_{11}+n_{21}$
Modalità 2	n_{12}	n_{22}	$n_{02}=n_{12}+n_{22}$
Totale	$n_{10}=n_{11}+n_{12}$	$n_{20}=n_{21}+n_{22}$	$n=n_{01}+n_{02}=n_{10}+n_{20}$

Vi sono vari modi per valutare congiuntamente il peso di concordanze e discordanze; nel caso delle tabelle tetracoriche, l'indice φ viene calcolato (utilizzando la notazione della tabella *h.*) mediante la seguente formula:

$$\varphi = \frac{n_{11}n_{22} - n_{21}n_{12}}{\sqrt[2]{n_{10} \cdot n_{20} \cdot n_{01} \cdot n_{02}}},$$

la quale, in virtù dell'unico grado di libertà delle tabelle di contingenza, è del tutto equivalente alla seguente (espressa semplicemente tramite la numerosità della prima casella e le frequenze marginali n_{10}, n_{01}, n):

$$\varphi = \frac{n \cdot n_{11} - n_{10}n_{01}}{\sqrt[2]{n_{10}n_{01}(n - n_{10})(n - n_{01})}}, \qquad [22]$$

Dalla prima formulazione si evince immediatamente che:

[27] Coppie di variabili qualitative dicotomiche con modalità "No"/"Sì", "Bianco"/"Nero", "Vuoto"/"Pieno", "Non fumatore"/"Fumatore", "Sano"/"Malato", "In disaccordo"/"D'accordo", ecc. si possono generalmente considerare legate fra loro da relazioni d'ordine, essendo appunto *ordinabili*, in quanto una modalità presuppone la *mancanza* di una qualità e l'altra la sua presenza (anche se l'ultima dicotomia citata ammette interpretazioni soggettive che possono configurare una "mancanza non totale" o una "presenza non piena"). Anzi, esse possono essere spesso definite come gli estremi opposti di variabili espresse su scala ordinale, ed è usuale attribuire loro i valori binari 0/1, tramite i quali calcolare statistiche consuete nella statistica quantitativa, come la varianza.

Definire la relazione d'ordine fra variabili con modalità quali "Liscio"/"Ruvido", "Salato"/"Piccante", "Italia"/"Cina", "Operaio/"Bracciante", invece, risulta generalmente arbitrario, salvo, in senso lato, nel caso di *coppie di variabili diverse con le medesime modalità* (ad esempio, sapore salato/piccante di una pietanza rispetto a un'altra: in questa nota, peraltro, li esempi sono limitato a coppie di modalità, ma possono aversi anche terne o modalità più numerose); in tal caso, infatti, l'ordine, anche casuale, con cui si elencano le modalità della prima variabile definisce strettamente l'ordine della seconda.

- $\varphi = -1$ se e solo se il prodotto dei termini della diagonale principale è nullo, ossia $n_{11}=0$ e/o $n_{22}=0$;
- $\varphi = +1$ se e solo se è invece nullo il prodotto dei termini della diagonale secondaria, ossia $n_{12}=0$ e/o $n_{21}=0$;
- $\varphi = 0$ se e solo se il prodotto dei termini di ciascuna diagonale è uguale a quello dell'altra, ossia $n_{11}\cdot n_{22}= n_{12}\cdot n_{21}$; la qual cosa corrisponde a dire che sia uguale il rapporto tra i termini di ciascuna riga o di ciascuna colonna: $n_{11}/n_{21}= n_{12}/n_{22}$ oppure $n_{11}/n_{12}= n_{21}/n_{22}$.

L'indice φ ha dunque un campo di variazione che va da **–1** se vi è totale discordanza a **+1** in caso di perfetta concordanza. Esso, in presenza di una relazione d'ordine tra le modalità oppure se le due variabili presentano le stesse modalità, fornisce risultati abbastanza conformi a quelli ottenuti tramite il coefficiente di correlazione lineare "esteso" al caso di classificazione dicotomica di due variabili quantitative.

Ove tale relazione d'ordine non sussista (oppure le variabili siano sconnesse e non presentino modalità simili), il segno negativo o positivo è del tutto ininfluente, posto che in tal caso l'ordine di righe e colonne è arbitrario ed è possibile permutare le une o le altre, invertendo in tal modo il segno del risultato.

Poiché si dimostra che il quadrato dell'indice di correlazione tetracorica equivale al rapporto tra statistica χ^2 e numerosità campionaria,

$$\varphi^2= \chi^2/n \,, \qquad \text{da cui} \qquad \chi^2 = n\varphi^2 \,,$$

anche la verifica della sua significatività statistica (come per l'indice *V* di Cramér) fa riferimento alla trasformazione in distribuzione χ^2 , logicamente con $(c-1)(r-1) = 1$ gradi di libertà.

Una annotazione: talvolta vengono studiate le relazioni tra variabili dicotomiche tramite il coefficiente di correlazione r di Pearson, la cui applicazione naturale è, com'è noto, su variabili continue. Non si tratta fondamentalmente di un errore: infatti, il coefficiente di correlazione calcolato su variabili dicotomiche corrisponde proprio all'indice di correlazione φ, come è facilmente dimostrabile con pochi passaggi matematici. Sarebbe tuttavia opportuno valutare il ricorso al coefficiente r tra due variabili dicotomiche solo quando entrambe fanno rilevare una numerosità adeguata a ipotizzare una sufficiente approssimazione alla curva normale (n_1 e n_2 maggiori di 30).

14. Gli indici *Q* e *Y* di Yule; l'indice *H* di Digby

Qualche mese prima dell'apparizione (sulle *Philosophical Transactions of the Royal Society of London*) del primo articolo di Pearson riguardante il suo

indice di correlazione tetracorica, sulla medesima autorevole pubblicazione era apparso un articolo del suo ex-allievo George Udny Yule (1900), il quale, partendo dal concetto di odds ratio[28] giunse a elaborare un indice di concordanza/discordanza per tabelle tetracoriche "concorrente" del φ .

Va detto, innanzitutto, che l'Odds Ratio (o *Rapporto di probabilità*)

$$\theta = \frac{(n_{11}/n_{01})/(n_{21}/n_{01})}{(n_{12}/n_{02})/(n_{22}/n_{02})} = \frac{n_{11}/n_{21}}{n_{12}/n_{22}} = \frac{n_{11}n_{22}}{n_{12}n_{21}},$$

benché sia considerato una statistica atta a misurare il grado di *associazione* tra due fattori e possieda alcune interessanti proprietà (tra cui quella di invarianza se si inverte l'ordine delle righe o delle colonne), come la statistica χ^2 non è un numero puro e non ha neanche un limite superiore: infatti $\theta = 0$ se $n_{11}=0$ e/o $n_{22}=0$ (indicando carenza o assoluta mancanza di associazione tra i fattori), ma se $n_{12}=0$ e/o $n_{21}=0$ (ossia in caso di associazione perfetta o tendente alla perfezione) l'equazione diventa indeterminata, e $\theta \to +\infty$.

Yule ne propose una semplice trasformazione normalizzante,

$$Q = \frac{\theta - 1}{\theta + 1} = \frac{\dfrac{n_{11}n_{22}}{n_{12}n_{21}} - 1}{\dfrac{n_{11}n_{22}}{n_{12}n_{21}} + 1} = \frac{n_{11}n_{22} - n_{12}n_{21}}{n_{11}n_{22} + n_{12}n_{21}} \qquad [23]$$

(ove il simbolo Q fu utilizzato per onorare proprio Quetelet), che, come è evidente, risolve il problema dell'Odds Ratio identificando anche il fenomeno dell'associazione inversa, ossia la discordanza.

Infatti se $n_{11}=0$ e/o $n_{22}=0$ si avrà $Q = -(n_{12}\cdot n_{21})/(n_{12}\cdot n_{21}) = -1$, che riflette una totale associazione negativa e dunque una completa discordanza, mentre se $n_{12}=0$ e/o n_{21} sarà logicamente $Q = (n_{11}\cdot n_{22})/(n_{11}\cdot n_{22}) = 1$, che riflette l'associazione positiva perfetta o perfetta concordanza; come nel caso dell'indice φ, si avrà assenza di qualsiasi associazione, indicata da $Q = 0$, se e solo se il prodotto dei termini di ciascuna diagonale è uguale a quello dell'altra.

Come sempre nel caso di tabelle tetracoriche, in assenza di criteri ordinatori oggettivi e per variabili categoriali con attributi differenti, il segno dipende da quali di detti attributi si vogliano considerare "concordanti" fra loro.

Quando la numerosità del campione o dei campioni studiati è abbastanza cospicua (>50), allora la distribuzione dell'indice Q tende a una v.c. normale,

[28] Concetto fondamentale nella scuola ottocentesca del belga Lambert Adolphe Jacques Quetelet, e su cui si basa la curva logistica ideata dall'allievo di questi, Pierre François Verhulst (1838, 1845), per spiegare matematicamente la dinamica delle popolazioni.

con media=Q e varianza data da (cfr. Bishop *et al.*, 1976, p. 378):

$$\sigma_Q^2 = \frac{(Q-1)^2}{4} \cdot \left(\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}} \right);$$

per cui la verifica della significatività dell'indice Q si riduce a verificare la significatività della sua trasformazione $Z = Q/\sigma_Q$. Per numerosità campionarie inferiori (ma non minime), si può fare riferimento, invece che alla v.c. Z, alla distribuzione della v.c. T di Student con n−1 gradi di libertà; tuttavia la sua affidabilità decresce rapidamente al ridursi della numerosità.

Nonostante il punto di partenza nettamente diverso, l'indice Q viene talora considerato un predecessore del γ di Goodman e Kruskal, ma sarebbe più giustificato considerare quest'ultimo indice come un *caso particolare* o una *estensione* del Q di Yule, essendo utilizzabile solamente con variabili ordinali (pur se con modalità multiple), mentre l'indice Q può essere utilizzato con variabili sia ordinali che nominali (purché dicotomiche/dicotomizzate).

Inoltre, l'indice Q di Yule viene talora utilizzato come approssimazione del coefficiente di correlazione tetracorica, sorte che del resto condivide anche con il suo concorrente immediato, l'indice φ di Pearson (Castellan, 1966).

Oltre un decennio più tardi, Yule (1912) tornò sull'argomento proponendo una modifica apparentemente di poco conto alla prima formulazione, ossia prendere in considerazione come quantità da normalizzare non più l'Odds Ratio, bensì la sua radice quadrata:

$$Y = \frac{\sqrt{\theta}-1}{\sqrt{\theta}+1} = \frac{\sqrt{\frac{n_{11}n_{22}}{n_{12}n_{21}}}-1}{\sqrt{\frac{n_{11}n_{22}}{n_{12}n_{21}}}+1} = \frac{\sqrt{n_{11}n_{22}}-\sqrt{n_{12}n_{21}}}{\sqrt{n_{11}n_{22}}-\sqrt{n_{12}n_{21}}}. \qquad [24]$$

La modifica, per quanto minima, ha una sensibile influenza sulle proprietà dell'indice stesso. Innanzitutto, dalla sua relazione con l'indice Q

$$Q = \frac{2 \cdot Y}{1+Y^2}; \qquad Y = \frac{1-\sqrt[2]{1-Q^2}}{Q}$$

(ricavabile con pochi passaggi aritmetici), si evince che il suo valore assoluto è sempre minore del primo o al più pari ad esso[29] (ossia $|Y| \leq |Q|$), avendosi il

[29] Tuttavia, è stato osservato anche dall'autore stesso (1912) che l'indice Q di tende a *sovrastimare* notevolmente (talora oltre il doppio) le relazioni che, con altri indici e coefficienti, fanno rilevare valori abbastanza ridotti (inferiori a 0,5 in valore assoluto), mentre l'indice Y fornisce valori maggiormente coerenti con le altre misure.

caso ha |Y| = |Q| se e solo se vi sia completa indipendenza (Y = Q = 0) o perfetta associazione, positiva o negativa che essa sia (nei quali casi, si ha |Y| = |Q| = 1).

In secondo luogo, si è avuto modo di constatare (Castellan, 1966; Digby, 1983) che l'approssimazione dell'indice Y al coefficiente di correlazione tetracorica è maggiore di quella del suo predecessore Q.

Come per l'indice Q, con campioni numericamente apprezzabili la distribuzione dell'indice Y tende a una v.c. normale, con media=Y e varianza

$$\sigma_Y^2 = \frac{(Y-1)^2}{16} \cdot \left(\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}} \right),$$

cosicché la verifica della significatività dell'indice Y di Yule corrisponde a verificare la significatività della sua trasformazione $Z = Y/\sigma_Y$ (oppure, per numerosità minori di 50 ma non esigue, $T = Y/\sigma_Y$ con n−1 g.d.l.).

Nei paesi anglosassoni, l'indice Y è noto anche come "coefficient of colligation" (traducibile, a stento, come "coefficiente di collegamento").

In tempi molto più recenti, è stata proposta da Digby (1983), basandosi sulle proprie osservazioni in tema di approssimazione al coefficiente di correlazione tetracorico, una ulteriore variante dell'indice Q, che egli chiama H, dimostrando che esso è il più performante in termini di approssimazione al coefficiente di correlazione tetracorica:

$$H = \frac{\sqrt[4]{\theta^3} - 1}{\sqrt[4]{\theta^3} + 1} = \frac{\sqrt[4]{\left(\frac{n_{11}n_{22}}{n_{12}n_{21}} \right)^3} - 1}{\sqrt[4]{\left(\frac{n_{11}n_{22}}{n_{12}n_{21}} \right)^3} + 1} = \frac{\sqrt[4]{(n_{11}n_{22})^3} - \sqrt[4]{(n_{12}n_{21})^3}}{\sqrt[4]{(n_{11}n_{22})^3} + \sqrt[4]{(n_{12}n_{21})^3}}. \qquad [25]$$

Anche l'indice H ha una distribuzione asintoticamente normale, con

$$\sigma_H^2 = 0{,}375 \cdot (H-1)^2 \cdot \left(\frac{1}{n_{11}} + \frac{1}{n_{12}} + \frac{1}{n_{21}} + \frac{1}{n_{22}} \right),$$

che consente di verificare la significatività dell'indice tramite la sua trasformazione $Z = Y/\sigma_H$.

Variabili	Y Quantitativa	Y Ordinale	X Nominale
X Quantitativa	r di Pearson, Biseriale r_b (*) Tetracorica (**)	Biseriale r_b	Punto-Biseriale r_{pb}
X Ordinale	Biseriale r_b	ρ di Spearman, τ di Kendall, γ di Goodman & Kruskal, γ_a di Amato, G di Gini, Tetracorica (dicotomizz.)	Rango Biseriale r_{rb}
X Nominale	Punto-Biseriale r_{pb}	Rango Biseriale r_{rb}	V di Cramér, φ di Pearson, Q di Yule e Y di Yule, λ di Goodman & Kruskal, K di Cohen

(*) Se le variabili sono originariamente continue ma una è rilevata o classificata in due o più categorie.
(**) Se entrambe le variabili (originariamente continue) sono rilevate o classificate in due categorie.

APPENDICE

7.1 Esempi di calcolo dell'indice di cograduazione di Kendall

Il calcolo pratico del τ di Kendall appare abbastanza complicato, soprattutto per campioni di una certa numerosità. Per questo motivo si vuole qui dare una guida operativa, tramite l'utilizzo di programmi informatici di uso generale come i "fogli elettronici", fermo restando il ricorso, per gli utenti professionali, ad appositi software statistici.

Poniamo innanzitutto di aver rilevato in 7 unità statistiche due vettori di dati senza alcuna parità, $\boldsymbol{x}$: [49, 48, 50, 44, 47, 51, 46]' e $\boldsymbol{y}$: [31, 30, 36, 29, 32, 35, 34]'; inseriamoli quindi come colonne in una tabella di calcolo: giusto per semplificare l'esposizione, la tabella è qui descritta secondo la notazione alfa-numerica usuale, a partire dagli albori dell'informatica, per la maggior parte dei fogli elettronici.

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	Unità	**x**	**y**	**Conc.**	**Disc.**			**u.1**	**u.2**	**u.3**	**u.4**	**u.5**	**u.6**
2	1	49	31	4	2								
3	2	48	30	3	2			1					
4	3	50	36	3	1			1	1				
5	4	44	29	3	0			1	1	1			
6	5	47	32	1	1			-1	-1	1	1		
7	6	51	35	1	0			1	1	-1	1	1	
8	7	46	34					-1	-1	1	1	-1	1
9													
10			Somme:	15	6								
11		n(n-1)/2:	21	**Tau:**	**0,42857**								

Come si vede, i vettori di dati $\boldsymbol{x}$ e $\boldsymbol{y}$ sono posizionati senza alcun ordinamento, ma solo associati all'unità statistica ove sono stati osservati: infatti, anche se Kendall propose l'indice τ come *misura della correlazione tra ranghi*, poiché esso si basa soltanto sulla concordanza o discordanza delle differenze fra *ciascuna coppia di osservazioni* e le coppie rilevate su unità successive, l'ordinamento delle variabili secondo una di esse è del tutto superfluo, come anche la trasformazione in ranghi.

A destra della tabella (colonne da H a M) sono calcolati, per ogni j-esima unità successiva a quella che identifica la colonna, i singoli prodotti dei segni delle differenze rispetto all'unità i di confronto, ossia le quantità $[\text{segno}(x_i - x_j)\cdot\text{segno}(y_i - y_j)]$; com'è logico, la sesta unità può essere confrontata solo con la settima, perché tutti gli altri suoi confronti (con la prima, la seconda, …, la quinta unità) sono stati fatti in precedenza. La funzione "segno" fornisce il valore 1 quando la differenza risulta positiva, il valore -1 quando essa è negativa, e ovviamente il valore 0 quando la differenza è nulla (ma nel caso presente non vi sono differenze nulle, non essendovi valori uguali in ciascuna serie di dati).

Nella sintassi di un foglio elettronico, la funzione nella casella H3 è la seguente:

```
=SEGNO(B$2-B3)*SEGNO(C$2-C3) ,
```

e copiata nelle celle sottostanti mantiene fisse nel confronto, tramite la notazione "$" che

trasforma un *indirizzo relativo* in *indirizzo assoluto*, le caselle B2 e C2 (quelle che contengono i dati rilevati nella prima unità), cosicché nelle caselle da H4 a H8 si hanno le funzioni

```
=SEGNO(B$2-B4)*SEGNO(C$2-C4)
=SEGNO(B$2-B5)*SEGNO(C$2-C5)
=SEGNO(B$2-B6)*SEGNO(C$2-C6)
=SEGNO(B$2-B7)*SEGNO(C$2-C7)
=SEGNO(B$2-B8)*SEGNO(C$2-C8)
```

che forniscono appunto i risultati visibili in tabella di calcolo.

Stessa procedura viene fatta per i confronti relativi alla seconda unità, inserendo nella casella I4 la formula

```
=SEGNO(B$3-B4)*SEGNO(C$3-C4)
```

e copiandola nelle caselle da I5 a I8. E poi di seguito, fino all'unico confronto dell'unità 6:

```
=SEGNO(B$7-B8)*SEGNO(C$7-C8).
```

La somma algebrica di tutte le cifre così ottenute fornisce il numeratore dell'indice, mentre il denominatore è $(7\cdot6)/2 = 21$. Quindi l'indice di Kendall è $\boldsymbol{\tau} = 9/21 = 0{,}42857$.

Tuttavia, quando il numero di unità campionate è ampio, il numero di colonne da compilare con funzioni diversificate è abbastanza ingente, rendendo disagevole l'utilizzo del metodo; e non tutti hanno accesso agli appositi software statistici.

Viene in soccorso la ricca dotazione di funzioni disponibile nei fogli elettronici più aggiornati. In particolare, la funzione statistica di conteggio con condizioni multiple, che in MS Excel assume la forma:

```
=CONTA.PIÙ.SE(dati1;“condizione 1”;dati2;”condizione 2”;…),
```

e che appunto è in grado di effettuare il conteggio solo dei casi che facciano rilevare contemporaneamente tutte le condizioni espresse. In inglese, la funzione ha la forma “`=COUNTIFS(…)`”.

Per valutare i casi di concordanza (sia positiva che negativa) dei confronti, dunque, è necessario inserire nella casella D2 una formula che contenga entrambi i tipi di condizioni, ripetendo per due volte la medesima funzione ma cambiando la condizione di confronto con i dati rilevati nella prima unità:

```
=CONTA.PIÙ.SE(B3:B$8;">"&B2;C3:C$8;">"&C2)+CONTA.PIÙ.SE(B3:B$8;"<"&B2;C3:C$8;"<"&C2)
```

per poi semplicemente copiare nelle sottostanti caselle detta formula[30], la quale, data la presenza degli indirizzi assoluti B8 e C8, fornirà il numero di concordanze nel confronto tra la i-esima unità e quelle successive fino a quelle presenti sulla riga 8 del foglio (ovviamente copiando la formula anche nella casella D8 si otterrebbe sempre uno zero, perché non sono presenti in tabella dati successivi all'ottava riga).

Anche per valutare i casi di discordanza dei confronti è necessario inserire (stavolta nella casella E2) una formula che contenga due distinte funzioni di conteggio condizionale:

---

[30] Per chi non abbia familiarità con le notazioni dei fogli elettronici, il carattere “&” serve a unire due testi: per cui la funzione di conteggio `CONTA.PIÙ.SE(B3:B$8;">"&B2;C3:C$8;">"&C2)` conterà tutte le unità successive alla prima in cui sia il valore x che il valore y siano superiori a quelli rilevati nella prima unità (infatti il carattere “&” trasforma la funzione data in: `CONTA.PIÙ.SE(B3:B$8;`**`">49"`**`;C3:C$8;`**`">31"`**`)`. Stessa trasformazione avviene, ovviamente, per la seconda funzione di conteggio condizionale inserita nella medesima cella.

=CONTA.PIÙ.SE(B3:B$8;">"&B2;C3:C$8;"<"&C2)+CONTA.PIÙ.SE(B3:B$8;"<"&B2;C3:C$8;">"&C2)

e poi semplicemente copiare la stessa formula nelle caselle sottostanti.

Le somme delle due colonne di dati così calcolati forniscono, rispettivamente, il numero totale di concordanze e di discordanze presenti nei confronti. Sottraendo il numero di discordanze a quello delle concordanze, si ottiene ancora il numeratore dell'indice $\boldsymbol{\tau}$, cioè 9.

Ma per calcolare l'indice di Kendall in presenza di parità di valori in una o entrambe le distribuzioni, occorre quantificare anche i casi di parità, per poi utilizzarli per correggere il denominatore dell'indice.

	A	B	C	D	E	F	G	H	I	J	K
1	Unità	**x**	**y**	**Conc.**	**Disc.**	**repliche x**	**repliche y**				
2	1	49	31	6	2	0	1				
3	2	48	30	6	2	0	0				
4	3	50	36	3	1	3	0				
5	4	44	29	6	0	0	0				
6	5	47	32	3	2	0	0				
7	6	51	35	3	1	0	0				
8	7	46	34	1	1	0	1				
9	8	50	34	0	0	3	1				
10	9	50	39	0	0	3	0				
11	10	50	31	-	-	3	1				
12											
13			Somme:	28	9	6	2				
14		n(n-1):	45	**Tau:**	**0,46397**						

Alla serie del precedente foglio di calcolo, come si nota, sono state aggiunte tre osservazioni che si presentano come altrettante repliche del terzo dato della serie x (che quindi si trova ad avere $t_{1x} = 4$ casi uguali, ossia parità), mentre la serie y vede replicati una sola volta due valori (e dunque $t_{1y} = 2$ parità e $t_{2y} = 2$ parità).

Per ottenere i valori con pochi calcoli le correzioni di parità $t_{xi}\,(t_{xi}-1)$ per la serie x, nella casella F2 si inserirà la funzione

=CONTA.SE(B$2:B$11;B2)-1

effettuante un conteggio dei soli valori della serie x che risultano *uguali* al valore posto in B2. Copiando questa formula fino alla casella B11, si avranno appunto i valori $(t_{xi}-1)$ relativi a tutte le parità rilevate.

A questo punto, basta copiare la medesima funzione nella colonna G in riferimento alle parità della serie di dati y.

Le semisomme dei dati in queste due colonne[31] ci forniscono direttamente i valori di parità da utilizzare per correggere il denominatore dell'indice..

L'algoritmo qui descritto, applicato ai dati presentati nella Tab. 2 del par. 5, fornisce un indice $\boldsymbol{\tau} = 0{,}3877$, perfettamente coerente con i risultati della formula [9].

[31] Diversamente da CONTA.PIÙ.SE(), la funzione CONTA.SE(), in inglese COUNTIF(), è diffusissima nei fogli elettronici fin dai tempi eroici del Lotus-123, per cui non si ritiene necessario fornire al lettore farraginosi procedimenti alternativi.

RIFERIMENTI BIBLIOGRAFICI

Agresti, A. (2010). *Analysis of Ordinal Categorical Data*, Second Edition. New York, John Wiley & Sons.

Amato, V. (1954). Una nuova espressione dell'indice di cograduazione di Spearman, *Bulletin of the International Statistical Institute*, Vol. 34, n. 2: 329-335.

Amato, V. (1970). *Metodologia statistica strutturale*, Volume III, Cacucci, Bari.

Amato, V. (1977). *Statistica – Una metodologia di tipo strutturale: dallo scalare empirico alla matrice statistica*, Volume I, Cacucci, Bari.

Angelini, G. (1977). *Gli indici di omofilia*, Cappelli editore, Bologna.

Apostol, T.M. (1977). *Calcolo -Volume 1 - Analisi I*, Boringhieri, Milano.

Benedetti, C. (1957). Di alcune disuguaglianze collegate al campo di variazione di indici statistici, *Metron*, vol. 18, n.3-4.

Becker, M. P.; Clogg, C. C. (1988). A note on approximating correlations from odds ratios. *Sociological methods & research*, 16: 407-424.

Best, D. J. (1973). Extended tables for Kendall's tau, *Biometrika*, Vol. 60: 429-430.

Bishop, Y. M. M.; Fienberg, S. E.; Holland, P. W. (1975). *Discrete multivariate analysis: Theory and practice*. MIT Press, Cambridge, Mass.

Bonett, D. G.; Price, R. M. (2005). Inferential Methods for the Tetrachoric Correlation Coefficient. *Journal of Educational and Behavioral Statistics*, Vol. 30, No. 2 (Summer): 213-225.

Bonferroni C. E. (1939). Di una estensione del coefficiente di correlazione. *Giornale degli Economisti e Annali di Economia*, Nuova Serie, Anno 1, No. 11/12: 797-826.

Bravais, A. (1846). Analyse mathématique sur les probabilités des erreurs de situation d'un point, *Mémoires présentés par divers savants a l'Académie des Sciences de l'Institut de France*, vol.IX: 255-332.

Camp, B. H. (1933). Karl Pearson and Mathematical Statistics. *Journal of American Statistical Association*, 28: 395-401.

Castellan, N.J. (1966). On the estimation of the tetrachoric correlation coefficient. *Psychometrika*, 31: 67-73.

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*. 20 (1): 37-46.

Corbetta, P.G. (2005) *Metodi di analisi multivariata per le scienze sociali. I modelli di equazioni strutturali*, Il Mulino, Bologna.

Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton: Princeton University Press.

Cucconi, O. (1964). La distribuzione campionaria dell'indice di cograduazione di Gini, *Statistica*, anno XXIV, 1964, n. 2.

Delvecchio, F. (2010). *Statistica per l'analisi di dati multidimensionali*, CLEUP, Padova.

Delvecchio, F. (2024). *Statistica per lo studio dei fenomeni sociali*, 2° ed., CLEUP, Padova.

Digby, P. G. N. (1983). Approximating the tetrachoric correlation coefficient. *Biometrics*, 38: 753-757.

Edwards, J. H. (1957). A note on the practical interpretation of 2 x 2 tables. *British Journal of Preventive and Social Medicine*, 11: 73-78

Ekström, J. (2011). *The Phi-coefficient, the Tetrachoric Correlation Coefficient, and the Pearson-Yule Debate*. UCLA: Department of Statistics, UCLA.

Fisher, R. A. (1915). Frequency distribution of the values of the correlation coefficient in samples of an indefinitely large population. *Biometrika*. 10 (4): 507–521. doi:10.2307/2331838 .

Fisher, R. A. (1921). On the 'probable error' of a coefficient of correlation deduced from a small sample (PDF). *Metron*. 1: 3–32.

Fortunati, P. (1967). Alcune considerazioni sulla impostazione giniana delle misure di concordanza, *Atti della XXV riunione della S.I.S.*, Bologna.

Galton, F. (1869). *Hereditary genius*, Macmillan, London.

Galton, F. (1888). Co-relations and their Measurement, chiefly from Anthropometric Data, in *Proceedings of the Royal Society of London*, vol. 45: 135–145.

Gart, J. J. (1966). Alternative analyses of contingency tables. *Journal of the Royal Statistical Society*, 28B: 164-179.

Gini, C. (1914). *Di una misura delle relazioni tra le graduatorie di due caratteri*, Cecchini ed., Roma.

Gini, C. (1916). Sul criterio di concordanza tra due caratteri, *Atti del Reale Istituto Veneto di Scienze, Lettere ed Arti*, Tomo LXXV, parte II, C. Ferrari, Venezia.

Girone, G. (1964). Su un indice di omogeneità del tipo dell'indice semplice di dissomiglianza, *Atti della XXIV riunione della S.I.S.*.

Girone, G. (1971). Sulla distribuzione campionaria dell'indice di cograduazione del Gini, *Annali dell'Istituto di Statistica*, Università di Bari, Vol. XXXV.

Girone, G. (1973). Su un nuovo test di adattamento, *Annali dell'Istituto di Statistica*, Università di Bari, vol. XXXVII.

Girone, G.; Montrone, S.; Leogrande, D. (2010). La distribuzione campionaria dell'indice di cograduazione di Gini per dimensioni campionarie fino a 24, *Annali del Dipartimento di Scienze statistiche "Carlo Cecchi"*, vol. IX: 245-271.

Giusti, F.; Guerrieri, G. (1979). *Elementi di statistica*, vol. II, Cacucci, Bari.

Goodman, L.A.; Kruskal, W.H. (1954). Measures of association for cross classifications. Part I. *Journal of the American Statistical Association*, 49: 732-764.

Goodman, L.A.; Kruskal, W.H. (1959). Measures of Association for Cross Classifications. II: Further Discussion and References. *Journal of the American Statistical Association*, 52: 123-163.

Goodman, L. A.; Kruskal, W. H. (1963). Measures of association for cross-classifications. III: Approximate sample theory, *Journal of the American Statistical Association*, 58: 310-364.

Goria, M. N. (1972). Some generalizations of Girone's test, *Annali dell'Istituto di Statistica*, vol. XXXVI, Bari.

Gosset, M. S. (1921). An experimental determination of the probable error of Dr. Spearman's correlation coefficients. *Biometrika*, 13 (2/3): 263-282.

Guilford, J. P. (1956). *Fundamental Statistics in Psychology and Education*. New York: McGraw-Hill.

Herzel, A. (1972). Sulla distribuzione campionaria dell'indice di cograduazione del Gini, *Metron*, (1/4), 137.

Hotelling, H.; Pabst, M. R. (1936). Rank correlation and tests of significance involving no assumption of normality. *Annals of Mathematical Statistics*, 7: 29-43.

Hotelling, H. (1953). New Light on the Correlation Coefficient and its Transforms. *Journal of the Royal Statistical Society, Series B (Methodological)*. 15 (2): 193–225. doi:10.1111/j.2517-6161.1953.tb00135.x. ISSN 0035-9246

Johnston, J. (1972). *Econometric Methods*, McGrawHill, New York.

Kendall, M. (1938). A New Measure of Rank Correlation. *Biometrika*, **30** (1–2): 81-89.

Kendall, M. (1948). *Rank Correlation Methods*, Charles Griffin & Company Ltd.

Lord, F. M.; Novick, M. R. (1968). *Statistical theories of mental test scores*. Reading. MA: Addison Wesley.

Maciak, W. (2009). Exact null distribution for n≤25 and probability approximations for Spearman's score in an absence of ties, *Journal of Nonparametric Statistics*, 21:1, 113-133, DOI: 10.1080/10485250802401038

Malkovich, J. F.; Afifi, A. A. (1973). On Tests for Multivariate Normality, *Journal of the American Statistical Association*, Vol.68: 176-179.

National Center for Education Statistics (2014). *Data Files from the 2003 National Assessment of Adult Literacy*, URL http://nces.ed.gov/NAAL/datafiles.asp

Noyan, F.; Gölbaşi Şimşek, G. (2012). Tetrachoric correlation as a measure of default correlation. *Procedia - Social and Behavioral Sciences*, 62: 1230-1234. https://doi.org/10.1016/j.sbspro.2012.09.210.

Otten, A. (1973). The null distribution of Spearman's ρ when n = 13 (1) 16, *Statistica Neerlandica*, vol. 27, n.1: 19-20.

Pearson, K. (1896). Mathematical Contributions to the Theory of Evolution - III. Regression, Heredity, and Panmixia, *Philosophical Transactions of the Royal Society of London*, vol. 187: 253–318.

Pearson, K. (1900). Mathematical Contributions to the Theory of Evolution - VII. On the correlation of characters not quantitatively measurable, *Philosophical Transactions of the Royal Society of London*, Series A, vol. 195: 1–47.

Pitman, E. J. G. (1948). *Lecture Notes on Nonparametric Statistical Inference*. Lecture given for the University of North Carolina. Chapel Hill.

Spearman, C. (1904). The proof and measurement of association between two things. *American Journal of Psychology*, vol. 15: 72-101.

Stuart, A. (1953). The Estimation and Comparison of Strengths of Association in Contingency Tables. *Biometrika*. 40 (1–2): 105–110.

UNESCO (1984). *Handbook of Household Surveys*, Revised Edition, Studies in Methods, Series F, United Nations, New York, No. 31: 189-192. URL: https://unstats.un.org/unsd/publication/SeriesF/SeriesF_31E.pdf

Verhulst, P.-F. (1838). Notice sur la loi que la population poursuit dans son accroissement. *Correspondance Mathématique et Physique*. 10: 113–121.

Verhulst, P.-F. (1845). Recherches mathématiques sur la loi d'accroissement de la population. *Nouveaux Mémoires de l'Académie Royale des Sciences et Belles-Lettres de Bruxelles*. 18: 8.

Yates, F. (1934). Contingency tables involving small numbers and the χ^2 test. *Journal of the Royal Statistical Society*, Suppl. 1: 217-235.

Yule, G. U. (1900). On the association of attributes in statistics: with illustrations from the material of the childhood society. *Philosophical Transactions of the Royal Society of London*, Series A, 194: 257-319.

Yule, G. U. (1912). On the Methods of Measuring Association Between Two Attributes. *Journal of the Royal Statistical Society*. 75 (6): 579-652.

Walker, H. M.; Lev, J. (1953). *Statistical inference*. New York: Holt, Rinehart & Winston.

Zar, J. H. (1972). Significance Testing of the Spearman Rank Correlation Coefficient, *Journal of the American Statistical Association*, vol. 67, 339: 578-580.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 65-82

La statistica per il calcio

Antonella Massari[1]*, Vittoria Claudia De Nicolò[2], Eleonora Lionetti[3].

[1]*Dipartimento di Economia, Management e Diritto dell'Impresa, Università degli studi di Bari Aldo Moro,*

[2]*Cultore della materia del Dipartimento di Economia, Management e Diritto dell'Impresa, Università degli studi di Bari Aldo Moro*

[3]*Dottoressa in Economia Aziendale, Dipartimento di Economia,Management e Diritto dell'impresa, Università degli studio di Bari Aldo Moro*

Riassunto: Nel presente lavoro si analizzano i metodi statistici impiegati maggiormente dai professionisti del settore calcistico per valutare la performance delle squadre e delle partite. L'indice degli Expected Goals consente di calcolare la probabilità che un tiro possa trasformarsi in un gol ed è espressione della qualità delle occasioni create da una squadra. Per effettuare la previsione dell'andamento delle partite si impiegano modelli statistici come, ad esempio, il processo di Poisson, quello esponenziale, la distribuzione uniforme standard, che consentono di osservare il numero di eventi che avvengono in un dato periodo di tempo, il tempo che intercorre tra i suddetti eventi e quando gli eventi si verificano. Negli ultimi anni, l'avvento dell'intelligenza artificiale ha permesso all'analisi dei dati di trasformare il calcio, cambiando il modo in cui i club studiano gli avversari, trovano nuovi acquisti e migliorano le prestazioni dei giocatori. Questo lavoro ha l'obiettivo di illustrare l'importanza dell'impiego dell'analisi statistica in ambito calcistico tenendo conto delle sue prospettive di sviluppo grazie al crescente utilizzo dell'intelligenza artificiale.

Keywords: metodi statistici; intelligenza artificiale; calcio.

1. Introduzione

La statistica e i big data sono al centro di una rivoluzione del settore sportivo, nel quale i dati e gli algoritmi giocano un ruolo sempre più importante nell'analisi delle

* Antonella Massari: antonella.massari@uniba.it
Il lavoro qui descritto è frutto di un progetto comune, ma Antonella Massari. ha provveduto alla redazione dei paragrafi 1 e 5, Eleonora Lionetti. ha redatto i paragrafi 2 e 3, Vittoria Claudia De Nicolò il paragrafo 4.

informazioni provenienti dalle prestazioni degli sportivi e delle squadre. In quasi tutti gli sport, le strategie decisionali adottate dagli allenatori e dalle società dipendono sempre più dai dati: dal reclutamento dei giocatori, al coinvolgimento dei tifosi attraverso il broadcasting e la realtà aumentata. Questa tendenza ha favorito un aumento degli investimenti in analisi dei dati in questo settore e, secondo il rapporto di Research and Markets, nel 2022 il business del mercato dei dati nello sport ha raggiunto il valore di circa 3 miliardi di euro, destinato a crescere fino a 8 miliardi di euro entro il 2026. Uno dei pionieri dell'impiego dell'analisi statistica in ambito sportivo è stato Billy Beane, manager della squadra di baseball degli Oakland Athletics, il quale ha messo a punto un metodo statistico per selezionare gli atleti basato sulla percentuale di conquista della base. (Ks, 2020).

La sabermetrica, ossia l'analisi empirica del baseball impiegando statistiche avanzate, ha cambiato profondamente l'analisi delle performance e dello scouting, con l'obiettivo di creare metriche finalizzate non solo alla valutazione della prestazione di un giocatore nelle stagioni precedenti, ma anche alla previsione delle sue prestazioni future. L'impiego dell'analisi statistica ha inizialmente avuto successo nel baseball per poi diffondersi in altri sport, come basket e hockey, ma ha incontrato difficoltà inizialmente nel calcio. In tale settore, si è deciso di impiegare statistiche di squadra, piuttosto che relative ai singoli, lavorando principalmente sui tiri.

Gli esperti sono giunti a questa conclusione analizzando i dati delle diverse stagioni calcistiche: le squadre migliori sono quelle che tirano di più, tanto meglio se in porta, e che allo stesso tempo subiscono meno tiri. A livello puramente intuitivo è lecito affermare che alcuni tiri "valgano" più di altri; tuttavia, in un'analisi empirica niente può essere lasciato al caso, né tantomeno all'intuizione; quindi, anche l'assunto per cui la posizione influenza l'esito del tiro necessita di essere supportato da una base statistica. A tal proposito, uno degli studi più noti è lo "Shot Position Average Model" (SPAM) di Paul Riley (Fusi, 2016).

Riley ha esaminato più di 30'000 tiri su tre stagioni di Premier League per determinare quanti tiri fossero necessari per segnare un gol da fuori area, dai lati dell'area di rigore e dal centro dell'area di rigore, nonché da situazioni come un calcio di rigore o un calcio di punizione diretta. Il risultato dello studio è stato che il numero di tiri necessari in media a segnare un gol da ciascun tipo di posizione rimanesse sostanzialmente invariato da stagione a stagione. Sono così nati i primi modelli di Expected Goals, un metodo di misurazione della qualità delle occasioni create da una squadra, con l'obiettivo di determinare quanti gol quella stessa squadra avrebbe segnato in media in base alla qualità e alla quantità dei tiri effettuati. Tutti i modelli di Expected Goals si differenziano l'uno dall'altro nel metodo di calcolo e per i

parametri impiegati nel calcolo stesso; fattori di utilizzo comune sono la posizione e la tipologia del tiro.

2. Materiali e metodi

2.1 I principali indici statistici per la misurazione della performance

I due modelli di Expected Goals maggiormente conosciuti sono quello di Paul Riley e quello di Michael Caley (Fusi, 2016). Paul Riley ha proceduto con lo sviluppo di un modello di Expected Goals esclusivamente per la Premier League. La novità apportata è stata l'abbandono dell'idea di prendere in analisi tutti i tiri, ma solamente quelli in porta. La posizione e la tipologia del tiro sono di medesima importanza: la posizione è essenziale, ed esaminando un campione di 13'000 tiri in porta, si è diviso il campo in 46 differenti settori e si è calcolata, per ognuno di essi, la probabilità, da un determinato settore, che ha un tiro di terminare in porta. La tipologia del tiro consente di effettuare una distinzione tra tiro su azione, su punizione diretta o su calcio di rigore. Il modello di Michael Caley, invece, prende in esame tutti i tiri, ma pur sempre escludendo i rigori e le autoreti, similmente al modello di Riley. Tale modello effettua una classificazione in 6 tipologie di tiro, a ciascuna delle quali viene associata una diversa equazione:

1. Tiri da punizione diretta;
2. Tiri conseguenti ad un dribbling sul portiere;
3. Tiri di testa assistiti da un cross;
4. Tiri di testa non assistiti da un cross;
5. Tiri non di testa assistiti da un cross;
6. Tiri non di testa non assistiti da un cross (o "tiri regolari");

La distanza dalla porta e l'angolo di tiro sono i due fattori dei quali si tiene conto maggiormente.

2.1.1 L'indice degli Expected Goals (xG)

L'indice degli expected goals consente di calcolare la probabilità che un tiro possa trasformarsi in un gol. Tale indice è stato ricavato dall'analisi di centinaia di migliaia di tiri, a ciascuno dei quali è stato assegnato un valore compreso tra 0 (non vi è alcuna probabilità di segnare) e 1 (vi è il 100% delle possibilità di segnare). Nel calcolo degli expected goals vengono presi in considerazione molteplici fattori pre-tiro, tra i quali si possono annoverare:

- l'angolo di tiro;
- la distanza dalla porta;
- la parte del corpo con cui si tira;
- il numero e la posizione dei difensori e del portiere;
- l'altezza dell'impatto col pallone;
- la tipologia di assist ricevuto.

In base a questi criteri è possibile raggruppare i tiri effettuati in condizioni simili e, dividendo quelli trasformati in rete sul numero totale, si ottiene un valore compreso tra 0 e 1, che appunto rappresenta l'xG. (Carey, 2021; Comana, 2022; Hewitt, 2023, Mead, 2023, Sitografia; 3).

2.1.2 Come si calcolano gli Expected Goals

In generale, data una variabile aleatoria discreta $X = \{x_1, x_2, \dots, x_n\}$ con probabilità associate (p_i), $i \in \{1, 2, \dots, n\}$, il suo valore atteso o speranza matematica è definito come

$$E[X] = \sum_{i=1}^{n} x_i p_i \tag{1}$$

Il valore atteso fornisce il valore medio per il fenomeno rappresentato dalla variabile aleatoria X. Al fine di applicarlo al calcio con gli xG, si consideri la variabile aleatoria X = {0, 1}, dove X = 0 sta a significare che non si è segnato, mentre X = 1 indica che si è segnato. Allora l'expected goal di una certa occasione è

$$E[X] = 0\ x\ \left(1 - p_{goal}\right) + 1\ x\ p_{goal} \tag{2}$$

dove p_{goal} è la probabilità di trasformare in goal una determinata occasione. In questo modo, l'xG coincide con la probabilità p_{goal} (Menale, 2024).

2.1.3 Gli xG nella Serie A 2021/2022

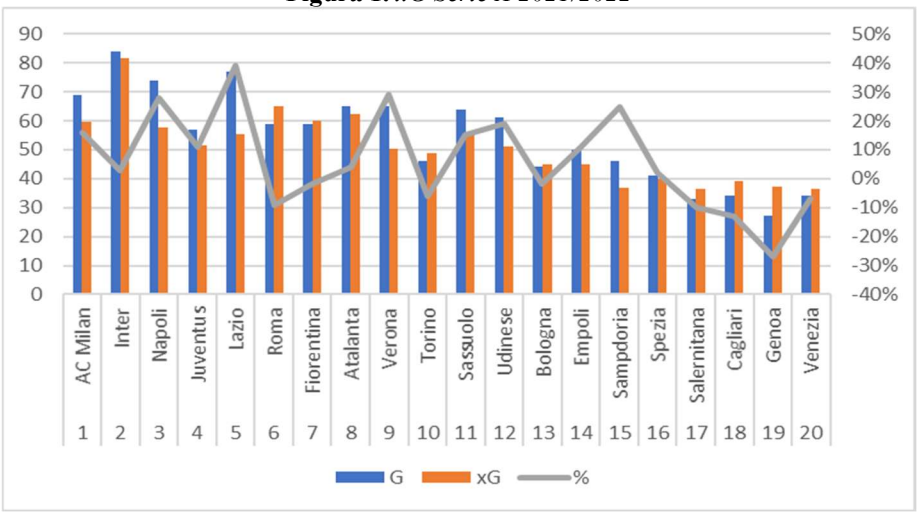
È stato analizzato il numero di gol effettuati da ciascuna delle 20 squadre facenti parte del campionato di Serie A relativamente alla stagione 2021/2022 ed è stato messo a confronto con il numero di gol che si prevedeva sarebbero stati segnati (expected goals). Per ogni squadra è stato calcolato il delta, ossia la differenza tra i gol effettivamente segnati nel corso del campionato ed i gol previsti; e di quanto, in termini percentuali, il numero dei gol segnati nella realtà si è discostato dagli expected goals.

Tabella 1. *G e xG Serie A 2021/2022*

Posizione	Team	G	xG	%	DELTA
1	AC Milan	69	59,7	+16%	+9,3
2	Inter	84	81,6	+3%	+2,4
3	Napoli	74	57,8	+28%	+16,2
4	Juventus	57	51,4	+11%	+5,6
5	Lazio	77	55,3	+39%	+21,7
6	Roma	59	65,1	-9%	-6,1
7	Fiorentina	59	60,0	-2%	-1,0
8	Atalanta	65	62,4	+4%	+2,6
9	Verona	65	50,4	+29%	+14,6
10	Torino	46	48,7	-6%	-2,7
11	Sassuolo	64	55,7	+15%	+8,3
12	Udinese	61	51,3	+19%	+9,7
13	Bologna	44	44,9	-2%	-0,9
14	Empoli	50	44,9	+11%	+5,1
15	Sampdoria	46	36,7	+25%	+9,3
16	Spezia	41	40,1	+2%	+0,9
17	Salernitana	33	36,5	-10%	-3,5
18	Cagliari	34	39,0	-13%	-5,0
19	Genoa	27	37,2	-27%	-10,2
20	Venezia	34	36,5	-7%	-2,5

Fonte dati: Società «Opta Sports» (2022)

Figura 1. *xG Serie A 2021/2022*



Fonte dati: Società «Opta Sports» (2022)

Dall'analisi svolta (Fig.1) risulta che le squadre posizionate in alto alla classifica, come Milan, Inter, Napoli, Juventus e Lazio, sono le più efficienti sotto porta, superando nettamente le aspettative. Mostrano difficoltà nella finalizzazione le squadre della Roma e del Torino, con gol effettivi inferiori agli expected goals, mentre, la restante parte delle squadre collocate al centro della classifica, come Atlanta, Empoli, Spezia, Fiorentina e Bologna mostrano una buona corrispondenza tra occasioni create e gol segnati. Le squadre in fondo alla classifica, più precisamente Salernitana, Cagliari, Genoa e Venezia, presentano problemi significativi nella conversione delle occasioni da gol, con differenze negative rilevanti tra G e xG.

2.1.4. L'indice degli Expected Goals Against (xGA)

Gli expected goals against (xGA), rappresentano la qualità delle occasioni che una squadra avversaria crea contro una determinata squadra. Analogamente all'xG, l'xGA è espresso come numero decimale, con valori più alti quando è maggiore la probabilità che la squadra avversaria segni. Osservando l'xGA di una squadra, si può avere un'idea della sua forza difensiva e della qualità delle occasioni che sta concedendo. (Felices, 2023)

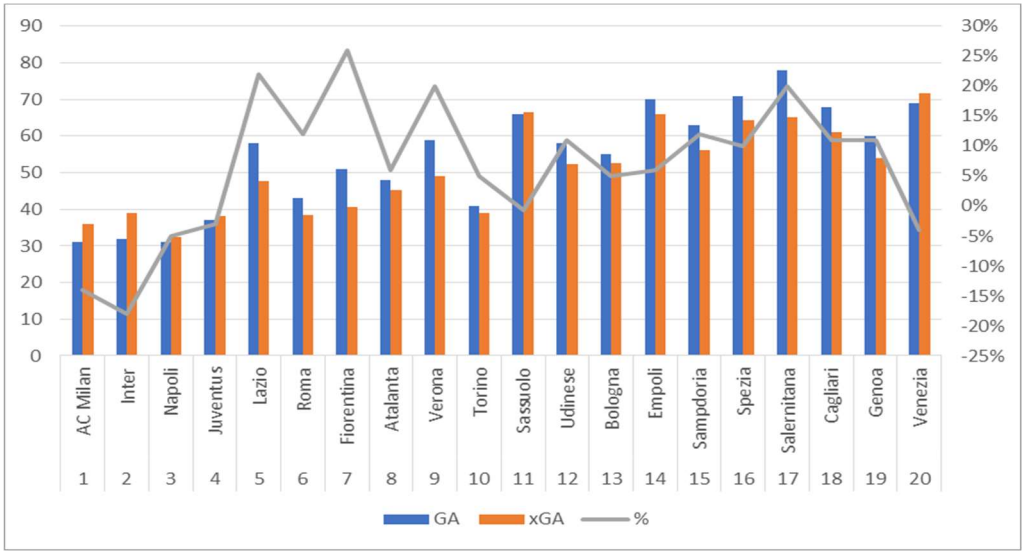
Tabella 2. *GA e xGA Serie A 2021/2022*

Posizione	Team	GA	xGA	%	DELTA
1	AC Milan	31	35,9	-14%	-4,9
2	Inter	32	39,1	-18%	-7,1
3	Napoli	31	32,5	-5%	-1,5
4	Juventus	37	38,1	-3%	-1,1
5	Lazio	58	47,7	+22%	+10,3
6	Roma	43	38,4	+12%	+4,6
7	Fiorentina	51	40,6	+26%	+10,4
8	Atalanta	48	45,3	+6%	+2,7
9	Verona	59	49,0	+20%	+10
10	Torino	41	38,9	+5%	+2,1
11	Sassuolo	66	66,4	-0,6%	-0,4
12	Udinese	58	52,4	+11%	+5,6
13	Bologna	55	52,6	+5%	+2,4
14	Empoli	70	66,0	+6%	+4
15	Sampdoria	63	56,1	+12%	+6,9
16	Spezia	71	64,4	+10%	+6,6
17	Salernitana	78	65,2	+20%	+12,8
18	Cagliari	68	61,0	+11%	+7
19	Genoa	60	54,1	+11%	+5,9
20	Venezia	69	71,8	-4%	-2,8

Fonte dati: Società «Opta Sports» (2022)

È stato analizzato il numero di gol subiti da ciascuna delle 20 squadre facenti parte del campionato di Serie A relativamente alla stagione 2021/2022 ed è stato messo a confronto con il numero di occasioni che si prevedeva sarebbero state concesse (expected goals against). Per ogni squadra è stato calcolato il delta, ossia la differenza tra i gol effettivamente concessi e le reti subite previste durante il campionato; e di quanto, in termini percentuali, il numero dei gol subiti nella realtà si è discostato dagli expected goals against.

Figura 2. *xGA Serie A 2021/2022*



Fonte dati: Società «Opta Sports» (2022)

Dall'analisi svolta (Fig. 2) risulta che Milan, Inter, Napoli e Juventus si distinguono per la loro efficienza difensiva, subendo meno gol di quelli attesi. Squadre come Lazio, Fiorentina, Verona, Sampdoria, Spezia, Salernitana, Cagliari e Genoa devono lavorare sulla fase difensiva per ridurre il numero di gol subiti rispetto alle aspettative. Una buona coerenza tra xGA e gol subiti è mostrata da Sassuolo e Venezia, suggerendo stabilità e consistenza nelle prestazioni difensive.

2.1.5 L'indice dell'Expected Goals Difference (xGD)

Gli expected goals (xG) e gli expected goals against (xGA) possono essere utilizzati insieme per calcolare l'expected goals difference (xGD) di una squadra. L'xGD è semplicemente la differenza tra l'xG e l'xGA di una squadra, e fornisce una misura della forza complessiva di attacco e difesa. Un xGD positivo indica che una squadra sta creando più occasioni di qualità elevate di quelle che sta concedendo, mentre un

xGD negativo indica il contrario. (Felices, 2023) È stata analizzata la differenza reti effettiva di ciascuna delle 20 squadre facenti parte del campionato di Serie A relativamente alla stagione 2021/2022 ed è stata messa a confronto con la differenza reti che si prevedeva si sarebbe verificata (expected goals difference). Per ogni squadra è stato calcolato il delta, ossia lo scarto tra la differenza reti effettiva e la differenza reti prevista per il campionato.

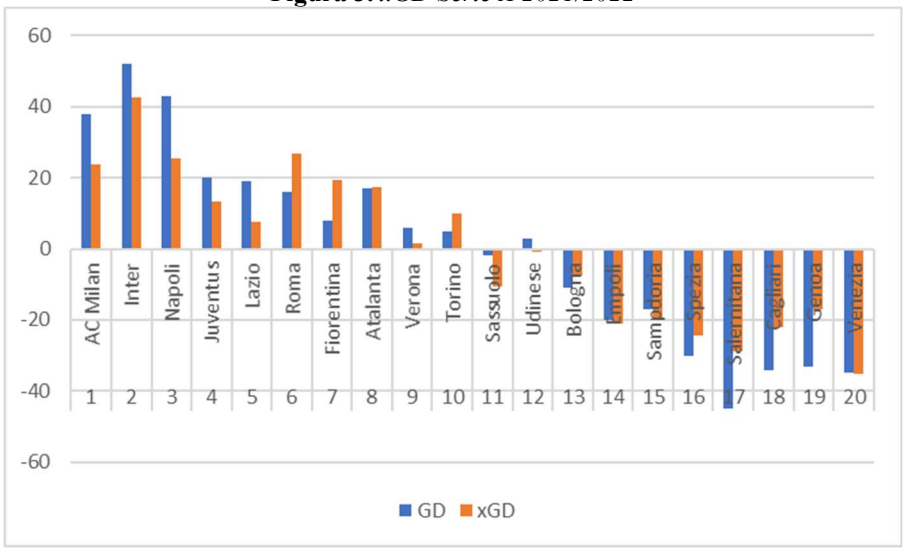
Tabella 3. *GD e xGD Serie A 2021/2022*

Posizione	Team	GD	xGD	DELTA
1	AC Milan	38	23,8	+14,2
2	Inter	52	42,5	+9,5
3	Napoli	43	25,3	+17,7
4	Juventus	20	13,4	+6,6
5	Lazio	19	7,6	+11,4
6	Roma	16	26,8	-10,8
7	Fiorentina	8	19,4	-11,4
8	Atalanta	17	17,2	-0,2
9	Verona	6	1,4	+4,6
10	Torino	5	9,8	-4,8
11	Sassuolo	-2	-10,7	+8,7
12	Udinese	3	-1	+4
13	Bologna	-11	-7,7	-3,3
14	Empoli	-20	-21,2	+1,2
15	Sampdoria	-17	-19,3	+2,3
16	Spezia	-30	-24,3	-5,7
17	Salernitana	-45	-28,7	-16,3
18	Cagliari	-34	-21,9	-12,1
19	Genoa	-33	-16,9	-16,1
20	Venezia	-35	-35,3	+0,3

Fonte dati: Società «Opta Sports» (2022)

Dall'analisi svolta (Fig. 3) risulta che Milan, Inter, Napoli, Juventus e Lazio hanno ottenuto risultati superiori alle aspettative, con GD significativamente più alti rispetto agli xGD. Hanno avuto, invece, una performance in linea con le aspettative, con GD vicini agli xGD, le squadre dell'Atalanta, dell'Empoli, della Sampdoria e del Venezia. Roma, Fiorentina, Spezia, Salernitana, Cagliari e Genoa hanno avuto risultati peggiori rispetto alle aspettative, spesso mostrando delta negativi più marcati tra GD e xGD.

Figura 3. *xGD Serie A 2021/2022*



Fonte dati: Società «Opta Sports» (2022)

2.1.6 L'indice degli Expected Points (xPTS)

Gli xPTS assegnano un punteggio da 0 a 3 a ogni squadra in ogni partita, punteggio basato su una serie di parametri (tra cui gli xG e gli xGA) poi convertiti nelle probabilità di vittoria, pareggio e sconfitta. Si tratta di una classifica basata sulle prestazioni della squadra e non sui risultati (Sitografia: 2).

È stata analizzato in numero di punti concretamente ottenuto da ciascuna delle 20 squadre facenti parte del campionato di Serie A relativamente alla stagione 2021/2022 ed è stato messo a confronto con il numero di punti che si prevedeva sarebbero stati ottenuti (expected points). Per ogni squadra è stato calcolato il delta, ossia la differenza tra i punti effettivi ottenuti durante il campionato e i punti attesi.

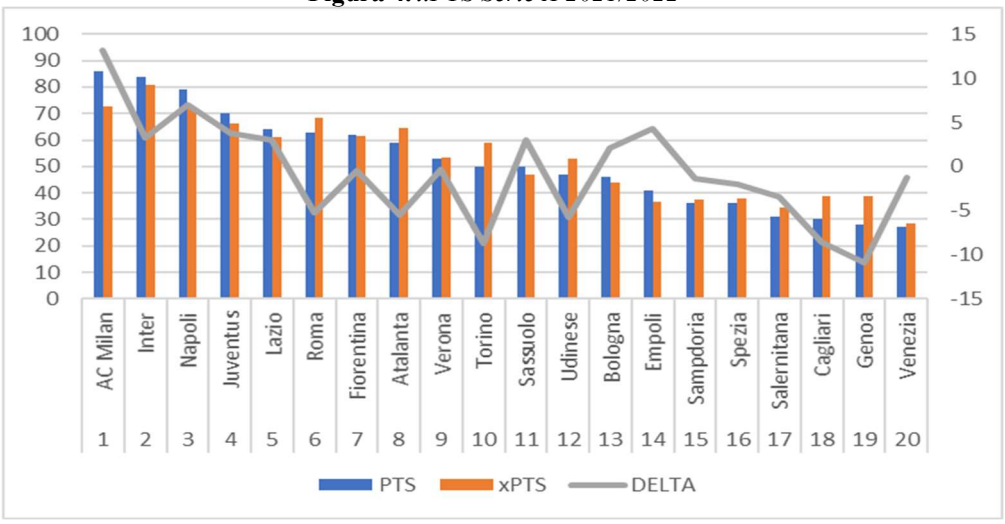
Dall'analisi svolta (Fig. 4) è risultato che squadre come Milan, Inter, Napoli e Juventus hanno superato le aspettative in termini di punti ottenuti, mentre squadre come Salernitana, Cagliari, Genoa e Venezia hanno performato al di sotto delle aspettative. Questa analisi è utile per comprendere l'efficacia e l'efficienza delle squadre nel convertire le opportunità di gioco in punti effettivi. Le squadre di alta classifica tendono ad avere delta positivi o neutri, mentre le squadre di bassa classifica mostrano tendenzialmente delta negativi. Questo indica una maggiore capacità delle squadre di alta classifica di superare le aspettative, mentre le squadre di bassa classifica tendono a non raggiungere gli expected points.

Tabella 4. *PTS e xPTS Serie A 2021/2022*

Posizione	Team	PTS	xPTS	DELTA
1	AC Milan	86	72,82	+13,18
2	Inter	84	80,70	+3,30
3	Napoli	79	72,03	+6,97
4	Juventus	70	66,21	+3,79
5	Lazio	64	60,96	+3,04
6	Roma	63	68,18	-5,18
7	Fiorentina	62	61,56	-0,44
8	Atalanta	59	64,44	-5,44
9	Verona	53	53,32	-0,32
10	Torino	50	58,73	-8,73
11	Sassuolo	50	46,95	+3,05
12	Udinese	47	52,75	-5,75
13	Bologna	46	43,88	+2,12
14	Empoli	41	36,69	+4,31
15	Sampdoria	36	37,39	-1,39
16	Spezia	36	37,96	-1,96
17	Salernitana	31	34,45	-3,45
18	Cagliari	30	38,62	-8,62
19	Genoa	28	38,93	-10,93
20	Venezia	27	28,29	-1,29

Fonte dati: Sito web «Understat» (2022)

Figura 4. *xPTS Serie A 2021/2022*



Fonte dati: Sito web «Understat» (2022)

2.2 La previsione dell'andamento delle partite

L'analisi statistica riveste un ruolo fondamentale nella previsione dell'andamento delle partite. Innanzitutto, consente di identificare delle tendenze; analizzando i dati storici, si possono individuare schemi ricorrenti nelle prestazioni delle squadre e dei singoli giocatori, ad esempio si può osservare che una squadra ottiene più vittorie quando gioca in casa oppure che un giocatore sta attraversando un periodo in cui è particolarmente performante. Un altro aspetto rilevante riguarda lo sviluppo di modelli predittivi; attraverso l'utilizzo di algoritmi matematici e tecniche di machine learning, gli analisti possono elaborare previsioni accurate sugli esiti delle partite, combinando dati storici con variabili attuali. Questo tipo di analisi può influenzare le decisioni strategiche degli allenatori e dei dirigenti.

2.2.1 La distribuzione di Poisson

Un modello molto utilizzato nella previsione dell'andamento delle partite è quello di Poisson (Inan, 2020; Menale, 2024; Nguyan, 2023; Şenol, 2021). Il processo di Poisson è utilizzato per modellare l'occorrenza di fenomeni su un intervallo, che nella maggior parte dei casi rappresenta il tempo. Ci sono diverse caratteristiche del processo di Poisson che possono essere osservate, tra cui il numero di eventi che avvengono in un dato periodo di tempo, il tempo che intercorre tra i suddetti eventi e quando gli eventi si verificano. La distribuzione di Poisson esprime il numero di occorrenze di un evento in un dato periodo di tempo, con un parametro di tasso di occorrenza λ. La funzione di probabilità di una variabile casuale di Poisson X con parametro λ è data da

$$p_X(x) = \frac{e^{-\lambda}\lambda^x}{x!} \;;\; x = 0, 1, 2, \dots \; e \;\; \lambda > 0 \tag{3}$$

dove X rappresenta il numero di occorrenze di un evento in un dato periodo di tempo unitario, e λ è il tasso costante di occorrenza per periodo di tempo. La media e la varianza della variabile casuale di Poisson X sono

$$\mu_X = \lambda \;\; e \;\; \sigma_X^2 = \lambda \tag{4}$$

2.2.2 La distribuzione esponenziale

Un'altra distribuzione utilizzata nella previsione dell'andamento delle partite è la distribuzione esponenziale (Nguyen, 2023); se il numero di occorrenze per intervallo di tempo è illustrato da Poisson, la descrizione della durata del tempo che trascorre tra le occorrenze è fornita dalla distribuzione esponenziale. Se si ha una variabile casuale non negativa X che rappresenta il tempo che intercorre fino alla prossima

occorrenza in un processo di Poisson, allora X segue una distribuzione esponenziale con funzione di probabilità

$$f_X(x) = \lambda e^{-\lambda x} = \frac{1}{\beta} e^{-\frac{1}{\beta}x} \; ; x \geq 0 \tag{5}$$

dove λ rappresenta il tasso medio di occorrenza e β è il tempo medio che intercorre tra le occorrenze. La media e la varianza di una variabile casuale X distribuita in modo esponenziale sono

$$\mu_X = \frac{1}{\lambda} = \beta \;\; e \;\; \sigma_X^2 = \frac{1}{\lambda^2} = \beta^2 \tag{6}$$

2.2.3 La distribuzione uniforme continua

Se un processo di Poisson esprime un numero finito di eventi in un dato intervallo di tempo, allora gli istanti di tempo in cui si verificano quegli eventi sono distribuiti uniformemente su quell'intervallo. La distribuzione uniforme continua (Nguyen. 2023) è una distribuzione di probabilità che assegna a ciascun risultato possibile la medesima probabilità, il che significa che la sua densità di probabilità è la stessa in ogni punto di un intervallo $[A, B]$. Una variabile casuale continua X è uniformemente distribuita su $[A, B]$ se la sua funzione di densità di probabilità è definita da

$$f_X(x) = \frac{1}{B-A} \;\; ; \;\; A \leq x \leq B \tag{7}$$

Inoltre, X ha media e varianza

$$\mu_X = \frac{A+B}{2} \;\; ; \;\; \sigma_X^2 = \frac{(B-A)^2}{12} \tag{8}$$

Si assume che la segnatura dei gol nel calcio possa essere descritta da un processo di Poisson. Se la segnatura dei gol per una squadra avviene a un certo ritmo in un dato periodo di tempo, allora una distribuzione di Poisson può essere utilizzata per modellare il numero di gol segnati. Inoltre, il tempo di attesa (in minuti) che intercorre tra gol successivi può essere descritto utilizzando una distribuzione esponenziale.

3. Applicazioni

Per analizzare la relazione tra il numero di gol segnati e la distribuzione di Poisson, è stato preso come caso di studio quello del Manchester United (MU) (Nguyen, 2023). La variabile dei gol è stata divisa in quattro livelli: 0, 1, 2, 3 e 4 o più gol ed è stato calcolato il numero di partite dal 1992 al 2018 che hanno avuto quei valori di

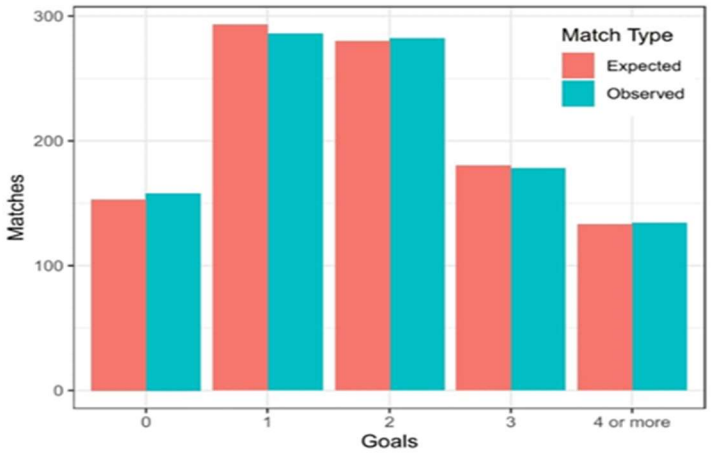
gol. È stata ricavata la probabilità che il Manchester United potesse segnare ogni singolo valore di gol, utilizzando la funzione di probabilità di una distribuzione di Poisson con media $\lambda = 1{,}916$ e poi sono state moltiplicate le probabilità per il numero totale di partite $n = 1038$ (Tab. 5), per ottenere il numero atteso di partite per ciascuna categoria di numero di gol. I conteggi per il numero osservato e atteso di partite sono molto vicini l'uno all'altro (Tab. 6 e Fig. 5). I risultati del test di bontà di adattamento Chi-quadrato utilizzato confermano ulteriormente che non c'è una differenza significativa tra i valori previsti e la distribuzione empirica, pertanto il numero di gol segnati dal Manchester United segue una distribuzione di Poisson.

Tabella 5. *Statistiche descrittive del numero di gol segnati dal Manchester United (1992-2018)*

Min	Q_1	Median	Q_3	Max	Mean	Sd	n
0	1	2	3	9	1.916	1.405	1.038

Fonte: Rivista "The New England Journal of Statistics in Data Science" (2023)

Figura 5. *Confronto, per ogni valore di gol, tra il numero effettivo di partite con quello previsto (1992-2018)*



Fonte: Rivista "The New England Journal of Statistics in Data Science" (2023)

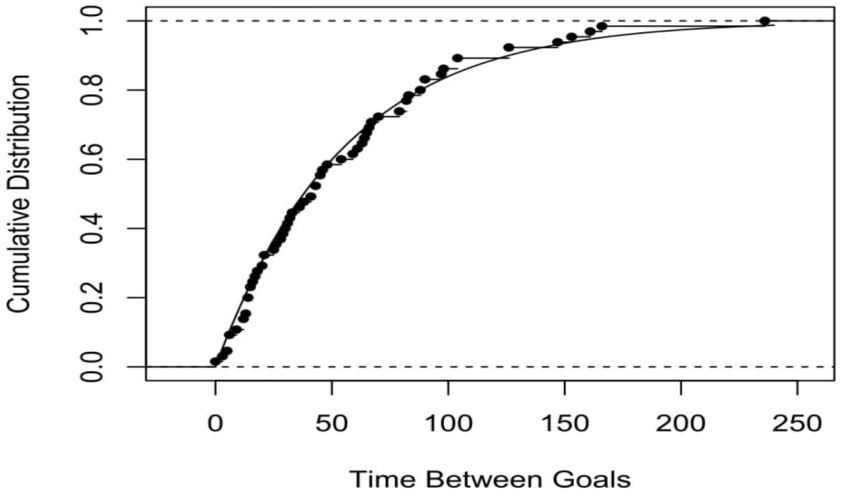
Tabella 6. *Frequenze osservate e previste del numero di partite per ogni valore di gol, e corrispondenti probabilità di Poisson (1992-2018)*

Goals	Probability	Observed	Expected
0	0.147	158	153
1	0.282	286	293
2	0.270	282	280
3	0.173	178	180
4 or more	0.128	134	133

Fonte: Rivista "The New England Journal of Statistics in Data Science" (2023)

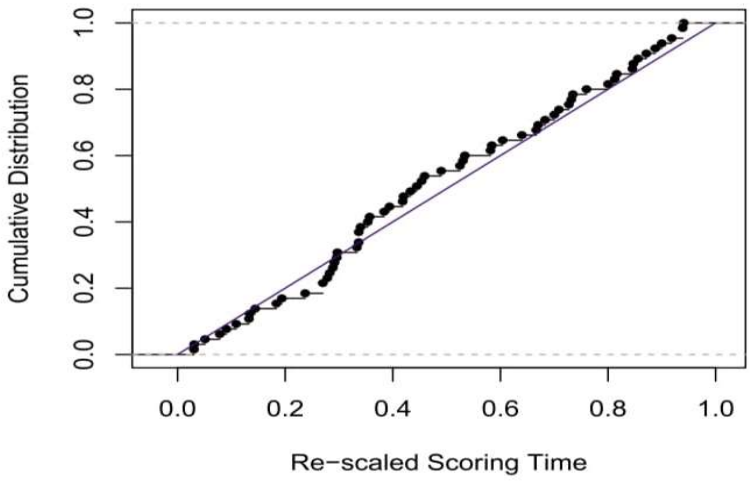
L'esempio del Manchester United è stato impiegato per verificare anche le connessioni tra il tempo intercorso tra i gol in una stagione e la distribuzione esponenziale, e i minuti di segnatura dei gol in una partita e la distribuzione uniforme standard. Nel caso di studio, è stata tracciata la curva di distribuzione cumulativa dei dati e questi ultimi sono stati confrontati con la distribuzione esponenziale ed uniforme (Figg. 6 e 7).

Figura 6. *Curva di distribuzione cumulativa del tempo intercorso tra i gol e funzione di distribuzione esponenziale (1992-2018)*



Fonte: Rivista "The New England Journal of Statistics in Data Science" (2023)

Figura 7. *Curva di distribuzione cumulativa dei minuti di segnatura dei gol in una partita e funzione della distribuzione uniforme standard (1992-2018)*



Fonte: Rivista "The New England Journal of Statistics in Data Science" (2023)

Dalle Fig. 6 e 7 si evince che le differenze tra le distribuzioni empiriche e teoriche analizzate in ciascuna figura sono marginali, il che è una conferma per credere che i dati sul punteggio dei gol seguano le distribuzioni specificate. Successivamente, è stato condotto un test di bontà di misura di Kolmogorov-Smirnov, i cui risultati hanno confermato che il tempo intercorso tra i gol e il tempo di segnatura seguono rispettivamente le distribuzioni esponenziale e uniforme.

4. Prospettive future: l'impiego dell'intelligenza artificiale in ambito calcistico

Negli ultimi anni, l'analisi dei dati ha trasformato il calcio, cambiando il modo in cui i club studiano gli avversari, trovano nuovi acquisti e migliorano le prestazioni dei giocatori. In questo momento storico viviamo un altro grande cambiamento dovuto alla crescita dell'impiego dell'intelligenza artificiale in questo settore.

4.1 Scouting

L'intelligenza artificiale nel calcio viene soventemente impiegata per semplificare il processo di scouting. Decidere se ingaggiare o meno un giocatore richiede un'attenta analisi dei dati sulle prestazioni atletiche, tecniche, cognitive e psicometriche. Sfruttando il machine learning, gli osservatori sono in grado di analizzare rapidamente e accuratamente vaste quantità di dati ottenendo, così, un aiuto nell'effettuare lo scouting di un'ampia gamma di giocatori. La piattaforma di scouting calcistico AiScout utilizza dati esistenti sui giocatori professionisti come parametro di confronto per analizzare i giocatori non firmati, offrendo agli osservatori la possibilità di stilare rapidamente una lista ristretta di giocatori da monitorare di persona. Questa tecnologia è stata già valutata positivamente da FIFA, che ha assegnato alla piattaforma un premio World Football Summit per l'innovazione (New Jack, 2022).

4.2 Strategia

Ci sono centinaia di passaggi durante una partita e se una squadra volesse sviluppare una strategia per prepararsi contro i propri avversari dovrebbe esaminare video e calcolare statistiche. Attualmente esistono aziende specializzate che analizzano le riprese registrate delle partite impiegando la visione artificiale, vendendone i risultati a prezzi eccessivi, portando, così, i ricercatori a concentrarsi sulla previsione di come si muovono i giocatori quando non sono nell'inquadratura. Recentemente il Liverpool FC ha collaborato con DeepMind per adottare questo approccio, utilizzando una

combinazione di apprendimento statistico, comprensione dei video e teoria dei giochi. I ricercatori hanno analizzato più di 12.000 calci di rigore eseguiti dai giocatori in Europa, raggruppandoli in base a come avrebbero calciato e se avessero segnato. L'analisi ha mostrato che i centrocampisti hanno una tendenza a calciare nell'angolo sinistro e ad utilizzare il loro lato più forte. Inoltre, parare un rigore è molto difficile per un portiere; ha solo un momento per decidere se e dove tuffarsi, pertanto, oggi i portieri ricevono statistiche su dove di solito i giocatori tendono a calciare i rigori. Ci sono anche studi dedicati ai calci di punizione, su come predisporre la barriera per dare al portiere la migliore visione possibile. Altri studi si concentrano sull'analisi di quando il giocatore dovrebbe calciare, quando dovrebbe passare il pallone o tenerlo, quando dovrebbe iniziare a correre verso la porta, e così via. Potrebbe sembrare che questi studi finora non abbiano avuto un impatto e siano solo ancora allo stadio della ricerca, invece, hanno contribuito a far ridurre la distanza da cui un giocatore tenta di segnare. È stato chiaramente dimostrato che più la distanza aumenta più la probabilità di segnare diminuisce. Supportate da dati e analisi, le squadre spingono i giocatori a tirare da distanze più ravvicinate ed evitare lunghe traversate nell'area avversaria (Ks Manu, 2020; Raieli, 2022; Thoman, 2024; Valtieri, 2024).

4.3 Decisioni degli arbitri

Il VAR è stato un passo importante verso decisioni migliori, ma la FIFA per rendere l'arbitraggio ancora più preciso ha iniziato a utilizzare l'IA per assistere gli ufficiali di gara. La Tecnologia Semiautomatizzata Offside (SAOT) è un nuovo sistema che utilizza 12 telecamere sparse attorno allo stadio per tracciare la posizione del pallone e di ciascun giocatore 50 volte al secondo. Un sensore posto all'interno del pallone da gioco registra l'esatto momento in cui questo viene calciato. Quando il sistema rileva un fuorigioco, invia un'allerta agli ufficiali della VAR, i quali possono quindi controllare le riprese video per verificare se si tratta di un fuorigioco o meno (Sitografia: 1, Ks, 2020; Nadikattu 2020)

4.4 Mantenere in forma i giocatori

Gli impegni dei giocatori, in particolare di quelli che affrontano le richieste combinate di competizioni domestiche, continentali e internazionali, richiedono il monitoraggio della forma fisica e l'individuazione tempestiva di eventuali rischi di infortunio. Zone7 è una società dati americana che utilizza l'IA per analizzare i dati e rilevare modelli che aiutino i giocatori a massimizzare i propri livelli di performance evitando infortuni (Sitografia: 1, Nadikattu, 2020).

5. Conclusioni

La statistica svolge un ruolo fondamentale e in continua crescita nella società moderna. I diversi settori in cui viene applicato il metodo statistico vanno ben oltre le questioni finanziarie ed economiche; professioni nel campo della medicina, delle scienze sociali, dello sport e molti altri ambiti si avvalgono del metodo statistico per sviluppare strategie ed effettuare previsioni affidabili; le analisi statistiche aiutano a prendere decisioni informate e consapevoli per la soluzione di problemi concreti partendo dai dati, consentendo di cogliere nuove opportunità in qualsiasi settore. L'aumento dell'impiego della statistica negli ultimi anni è stato anche favorito dallo sviluppo di strumenti e programmi digitali all'avanguardia che hanno reso più semplici le analisi su grandi volumi di dati. L'era digitale ha reso l'uso delle statistiche più accessibile a individui, piccole imprese e altre organizzazioni. L'intelligenza artificiale ha in particolare rivoluzionato l'analisi dei dati in ambito sportivo. Sebbene le misurazioni e l'analisi quantitativa abbiano avuto un ruolo centrale per lungo tempo, l'I.A. sta cambiando in modo significativo come i giochi vengano progettati, giocati e coinvolgano il pubblico. Questa tendenza si sta diffondendo in sport come baseball, tennis, calcio, football americano, basket e molti altri. La statistica, sostenuta dall'avanzamento tecnologico, è diventata fondamentale nel mondo dello sport, contribuendo in modo significativo al miglioramento delle performance di atleti e squadre. Allenatori e giocatori ricercano costantemente intuizioni che possano ottimizzare il loro rendimento, mentre gli arbitri necessitano di supporto per prendere decisioni fondamentali nei momenti decisivi. L'impiego di metodologie statistiche e dell'intelligenza artificiale sta rapidamente crescendo, consentendo analisi in tempo reale volte a perfezionare le strategie di gioco e potenziare le prestazioni complessive. Il rapido accesso a dati dettagliati riguardanti tattiche e situazioni di gioco, facilita i professionisti del settore nella formulazione di piani mirati e nell'analisi approfondita delle prestazioni, fornendo strumenti per valutare punti di forza e debolezza sia della propria squadra, sia degli avversari. In un panorama calcistico in costante evoluzione, l'impiego di un numero crescente di dati, statistiche e nuove metodologie si configura come la chiave per il successo nel futuro.

Riferimenti bibliografici

Carey, M., e Worville, T. (2021). The Athletic's Football Analytics Glossary: Explaining XG, PPDA, Field Tilt and How to Use Them. *The Athletic*, *The New York Times*.

Comana, A. (2022). Cosa sono gli Expected Goals e a cosa servono? Le 5 statistiche avanzate più utilizzate per capire meglio il calcio. *Eurosport*.

Felices, A. M. (2023). What is Expected Goals (XG) and how is it changing the way we analyze football?. *Medium*.

Fusi, F. (2016). Cosa sono gli Expected Goals. *L'Ultimo Uomo*.

Hewitt, J. H., Karakuş, O. (2023). A Machine Learning approach for player and position adjusted Expected Goals in football (Soccer). *Franklin Open*, 4.

Inan, T. (2020). Using Poisson Model for goal prediction in European Football. *Journal of Human Sport and Exercise*, 16.

Ks, M. (2020). Applications of Artificial Intelligence in the game of football: the global perspective. *Researchers World – Journal of Arts Science & Commerce*, 11: 18–29.

Mead, J., O'Hare, A., McMenemy, P. (2023). Expected Goals in football: improving model performance and demonstrating value. *PLoS ONE*, 18(4).

Menale, M. (2024). Expected Goals: La Matematica nel calcio. *Maddmaths!*.

Menale, M. (2024). Quanti goal in una Partita? Risponde Poisson. *Maddmaths*!.

Nadikattu, R. R. (2020). Implementation of new ways of Artificial Intelligence in sports. *Journal of Xidian University*, 14(5): 5983 – 5997.

New, J. (2022). Will AI change football?. *Technology.org*.

Nguyen, Q. (2023). Poisson modeling and predicting english Premier League goal scoring. *The New England Journal of Statistics in Data Science*, 1(1): 95–101.

Raieli, S. (2022). Is AI changing football?. *Medium*.

Şenol, Ç. (2021). Predicting the number of goals in football matches with the Poisson distribution: example of Spain La Liga. *Scholars Journal of Physics, Mathematics and Statistics*, 8(8): 133-142.

Thoman, F. (2024). Intelligenza artificiale nel calcio, ka Collaborazione tra Google e Liverpool. *Corriere Della Sera*.

Trabucchi, M. (2022). Data analytics negli sport, un mercato da 3 miliardi di dollari. *Il Sole 24 ORE*.

Valtieri, S. (2024). Il Liverpool "studia" i calci d'angolo con l'Intelligenza Artificiale di Google. *Focus*.

Sitografia

1. analyisport.com/insights/how-is-artificial-intelligence-being-used-in-football/.
2. www.calcioefinanza.it/2018/03/19/statistica-applicata-al-calcio-expected-goals/.
3. statsbomb.com/it/metriche-avanzate/cosa-sono-gli-expected-goals-xg/.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 83-97

Analisi territoriale dei low-income earners in Italia

Monica Carbonara[1], Sara Casacci[1]*

[1]*Istat - Istituto Nazionale di Statistica.*

Riassunto: Il fenomeno dei "lavoratori poveri" ha suscitato attenzione sia nel dibattito politico sia nella ricerca socioeconomica degli ultimi anni, grazie alla sua crescita diffusa. Questo lavoro propone un'analisi delle caratteristiche dei lavoratori a basso reddito sfruttando il potenziale informativo degli archivi amministrativi integrati. I dati contengono informazioni sul reddito e sull'occupazione di tutti i componenti della famiglia; questo rende possibile analizzare lo svantaggio economico sia a livello individuale sia familiare. In particolare, il paper descrive (1) la relazione che esiste tra la probabilità di essere un lavoratore dipendente a basso reddito in Italia e un set di variabili socio-demografiche e (2) la relazione tra la probabilità di un lavoratore a basso reddito di vivere in una famiglia economicamente svantaggiata e un insieme di caratteristiche relative alla famiglia di appartenenza. Inoltre, viene proposta un'analisi del fenomeno ad un livello territoriale fine, con l'obiettivo di fornire elementi utili per individuare aree particolarmente vulnerabili.

Keywords: lavoratori a basso reddito; archivi amministrativi; regressione logistica; analisi territoriale.

1. Introduzione

Negli ultimi anni è cresciuto il fenomeno dei "*working poor*", ossia di coloro che pur lavorando percepiscono un reddito inferiore alla soglia di povertà. Secondo i dati ufficiali, nell'Unione Europea, nel 2017 il 9,4% degli occupati in età 18-64 an-

* Autore corrispondente: casacci@istat.it
Il lavoro qui descritto è frutto di un progetto comune, ma Monica Carbonara ha provveduto alla redazione dei paragrafi 1, 2.2, 3.2 e 4 mentre Sara Casacci ha redatto i paragrafi 2.1 e 3.1.

ni viveva al di sotto della soglia di povertà relativa. Questa percentuale per l'Italia era del 12,2%, in crescita costante anche negli ultimi anni, a differenza della maggior parte degli altri paesi (Saraceno, 2020). La mancanza di lavoro, che resta la prima causa di povertà, assieme alla scarsa qualità del lavoro (basse retribuzioni, poche garanzie contributive, irregolarità delle carriere, ecc.,) sembrano delineare un nuovo preoccupante problema di politica sociale che comporta un significativo rischio di povertà individuale per i lavoratori e l'intero nucleo familiare.

Nel dibattito pubblico, la povertà lavorativa è spesso collegata a salari insufficienti, mentre è il risultato di un processo che va oltre il salario e che riguarda anche i tempi di lavoro (quante ore si lavora abitualmente a settimana e quante settimane si lavora nel corso di un anno), la composizione familiare (in particolare quante persone percepiscono un reddito all'interno del nucleo) e l'azione redistributiva dello Stato. A livello individuale, infatti, il rischio di basse retribuzioni è particolarmente elevato per i lavoratori occupati solo pochi mesi all'anno, per i lavoratori a tempo parziale e per i lavoratori autonomi. A livello familiare, a questi fattori di rischio si aggiungono anche la composizione del nucleo e il numero di percettori di reddito.

Numerosi studi (Carrieri, 2012; Raitano *et al*., 2019a, Saraceno, 2018) sul tema della distribuzione del reddito e della povertà lavorativa hanno utilizzato dati di natura campionaria, con i conseguenti limiti di significatività dei dati quando il livello di dettaglio territoriale si fa molto fine. L'utilizzo di singole fonti amministrative (Franzini e Raitano, 2019; Bavaro, 2022) consente di scendere ad un livello territoriale più fine rispetto alle indagini campionarie, ma non di integrare le informazioni individuali con quelle familiari. Inoltre, l'uso di un singolo archivio permette di focalizzarsi solamente su sotto-insieme di lavoratori, in genere alcune categorie di lavoratori dipendenti del settore privato.

Questo lavoro[1] si pone l'obiettivo di analizzare il fenomeno dei *low-income earners* nei comuni italiani, di individuare le principali determinanti del rischio della povertà lavorativa e le aree particolarmente esposte al fenomeno sfruttando il potenziale informativo degli archivi amministrativi integrati.

In linea con le definizioni utilizzate a livello europeo, la soglia di povertà è fissata al 60% del reddito mediano[2]. Dal momento che i le fonti di natura amministrativa presentano dei disallineamenti definitori rispetto alle indagini campionarie,

[1] Il presente contributo rappresenta un aggiornamento con dati più recenti e un approfondimento di Carbonara e Casacci (2024).

[2] Eurostat fissa la soglia del rischio di povertà al 60% della mediana nazionale disponibile equivalente reddito (dopo i trasferimenti sociali).

non è appropriato usare il termine "povertà" in relazione ai dati amministrativi. Si adottano le seguenti definizioni:

- Lavoratore dipendente: individuo, che negli archivi amministrativi presenta almeno un segnale di occupazione ad ottobre 2020, percepisce redditi da lavoro dipendente, e presenta segnali di attività lavorativa per almeno sei mesi l'anno.
- Lavoratore a basso reddito: lavoratore dipendente, come definito al punto precedente, con reddito da lavoro dipendente inferiore o uguale al 60% del reddito mediano da lavoro dipendente.
- Famiglia: insieme di persone legate da vincolo di matrimonio, parentela, affinità, adozione, tutela o convivenza e iscritte nei registri comunali.
- Famiglia a basso reddito (famiglie economicamente svantaggiate): famiglia con reddito familiare equivalente lordo inferiore al 60% del reddito equivalente lordo mediano.

Il presente lavoro è articolato come segue. Nel paragrafo 2 vengono descritti i dati utilizzati e il metodo applicato. Il paragrafo 3 illustra i risultati ottenuti, mentre nel paragrafo 4 si presentano le conclusioni, le criticità e i possibili sviluppi futuri.

2. Materiali e metodi

2.1 Fonte dei dati

La fonte dei dati è la collezione integrata di microdati "Condizioni socio-economiche delle famiglie ARCH.I.M.E.DE", dell'Istituto Nazionale di Statistica. Si tratta di una collezione di microdati realizzata con il fine di studiare le condizioni socio-economiche di individui e famiglie in Italia a livello comunale (Garofalo, 2014). I dati si riferiscono al 2020.

Questa raccolta di microdati si basa sull'integrazione di diverse fonti amministrative e registri statistici e contiene una molteplicità di informazioni relative a caratteristiche socio-demografiche, occupazione, istruzione e reddito. In particolare, le variabili occupazionali derivano dall'integrazione di più fonti previdenziali, le variabili di reddito dall'integrazione della Banca Dati Reddituale del Ministero dell'Economia e delle Finanze con altre fonti quali il Casellario Centrale dei Pensionati dell'Istituto Nazionale di Previdenza Sociale (INPS) e l'Archivio dei Trattamenti Monetari Non Pensionistici (INPS). Le informazioni derivate da fonti amministrative consentono una copertura completa delle popolazioni di riferimento (l'universo di individui e famiglie residenti in Italia). Si segnala, tuttavia, che vi sono alcune lacune informative e la comparabilità con le indagini (come la Rileva-

zione campionaria sulle forze di lavoro o l'indagine sulle condizioni di vita EU-SILC) non è garantita. In particolare, i microdati coprono solo l'occupazione regolare e forniscono un reddito al lordo delle imposte (il reddito non è quindi influenzato dagli effetti redistributivi della tassazione). Inoltre, il reddito potrebbe essere affetto da sottocopertura, ad esempio a causa di evasione fiscale o scarsa *compliance*.

Poiché le informazioni sui lavoratori dipendenti sono considerate più affidabili rispetto a quelle sui lavoratori non dipendenti, l'analisi viene condotta sulla prima categoria di lavoratori.

2.2 Metodo

Per descrivere la relazione che esiste tra la probabilità di essere un lavoratore dipendente con reddito inferiore o uguale al 60% della mediana e un insieme di variabili socio-demografiche, è stato utilizzato un modello di regressione logistica. Dal momento che non tutti *low-income earners* vivono in una famiglia a basso reddito, un secondo modello di regressione logistica è stato adoperato per valutare se e quali caratteristiche della famiglia possano mediare sullo stato di svantaggio economico derivante da un basso reddito da lavoro dell'individuo. In particolare, il secondo modello è stato eseguito su un sottoinsieme dei dipendenti con reddito inferiore o uguale al 60% della mediana, per stimare la probabilità che anche la famiglia di appartenenza si trovi in una situazione di svantaggio economico, attraverso un determinato set di variabili indipendenti, quali il numero di percettori di reddito, l'intensità di lavoro della famiglia, la presenza di minori in famiglia.

Per la selezione del regressori, in entrambi i modelli, è stata eseguita una procedura *stepwise*. La procedura costruisce il modello in modo iterativo, aggiungendo o rimuovendo variabili che acquisiscono o perdono significato ad ogni passaggio. I parametri sono stati stimati utilizzando il metodo della massima verosimiglianza, secondo il quale i valori preferiti dei parametri sono quelli che massimizzano la probabilità di ottenere i dati osservati (funzione log-verosimiglianza).

Per visualizzare la distribuzione territoriale di un fenomeno e per individuare aree di maggiore o minore intensità sono state realizzate mappe tematiche con valori grezzi raggruppati in quartili ("*quartile maps*"). Questa soluzione è comunemente adottata per visualizzare la distribuzione territoriale di un fenomeno e individuare aree di maggiore o minore intensità (Cariello e Carbonara, 2019).

3. Risultati

3.1 Le determinanti del fenomeno

Secondo i dati utilizzati, circa 16,2 milioni di persone hanno un segnale amministrativo di lavoro dipendente nel mese di ottobre e di lavoro per almeno sei mesi nel 2020. L'incrocio fra la dimensione individuale e quella familiare suddivide l'universo dei lavoratori dipendenti in quattro gruppi (Tab.1). Il 76,7% dei lavoratori cade al di fuori dell'area di svantaggio economico, mentre il 7,6% mostra uno svantaggio economico sia a livello individuale che familiare.

Tabella 1. *Lavoratori dipendenti per reddito da lavoro e reddito familiare (%).*

		Lavoratore	
		Con reddito da lavoro superiore al 60% del reddito mediano	Con reddito da lavoro inferiore o uguale al 60% del reddito mediano
Famiglia	Con reddito complessivo superiore al 60% del reddito mediano	76,7	11,7 (A)
	Con reddito complessivo inferiore o uguale al 60% del reddito mediano	4,0 (B)	7,6 (C)

Fonte: elaborazione sui dati Condizioni socio-economiche delle famiglie ARCH.I.M.E.DE

3.1.1 Le caratteristiche individuali dei low-income earners

I risultati del primo modello di regressione logistica, volto a stimare la probabilità di essere un *low-income earner*, mostrano che tipologia di contratto di lavoro, sesso, livello di istruzione e regione di residenza sono le variabili indipendenti più importanti. Inoltre, cittadinanza straniera, status di studente universitario, numero di componenti del nucleo familiare e stato civile sono variabili che migliorano significativamente l'adattamento del modello.

I tre test (Likelihood Ratio, Score e Wald) effettuati per verificare l'ipotesi nulla che tutte le variabili esplicative abbiano un coefficiente di regressione pari a zero sono significativi, per cui si può trarre la conclusione che almeno uno dei coefficienti di regressione del modello sia diverso da zero. Inoltre, i test di ipotesi condotti indicano che tutte le variabili incluse nel modello contribuiscono a un miglioramento significativo dell'adattamento. La Tabella 2 riporta le stime dei parametri e i corrispondenti errori standard e il p-value, utilizzato per verificare l'ipotesi nulla che il coefficiente di regressione di ogni singolo predittore sia uguale a zero, date le altre variabili esplicative del modello.

Tabella 2. *Analisi delle stime di massima verosimiglianza*

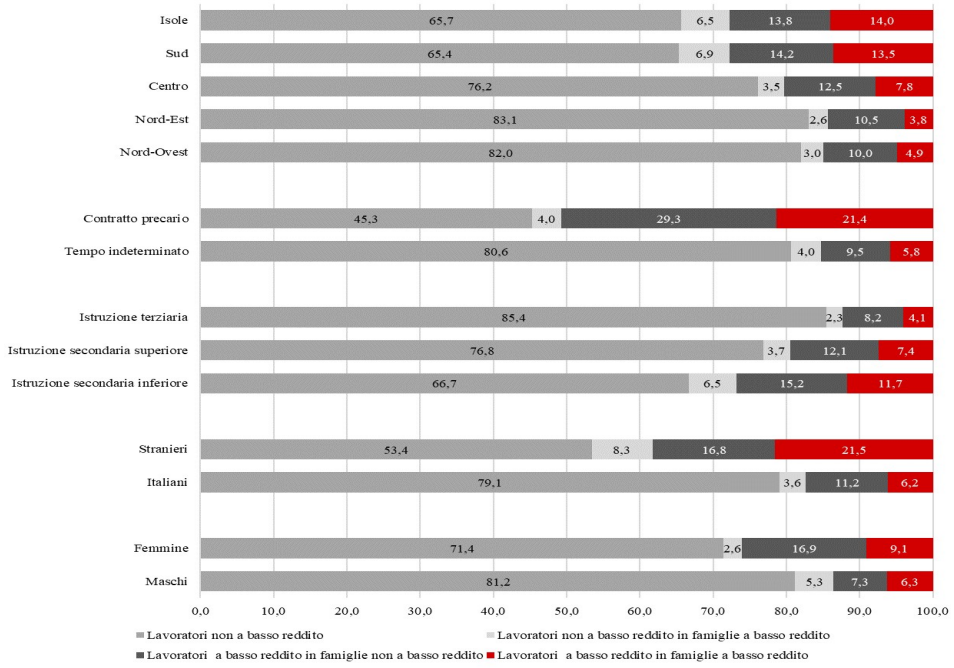
Parametro		Stima	Errore standard	Pr > ChiQuadr di Wald
Intercetta		0,630	0,006	<,0001
Regione di residenza	Valle d'Aosta	-0.444	0,015	<,0001
	Bolzano	-0,847	0,015	<,0001
	Piemonte	-0,421	0,002	<,0001
	Lombardia	-0,463	0,002	<,0001
	Veneto	-0,422	0,003	<,0001
	Friuli-Venezia Giulia	-0,472	0,005	<,0001
	Liguria	-0,126	0,005	<,0001
	Emilia-Romagna	-0,578	0,003	<,0001
	Toscana	-0,161	0,003	<,0001
	Umbria	-0,075	0,006	<,0001
	Marche	-0,114	0,004	<,0001
	Lazio	0,260	0,002	<,0001
	Abruzzo	0,237	0,005	<,0001
	Molise	0,526	0,009	<,0001
	Campania	0,716	0,003	<,0001
	Puglia	0,595	0,003	<,0001
	Basilicata	0,477	0,007	<,0001
	Calabria	0,810	0,004	<,0001
	Sicilia	0,700	0,003	<,0001
	Sardegna	0,254	0,004	<,0001
Sesso	Maschio	-0,581	0,001	<,0001
Stato civile	Celibe/nubile	0,042	0,001	<,0001
	Sposato	-0,132	0,001	<,0001
Cittadinanza	Italiana	-0,356	0,001	<,0001
Numero di componenti		0,070	0,001	<,0001
Titolo di studio	Fino al diploma di scuola media inferiore	0,918	0,003	<,0001
	Fino al diploma di scuola media superiore	0,237	0,003	<,0001
	Terziario	-0,290	0,009	<,0001
Età		-0,034	0,000	<,0001
Studente universitario	No	-0,314	0,002	<,0001
Contratto precario	No	-0,663	0,001	<,0001

Considerando congiuntamente il reddito da lavoro dei lavoratori dipendenti e il reddito equivalente delle loro famiglie (Tab.1), sono stati individuate quattro sotto-popolazioni di interesse:

1) lavoratori non a basso reddito;
2) lavoratori non a basso reddito in famiglie a basso reddito;
3) lavoratori a basso reddito in famiglie non a basso reddito;
4) lavoratori a basso reddito in famiglie a basso reddito.

In Figura 1 è riportata la distribuzione dei lavoratori dipendenti nei quattro gruppi in funzione delle determinanti individuate con il modello di regressione. Le condizioni che contribuiscono ad aumentare la probabilità di avere un reddito da lavoro dipendente inferiore o uguale al 60% della mediana sono: essere residente in una regione meridionale (soprattutto Campania, Sicilia, Calabria), essere donna, essere straniero, avere un titolo di studio inferiore al diploma di scuola secondaria superiore, avere un contratto di lavoro precario. I risultati ottenuti sono coerenti con altri lavori sul tema (Carrieri, 2012; Raitano *et al*., 2019b; Bavaro, 2022; Bovini *et al*., 2023).

Figura 1. *Distribuzione percentuale dei quattro gruppi di lavoratori in funzione delle determinanti individuate*



3.1.2 Le caratteristiche familiari dei low-income earners

La distribuzione dei quattro gruppi di lavoratori differenzia non solo i *low-income earners* rispetto ai lavoratori non a basso reddito, ma anche i *low-income earners* che vivono in famiglie economicamente svantaggiate rispetto ai *low-income earners* che vivono in famiglie non a basso reddito. Per comprendere il ruolo della famiglia di appartenenza, è stato svolto un approfondimento volto a confrontare queste ultime due sotto-popolazioni.

I risultati del secondo modello di regressione logistica mettono in luce la presenza di alcune caratteristiche che aumentano il rischio per la famiglia di un *low-income earner* di trovarsi in una situazione di svantaggio economico.

Come per il primo modello, i test effettuati per verificare l'ipotesi nulla che tutte le variabili esplicative abbiano un coefficiente di regressione pari a zero sono significativi e tutte le variabili incluse nel modello contribuiscono a un miglioramento significativo dell'adattamento.

La Tabella 3 mostra l'analisi delle stime di massima verosimiglianza. Anche in questo caso, la dimensione territoriale risulta molto importante: risiedere in una regione del Nord o del Centro costituisce un fattore protettivo, mentre vivere in una regione del Sud, in particolare Campania e Calabria, non lo è.

Le principali variabili che contribuiscono a diminuire o aumentare la probabilità di una famiglia di un *low-income earner* di avere un reddito inferiore o uguale al 60% del reddito mediano sono: il numero di percettori di reddito in famiglia; la fonte principale di reddito; la tipologia familiare; la cittadinanza dei membri della famiglia; il numero di occupati in famiglia; il numero di minori in famiglia; il numero di giovani di età compresa tra 15 e 29 anni in famiglia che non risultano occupati o iscritti a percorsi di istruzione.

Le famiglie in cui sono presenti altri redditi oltre a quello da lavoro del *low-income earner*, e quelle in cui la fonte principale di reddito proviene da pensione o da trasferimento pubblico mostrano un rischio minore di svantaggio. Come era lecito attendersi, le famiglie in cui l'unico percettore di reddito è un lavoratore dipendente a basso reddito hanno una probabilità maggiore di trovarsi in una situazione di svantaggio economico.

Il rischio che il reddito non sia sufficiente a soddisfare i bisogni familiari è più alto, inoltre, per le famiglie monogenitore, per le famiglie con minori e per le famiglie straniere. Si tratta di risultati in linea con i dati derivanti dalle statistiche ufficiali sulla povertà delle famiglie (Istat, 2021).

Tabella 3. *Analisi delle stime di massima verosimiglianza*

Parametro		Stima	Errore standard	Pr > ChiQuadr di Wald
Intercetta		2,274	0,095	<.0001
Regione di residenza	Valle d'Aosta	-0,235	0,006	<.0001
	Bolzano	-0,843	0,019	<.0001
	Piemonte	-0,603	0,033	<.0001
	Lombardia	-0,292	0,005	<.0001
	Veneto	-0,444	0,006	<.0001
	Friuli-Venezia Giulia	-0,498	0,012	<.0001
	Liguria	-0,101	0,009	<.0001
	Emilia-Romagna	-0,419	0,006	<.0001
	Toscana	-0,121	0,006	<.0001
	Umbria	-0,120	0,012	<.0001
	Marche	-0,143	0,009	<.0001
	Lazio	0,264	0,005	<.0001
	Abruzzo	0,198	0,009	<.0001
	Molise	0,525	0,019	<.0001
	Campania	0,862	0,005	<.0001
	Puglia	0,476	0,006	<.0001
	Basilicata	0,261	0,014	<.0001
	Calabria	0,826	0,008	<.0001
	Sicilia	0,594	0,005	<.0001
	Sardegna	0,494	0,008	<.0001
Classe di intensità lavorativa	Minore di 0,2	-0,186	0,005	<.0001
	Tra 0,2 e 0,5	1,062	0,004	<.0001
	Tra 0,5 e 0,8	-0,059	0,003	<.0001
Numero di percettori		-0,896	0,003	<.0001
Fonte principale di reddito	Lavoro autonomo	-0,322	0,095	0.0006
	Pensione più trasferimento pubblico	-0,712	0,094	<.0001
	Capitale	-0,358	0,095	0.0002
	Trasf. privato	-0,247	0,107	0.0210
Cittadinanza dei membri della famiglia	Italiana	-0,486	0,003	<.0001
	Straniera	0,385	0,003	<.0001
Tipologia familiare	Unipersonali	-0,202	0,007	<.0001
	Coppie senza figli	-0,467	0,007	<.0001
	Coppie con figli	-0,235	0,006	<.0001
	Monogenitore	0,326	0,007	<.0001
	Altro	0,069	0,006	<.0001
Numero di occupati a ottobre		-0,596	0,004	<.0001
Numero di precari a ottobre		-0,107	0,003	<.0001
Sesso dell'intestatario	Maschio	-0,104	0,002	<.0001
Numero di minori in famiglia		0,529	0,002	<.0001
Numero di NEET in famiglia		0,458	0,005	<.0001
Numero di over 64 in famiglia		-0,181	0,004	<.0001

3.2 Analisi territoriale

Dall'analisi dei dati a livello comunale si conferma l'evidente concentrazione territoriale del fenomeno nelle regioni del Mezzogiorno. La Figura 2 riporta le *quartile maps* relative all'incidenza dei dipendenti a basso reddito in famiglie non a basso reddito (A), dei dipendenti non a basso reddito in famiglie a basso reddito (B), dei dipendenti a basso reddito in famiglie a basso reddito (C) e dei dipendenti a basso reddito o dipendenti che vivono in famiglie a basso reddito (A+B+C). Si osserva, per i cartogrammi B e C una netta contrapposizione tra i comuni del Nord e i comuni del Sud del Paese.

Relativamente all'incidenza dei dipendenti non a basso reddito in famiglie a basso reddito, si osserva (Fig. 3) che il 67,2% dei comuni del Sud e il 73,7% dei comuni delle Isole presentano un valore superiore al terzo quartile. Di contro, il 3,5% dei comuni del Nord-Ovest, il 13,2% dei comuni del Centro e solo 6 comuni del Nord-Est ricadono in questa casistica.

Restringendo l'analisi ai dipendenti a basso reddito che vivono in famiglie economicamente svantaggiate (Cartogramma C di Fig. 2), si conferma la maggiore concentrazione nelle regioni meridionali, specialmente nelle Isole.

Per quanto riguarda, invece, i dipendenti a basso reddito che vivono in famiglie con reddito superiore alla soglia (situazione di minore svantaggio, in cui il nucleo familiare svolge un ruolo di protezione sociale), il divario Nord-Sud si riduce (Cartogramma A della Fig. 2). È interessante notare la presenza di aree, anche al Sud, in cui il ruolo della famiglia mitiga la scarsità di reddito da lavoro dipendente. Infatti, per questa distribuzione, appartengono all'ultimo quartile il 51,5% dei comuni del Sud, contro l'8,7% dei comuni del Nord-Ovest, il 7,5% dei comuni del Nord-Est e il 33,6% dei comuni del Centro[3].

[3] Un'elevata incidenza del fenomeno si osserva anche in alcuni comuni confinanti con la Francia e Svizzera, a causa dell'effetto distorsivo del lavoro transfrontaliero. Infatti, i redditi dei lavoratori frontalieri non sono inclusi nella raccolta di microdati ArchiMEDe.

Figura 2. *Incidenza dei dipendenti a basso reddito in famiglie non a basso reddito (A), dei dipendenti non a basso reddito in famiglie a basso reddito (B), dei dipendenti a basso reddito in famiglie a basso reddito (C) e dei dipendenti a basso reddito o dipendenti che vivono in famiglie a basso reddito (A+B+C). Quartile maps.*

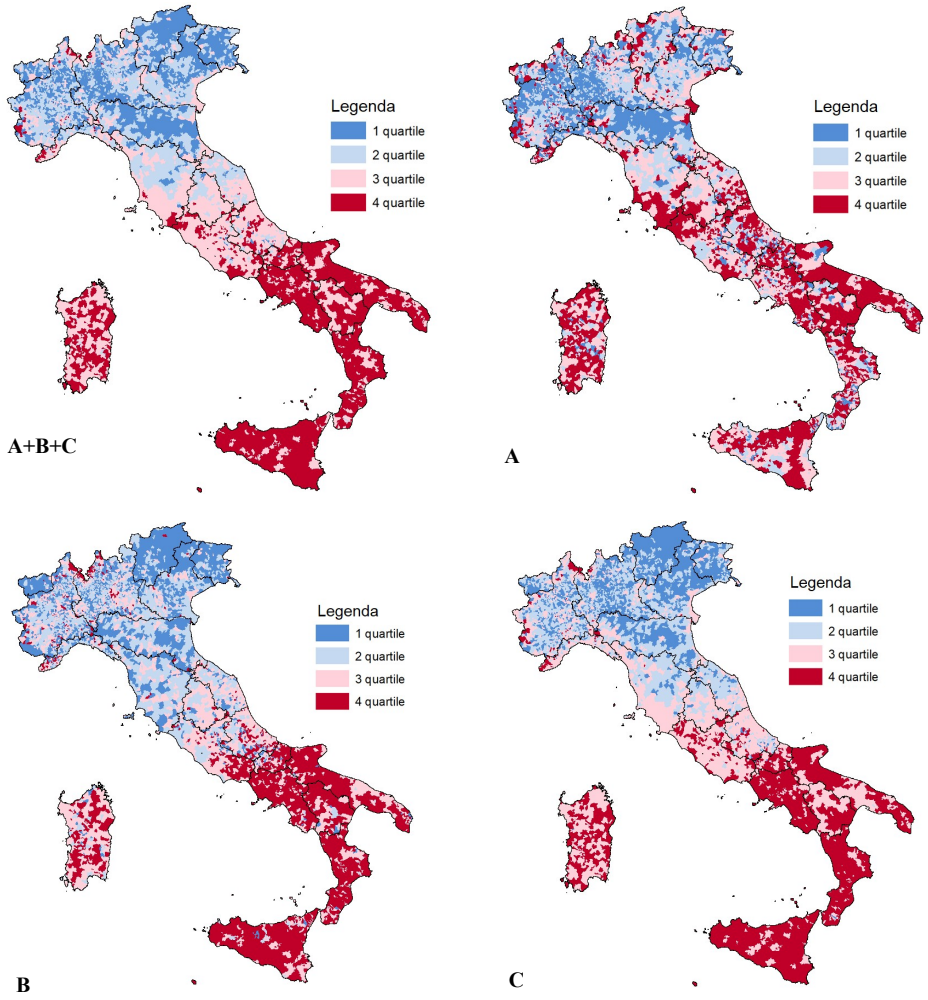


Figura 3. *Comuni in cui l'incidenza dei dipendenti a basso reddito in famiglie non a basso reddito (A) è superiore al terzo quartile; comuni in cui l'incidenza dei dipendenti non a basso reddito in famiglie a basso reddito (B) è superiore al terzo quartile e comuni in cui l'incidenza dei dipendenti a basso reddito in famiglie a basso reddito (C) è superiore al terzo quartile, per ripartizione. Incidenza percentuale sul totale dei comuni della ripartizione*

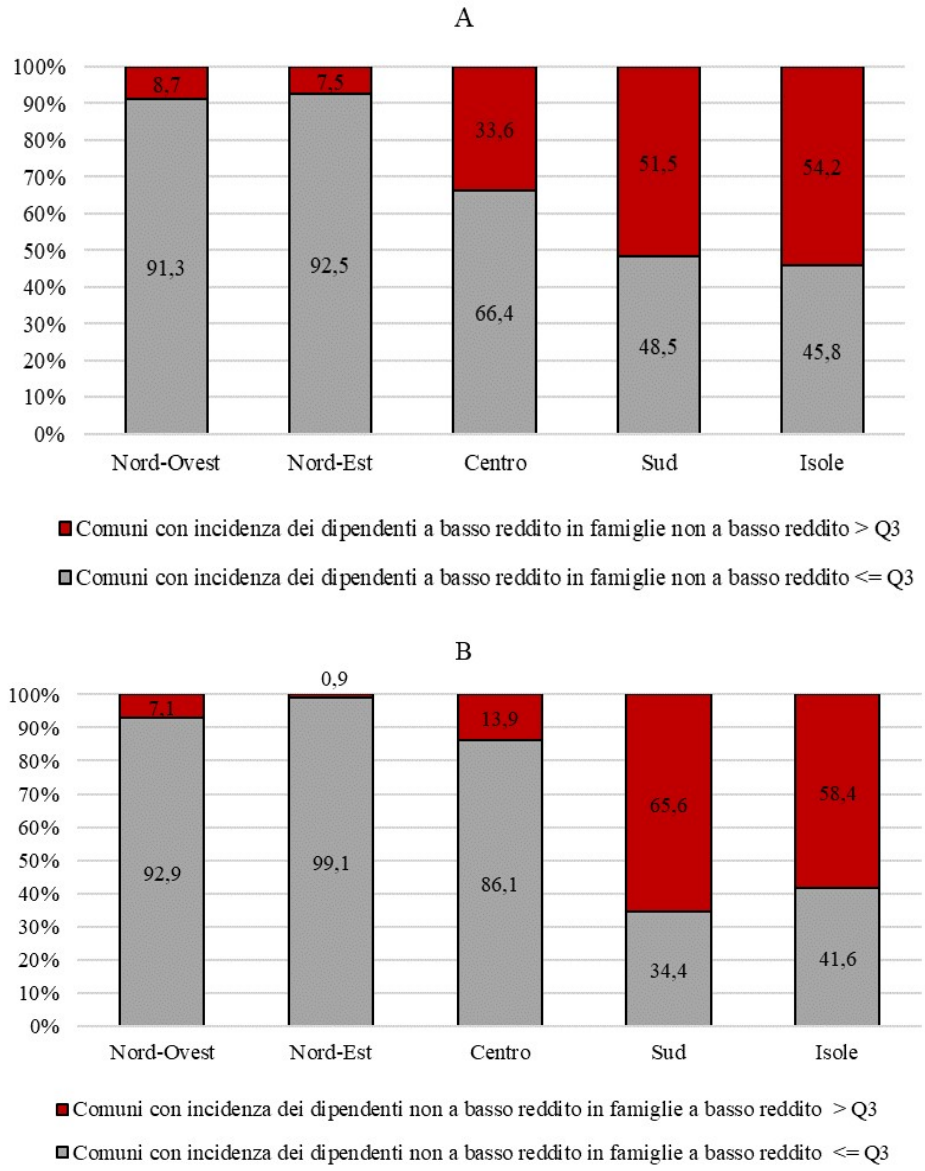
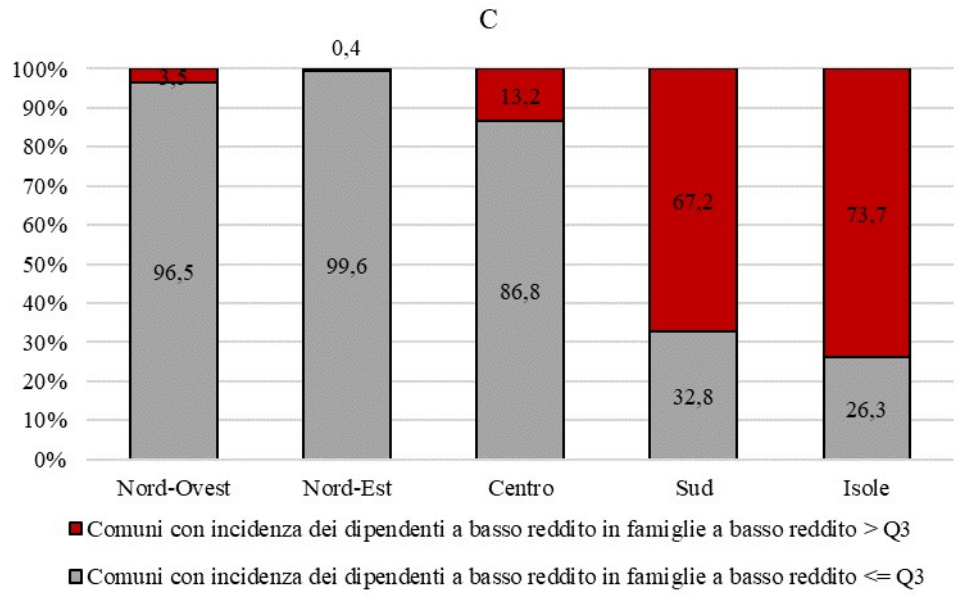


Figura 3. (*segue*)



4. Conclusioni

L'analisi dell'occupazione a basso reddito proposta in questo lavoro mette in luce la potenzialità dei dati amministrativi integrati. La ricchezza e la multidimensionalità di questa tipologia di dati ha permesso di effettuare uno studio descrittivo del fenomeno in Italia[4]. In particolare, è stata eseguita un'analisi multivariata, descrivendo la relazione tra la probabilità di essere un dipendente a basso reddito e un insieme di variabili socio-demografiche. I dati hanno fornito anche l'opportunità di esplorare l'utilità di nuove definizioni operative. Infatti, avere un lavoro a bassa remunerazione, non sempre comporta uno stato di povertà e deprivazione materiale. Una ragione di questo apparente paradosso sta nella mediazione operata dalla condizione famigliare[5]. Infatti, un lavoro a basso reddito non necessariamente im-

[4] Tuttavia, al momento, i dati disponibili non consentono di considerare informazioni potenzialmente utili come il settore di attività economica e il tempo pieno/parziale. (Lucifora, *et al*., 2005).
[5] Un altro aspetto, non considerato in questo lavoro, è il ruolo delle politiche redistributive (Saraceno, 2015).

plica una situazione di svantaggio (personale e familiare) e può anzi costituire un'utile integrazione ad altri redditi che entrano in famiglia. Tuttavia, se un reddito da lavoro basso non sempre è collegato alla povertà rispetto alla capacità di consumo, può invece rappresentare un vincolo alla libertà individuale, come quella di formare una propria famiglia per i lavoratori più giovani (Saraceno, 2020).

L'inclusione nelle analisi svolte del reddito equivalente familiare ha permesso di segmentare la popolazione e delineare tre ulteriori categorie concettuali: (1) dipendenti a basso reddito che vivono in una famiglia con deprivazione economica, (2) dipendenti non a basso reddito che vivono in una famiglia con deprivazione economica (3) dipendenti a basso reddito che vivono in un nucleo familiare con reddito sopra la soglia di povertà.

Inoltre, poiché i dati consentono una granularità a livello sub-regionale, è stata effettuata un'analisi territoriale a livello comunale. La possibilità di disaggregazione territoriale è un aspetto particolarmente utile per i decisori locali. I risultati mostrano la forte variabilità territoriale e confermano il dualismo Nord-Sud. Tuttavia, l'analisi delle nuove categorie concettuali mostra un quadro più differenziato ed evidenzia la presenza di aree in cui il ruolo della famiglia mitiga la scarsità di occupazione reddito e viceversa.

Riferimenti bibliografici

Bavaro, M. (2022). Is working enough? A study on low-paid workers in Italy. *WorkINPS papers*, 52.

Bovini, G.; Ciani, E.; De Philippis E.; Romano, S. (2023) *Labour income inequality and in-work poverty: a comparison between euro area countries*. Occasional Papers Banca d'Italia.

Carbonara, M.; Casacci, S. (2024). Low-income earners: new possibilities of study from administrative archives. *52esima Riunione Scientifica della Società Italiana di Statistica*, Bari, 17-20 giugno 2024.

Cariello, S.; Carbonara, M. (2019). Working poor nel Nord ovest. In F. Verrecchia, (ed.), *Dati amministrativi, metodi e statistiche per le politiche territoriali*. Franco Angeli, Milano: 85-92.

Carrieri, V. (2012). I working poor in Italia: quanti sono, chi sono, quanto sono poveri. *La Rivista delle Politiche Sociali / Italian Journal of Social Policy*, 2: 71-96.

Franzini, M.; Raitano, M. (2019). Earnings inequality and workers' skills in Italy. *Structural Change and Economic Dynamic*, 51: 215-224.

Garofalo, G. (2014). *Il Progetto ARCHIMEDE obiettivi e risultati sperimentali*. Istat Working Paper.

Istat, (2021). *Le statistiche dell'Istat sulla povertà. Anno 2020*, Statistiche report. URL https://www.istat.it/it/files/2021/06/REPORT_POVERTA_2020.pdf

Lucifora, C.; McKnight, A.; Salverda, W. (2005) Low-Wage Employment in Europe: a Review of Evidence. *Socio-Economic Review*, 3: 259-292.

Raitano, M.; Jessoula M.; Pavolini, E.; Natili, M. (2019a). I working poor in Italy. *Social cohesion paper,* 2, Osservatorio internazionale per la coesione e l'inclusione sociale.

Raitano, M.; Jessoula M.; Pavolini, E.; Natili, M. (2019b). *ESPN Thematic Report on Inwork poverty – Italy*. European Social Policy Network (ESPN), Brussels, European Commission.

Saraceno C. (2015). *Il lavoro non basta. La povertà in Europa negli anni della crisi*. Feltrinelli, Milano.

Saraceno, C. (2018). Il lavoro non basta a proteggere dalla povertà. *Neodemos.* URL https://www.neodemos.info/2018/04/10/il-lavoro-non-basta-a-proteggere-dalla-poverta/

Saraceno, C. (2020*). Quando avere un lavoro non basta a proteggere dalla povertà*, Lectio Magistralis, No. 20, ISBN 978-88-5518-041-2, Firenze University Press, Firenze.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 99-112

Evoluzione e prospettive dell'industria alimentare nella città metropolitana di Bari

Domenico Viola[1], Carlo Cusatelli[2]*, Debora Cazzetta[2], Andrea Troisi[3]

[1]DEMDI-UniBa, [2]DJSGE-UniBa, [3]DIRIUM-UniBa

Riassunto: Negli ultimi anni, l'industria alimentare della città metropolitana di Bari ha vissuto cambiamenti significativi, con rami che hanno saputo adattarsi alle mutevoli condizioni economiche, sociali e sanitarie, e altri che hanno affrontato importanti flessioni. Utilizzando i dati ufficiali ISTAT, questa ricerca analizza l'andamento delle unità locali attive nelle più generiche sottocategorie del settore alimentare tra il 2012 e il 2022, per esplorare come l'industria abbia reagito agli shock esogeni e quali tendenze si prospettano per il triennio successivo.

Keywords: agroalimentare; città metropolitana; Bari.

1. Introduzione

La struttura produttiva dell'area metropolitana barese è caratterizzata da una decisa impronta agroalimentare, un settore manifatturiero innovativo e dinamico che tende verso conformazioni distrettuali e specializzate, nonché un settore commerciale radicato sul territorio, cui si aggiunge lo scalo marittimo decisivo anche per l'esportazione: tale insieme configura un "sistema glocale". Il potenziale dell'area è elevato ma decisamente poco sfruttato, soprattutto nelle due direttrici più forti anche a livello internazionale: agroalimentare, in particolare nella forma dei prodotti tipici (in cui, però, a metodi di produzione del tutto "genuini" si contrappongono debolezze dal punto di vista della trasformazione e della commercializzazione, finendo così per annullare o trasferire a terzi non appartenenti al territorio il valore aggiunto del prodotto), e turismo, soprattutto nel legame con le tipicità territoriali.

* Autore corrispondente: carlo.cusatelli@uniba.it

Bisognerebbe incentivare i Comuni dell'area a organizzare sistemi unici di offerta e modalità di gestione efficaci: il fenomeno della cooperazione, derivante da una comunanza di interessi, sembra ancora essere lontano da una costante e sistematica applicazione, anche se negli ultimi anni, soprattutto sotto la spinta dei programmi di fondi strutturali dell'Unione Europea, si intravedono tentativi di azioni strategiche riferite al territorio barese come sistema, che comprende attori che appartengono a diversi centri di attrattiva.

2. Materiali e metodi

Il settore agroalimentare di Bari rappresenta quindi un pilastro cruciale dell'economia locale e nazionale, e la struttura del comparto mostra un'interessante varietà, con dinamiche distintive e livelli di resilienza diversi: l'analisi dei dati Istat, effettuata con il software R, consente di tracciare le tendenze imprenditoriali e di esplorare il potenziale impatto di eventi esterni, tra cui la pandemia di COVID-19, sulle unità locali di ciascun segmento di mercato.

Per esaminare l'evoluzione del settore sono stati utilizzati i codici Ateco a tre cifre che rappresentano le principali categorie dell'industria. I dati Istat sulle unità locali attive sono stati strutturati in un data frame, consentendo un'analisi dettagliata dell'ultimo undicennio di dati disponibili (Tab. 1) e facilitando previsioni per il triennio successivo (2023-2025) tramite modelli ARIMA (AutoRegressive Integrated Moving Average).

Una volta convertito il dataset in serie storiche per ogni singolo settore, è stato necessario effettuare il test ADF (Augmented Dickey-Fuller): uno strumento fondamentale per verificare la stazionarietà delle serie storiche. Se una serie non è stazionaria, si possono applicare differenziazioni per renderla tale e poi confermare la stazionarietà con il test ADF, per essere sicuri che i modelli di previsione siano applicati correttamente.

Dopo aver reso la serie stazionaria è possibile applicare i modelli ARIMA: una famiglia di modelli statistici ampiamente utilizzati per l'analisi e la previsione di serie temporali. Si basano sulla combinazione di componente autoregressiva (AR) che mette in relazione il valore attuale ai valori precedenti della serie mediante un termine di regressione, di media mobile (MA) che considera il valore attuale della serie dipendente da uno o più errori casuali passati, espresso mediante un termine di regressione che include gli errori passati, e di integrazione (I) per modellare la struttura di dipendenza temporale dei dati.

Tabella 1. *Numero di unità locali delle imprese attive nella città metropolitana di Bari*

	Anno										
Codice Ateco	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022
101: lavorazione e conservazione di carne e produzione di prodotti a base di carne	27	27	21	23	23	28	21	21	27	22	18
102: lavorazione e conservazione di pesce, crostacei e molluschi	11	7	6	7	7	5	7	8	8	8	7
103: lavorazione e conservazione di frutta e ortaggi	58	55	49	47	41	47	50	50	58	50	50
104: produzione di oli e grassi vegetali e animali	200	187	190	188	200	194	198	190	163	152	149
105: industria lattiero-casearia	212	211	214	218	234	227	235	215	203	200	192
106: lavorazione delle granaglie, produzione di amidi e di prodotti amidacei	23	22	24	28	29	33	28	24	22	22	23
107: produzione di prodotti da forno e farinacei	949	932	901	907	927	917	905	863	827	813	832
108: produzione di altri prodotti alimentari	133	133	122	125	128	117	120	211	228	214	227
109: produzione di prodotti per l'alimentazione degli animali	11	12	11	14	16	16	16	16	16	14	14
110: industria delle bevande	69	71	81	89	94	88	92	82	83	84	78
Totale	1.693	1.657	1.619	1.646	1.699	1.672	1.672	1.680	1.635	1.579	1.590

La componente autoregressiva utilizza i valori passati della serie temporale per predire i valori futuri: con la funzione "auto.arima" è possibile trovare il miglior modello ARIMA per i dati. In particolare, il modello senza componente stagionale ARIMA(p,d,q) è definito dai tre parametri:

- *p* è l'ordine della componente autoregressiva (AR), per cui
$$y_n=c+\varphi_1 y_{n-1}+\varphi_2 y_{n-2}+\ldots+\varphi_p y_{n-p}+\varepsilon_n$$
dove c è una constante, φ_1, …, φ_p sono parametri e ε_n è white noise;
- *d* è il grado differenziale della componente d'integrazione (I) necessario per rendere stazionaria la serie,
- *q* è l'ordine della componente di media mobile (MA), dimensione della finestra della media mobile per cui
$$y_n=c+\varepsilon_n+\theta_1\varepsilon_{n-1}+\theta_2\varepsilon_{n-2}+\ldots+\theta_q\varepsilon_{n-q}$$
può essere considerato come una media mobile ponderata degli errori di previsione passati.

L'equazione del modello completo di ARIMA(p,d,q) è pertanto:
$$\Delta^{(d)}y_n=c+\varphi_1\Delta^{(d)}y_{n-1}+\ldots+\varphi_p\Delta^{(d)}y_{n-p}+\varepsilon_n+\theta_1\varepsilon_{n-1}+\ldots+\theta_q\varepsilon_{n-q}.$$
Un modello ARIMA(p,d,q) è in pratica un modello ARMA(p,q) applicato a $\Delta^{(d)}y_n$, e in particolare il modello ARIMA(p,0,q) coincide con il modello ARMA(p,q).

Dopo aver creato i modelli (Tab. 2), si può usare la funzione "forecast" per generare le previsioni per un certo numero di periodi futuri, uno strumento ben integrato ai modelli ARIMA, che ha permesso di ottenere previsioni per il triennio 2023-2025, successivo alla serie storica relativa all'undicennio 2012-2022, anche mediante intervalli di confidenza.

Tabella 2. *Parametri funzione "Auto.Arima" software R-Studio*

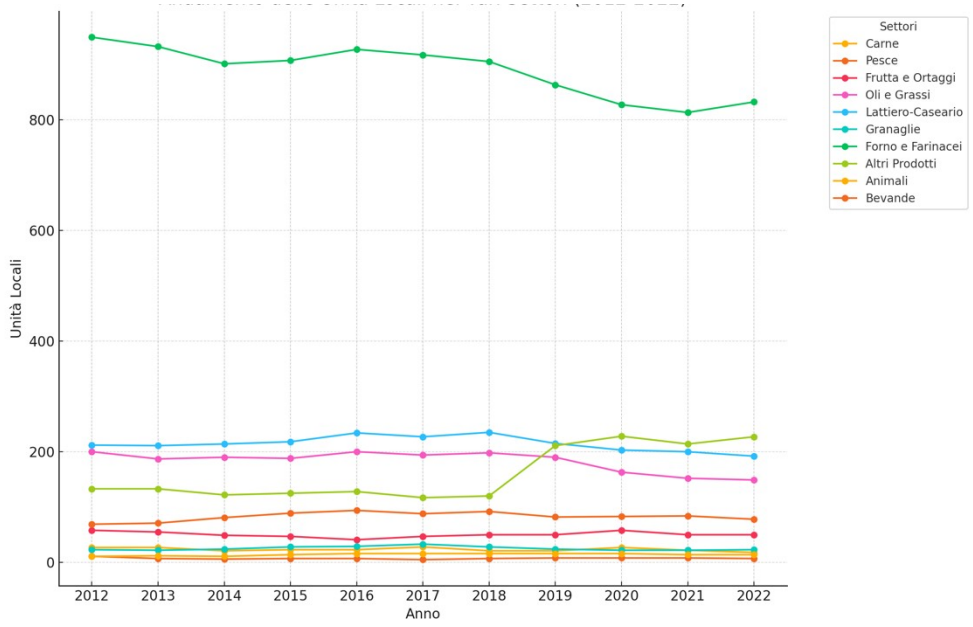
Codice Ateco	p	d	q
101: lavoraz. e conservazione di carne e produz. di prodotti a base di carne	0	0	0
102: lavorazione e conservazione di pesce, crostacei e molluschi	0	1	0
103: lavorazione e conservazione di frutta e ortaggi	0	1	0
104: produzione di oli e grassi vegetali e animali	1	1	0
105: industria lattiero-casearia	1	1	0
106: lavorazione delle granaglie, produzione di amidi e di prodotti amidacei	1	0	0
107: produzione di prodotti da forno e farinacei	2	0	0
108: produzione di altri prodotti alimentari	1	1	0
109: produzione di prodotti per l'alimentazione degli animali	1	1	0
110: industria delle bevande	1	0	0

Per quanto riguarda l'orizzonte *h* di previsione, in questo studio è stato fissato a 3, potendo in tal modo presto verificare l'accuratezza predittiva dei modelli mediante i dati di prossima pubblicazione, ancora da riferire all'anno 2023 del tutto già passato, e inoltre ottenere una stima per il 2024 attualmente in corso, nonché una proiezione per il prossimo 2025.

3. Risultati

Da una prima analisi anche grafica (Fig. 1) è possibile osservare quali settori hanno mantenuto una costanza imprenditoriale e quali invece mostrano fluttuazioni sintomatiche, probabilmente dovute a fattori esterni, come la pandemia di COVID-19.

Figura 1. *Numero di unità locali nei vari settori*



In particolar modo, l'imprenditorialità nei prodotti da forno e farinacei risulta superiore rispetto agli altri comparti, sebbene si osservi una leggera flessione tra il 2019 e il 2022. Alcuni settori mostrano, soprattutto negli ultimi anni considerati, una tendenza al ribasso (es. carne, lattiero-caseario, bevande), forse a causa di cambiamenti nelle preferenze alimentari, innovazioni tecnologiche che riducono la domanda di certi prodotti o sfide economiche come la pandemia. Altri settori, come la lavorazione della frutta e degli ortaggi, la produzione di altri prodotti alimentari,

e il settore dei prodotti da forno, mostrano una certa resilienza o ripresa, soprattutto nel 2022.

Il settore "Lavorazione e conservazione di carne e produzione di prodotti a base di carne" ha mantenuto una presenza stabile mostrando un lieve calo nel periodo analizzato, passando da un picco di 28 nel 2017 a 21 nel 2018. Il calo riflette una possibile riduzione del consumo di carne: probabilmente a causa delle restrizioni pandemiche.

La "Lavorazione e conservazione di pesce, crostacei e molluschi" ha mantenuto numerosità molto basse durante tutto il periodo, con una piccola ripresa nel 2019. Il dato resta piuttosto stabile, indicativo di un mercato di nicchia o una domanda costante e limitata.

Il settore "Lavorazione e conservazione di frutta e ortaggi" presenta una leggera tendenza negativa dal 2012 al 2016, ma recupera fino al 2020. Ciò potrebbe essere legato a una crescita della domanda di prodotti freschi o conservati in un mercato più stabile.

La "Produzione di oli e grassi vegetali e animali" mostra un andamento fluttuante, con un picco iniziale di 200 nel 2012 e una discesa fino a 149 nel 2022, probabilmente a causa della pandemia.

L'imprenditoria nel settore lattiero-caseario ha mostrato una crescita fino al 2018 (235), ma da allora è in calo, fino ad arrivare a 192 nel 2022. Questo potrebbe riflettere cambiamenti nei consumi di prodotti caseari dovuti alle dinamiche legate alla globalizzazione e alla concorrenza internazionale, oltre che alla crescente domanda di alternative vegetali al latte.

Il settore "Lavorazione delle granaglie, produzione di amidi e di prodotti amidacei", dopo un leggero aumento tra il 2012 e il 2017, con un picco di 33, si è stabilizzato e successivamente ridotto nel 2022. Questo potrebbe essere dovuto a una variazione nella domanda di prodotti amidacei o a cambiamenti nei prezzi delle materie prime.

La "Produzione di prodotti da forno e farinacei" è la più consistente in termini di unità locali, ma con un calo continuo a partire dal 2012, passando da 949 a 832 nel 2022. Il trend è indicativo e potrebbe suggerire cambiamenti nelle preferenze alimentari e una crescente concorrenza con altri prodotti a base vegetale, magari senza glutine.

Un notevole aumento dell'imprenditorialità nel settore "Produzione di altri prodotti alimentari" è evidente nel 2019, con un picco a 211 rispetto alle 122 unità locali del 2014. Il numero si mantiene alto anche negli anni successivi (227 nel

2022), suggerendo un'espansione del mercato o un aumento della domanda di questi "altri prodotti alimentari".

Il settore "Produzione di prodotti per l'alimentazione degli animali" rimane stabile a livelli bassi, con una numerosità che oscilla tra 11 e 16 nel periodo considerato. Questo potrebbe indicare un mercato costante ma non in crescita.

L'industria delle bevande ha mostrato una crescita fino al 2016 (94), seguita da un calo graduale, toccando 78 nel 2022.

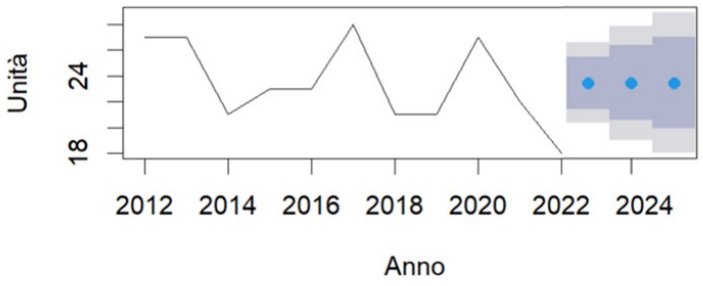
3.1 Previsioni

Il settore agroalimentare di Bari non solo rappresenta un pilastro dell'economia locale, ma si trova anche ad affrontare sfide e opportunità legate alle dinamiche economiche globali. Secondo le previsioni dell'Unione Europea, il mercato agroalimentare italiano potrebbe crescere del 3,5% annuo nei prossimi cinque anni, con un aumento della domanda di prodotti biologici e sostenibili. Tuttavia, le piccole e medie imprese del settore devono adattarsi rapidamente per sfruttare queste opportunità. Un esempio di iniziativa promettente è l'espansione delle esportazioni di prodotti tipici pugliesi verso i mercati asiatici, dove la domanda di olio extravergine di oliva e vino italiano è in continua crescita. I dati del Ministero degli Affari Esteri indicano un incremento delle esportazioni del 12% nel 2023 rispetto all'anno precedente, con la regione Puglia in testa tra le aree esportatrici.

Le proiezioni sui tre anni successivi all'ultimo disponibile (2023-2025), elaborate con modelli ARIMA attraverso la funzione "forecast" e riportate nelle figure seguenti, evidenziano come la stabilità prevalga in alcuni settori, mentre altri mostrano segnali di crescita o di ripresa, almeno in termini di stime puntuali (in modo più sfocato per quelle intervallari al 95% e soprattutto al 99% di confidenza).

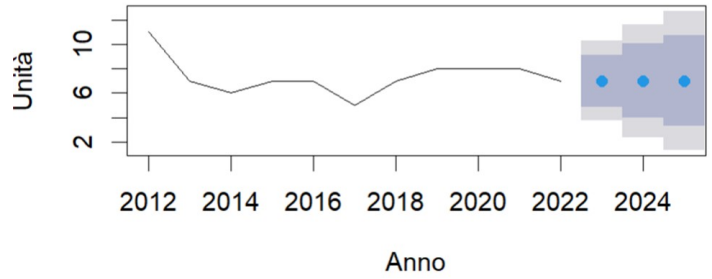
In particolare, si confida in una ripresa intorno alle 24 unità locali per la lavorazione e conservazione di carne e produzione di prodotti a base di carne (Fig. 2).

Figura 2. *Lavorazione e conservazione di carne e produzione di prodotti a base di carne*



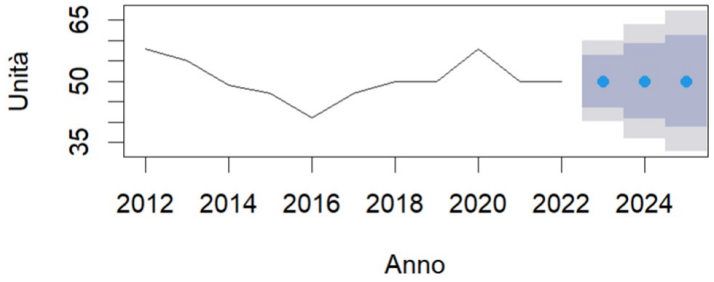
Per la lavorazione e conservazione di pesce, crostacei e molluschi (Fig. 3) si stimano attorno a 7 unità.

Figura 3. *Lavorazione e conservazione di pesce, crostacei e molluschi*



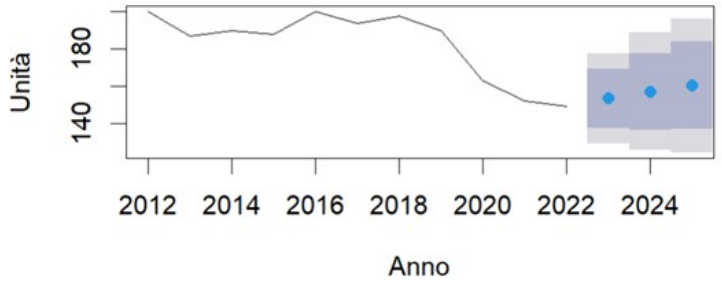
Per la lavorazione e conservazione di frutta e ortaggi (Fig. 4) si prevedono unità intorno a 50.

Figura 4. *Lavorazione e conservazione di frutta e ortaggi*



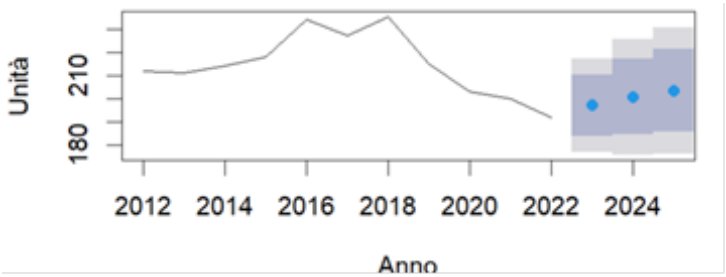
Nel caso della produzione di oli e grassi vegetali e animali (Fig. 5) si prevede un andamento crescente con valori puntuali pari a 153, 157, 160 rispettivamente nel 2023, 2024 e 2025.

Figura 5. *Produzione di oli e grassi vegetali e animali*



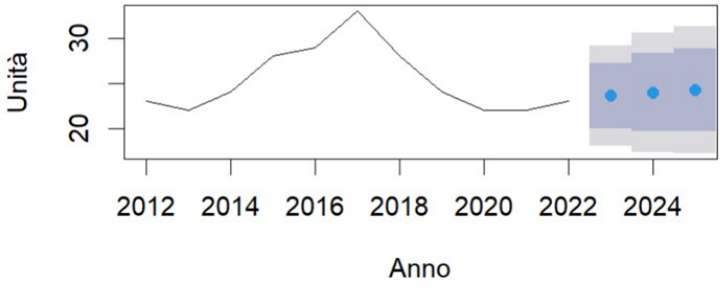
Nel caso dell'industria lattiero-casearia (Fig. 6) si prevede una tendenza puntuale leggermente crescente da 197 del 2023 a 200 del 2024 a 203 del 2025.

Figura 6. *Industria lattiero-casearia*



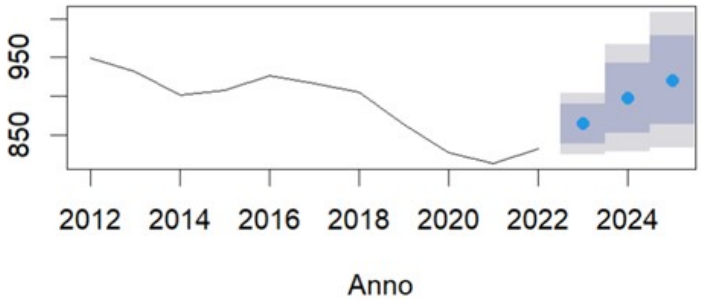
Nel caso della lavorazione delle granaglie, produzione di amidi e di prodotti amidacei (Fig. 7) si prevedono unità intorno a 23 e 24.

Figura 7. *Lavorazione delle granaglie, produzione di amidi e di prodotti amidacei*



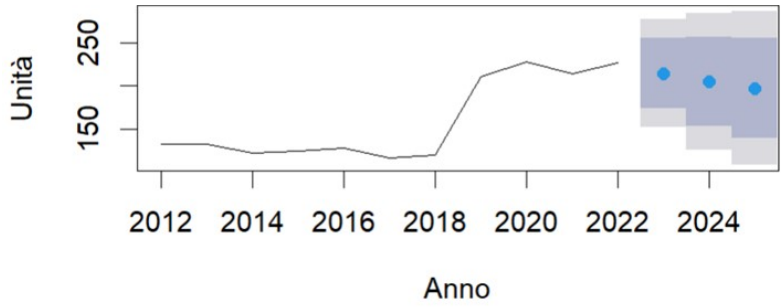
Per i prodotti da forno e farinacei (Fig. 8) si prevedono valori puntuali crescenti da 864 a 920 (unico caso in cui anche le stime intervallari potrebbero far confidare univocamente in un aumento).

Figura 8. P*roduzione di prodotti da forno e farinacei*



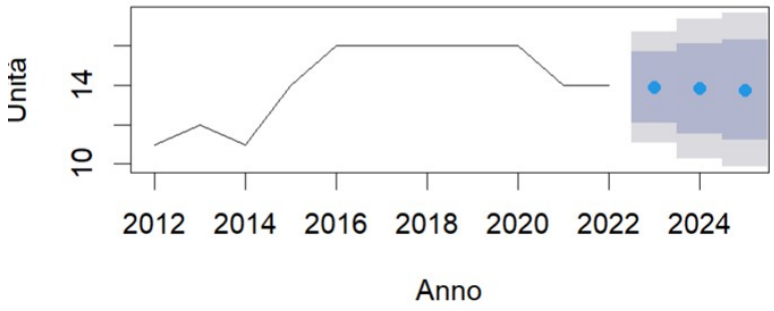
Per gli altri prodotti alimentari (Fig. 9) si prevede una tendenza decrescente con stime puntuali di 214, 205 e 197 rispettivamente nel 2023, 2024 e 2025.

Figura 9. *produzione di altri prodotti alimentari*



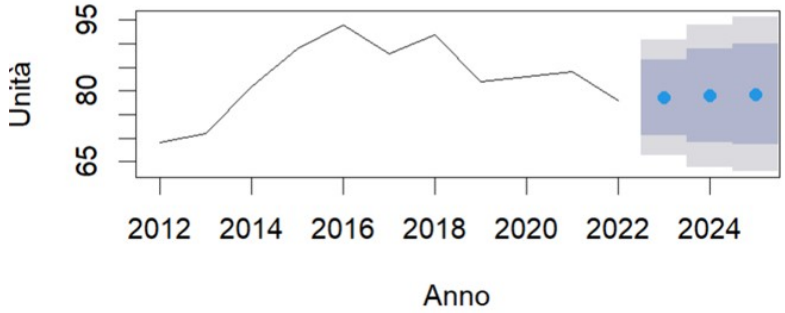
Per l'alimentazione degli animali (Fig. 10) si prevedono valori attorno a 13 e 14.

Figura 10. *Produzione di prodotti per l'alimentazione degli animali*



Nel caso dell'industria delle bevande (Fig. 11) si fanno stime intorno a 78 e 79.

Figura 11. *Industria delle bevande*



3.1.1 Le prospettive di sostenibilità nell'industria agroalimentare

L'attenzione crescente verso la sostenibilità ha spinto molte imprese agroalimentari ad adottare pratiche ecologiche che rispettano l'ambiente, migliorando al contempo l'efficienza produttiva. Secondo i dati più recenti dell'Istituto Superiore per la Protezione e la Ricerca Ambientale (ISPRA), le emissioni di gas serra del settore agricolo in Italia sono state responsabili del 7% delle emissioni totali nel 2022, con una riduzione del 4% rispetto al 2015. Questo miglioramento è stato reso possibile grazie a interventi mirati volti a ridurre l'impatto ambientale, come l'adozione di tecniche di agricoltura di precisione e la promozione di filiere corte e a basso impatto.

Le statistiche fornite da Coldiretti evidenziano che il 23% delle imprese agroalimentari pugliesi ha già implementato tecnologie green per migliorare la gestione delle risorse idriche e ridurre lo spreco alimentare. Un esempio rilevante è rappresentato dal progetto 'Acquacoltura Sostenibile' nel Sud Italia, che ha dimostrato come l'uso di energia rinnovabile nei processi produttivi possa ridurre i costi operativi fino al 15%.

L'industria alimentare ha un impatto significativo sull'ambiente, soprattutto in termini di consumo delle risorse naturali ed emissioni di gas serra. Tuttavia, il passaggio a modelli produttivi più sostenibili potrebbe ridurre questo impatto e creare benefici economici. Secondo uno studio del WWF Italia, la gestione sostenibile delle risorse idriche potrebbe ridurre il consumo di acqua del 20% nei prossimi dieci anni, con un impatto positivo sia sull'ambiente che sulle comunità locali.

Questi risultati indicano un crescente interesse per le iniziative di sostenibilità che potrebbero essere ulteriormente sviluppate per massimizzare i benefici economici e ambientali nel settore agroalimentare barese. Inoltre, l'adozione di pratiche di agricoltura rigenerativa non solo migliora la qualità del suolo, ma contribuisce anche alla sicurezza alimentare, un tema di crescente rilevanza sociale. Le aziende agroalimentari potrebbero giocare un ruolo cruciale nel promuovere un equilibrio tra la produzione alimentare e la conservazione degli ecosistemi.

4. Conclusioni

L'industria alimentare della Città metropolitana di Bari ha evidenziato notevoli capacità di adattamento alle trasformazioni del mercato e agli shock esogeni, come dimostrato dalla ripresa in molti comparti dopo la pandemia. Le politiche di sostegno per la competitività e l'innovazione delle imprese agroalimentari potrebbero

rafforzare ulteriormente la resilienza del settore, promuovendo un approccio sostenibile e adattivo di fronte a un mercato globale in continua evoluzione.

In particolare, l'obiettivo delle azioni di marketing territoriale dovrà essere quello di incrementare il valore dello scambio tra le diverse offerte che la provincia di Bari propone e la corrispondente domanda, ricercando le massime "sinergie" tra i diversi assi di attrattiva, quali per esempio ai possibili effetti positivi delle interrelazioni tra turismo e prodotti agroalimentari, anche attraverso la creazione di distretti rurali in cui si formi un nuovo tipo di attività legata a una combinazione di molti fattori: in tale ambito, il territorio barese presenta un elevato numero di opportunità, dovute sia ai fattori di attrattiva naturalistici e paesaggistici del suo territorio sia alla presenza di agriturismo e di produzioni tipiche (la stessa esistenza delle cosiddette strade del vino e dell'olio testimoniano questo potenziale).

La promozione del settore agroalimentare passa quindi attraverso un legame sempre più stretto tra prodotti e territorio, il che comporta la necessità di creare reti tra attori poco abituati a dialogare tra loro, una cultura di prodotto tra gli attori interni al sistema economico, e di comunicare e valorizzare i prodotti baresi presso i soggetti esterni. Il territorio barese, nell'ambito di un'azione di marketing, attraverso il sistema agroalimentare può:

- enfatizzare la propria specificità attraverso i prodotti, creando il contenuto e il valore implicito di un marchio e diffondendo la sua immagine (Identità culturale);
- valorizzare i prodotti tipici, sviluppandone l'identità e contribuendo, in questo modo, al miglioramento del loro posizionamento nel mercato interno ed esterno (Prodotti tipici);
- creare un raccordo tra prodotti di successo e marchio collettivo, anche in relazione al posizionamento della provincia nel mercato turistico (Marchio territoriale);
- favorire la nascita di una cultura di sistema tra i comparti dell'agroalimentare (con particolare riferimento a quelli del vino, olio, lattiero-caseario, ittico), del turismo, della cultura e dell'artigianato (Cultura di sistema e internazionalizzazione).

Sebbene l'espansione dei mercati e una maggiore attenzione verso i processi manageriali stiano minando la competitività del sistema agroalimentare barese (risultando in una perdita di potere di mercato a favore delle grandi catene distributive straniere), le piccole realtà sono caratterizzate da metodi tradizionali di produzione, creando in tal modo una specie di "identità di marca" che può accompagnare la tendenza del mercato di consumo, sempre più orientato verso prodotti di qualità

e dalle connotazioni locali, fornendo ampie opportunità a un'area ricca di prodotti tipici, che si inserisce in un contesto nazionale e regionale già forte in tal senso.

In sostanza, il settore agroalimentare barese presenta opportunità e potenzialità elevate basate sia su condizioni di settore che, pur rappresentando delle debolezze, lasciano ampi margini di miglioramento, sia su condizioni di contesto favorevoli: accanto a sottodimensionamenti e sottoutilizzazioni del potenziale agroalimentare, esistono anche best practices, soprattutto nei settori del vino, dell'olio e del pane, sia attraverso l'utilizzo di marchi di tutela dell'Unione Europea (DOC e DOP), sia attraverso modelli organizzativi efficienti (consorzi). Le direttrici su cui operare vanno pertanto individuate nell'aumento delle dimensioni delle imprese (attraverso processi di crescita interna, fusioni, acquisizioni e consorzi), nelle strategie di valorizzazione dei prodotti tipici (attraverso strategie di branding, di rapporti con i territori d'origine), nella diversificazione produttiva e di mercato (attraverso una migliore valorizzazione produttiva dei prodotti e dei mercati, soprattutto quelli internazionali) e nell'introduzione di pratiche di innovazione di prodotto e di processo.

A tale scopo, tra le varie tipologie di prodotti, esiste una classificazione che, a vari livelli, sono chiamate a trasmettere le identità territoriali:

1. prodotti-simbolo (ad esempio la mozzarella, l'olio e il vino) che sono consolidati sul mercato, hanno ottenuto significativi riconoscimenti a livello nazionale, sono sostenuti da un'azienda "forte" o gruppi di aziende con leadership sui mercati e hanno una forte connotazione territoriale;
2. prodotti che hanno ottenuto certificazioni, da quelle di "filiera" o di rintracciabilità del prodotto, a quelle di qualità, ambientali e di prodotto;
3. prodotti di nicchia o "minori", quali quelli definiti tali da Slow Food nell'ambito del progetto "Presidi enogastronomici" (ad esempio la cipolla rossa di Acquaviva, la mandorla di Toritto e il pane tradizionale di Altamura), con caratteristiche di unicità, peculiarità e qualità comprovate da un prodotto in grado di rappresentare la "specificità", contenuti storico-artistici di una tipologia di prodotti che sappiano trasmettere e comunicare le caratteristiche del particolare contesto ambientale o culturale, prodotti che possono esprimere, non essendo conosciuti dal "consumatore" al di fuori delle subaree territoriali, i valori e la qualità del territorio.

In definitiva, per quanto riguarda il settore agroalimentare, una coerente strategia di marketing, che si innesti in un processo di sviluppo più ampio del sistema provinciale, dovrebbe partire da una chiara identificazione della vision del settore, volta alla massimizzazione del suo potenziale caratterizzato da imprese profittevoli,

innovazione, alta flessibilità e dinamismo per affrontare i cambiamenti, forte identità di marca, forti legami con il turismo e sostenibilità.

Riferimenti bibliografici

AA.VV. (2017). *I dossier delle Città Metropolitane: Città metropolitana di Bari*. Dipartimento per gli Affari Regionali e le Autonomie, Presidenza del Consiglio dei Ministri, Roma.

Crocetta, C. (2012). *Scenari occupazionali e fabbisogni formativi delle aziende del comparto agroalimentare della Capitanata*. Franco Angeli, Milano.

Fernàndez-Armesto, F. (2012). *Storia del Cibo*. Bruno Mondadori, Torino.

Mohan Babu, A.; Venkataramanaiah, M.; Jahnavi, M. (2013). *Forecasting with Econometric Methods: A Comparative Performance of ARIMA Models*. Scholars' Press, Chișinău.

Onorati, M. G.; d'Ovidio, F. D.; D'Uggento, A. M.; Toma, E. (2024). Comparative analysis of recent changes in the dietary behavior of Italian and US consumers: The made in Italy market and its factorial conceptualization. *Socio-Economic Planning Sciences*, 95:102028.

Roncaglia, S. (2010). *Nutrire la città: i dabbawala di Mumbai nella diversità delle culture alimentari urbane*.

Sitografia

https://esploradati.istat.it/databrowser/#/it/dw/categories/IT1,Z0900ENT,1.0/ENT_STRU/DICA_ASIAULP/IT1,183_285_DF_DICA_ASIAULP_3,1.0

https://indicatoriambientali.isprambiente.it

https://puglia.coldiretti.it

https://www.istat.it/tag/agroalimentare/

https://www.wwf.it/

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 113-127

Analisi quantitativa dei dati del servizio Copernicus per la valutazione e la gestione degli incendi boschivi in Italia nella stagione estiva 2023

Alessio Tafuni[1], Crescenza Calculli[1,*], Alessio Pollice[1]

[1] *Dipartimento di Economia e Finanza, Università di Bari degli Studi Di Bari Aldo Moro*

Riassunto: In questo lavoro vengono analizzati la distribuzione e l'impatto degli incendi boschivi in Italia durante i mesi estivi del 2023, utilizzando i dati provenienti dal servizio di osservazione della Terra dell'Unione Europea, Copernicus. L'obiettivo dell'analisi consiste nel valutare preventivamente il rischio di incendi e nel monitorare ed analizzare le aree bruciate. La metodologia utilizzata prevede la manipolazione di dati vettoriali e raster attraverso gli strumenti per la gestione dei dati spaziali del software statistico R e dell'ambiente di sviluppo integrato R-Studio. L'Indice di Pericolo di Incendio (Fire Danger Rating) permette di effettuare la valutazione preventiva del rischio di incendi, mentre la rilevazione della Potenza Radiativa degli Incendi (Fire Radiative Power, FRP) permette di localizzare hotspot o aree a maggior rischio. L'impatto e l'entità degli incendi vengono valutati attraverso l'analisi delle aree bruciate (Burnt areas) con un focus sulla tipologia di vegetazione colpita. A tale riguardo, l'analisi evidenzia una concentrazione maggiore di tali fenomeni nelle regioni meridionali della penisola, soprattutto in Sicilia, con aree bruciate molto vaste caratterizzate da macchia mediterranea e foreste di sclerofille.

Keywords: dati satellitari; incendi; cartogrammi; data visualization.

1. Introduzione

Negli ultimi anni, in risposta alla crescente necessità di affrontare disastri naturali di grande portata e sempre più frequenti, la disponibilità di informazioni affidabili

[*] Crescenza Calculli: crescenza.calculli@uniba.it
Il lavoro descritto è stato realizzato da A. Tafuni, che ha effettuato le elaborazioni e ha redatto la prima bozza. Il Paragrafo 1 è stato scritto da C. Calculli, mentre revisione, riscrittura e supervisione sono state curate congiuntamente da C. Calculli e A. Pollice.

e aggiornate è divenuta cruciale per garantire risposte tempestive ed efficaci nella gestione delle emergenze e nella salvaguardia delle vite umane (Jones et al., 2022; Wirtz et al., 2012). In questo contesto, agenzie ed enti governativi di tutto il mondo hanno implementato sistemi e programmi spaziali per l'osservazione e la navigazione della Terra (Hohensinn et al., 2024), riconoscendo l'importanza dell'informazione geospaziale nella pianificazione e nell'esecuzione delle operazioni di soccorso (Martínez–Álvarez and Morales–Esteban, 2018).

Il Copernicus Emergency Management System (CEMS), gestito dalla Commissione Europea, rappresenta un esempio di questi programmi. Il sistema fornisce informazioni geospaziali tempestive e precise, fondamentali per affrontare disastri naturali, emergenze di origine antropica e crisi umanitarie (Ceccato et al., 2023). Integrando dati provenienti dal telerilevamento satellitare, informazioni raccolte in situ e modelli predittivi, il CEMS mira a creare una base informativa ricca e dettagliata, che supporti decisioni strategiche in scenari complessi. Attraverso il Joint Research Center (JRC) della Commissione Europea, il CEMS svolge un ruolo cruciale nella risposta alle emergenze, sia a livello europeo che nelle regioni circostanti, contribuendo a un approccio integrato e globale nella gestione del rischio. Il CEMS si articola principalmente in due servizi chiave:

1. **Mappatura on-demand**: che consente la visualizzazione e l'analisi delle aree colpite da emergenze in tempo reale, fornendo informazioni geografiche dettagliate per consentire interventi mirati (Wania et al., 2021);
2. **Allerta precoce e monitoraggio**: che offre avvisi tempestivi riguardo a potenziali disastri, consentendo alle autorità di adottare misure preventive e mitigare gli impatti sui territori e sulle comunità vulnerabili.

Dell'ultimo servizio fa parte il Sistema Europeo di Informazione sugli Incendi Boschivi (European Forest Fire Information System, EFFIS) che fornisce dati in tempo (quasi) reale e dati storici sugli incendi boschivi in Europa, Medio Oriente e Nord Africa (European Commission, 2018). Dal 2008, EFFIS ha inoltre introdotto prodotti avanzati che includono mappe di pericolo di incendio e classificazioni basate sull'Indice di rischio di incendio.

Considerando alcuni dei prodotti forniti dal servizio EFFIS, questo lavoro propone un'analisi volta a valutare l'efficacia delle azioni di monitoraggio e gestione degli incendi boschivi, con particolare attenzione alla stagione estiva del 2023 in Italia. Storicamente, l'estate nei paesi del bacino del Mediterraneo è contrassegnata da un elevato rischio di incendi a causa delle alte temperature e delle scarse precipitazioni, che creano condizioni favorevoli alla combustione (Ruffault et al., 2020).

Inoltre, la presenza di vegetazione infiammabile e i venti caldi possono ulteriormente accelerare la diffusione delle fiamme, mentre l'aumento dell'attività umana, come il turismo, contribuisce ad incrementare il rischio (Molina-Terrén et al., 2019). Questi fattori rendono fondamentali le attività di monitoraggio, nonché le strategie di prevenzione e gestione degli incendi durante questo periodo particolarmente critico. In quest'ottica, il presente lavoro affianca alla valutazione preventiva del rischio di incendio su tutto il territorio nazionale un'analisi dettagliata delle aree colpite, considerando la tipologia di vegetazione nel periodo esaminato.

Il lavoro è strutturato come segue: dopo la descrizione dei dati e delle metodologie utilizzate (paragrafo 2), sono presentati i risultati dell'analisi del Fire Danger Rating (paragrafo 3.1), degli incendi attivi (paragrafo 3.2) e delle aree bruciate (paragrafo 3.3). Infine, verranno discusse le implicazioni di tali risultati, finalizzate alla prevenzione e gestione degli incendi (paragrafo 4).

2. Materiali e metodi

I dataset riguardanti gli incendi boschivi utilizzati in questo lavoro, sono stati acquisiti accedendo al repository Climate Data Store del servizio Copernicus (https://cds.climate.copernicus.eu/). I dati spaziali contenuti nello store sono disponibili nei formati shapefile (vettoriale) e NetCDF (raster, Network Common Data Form). In particolare, lo shapefile è un formato che supporta l'archiviazione di dati vettoriali ed è composto da più file correlati utilizzati per rappresentare la posizione, la forma e gli attributi delle caratteristiche (feature) geografiche oltre agli attributi associati. Una rappresentazione spaziale alternativa è fornita dai dati raster che permettono la visualizzazione di dati spaziali sotto forma di una griglia. A ciascuna cella della griglia corrisponde un valore che rappresenta una proprietà geografica o ambientale, come ad esempio altitudine o temperatura. Le analisi sono state effettuate utilizzando l'ambiente di sviluppo integrato (IDE) R-Studio e l'ambiente grafico del software statistico R. Sono stati inoltre utilizzati alcuni pacchetti specifici come: `sf` (Pebesma, 2018, Pebesma and Bivand, 2023) che permette l'importazione e la gestione di shapefile e altri dati vettoriali spaziali e la loro rappresentazione attraverso la combinazione di geometrie e dati tabulari; `tidyr` (Wickham, 2024) e `dplyr` (Wickham, 2023) per la manipolazione dei dati complessi da file NetCDF; `ggplot2` (Wickham, 2016) per le rappresentazioni grafiche delle burnt areas ed infine `raster` (Hijmans, 2024) utilizzato per l'analisi di dati climatici e spaziali con riferimento ai file NetCDF.

Per questo lavoro sono stati analizzati diversi indicatori per la prevenzione e valutazione del rischio degli incendi. In particolare:

- **Fire Danger Rating** (FDR), utilizzato per valutare il rischio di incendio in un'area specifica. È ottenuto combinando indici e fattori come l'indice di umidità di Duff, l'indice di Siccità, la velocità del vento e l'umidità del combustibile. Il FDR possiede sei classi di pericolo (molto basso, basso, medio, alto, molto alto, estremo) armonizzate per tutti i paesi europei;
- **Active Fires** rappresenta gli incendi attivi rilevati attraverso il sensore satellitare MODIS che misura le anomalie termiche. È una misura della potenza radiativa degli incendi e ne indica l'intensità e la quantità di energia rilasciata (espressa in Megawatt);
- **Burnt Areas** fornisce informazioni sulle aree bruciate al fine di valutare l'entità dei danni causati dagli incendi boschivi, fornisce una misura precisa dell'impatto ambientale e permette il riferimento alla tipologia di vegetazione colpita.

3. Alcuni risultati

3.1 Fire Danger Rating: valutazione preventiva del rischio di incendio

Il FDR è un indicatore utilizzato per informare il pubblico sulle condizioni di pericolo di incendio dei territori. Si ottiene combinando quattro indicatori che rappresentano e misurano:

1) l'umidità del combustibile fine;
2) la velocità del vento;
3) l'umidità (indicatore di Duff, misura il livello di umidità nel materiale organico in decomposizione sul suolo della foresta);
4) la presenza di siccità.

I primi due indicatori contribuiscono a definire il tasso di propagazione di incendio previsto, gli ultimi due indicano la quantità totale di materiali disponibili per la combustione da parte di un fronte di fiamma in movimento. Il sistema EFFIS prevede sei classi di pericolo di incendio definite sulla base del FDR, armonizzate per tutti i Paesi europei: *molto basso*, *basso*, *medio*, *alto*, *molto alto* ed *estremo*. In Fig.1 è riportato l'andamento temporale della media nazionale del FDR in Italia per i mesi estivi del 2023. I giorni segnalati (triangoli) corrispondono ai picchi della media nazionale dei valori del FDR superiori a due, concentrati soprattutto nel me-

se di agosto. Si noti che i picchi più alti della serie storica corrispondono generalmente a giorni del fine settimana. Nella Fig. 2, sono riportate le mappe del FDR per il territorio italiano relative ad alcuni giorni prefestivi dei mesi di giugno, luglio e agosto 2023 per i quali si è osservato un medio nazionale del FDR maggiore rispetto ai restanti giorni del mese. L'intensità del fenomeno è individuata dalla scala della colorazione (con il rosso che rappresenta i valori più elevati di pericolosità). Si notano l'intensità e la diffusione crescente nel corso del periodo oltre alla localizzazione delle aree interessate a sud della penisola ed in corrispondenza delle zone montane.

Figura 1. *Andamento temporale della media nazionale dei valori del FDR per la stagione estiva 2023.*

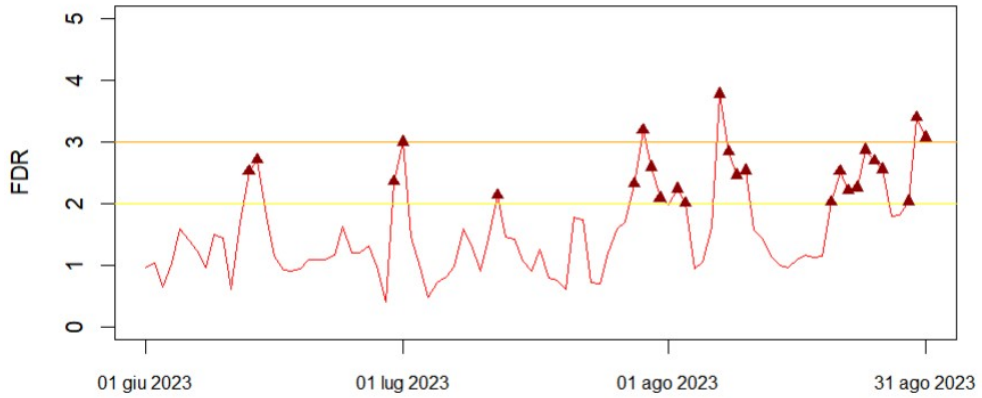
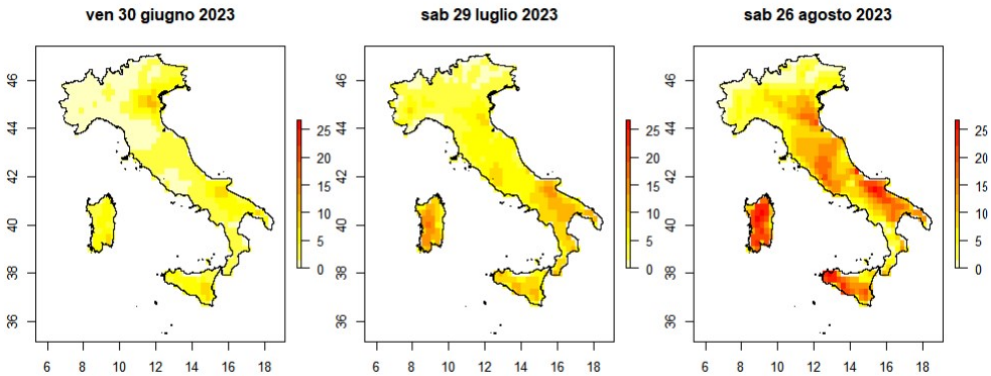


Figura 2. *Distribuzione spaziale del FDR in Italia in alcune giornate della stagione estiva 2023.*



3.2 Active fires

Gli incendi attivi (active fires o *hotspot*) vengono rilevati attraverso le anomalie termiche captate dal sensore MODIS, montato sui satelliti TERRA e ACQUA. Il sistema EFFIS si avvale dei dati forniti dal sistema FIRMS della NASA per monitorare questi incendi in tempo reale al passaggio dei satelliti sulla superficie terrestre.

Insieme alla posizione e ad alcune caratteristiche dell'osservazione satellitare, viene anche fornito il *grado di fiducia* associato a ciascuna osservazione. Le distorsioni delle rilevazioni possono essere dovute a molteplici fattori, tra cui le interferenze atmosferiche (come, ad esempio, la presenza di formazioni nuvolose).

Gli incendi attivi vengono individuati mediante il cosiddetto *potere radiativo del fuoco* (Fire Radiative Power, FRP) che, espresso in MWatt, rappresenta il tasso di energia radiativa termica in uscita proveniente da un incendio paesaggistico, integrato su tutte le lunghezze d'onda emesse e sull'emisfero che insiste sopra l'incendio stesso (Partanen and Sofiev, 2022).

Nella Fig. 3 si osserva la relazione tra il grado di fiducia e il logaritmo dell'indice FRP: la figura evidenzia un'associazione positiva tra i valori di log(FRP) e la loro affidabilità.

Figura 3. *Relazione tra affidabilità della misurazione e log(FRP).*

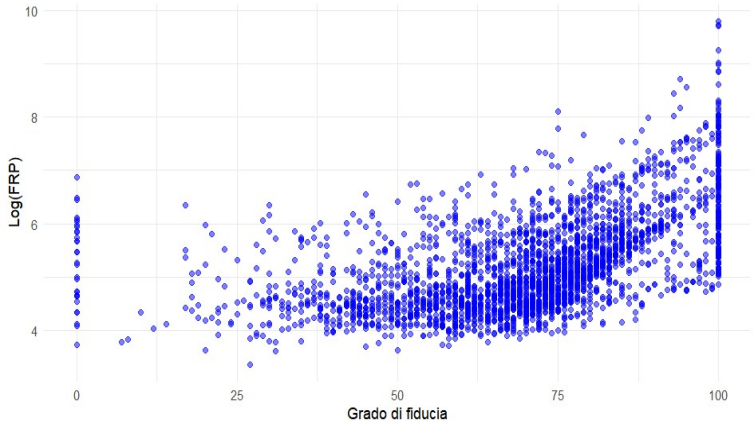
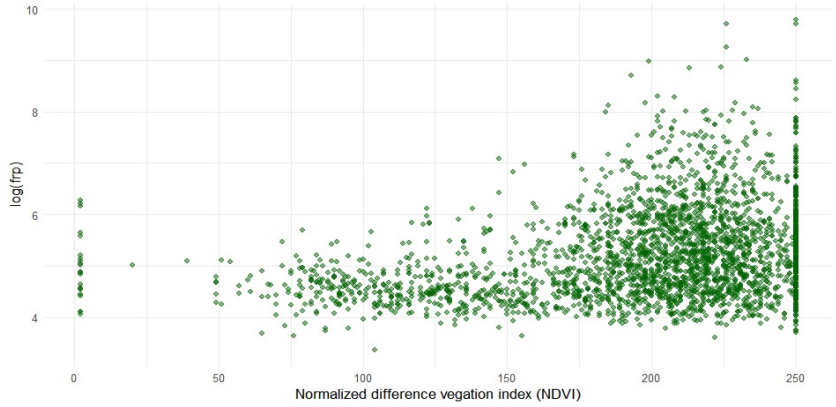


Figura 4. *Relazione tra l'indice di vegetazione e log(FRP)*



Un altro prodotto utile al monitoraggio degli incendi fornito dal sensore MODIS è l'*Indice di vegetazione* (Normalized Difference Vegetation Index, NDVI). L'indice rappresenta una combinazione delle percentuali di radiazione riflessa dalle piante nelle seguenti bande di lunghezze d'onda (Huang et al., 2021):

- banda del rosso visibile (RED), lunghezze d'onda comprese tra 620 e 670 nanometri (nm), fortemente assorbita dalla clorofilla delle piante;
- banda del vicino infrarosso (NIR), lunghezze d'onda comprese tra 841 e 876 nanometri (nm), riflessa in grande quantità dalle foglie delle piante (descrive dunque il livello di vigoria della coltura).

Nella Fig. 4 l'indice NDVI viene messo in relazione con il logaritmo del FDR: si può notare un'accentuata variabilità del log(FRP) in presenza di valori più elevati dell'indice NDVI superiori a 150. Questo indica che incendi con una maggior potenza radiativa colpiscono aree con maggiore ricchezza di vegetazione.

Nella Fig. 5 invece è riportata la distribuzione spaziale del log(FRP) per tutti gli incendi avvenuti in Italia nei mesi di giugno, luglio e agosto 2023. La mappa evidenzia valori maggiori nelle regioni meridionali della penisola.

La *luminosità nel canale medio infrarosso* (bright mid-infrared o bright MIR) rappresenta un parametro chiave nell'analisi degli incendi (Chen et al., 2024): è un indice che misura l'intensità termica degli incendi attraverso il rilevamento della radiazione infrarossa emessa. La Fig. 6 mostra l'associazione positiva tra la luminosità intercettata dai satelliti europei Sentinel-3A e Sentinel-3B log(FRP).

Figura 5. *Distribuzione spaziale di log(FRP) nella stagione estiva 2023.*

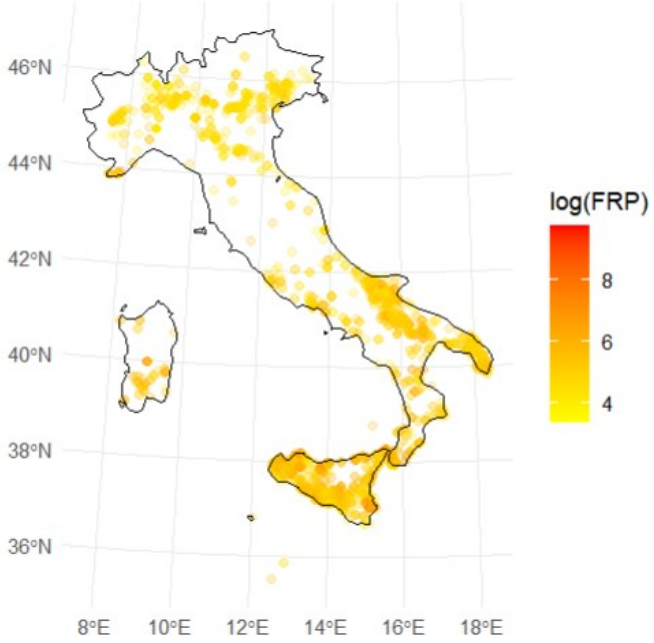
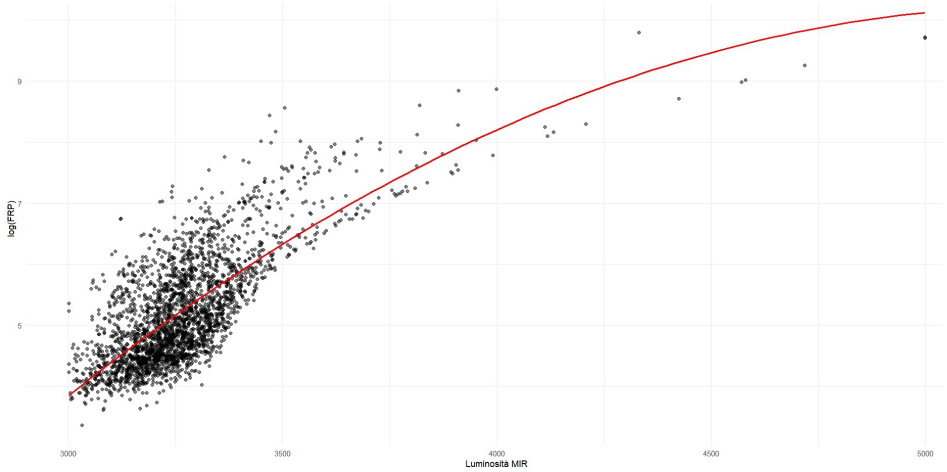


Figura 6. *Relazione tra Luminosità nel canale medio infrarosso (MIR) e log(FRP).*



Un ulteriore approfondimento riguardante l'analisi degli Active fires viene proposto utilizzando un algoritmo di clustering. In particolare, il clustering K-means è un algoritmo di apprendimento non supervisionato che permette di suddividere un insieme di dati multidimensionali in gruppi omogenei, raggruppando le osservazioni individuali in cluster in modo che gli elementi di ogni cluster siano più simili tra loro rispetto agli elementi di cluster diversi. Di seguito vengono considerate le osservazioni individuali riferite ai giorni dei mesi di giugno, luglio e agosto 2023 per le 5 variabili seguenti: FRP, luminosità totale (bright total infrared o bright TIR), MIR, grado di fiducia (confidence) e NDVI.

La Fig. 7 evidenzia come il secondo cluster sia associato a valori più elevati per tutte le variabili rispetto al primo. In generale, possiamo affermare che secondo cluster faccia riferimento ad incendi più intensi e di maggiori dimensioni (megafires). Come si può notare dalla Fig. 8, la maggior parte delle osservazioni riferite al secondo cluster, si collocano nelle regioni meridionali della penisola.

Figura 7. *Boxplot delle distribuzioni delle variabili associate agli active fires nei due cluster individuati con il metodo K-means.*

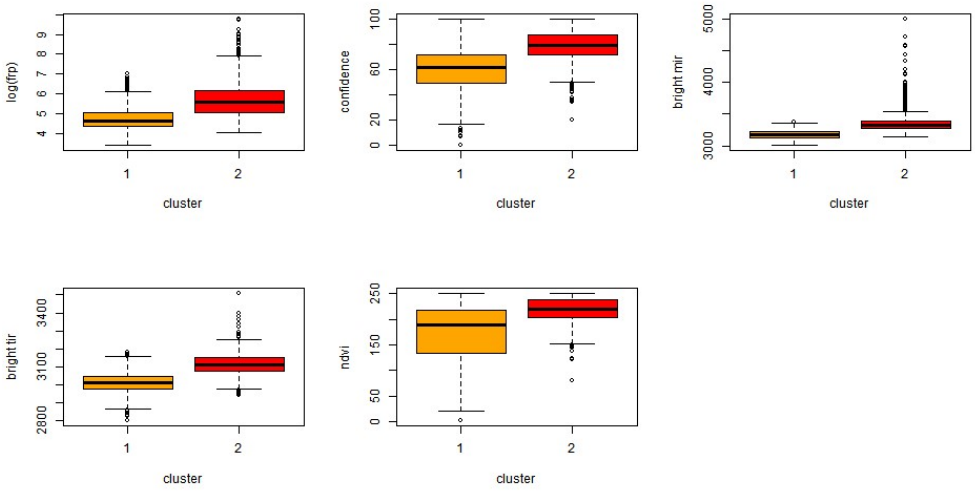
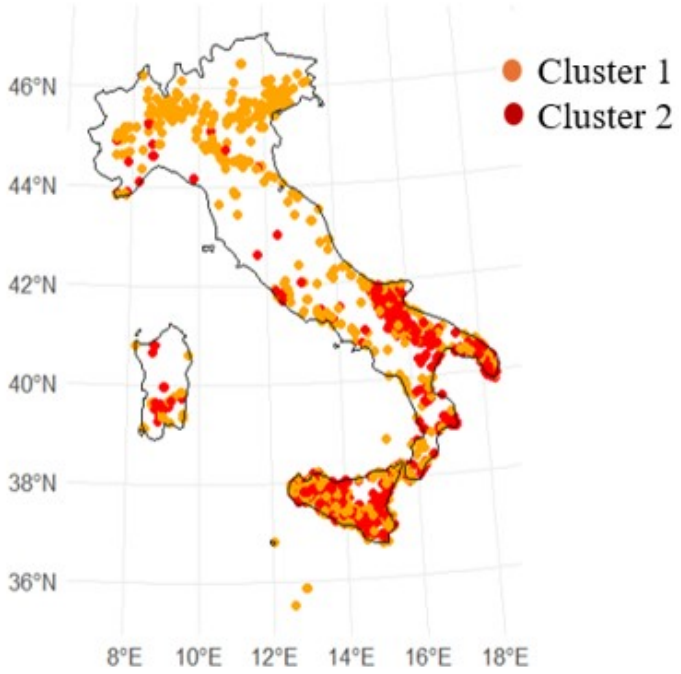


Figura 8. *Distribuzione spaziale dei cluster individuati tramite algoritmo K-means.*



3.3 Burnt Areas: distribuzione dell'estensione delle zone bruciate

Le *Burnt Areas* sono aree che sono state percorse da incendi e dove la vegetazione o altri materiali sono stati bruciati. Il relativo prodotto fornito da EFFIS è espresso in ettari e viene utilizzato per valutare l'impatto e l'entità degli incendi boschivi, indifferentemente dalla causa (sia essa di natura dolosa o accidentale).

In Fig. 9 è mostrata la distribuzione dell'estensione delle zone bruciate nel Sud Italia e nelle Isole durante i mesi estivi del 2023. La figura evidenzia le aree del Paese maggiormente colpite da incendi di grandi dimensioni, in particolare la Sicilia (provincia di Palermo e area sud-occidentale) e la Calabria (provincia di Reggio Calabria), che risultano tra le regioni più vulnerabili rispetto a questi eventi.

La Tab. 1 conferma questo primato riportando la lista dei dieci incendi più estesi in ordine decrescente, osservati in tutta la penisola nei tre mesi estivi 2023. Vengono indicati la durata dell'incendio e gli ettari bruciati. Questi incendi sono tutti localizzati in Sicilia ad eccezione del primo, verificatosi nel comune di Motta S. Giovanni (RC) con un'estensione totale di 3114 ettari bruciati.

Figura 9. *Estensione delle Burnt areas nel Sud Italia e Isole, giugno-agosto 2023*

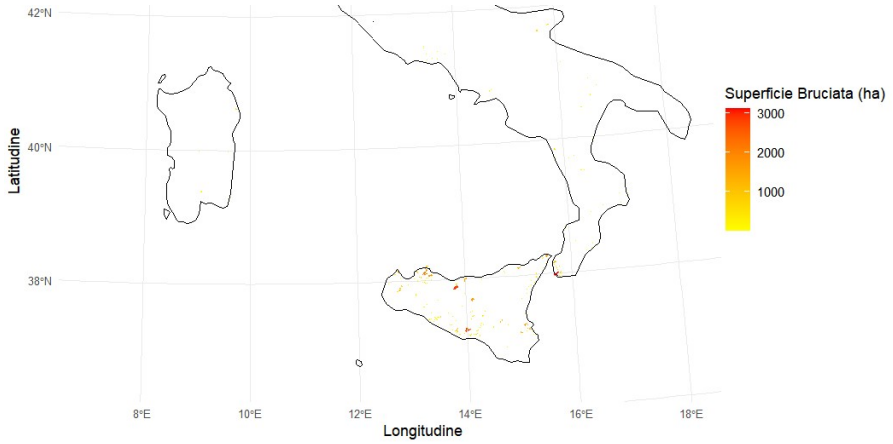


Tabella 1. *I dieci incendi più vasti in Italia da giugno ad agosto 2023*

Comuni	Provincia	Data inizio	Data fine	Ettari Bruciati
Motta S. Giovanni	R. Calabria	19/07/2023	24/07/2023	3114
Aliminusa	Palermo	24/07/2023	25/07/2023	2862
Ravanusa	Agrigento	20/07/2023	22/07/2023	2776
Monreale	Palermo	24/07/2023	26/07/2023	2029
Palermo	Palermo	24/07/2023	25/07/2023	1699
Palermo	Palermo	27/07/3023	27/07/2023	1633
Messina	Messina	24/07/2023	26/07/2023	1632
Alimena	Palermo	25/07/2023	26/07/2023	1612
Melilli	Siracusa	25/07/2023	26/07/2023	1525
Gratteri	Palermo	25/07/2023	26/07/2023	1450

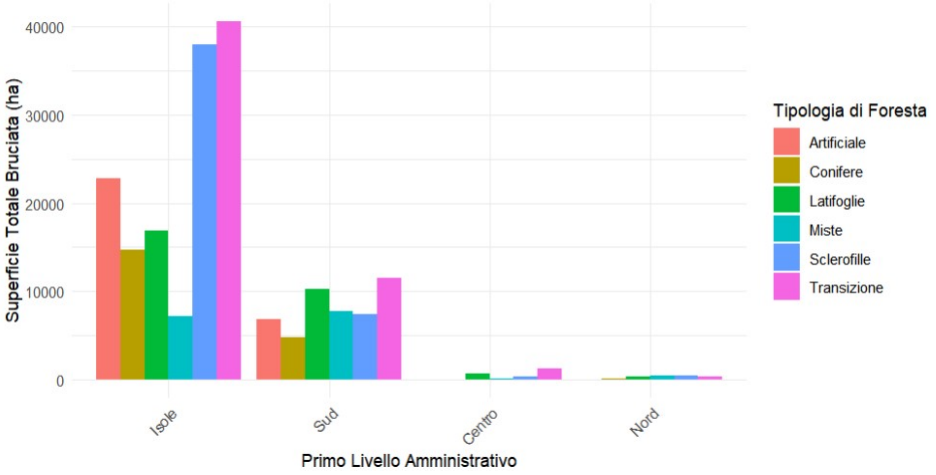
Al fine di esaminare quali tipologie di vegetazione siano state maggiormente colpite dagli incendi nella stagione in esame, viene considerata di seguito la classificazione delle tipologie di foreste secondo il prodotto *Burnt Areas* di EFFIS:

- *foreste artificiali*: aree dove gli alberi sono piantati dall'uomo. Queste foreste sono molto vulnerabili agli incendi poiché non replicano gli equilibri ecologici naturali e accumulano materiale infiammabile;
- *foreste di conifere*: alberi e arbusti come pini e abeti; Queste foreste sono più suscettibili agli incendi, presentano foglie a forma di aghi e producono

semi in coni, anche le foreste di conifere accumulano materiali infiammabili;

- *foreste di latifoglie*: alberi e arbusti come querce e faggi sono generalmente. Sono foreste più resistenti agli incendi con le loro foglie larghe e decidue che contribuiscono alla fertilità del suolo, facilitando la rigenerazione dell'ecosistema dopo un incendio;
- *foreste di transizione*: situate tra due ecosistemi forestali principali. Queste foreste, caratterizzate da presenza di macchia mediterranea, sono soggette ad incendi regolari che fanno parte del ciclo ecologico, ma l'aumento della frequenza e dell'intensità degli incendi è causa gravi danni a questi ecosistemi;
- *foreste di sclerofille*: piante (leccio e ulivi) che si adattano a climi aridi, possiedono foglie coriacee e radici profonde per conservare l'acqua. Sono generalmente foreste resistenti agli incendi naturali e possono ricacciare e germinare dopo il passaggio del fuoco.

Figura 10. *Burnt areas per tipologia di foreste e primo livello amministrativo.*



Nella Fig. 10 viene rappresenta la distribuzione delle aree bruciate per tipologia di vegetazione colpita dagli incendi, considerando la ripartizione geografica del territorio italiano al primo livello amministrativo, NUTS 1 (EU - Nomenclature of territorial units for statistics). I risultati mostrano come per le isole, la macchia mediterranea e le sclerofille sono state, nel 2023, le tipologie di foreste più colpite dagli

incendi con valori che si attestano oltre i 35000 ettari; per le regioni del sud, le tipologie di foreste colpite sono principalmente la macchia mediterranea e le foreste di latifoglie con estensione delle aree bruciate di poco superiori a 10000 ettari, mentre le regioni centrali e settentrionali presentano dei valori molto più bassi dell'ordine di qualche centinaia di ettari.

4. Conclusioni

Le analisi effettuate per l'estate 2023 mostrano un elevato numero di incendi di grandi dimensioni, con una particolare concentrazione nel sud Italia e nelle isole. Questi fenomeni estremi, dovuti alle condizioni di caldo torrido e siccità persistente, hanno reso particolarmente vulnerabile la vegetazione, portando a incendi sempre più intensi e difficili da controllare, soprattutto in queste aree geografiche. Condizioni ambientali caratterizzate da temperature più elevate e maggiore umidità sempre più frequenti e in parte attribuibili al cambiamento climatico favoriscono la propagazione del fuoco. Inoltre, la vulnerabilità di alcuni ecosistemi agli incendi, soprattutto in aree soggette a stress ambientale, può contribuire alla difficoltà di controllo di questi eventi estremi.

La prevenzione e il contrasto di questi fenomeni richiedono l'adozione di strategie preventive e di controllo dei territori, come l'impianto di foreste artificiali con specie vegetali meno soggette agli incendi. La manutenzione e la pulizia del suolo delle foreste, con la rimozione dei materiali organici che fungono da combustibile costituisce un ulteriore elemento non trascurabile per la prevenzione degli eventi incendiari. Tuttavia, l'alto numero di incendi dolosi ed il fatto che la gran parte delle foreste italiane sia di proprietà privata, rendono più difficili gli interventi coordinati. In conclusione, la gestione proattiva del territorio e l'uso dei sistemi di monitoraggio come Copernicus sono strumenti essenziali per affrontare il problema sempre più grave degli incendi boschivi in Italia. L'uso di telerilevamento permette infatti la mappatura in tempo quasi reale delle aree colpite, fornendo dati accurati sull'estensione e l'intensità degli incendi. Questi sistemi garantiscono una maggiore precisione e tempestività nell'individuare nuovi focolai, migliorando la capacità di intervenire rapidamente e riducendo i danni. Inoltre, l'ampia copertura territoriale di tali tecnologie consente di monitorare vaste aree, anche in regioni remote, migliorando così la gestione complessiva delle risorse e la pianificazione delle operazioni di contenimento degli incendi.

Riconoscimenti

Lo studio pubblicato è stato parzialmente finanziato dall'Unione Europea – Next-GenerationEU, Missione 4, Componente 2, nell'ambito del progetto GRINS - Growing Resilient, INclusive and Sustainable (GRINS PE00000018 – CUP H93C22000650001). I punti di vista e le opinioni espresse sono esclusivamente quelle degli autori e non riflettono necessariamente quelle dell'Unione Europea, nè può l'Unione Europea essere ritenuta responsabile per esse.

Riferimenti bibliografici

Ceccato, P., Moreira Agrela Goncalves, A., Pekel, J., Kemper, T., Spruyt, P., Salamon, P., Toreti, A., San-Miguel-Ayanz, J. and De Groeve, T. (2023). The 2022 COPERNICUS Emergency Management Service General Assembly. Publications Office of the European Union, Luxembourg, 2023. https://doi.org/10.2760/250455.

Chen, Y., Morton, D. C., Randerson, J. T. (2024). Remote sensing for wildfire monitoring: Insights into burned area, emissions, and fire dynamics. *One Earth*, 7(6): 1022-1028. https://doi.org/10.1016/j.oneear.2024.05.014.

Copernicus Emergency Management Service. (n.d.). Retrieved October 30, 2024 from https://emergency.copernicus.eu/

European Commission, Joint Research Centre (JRC) (2018). Fire events in the European Forest Fire Information System (version 2-3-1) [Dataset] http://data.europa.eu/89h/022cdeed-159f-407d-be18-0dface69ef92.

Huang, S., Tang, L., Hupy, J.P., Wang, Y., Shao, G. (2021). A commentary review on the use of normalized difference vegetation index (NDVI) in the era of popular remote sensing. *Journal of Forestry Research*, 32: 1–6. https://doi.org/10.1007/s11676-020-01155-1

Hijmans, R. (2024). raster: Geographic Data Analysis and Modeling. R package version 3.6-30, https://rspatial.org/raster.

Hohensinn, R., Aichinger-Rosenberger, M., Wareyka-Glaner, M.F., Ravanelli, M. (2024). Natural-hazard monitoring with global navigation satellite systems (GNSS). In: Roland Hohensinn, Cedric Schmelzbach (eds.), Advances in Geophysics, 65(1): 1-123. Elsevier.

Jones, R.L., Guha-Sapir, D., Tubeuf, S. (2022). Human and economic impacts of natural disasters: can we trust global data? Scientific Data, 9: 572. https://doi.org/10.1038/s41597-022-01667-x.

Martínez–Álvarez, F., Morales–Esteban, A. (2019). Big data and natural disasters: New approaches for spatial and temporal massive data analysis. Computers &

Geosciences, 129: 38-39. https://doi.org/10.1016/j.cageo.2019.04.012.

Molina-Terrén, D. M., Xanthopoulos, G., Diakakis, M., Ribeiro, L., Caballero, D., Delogu, G. M., Viegas, D. X., Silva, C. A., Cardil, A. (2019). Analysis of forest fire fatalities in Southern Europe: Spain, Portugal, Greece and Sardinia (Italy). *International Journal of Wildland Fire,* 28: 85-98.

Partanen, T. M., Sofiev, M. (2022). Forecasting the regional fire radiative power for regularly ignited vegetation fires. *Natural Hazards and Earth System Sciences,* 22: 1335-1346. https://doi.org/10.5194/nhess-22-1335-2022, 2022

Pebesma, E., Bivand, R. (2023). Spatial Data Science: With applications in R. Chapman and Hall/CRC.

Pebesma, E. (2018). Simple Features for R: Standardized Support for Spatial Vector Data. *The R Journal*, 10(1): 439–446. doi:10.32614/RJ-2018-009, https://doi.org/10.32614/RJ-2018-009.

Ruffault, J., Curt, T., Moron, V., Trigo, R. M., Mouillot, F., Koutsias, N., Pimont, F., Martin-StPaul, N., Barbero, R., Dupuy, J-L., Russo, A. & Belhadj-Khedher, C. (2020). Increased likelihood of heat-induced large wildfires in the Mediterranean Basin. *Scientific Reports,* 10, 13790. https://doi.org/10.1038/s41598-020-70069-z.

Wania, A., Joubert-Boitat, I., Dottori, F., Kalas, M. & Salamon, P. (2021). Increasing Timeliness of Satellite-Based Flood Mapping Using Early Warning Systems in the Copernicus Emergency Management Service. Remote Sensing 13(11): 2114.

Wickham, H., Vaughan, D., Girlich, M. (2024). tidyr: Tidy Messy Data. R package version 1.3.1, https://github.com/tidyverse/tidyr, https://tidyr.tidyverse.org.

Wickham, H., François, R., Henry, L., Müller, K., Vaughan, D. (2023). dplyr: A Grammar of Data Manipulation. R package version 1.1.4, https://github.com/tidyverse/dplyr.

Wickham, H. (2016). ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag New York. ISBN 978-3-319-24277-4.

Wirtz, A., Kron, W., Löw, P. & Steuer, M. (2012). The need for data: natural disasters and the challenges of database management. *Natural Hazards,* 70: 135–157.

Sitografia

CEMS: https://emergency.copernicus.eu/

Copernicus: https://cds.climate.copernicus.eu/

EFFIS: http://effis.jrc.ec.europa.eu/

EU - Nomenclature of territorial units for statistics: https://ec.europa.eu/eurostat/web/nuts

R- project: https://cran.r-project.org/web/packages

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 129-141

Analisi della soddisfazione rispetto ai servizi erogati da Sanitaservice ASL Foggia s.r.l.

Laura Antonucci[1]*, Antonia Cofano[2], Corrado Crocetta[2], Massimo Russo[1]

[1]Università degli Studi di Foggia, [2]Università degli Studi di Bari Aldo Moro

Riassunto: Il presente elaborato ha come obbiettivo l'analisi della customer Satisfaction dei servizi erogati da Sanitaservice ASL FG s.r.l. nell'anno 2023. Lo studio ha valutato 8 servizi e ne ha individuato punti di forza e di debolezza. L'indagine ha evidenziato un significativo aumento nella valutazione dei singoli servizi e nella soddisfazione media complessiva ma, allo stesso tempo, ha fatto emergere difficoltà organizzative e comunicative avvertite in alcuni distretti. In conclusione i servizi offerti sembrano migliorare di anno in anno, tuttavia sarebbe necessario valutare le problematiche emerse al fine di implementare l'efficacia dei servizi stessi.

Keywords: valutazione servizi sanitari, customer satisfaction.

1. Introduzione

La Sanitsaservice ASL Fg s.r.l., da sette anni effettua una indagine sulla soddisfazione rispetto ai servizi erogati, affidandola a dipartimenti dell'Università degli Studi di Foggia. L'edizione 2023 è stata affidata alla prof. Laura Antonucci, docente di statistica sociale presso il dipartimento di medicina clinica e sperimentale. Tale indagine, giunta ormai alla settima edizione, mira a valutare, attraverso i giudizi espressi dai responsabili delle diverse strutture della ASL FG che si avvalgono dei servizi della Sanitaservice ASL FG, quale sia il livello di soddisfazione degli stessi

* Autore corrispondente: laura.antonucci@unifg.it
Il lavoro qui descritto è frutto di un progetto comune, ma L. Antonucci ha provveduto alla redazione dei paragrafi 3.5, 3.6, 3.7 e 3.8, A. Cofano ha scritto i paragrafi 3.1, 3.2, 3.3 e 3.4, M. Russo ha redatto il paragrafo 2 e C. Crocetta i paragrafi 1 e 4.

e ad individuare eventuali criticità o aree di miglioramento. biettivi generali e specifici, rassegna bibliografica sull'argomento, articolazione del lavoro.

2. Materiali e metodi

L'oggetto della ricerca e i diversi aspetti analizzati sono rimasti pressappoco invariati rispetto alle precedenti edizioni per ovvi motivi di continuità e per garantire la confrontabilità coi dati rilevati nei sei anni precedenti. Ciò nonostante si è ritenuto necessario, considerando il Disciplinare 2023, modificare alcuni aspetti circa la valutazione del servizio di Hospitality e di Gestione del Servizio Informatico al fine di rendere l'analisi più coerente alle attività effettivamente svolte. Inoltre, a differenza delle edizioni 2020, 2021 e 2022, si è deciso di eliminare le domande inerenti l'emergenza sanitaria della pandemia COVID-19.

2.1 Il questionario e le sue novità

Come di consueto sono state analizzate le diverse tipologie di servizi erogati, tuttavia si è ritenuto necessario integrare anche la valutazione del servizio inerente le attività di Front Office e di Portineria. Quindi le otto tipologie di servizi analizzati nel 2023 sono:

- Servizio di Ausiliariato;
- Servizio di Pulizie e Sanificazione ambientale;
- Servizio di Manutenzione degli immobili;
- Servizio di Trasporto beni economali;
- Servizio Emergenza/Urgenza 118;
- Servizio Gestione sistemi informativi e supporto tecnico informatico;
- Servizio Hospitality;
- Servizio di Front Office e Portineria.

I questionari, così come per le passate edizioni, sono suddivisi in quattro sezioni distinte:

- PARTE 1:
  - Intestazione con nomi e loghi dell'azienda da valutare ed ente incaricato della rilevazione.
  - Ruolo o figura professionale di riferimento;
- PARTE 2:
  - Informazioni circa il ruolo e la struttura di appartenenza del rispondente;

- PARTE 3:
  - Attività operative della SanitaService;
- PARTE 4:
  - Frequenza mensile, gestita dall'ente erogatore, della fruizione dei vari servizi;
  - Domanda riepilogativa attinente l'intera organizzazione della SanitaService;
  - Domanda aperta per commenti, suggerimenti o eventuali reclami.apoversi successivi con rientro prima riga pari a 0,5 cm.

2.2 La popolazione oggetto dell'indagine

Nel 2023 sono stati raccolti 231 questionari compilati da ben 153 rispondenti. Il numero di questionari è stato leggermente superiore rispetto all'anno precedente.

La minima variazione nella quantità di questionari raccolti, rende i dati confrontabili con quelli degli anni precedenti non comportando alcun rischio per il corretto sviluppo dell'analisi.

Anche quest'anno, la raccolta dei questionari è stata effettuata dal personale di SanitaService, nel periodo compreso tra il 18 Marzo 2022 e il 26 maggio 2022.

Tabella 1. *Numero questionari raccolti relativi ai diversi servizi erogati da SanitaService nel 2023.*

SERVIZI EROGATI DA SANITASERVICE	QUESTIONARI RACCOLTI 2021
Servizio di Ausiliariato	72
Servizio di Pulizie e Sanificazione ambientale	73
Servizio di Manutenzione degli immobili	45
Servizio di Trasporto beni economali	14
Servizio di Emergenza/Urgenza 118	9
Gestione SI e supporto tecnico informatico	4
Hospitality	4
Front Office e Portineria	10
Totale	231

3. I risultati della Customer Satisfaction

3.1 Il servizio di Ausiliariato

I rispondenti hanno assegnato un punteggio da 1 a 10 alla propria percezione delle seguenti quattro dimensioni da valutare: Professionalità, Comportamento, Capacità Relazionali e Soddisfazione complessiva.

La soddisfazione media complessiva è stata pari a 8,9 ovvero 0,3 punti in più rispetto all'edizione precedente e superando persino la valutazione di 8,8 del 2021 evidenziando quindi un ottimo recupero in tutte le quattro dimensioni valutate. complessiva.

Ad esclusione dell'attività di "accompagnamento e trasporto dei degenti" che, con una media di 8,8 punti, si mantiene in linea con le rilevazioni degli anni precedenti; tutte le altre attività sono state valutate in maniera decisamente positiva con una media di 9,00 punti.

Inoltre si evidenzia come il servizio "controllo degli accessi delle persone" sia stato quello ad essere maggiormente cresciuto passando da una media di 8,3 a una valutazione di 8,8.

Tabella 2. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività di ausiliariato. Rilevazione 2023*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	AUSILIARIATO 2023	PROF.	COMP.	REL.	SODD.
71	1. Accompagnamento e trasporto dei degenti con mezzi adeguati;	8,8	8,7	8,8	8,8
	2. Pulizia degli ambienti e operazioni elementari e di supporto necessarie al funzionamento del reparto, quali lo spostamento dei ricoverati;	8,9	9,0	8,9	8,9
	3. Trasporto di medicine , referti, materiale biologico, sanitario ed economale, vitto, attrezzature, vestiario, biancheria, etc.	9,1	9,1	9,1	9,1
	4. Areare, spazzare, lavare e spolverare tutti gli ambienti dell'unità operativa alla quale è addetto;	9,1	9,1	9,1	9,1
	5. Partecipazione con l'équipe di lavoro, limitatamente ai propri compiti;	8,9	8,9	9,0	8,9
	6. Controllo degli accessi delle persone.	8,8	8,8	8,8	8,8
	MEDIA	**8,9**	**8,9**	**8,9**	**8,9**

3.2 I Servizi di Pulizia e Sanificazione ambientale

In questa sezione i rispondenti hanno dovuto valutare quattro dimensioni, ovvero: Professionalità, Tempestività d'intervento, Qualità dell'intervento e Soddisfazione Complessiva; utilizzando una scala di valutazione da 1 a 10.

La soddisfazione complessiva media pari a 9 punti è aumentata rispetto ai 8,6 punti registrati nel 2022 ritornando così ai livelli registrati nel 2019, anno in cui il servizio aveva registrato una soddisfazione media proprio di 9,0 punti.

Tabella 3. *Punteggi attribuiti ai diversi servizi erogati da SS all'attività di pulizia. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	PULIZIE 2023	PROF.	COMP	REL.	SODD.
72	1. Attività ordinarie di pulizia e sanificazione e disinfezione;	9,0	9,0	9,0	9,0
	2. Decontaminazione e rimozione di eventuale materiale organico da tutte le superfici;	9,1	9,0	9,0	9,0
	3. Raccolta e trasporto di tutte le categorie di rifiuti, sostituzione del sacchetto, detersione e disinfezione dei contenitori;	9,0	8,9	8,9	9,0
	4. Pulizia e disinfezione degli arredi e delle attrezzature mobili;	8,9	8,9	8,9	8,9
	5. Spolveratura ad umido, detersione e successiva disinfezione, di tutte le superfici orizzontali e verticali;	9,0	8,9	8,9	9,0
	6. Detersione e disinfezione dei lavabi, accessori e arredi sanitari;	9,0	9,0	9,0	9,0
	7. Pulizia a fondo e disinfezione degli arredi mobili;	8,9	8,9	8,9	8,9
	8. Disincrostazione sanitaria, rubinetterie e zone limitrofe;	8,9	8,9	8,9	8,9
	9. Raccolta e trasporto dei rifiuti speciali fino al punto di deposito temporaneo;	9,1	9,1	9,1	9,1
	10. Palestre: detersione materassini, letti per fisioterapia, ecc. (esclusi i giocattoli).	9,1	9,1	9,1	9,1
	MEDIA	**9,0**	**9,0**	**9,0**	**9,0**

3.3 Il servizio di Manutenzione degli immobili

Anche per questa tipologia di servizio i rispondenti hanno dovuto valutare 4 distinte dimensioni: Professionalità, Tempestività d'intervento, Qualità dell'intervento e la Soddisfazione complessiva; utilizzando una scala di punteggi discreti da 1 a 10.

La soddisfazione media risulta pari a 9,1 punti, decisamente superiore rispetto al valore medio di 8,2 registrato nel 2022.

In netto contrasto con quanto riscontrato nelle edizioni precedenti, il servizio relativo alla manutenzione del verde è passato da un punteggio medio di 8,1 nel 2022 a quello di 8,9 nel 2023 con un incremento di ben 0,8 punti.

L'attività di manutenzione effettuata da parte di Sanitaservice nei locali interni ed esterni ha registrato anch'essa una crescita significativa in ciascuna delle dimensioni analizzate passando così da una media di 8,4 nel 2022 a quella di 9,3 della presente edizione.

Tabella 4. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività di manutenzione degli immobili. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	MANUTENZIONE 2023	PROF.	COMP.	REL.	SODD.
45	1. Gli interventi di manutenzione effettuati da parte di Sanitaservice nei locali interni ed esterni, (a titolo esemplificativo e non esaustivo: interventi su infissi, opere murarie, cancellate, impianti di scarico delle acque, etc.);	9,3	9,3	9,3	9,4
	2. Mantenere nelle condizioni estetiche migliori l'arredo verde esterno, intesa qualunque coltura arborea e floreale;	8,8	8,9	8,9	9,0
	3. Gestione e smistamento delle richieste di manutenzione ordinaria sugli impianti e gli immobili, pervenuti sui protocolli informatici dei vari presidi ospedalieri e dai D.S.S. dell'ASL di Foggia;	9,2	9,1	9,2	9,2
	4. Supporto alla pianificazione e programmazione degli interventi di manutenzione da eseguire presso le varie strutture sanitarie dell'ASL.	9,1	9,1	9,2	9,2
	MEDIA	**9,1**	**9,1**	**9,1**	**9,2**

3.4. Il servizio di Trasporto beni economali

Il servizio di Trasporto beni economali è stato valutato da 14 intervistati ovvero un numero di individui coinvolti coerente con le rilevazioni degli anni precedenti.

Nell'analizzare questa specifica attività si evidenzia una soddisfazione media complessiva pari a 9,1 punti, ovvero superiore di 0,8 punti rispetto all'8,3 del 2022.

Possiamo osservare come l'attività di Prelievo, trasporto e distribuzione farmaci, materiale sanitario e cancelleria abbia registrato un netto aumento in tutti gli aspetti

valutati passando da una media di 8,2 punti nel 2022 a quello di 8,9 punti nell'ultima rilevazione.

L'attività di Stoccaggio e deposito, seppur valutata per la prima volta, registra una media complessiva di 9,6 pertanto si attesta come una delle attività con il punteggio medio maggiore dell'analisi dei servizi 2023.

L'attività di Movimentazione dei flussi documentali, di materiale biologico e dei referti tra le strutture dell'ASL di Foggia mostra una lieve crescita d'altronde è passata da una media di 8,4 punti nel 2022 a quella di 8,7 nel 2023. Dunque è stata valutata in media 0,3 punti in più rispetto la passata edizione.

Tabella 5. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività di traporto beni economali. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	TRASP. BENI ECONOMALI 2023	PROF.	COMP.	REL.	SODD.
14	1. Movimentazione dei flussi documentali, di materiale biologico e dei referti tra le strutture dell'ASL di Foggia;	8,7	8,8	8,6	8,7
	2. Prelievo, trasporto e distribuzione farmaci, materiale sanitario e cancelleria;	8,8	8,9	8,8	8,9
	3. Prelievo, trasporto e consegna di ricette farmaceutiche e specialistiche.	9,2	9,4	9,2	9,2
	4. Attività di stoccaggio e deposito	**9,4**	**9,7**	**9,6**	**9,6**
	MEDIA	**9,0**	**9,2**	**9,0**	**9,1**

3.5 I servizi di Emergenza/Urgenza 118

I servizio di Emergenza/Urgenza sono stati valutati da 9 rispondenti ovvero dal numero più alto di intervistati in questo abito dal 2019 ad oggi inoltre si è rivelato il servizio più efficace ed efficiente di questa rilevazione dimostrando una crescita continua e significativa come evidenziato dalla media complessiva pari a 10 punti e superiore di 1,1 punti rispetto all'edizione precedente quando essa è stata pari ad 8,9.

Si registra pertanto un miglioramento generale in ogni singola attività analizzata.

Ad essere cresciuti maggiormente sono stati i servizi di Utilizzo di linee guida e protocolli elaborati dalla Centrale operativa per la gestione dell'emergenza/urgenza e di Livello di conoscenza della legge sulla privacy in relazione all'intervento i quali sono passati da una media di 8,7 punti nel 2022 a quella di 10 punti nel 2023. Si è registrato dunque un incremento di 1,3 punti in ognuna delle quattro dimensioni analizzate.

Tabella 6. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività Emergenza/Urgenza 118. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	EMERGENZA/URGENZA 118 2023	PROF.	COMP.	REL.	SODD.
9	1. Utilizzo di linee guida e protocolli elaborati dalla Centrale operativa per la gestione dell'emergenza/urgenza;	10,0	10,0	10,0	10,0
	2. Coordinamento con gli altri servizi pubblici addetti alle emergenze;	10,0	10,0	10,0	10,0
	3. Utilizzo degli specifici strumenti informatici, di fonia, radiocomunicazione ed orografici;	10,0	10,0	10,0	10,0
	4. Modalità di rapporto con l'utenza, soprattutto nei casi di alta criticità;	10,0	10,0	10,0	10,0
	5. Livello di conoscenza della propria mansione sull'intervento;	10,0	10,0	10,0	10,0
	6. Livello di conoscenza della legge sulla privacy in relazione all'intervento.	10,0	10,0	10,0	10,0
	MEDIA	**10,0**	**10,0**	**10,0**	**10,0**

3.6 Gestione SI e supporto tecnico informatico

Anche per questa tipologia di servizio i rispondenti hanno valutato: Professionalità, Tempestività d'intervento, Qualità dell'intervento e la Soddisfazione complessiva.

Il servizio è stato valutato, come nella precedente edizione, da 4 rispondenti.

In media il servizio è stato valutato con un punteggio di 9,3 ovvero 0,1 punti in più rispetto alla valutazione registrata nel 2022. Si può pertanto affermare che il servizio è rimasto stabile e costante nei due anni analizzati.

Il servizio di Help Desk di primo livello condotto dagli operatori tecnici ICT è passato da una valutazione di 9 punti nel 2022 a 9,3 nel 2023 registrando un aumento di 0,3 punti.

Il servizio di assistenza e manutenzione hardware (IMAC) ha registrato invece la crescita più rilevante passando da un punteggio medio di 9,0 punti del 2022 a quello di 9,5 nel 2023. Si è attestata dunque una crescita pari allo 0,5 punti in ognuno degli aspetti valutati.

Tabella 7. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività Gestione SI e supporto tecnico informatico. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	SUPPORTO AI S. I. 2023	PROF.	COMP.	REL.	SODD.
4	1. La gestione del SISTEMA INFORMATICO AZIENDALE	9,3	8,8	9,3	9,3
	2. Il servizio di Help Desk/ Assistenza Tecnico Applicativa di livello 0	9,0	9,0	9,0	9,0
	3. Servizio di Help Desk di primo livello condotto dagli operatori tecnici ICT	9,3	9,3	9,3	9,3
	4. Servizio di Help Desk di primo livello condotto dagli operatori tecnici CUP	9,5	9,5	9,5	9,5
	5. Servizio di assistenza e manutenzione hardware (IMAC)	9,5	9,5	9,5	9,5
	6. Servizio di manutenzione di infrastrutture di rete, WiFi e ponti radio	9,3	9,3	9,3	9,3
	MEDIA	**9,3**	**9,2**	**9,3**	**9,3**

3.7 Hospitality

Il servizio è stato valutato da quattro rispondenti.

In media il servizio è stato valutato con un punteggio di 9,1 dimostrando un importante crescita rispetto alla valutazione registrata nell'anno 2022 quando la media totale si era dimostrata essere 8,2.

L'attività di back office per la registrazione di ricette ed altri documenti da parte del personale addetto al servizio è quella ad essere maggiormente cresciuta passando da un punteggio medio di 7,5 punti nel 2022 a quella di 10 nella presente edizione.

Le attività di recall e di cancellazione o disdetta è stata valutata in modo decisamente positivo registrando una votazione media pari a 9 punti mentre nel 2022 era stata di 7,6 punti.

L'attività di gestione tecnica e operativa delle agende si è rivelata costante nelle diverse edizioni registrando annualmente un punteggio medio pari a 9,3 punti.

Tabella 8. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività Hospitality. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	HOSPITALITY 2023	PROF.	COMP.	REL.	SODD.
4	1. La gestione tecnica e operativa delle agende da parte del personale addetto al servizio	9,5	9,3	9,3	9,3
	2. La gestione dei servizi di prenotazione delle prestazioni sanitarie da parte del personale addetto al servizio	8,3	8,3	8,3	8,5
	3. Le attività di recall e di cancellazione o disdetta della prenotazione da parte del personale addetto al servizio	9,0	9,0	9,0	9,0
	4. La gestione dei servizi online da parte del personale addetto al servizio	8,5	8,5	8,5	8,5
	5. L'attività di back office per la registrazione di ricette ed altri documenti da parte del personale addetto al servizio	10,0	10,0	10,0	10,0
	6. L'attività di gestione ALPI svolta dal personale addetto al servizio	9,5	9,5	9,5	9,5
	MEDIA	**9,1**	**9,1**	**9,1**	**9,1**

3.8 Front Office e Portineria

Il servizio di Front Office e Portineria è stato inserito per la prima volta durante la rilevazione 2023 poiché la Sanitaservice ha deciso di promuovere questo nuovo servizio al fine di agevolare l'utenza sin dalla fase di primo accesso ai servizi ambulatoriali e territoriali.

Anche in questo caso i rispondenti hanno assegnato un punteggio da 1 a 10 alla propria percezione delle solite quattro dimensioni: Professionalità, Comportamento, Capacità Relazionali e Soddisfazione complessiva.

Il servizio è stato valutato da 10 intervistati che hanno riportato una soddisfazione media del servizio pari a 9,5 punti ovvero una delle valutazioni più alte registrate nella presente edizione.

I dati rilevati permettono di definire ottima la valutazione complessiva di questo servizio con un punteggio medio pari a 9,4 punti.

I servizi di Gestione dei servizi di front office da parte del personale addetto e di Attività di back office svolte dal personale sono da segnalare per l'ottima media che registrano infatti, in entrambi i casi, essa si attesta attorno al 9,5.

Tabella 9. *Punteggi in scala 1 – 10 attribuiti dai rispondenti ai diversi servizi erogati da Sanitaservice ASL FG relativi all'attività Front Office e Portineria. Rilevazione 2023.*

FREQ. ASSOL.	ATTIVITÀ DA VALUTARE	ASPETTI DA VALUTARE			
	ACCOGLIENZA, FRONT OFFICE E PORTINERIA 2023	PROF.	COMP.	REL.	SODD.
10	1. Accoglienza degli utenti da parte del personale addetto al servizio	9,5	9,4	9,2	9,5
	2. Gestione dei servizi di front office da parte del personale addetto	9,6	9,4	9,6	9,6
	3. Attività di back office svolte dal personale addetto al servizio	9,5	9,5	9,3	9,5
	4. Gestione della portineria da parte del personale addetto al servizio	9,0	9,3	9,3	9,3
	MEDIA	**9,4**	**9,4**	**9,4**	**9,5**

4. Conclusioni

Di seguito presentiamo i risultati dell'indagine 2023 in modo sintetico considerando i valori medi rilevati per i diversi servizi esaminati tenendo conto dei quattro aspetti considerati: professionalità, tempestività, qualità del servizio e soddisfazione complessiva.

Dalla tabella che segue si rileva un quadro decisamente positivo visto che tutti i punteggi, espressi in una scala 1-10, sono ampiamente superiori al 9.

Tabella 10. *Medie dei punteggi attribuiti ai diversi servizi erogati da Sanitaservice ASL FG s.r.l. rispetto agli aspetti sottoposti a valutazione, nel 2023.*

PUNTEGGI MEDI ATTRIBUITI AI DIVERSI SERVIZI OFFERTI DA SANITASERVICE NEL 2023	**PROF.**	**COMP.**	**REL.**	**SODD.**	**MEDIA**	**FREQ.**
Servizio di Ausiliariato;	8,9	8,9	8,9	8,9	8,9	72
Servizio di Pulizia;	9,0	9,0	9,0	9,0	9,0	73
Servizio di Manutenzione;	9,1	9,1	9,1	9,2	9,1	45
Servizio di Trasporto di farmaci e beni economali;	9,0	9,2	9,0	9,1	9,1	14
Servizio di Emergenza Urgenza;	10,0	10,0	10,0	10,0	10,0	9
Servizio di Supporto SI	9,3	9,2	9,3	9,3	9,2	4
Servizio di Hospitality	9,1	9,1	9,1	9,1	9,1	4
Servizio di Accoglienza, Front Office e portineria	9,4	9,4	9,4	9,5	9,4	10
MEDIA	**9,2**	**9,2**	**9,2**	**9,3**	**9,2**	**231**

Riteniamo importante considerare separatamente i diversi aspetti perché ciò ci consente di individuare più facilmente le aree e di intervenire in modo più tempestivo.

Il primo aspetto considerato è la professionalità. In continuità con le passate edizioni non emerge in modo netto una differenza tra servizi tecnici e generali. L'andamento si rivela superiore alla media in tutti i settori e soprattutto nel servizio di Emergenza Urgenza.

La tempestività, così come la qualità dei servizi, registra un alto rendimento in particolare nel servizio di Accoglienza, Front Office e Portineria.

Ai testimoni privilegiati è stato chiesto infine di dare un punteggio alla Soddisfazione Complessiva rispetto alla qualità dei servizi forniti dagli operatori di Sanitaservice. Questo punteggio rappresenta la sintesi dei 3 aspetti sopra descritti e come è facile verificare, è congruo rispetto agli altri punteggi attribuiti indicando, quindi, che i rispondenti hanno attribuito i punteggi in modo accurato.

L'indagine ha inoltre permesso la raccolta delle osservazioni riportate da un numero rilevante di rispondenti i quali, pur essendo molto soddisfatti dei servizi offerti, ritengono necessario:

- prevedere sostituzioni tempestive del personale in caso di ferie e di malattia in modo tale da non lasciare scoperti i turni di lavoro;
- condividere organizzazione dei turni di servizio del personale di Sanitaservice e a fine mese consegnare copia del turno espletato;
- prevedere una valutazione dei singoli dipendenti per non sottostimare chi lavora e valutare in maniera inappropriata la complessità del servizio;
- prevedere maggiore confronto, condivisione dei problemi per soluzioni condivise e comunicazione più efficace.

In conclusione l'indagine ha evidenziato un aumento generale della qualità ed efficienza dei servizi offerti da Sanitaservice ASL FG soprattutto nel settore Emergenza e Urgenza e in quello di Accoglienza, Front Office e Portineria.

Riferimenti bibliografici

Hauck K., Rice N., Smith P., (2003). The influence of health care organisations on health system performance. Journal of Health Services Research and Policy 8(2):68–74.

Loeb JM. (2004). The current state of performance measurement in health care. International Journal for Quality in Health Care, 16 (Suppl. 1):15–19.

Mant J. (2001). Process versus outcome indicators in the assessment of quality of health care. International Journal for Quality in Health Care, 13(6):475–480.

Smith P.C. (2005). Performance measurement in health care: history, challenges and prospects. Public Money & Management, 25(4): 213–220.

Smith P.C. (1990). The use of performance indicators in the public sector. Journal of the Royal Statistical Society, 153(1): 53–72.

Steinke C., Webster L. and Fontaine M. (2010). Evaluating building performance in healthcare facilities: an organizational perspective HERD: Health Environments. Research & Design Journal, 3(2): 63-83.

Tucker M. and Smith A. (2011). User perceptions in workplace productivity and strategic FM delivery. Facilities, 26(5/6): 196-212.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 143-154

L'impatto delle mutazioni del DNA sul processo di *splicing*: un'analisi statistica nel contesto del gene BRCA1

Barbara Nocca[1], Nunziata Ribecco[1], Alessandro Stella[2]

[1] Dipartimento di Economia e Finanza, Università degli Studi di Bari Aldo Moro,
[2] Dipartimento di Scienze biomediche e oncologia umana, Università degli Studi di Bari Aldo Moro

Riassunto: In questo lavoro ci si propone di analizzare l'effetto delle mutazioni del DNA sul processo di splicing, con particolare attenzione al gene BRCA1 sito sul cromosoma 17. Utilizzando un campione di 105 soggetti suddivisi tra i soggetti portatori di mutazioni note per influenzare lo splicing (positivi) e i soggetti portatori di mutazioni che non lo influenzano (negativi), a seguito di una prima analisi esplorativa dei dati, è stata condotta l'analisi delle corrispondenze multiple. Essa ha rivelato che specifiche mutazioni negli esoni 16, 19, 20 e 21 del gene BRCA1, localizzato sul cromosoma 17, sono significativamente associate a variazioni nel processo di splicing. Al contrario, mutazioni negli esoni 3, 4, 17 e 18 non hanno mostrato un impatto significativo sullo splicing. Questi risultati forniscono nuove informazioni sulle mutazioni genetiche del gene BRCA1 con importanti conseguenze sul processo di splicing, contribuendo alla comprensione della patogenesi delle malattie che ne derivano e suggerendo potenziali direzioni per future ricerche.

Keywords: Mutazione, Processo di Splicing, Corrispondenze multiple.

1. Introduzione

La trascrizione è il processo attraverso il quale una cellula produce una copia complementare di una sequenza di DNA in forma di RNA messaggero (mRNA). Tale trascritto è quindi utilizzato per la sintesi di proteine, non prima di aver subito un processo di maturazione detto "splicing" durante il quale dal pre-mRNA sono rimosse dal trascritto primario le sequenze non codificanti dette *introni*. Le rimanenti porzioni codificanti, dette *esoni*, saranno unite tra loro per ottenere l'mRNA maturo

che sarà tradotto in proteine.

Ogni individuo è portatore di centinaia di variazioni nucleotidiche rispetto alla sequenza di riferimento (normale) del DNA che sono responsabili della naturale diversità tra esseri umani. Tuttavia, alcune di queste variazioni possono essere causa di malattia. Il processo di splicing è un processo fondamentale perché l'inserimento erroneo di sequenze *intronіche*, o l'omissione di sequenze *esoniche*, porterebbe alla traduzione di proteine anomali con perdita della normale funzione biologica. Tuttavia, non è facile prevedere quali sostituzioni nucleotidiche possano avere delle conseguenze sull'esecuzione corretta del processo di splicing.

2. Materiali e metodi

Il campione analizzato era costituito da 105 individui a sua volta distinto in due sottocampioni:

- il primo sotto-campione, composto da 50 individui, è relativo alla popolazione dei **"positivi"** ovvero coloro in cui la mutazione ha effetto sullo splicing;
- il secondo sotto-campione, composto da 55 individui, è relativo alla popolazione dei **"negativi"** ovvero coloro in cui la mutazione non ha effetto sullo splicing;

Il dataset include le seguenti variabili rilevanti per l'analisi degli errori nella trascrizione associate a un effetto sullo splicing:

- Transcript ID: rappresenta l'Id del transcript in banca dati (www.ensembl.org);
- Exon: rappresenta l'esone interessato dalla mutazione;
- Chrom: è il cromosoma dove è localizzato il gene in cui è presente la mutazione;
- HG19 pos: sono le coordinate nel genoma umano (versione 19) di ogni singola mutazione;
- Ref: è il nucleotide di riferimento; ovvero il nucleotide presente nella sequenza normale;
- Alt: è il nucleotide alternativo, ovvero il nucleotide presente a seguito della mutazione;
- Splicing Site: è la tipologia di sito di splicing: SD è localizzato all'inizio dell'introne dove avviene il primo taglio ed è definito sito donatore, SA è alla fine dell'introne dove avviene il secondo taglio ed è definito sito accettatore;

- Distance from SJ: rappresenta la distanza dalla più vicina giunzione di splicing espressa in numero di nucleotidi;
- Gene: è il gene su cui è presente la mutazione.

Si è passati dapprima a selezionare le variabili più rilevanti del dataset. In entrambi i due sotto-campioni analizzati, il gene che si presenta più frequentemente mutato è il gene BRCA1 questo perché in generale, nel campione di mutazioni analizzate, quelle che possono essere responsabili di tumore della mammella ereditario sono tra le più studiate e il gene BRCA1 è quello più comunemente coinvolto.

Pertanto, l'analisi si è focalizzata sulle mutazioni che riguardavano il gene BRCA1 sito sul Cromosoma 17.

I dati sono stati studiati mediante l'analisi esplorativa (EDA, Exploratory Data Analysis), una fase importante del processo di analisi dei dati, in quanto mira a comprendere la struttura e le caratteristiche principali dei dati. Questo approccio è fondamentale per identificare modelli, anomalie, relazioni e per formulare ipotesi iniziali che guideranno ulteriori analisi. Sulla base dei risultati delle analisi esplorative sono state effettuate delle ipotesi, poi confermate dall'analisi delle corrispondenze multiple.

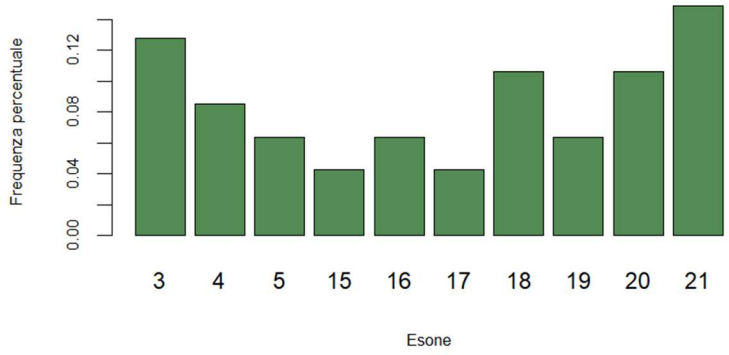
L'analisi delle corrispondenze multiple (ACM), o Multiple Correspondence Analysis (MCA), è una tecnica statistica utilizzata per esplorare e visualizzare le relazioni tra più variabili categoriali. Questa tecnica mira a identificare la struttura dell'associazione all'interno di un dataset, rappresentando graficamente le modalità dei caratteri in uno spazio di dimensioni minime, generalmente rappresentato su un piano cartesiano. Sulla base della vicinanza tra le varie mutabili nel piano è possibile ricavare un'associazione tra le variabili permettendo di dedurre quali relazioni caratterizzano il dataset.

3. Risultati

3.1 Analisi della distribuzione delle mutazioni negli esoni

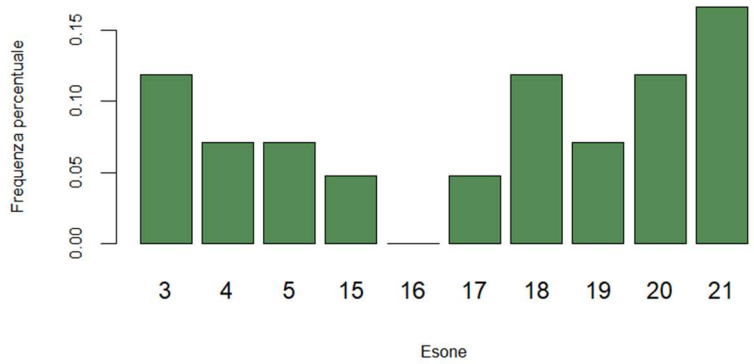
Analizzando la distribuzione delle mutazioni con putativo effetto sullo splicing nei diversi esoni del gene BRCA1 si ottengono i seguenti risultati:

Figura 1. Distribuzione degli esoni interessati nella mutazione riguardante il cromosoma 17 nella popolazione dei positivi



La distribuzione degli esoni interessati da mutazioni nel gene BRCA1 nella popolazione dei positivi è rappresentata nella Figura 1. Si osserva che l'esone 21 presenta la frequenza percentuale maggiore. Inoltre, osservando il grafico, è possibile affermare che gli esoni maggiormente colpiti da mutazioni sono l'esone 21, l'esone 3, gli esoni 18 e 20 e infine l'esone 4.

Figura 2. *Distribuzione degli esoni interessati nella mutazione riguardante il cromosoma 17 nella popolazione dei negativi*



La distribuzione degli esoni nella popolazione dei negativi è rappresentata nella Figura 2. La distribuzione presenta anche qui un punto di massimo in corrispondenza dell'esone 21, conseguentemente la distribuzione si presenta asimmetrica. È possibile, quindi, affermare che nella popolazione dei negativi gli esoni con maggiore frequenza di alterazioni prive di effetto sullo splicing sono l'esone 21, l'esone 3 e gli esoni 18 e 20.

Confrontando ora i due grafici, si denota come tra la popolazione dei Positivi e la popolazione dei Negativi la differenza principale risiede nella frequenza di alterazioni patogenetiche nell'esone 16. Esso, infatti, è presente nella popolazione dei Positivi, ma risulta essere totalmente assente nella popolazione dei Negativi.

Si denota poi, che la frequenza relativa degli esoni 3 e 4 è maggiore nella popolazione dei positivi, mentre la frequenza relativa degli esoni 5, 15, 17, 18, 19, 20 e 21 è maggiore nei negativi.

In conclusione, si osserva che le due distribuzioni sono molto simili. BRCA1 è, composto da 27 esoni, pertanto nei due grafici gli esoni più frequentemente presenti corrispondono a esoni con una regolazione dello Splicing più complicata e più sensibile ai cambiamenti nel DNA. Tuttavia, la maggiore frequenza di alterazioni con effetto sullo splicing nell'esone 16 di BRCA1 fa sospettare che in questo esone le sostituzioni nucleotidiche abbiano una più alta probabilità di provocare anomalie nel processo di splicing.

Nella Tabella 1 è riportata la distribuzione degli esoni nella popolazione dei positivi e in quella dei negativi allo scopo di analizzare se esiste una relazione di dipendenza fra le due popolazioni. Essendoci caselle vuote, si è reso necessario considerare come unico gruppo gli esoni che nella popolazione dei Positivi, presentavano una maggiore frequenza rispetto alla popolazione dei Negativi.

Tabella 1. *Distribuzione delle popolazioni (positivi/negativi) per presenza di esoni*

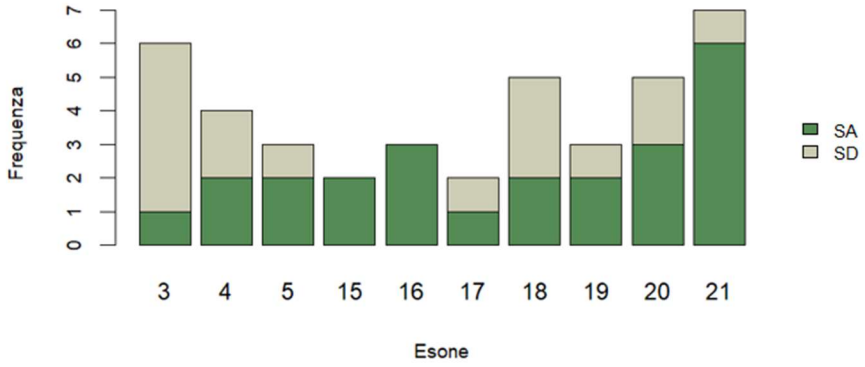
	Esone	
Popolazione	Esone 3-4-16	Altri
Positivi	19	21
Negativi	0	39
Totale	20	59

Avendo verificato che nessuna frequenza teorica è più piccola di cinque, al fine di verificare che non ci fosse alcuna relazione fra le due variabili osservate, è stato utilizzato il test Chi-quadro. I risultati del test portano a rifiutare l'ipotesi di indipendenza fra le distribuzioni in quanto il p-value (2.933e-06) è inferiore al livello di significatività α posto pari a 0,05.

3.2 Analisi del sito di splicing nei diversi esoni

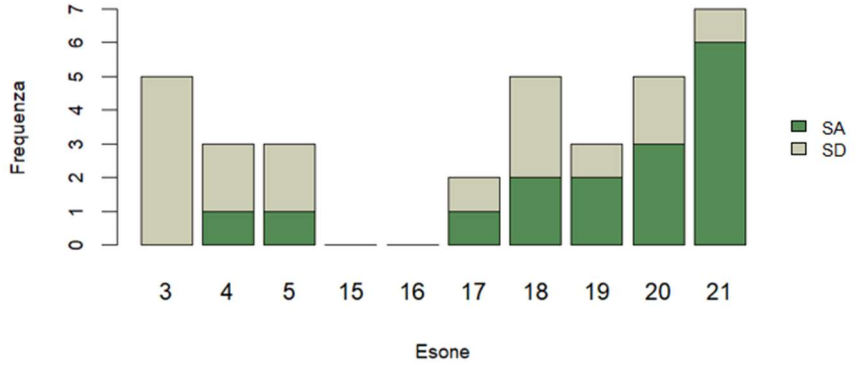
Analizzando la tipologia di sito di Splicing (SD vs SA) interessato dalle mutazioni nelle due sottopopolazioni nei diversi esoni si osserva che:

Figura 3. *Distribuzione degli esoni interessati nella mutazione riguardante il cromosoma 17 nella popolazione dei positivi e il sito di splicing da essi posseduto*



La distribuzione del tipo di sito di splicing oggetto di mutazione nella popolazione dei positivi e nei diversi esoni del gene BRCA1 è rappresentata nella Figura 3, da cui si evince che l'esone 3 è caratterizzato prevalentemente da sostituzioni nel sito di splicing di tipo SD, mentre l'esone 16, assente nella popolazione dei negativi, è caratterizzato esclusivamente da sostituzioni nel sito di splicing di tipo SA.

Figura 4. *Distribuzione degli esoni interessati nella mutazione riguardante il cromosoma 17 nella popolazione dei negativi e il sito di splicing da essi posseduto*



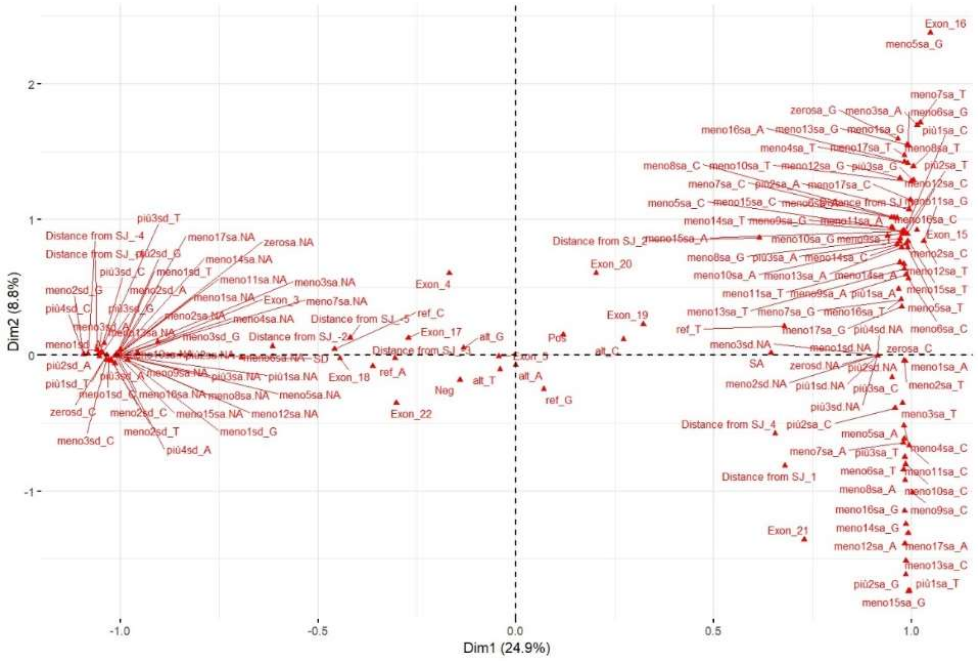
La distribuzione degli esoni in relazione al sito di splicing nella popolazione dei negativi è rappresentata nella Figura 4. Dal grafico si osserva che l'esone 3 è caratterizzato esclusivamente da sostituzioni nel sito di splicing di tipo SD, non si possiedono osservazioni sui siti di splicing dell'esone 15, mentre nella popolazione dei positivi due sostituzioni interessano un sito di splicing di tipo SA.

Inoltre, per l'esone 3 si nota come il sito di splicing di tipo SA è presente solo nella popolazione dei positivi. Analogamente per l'esone 4 si nota che il sito di splicing di tipo SA è maggiormente presente nei positivi.

3.3 Analisi delle corrispondenze multiple

Al fine di studiare l'associazione fra le variabili è stata effettuata l'analisi delle corrispondenze, considerando la totalità delle variabili e successivamente solo le 4 variabili principali. Considerando il dataset nella sua totalità è possibile osservare il seguente plot delle corrispondenze:

Figura 5. *Primo plot delle corrispondenze sull'intero dataset.*



Dal grafico è possibile notare che sia l'asse delle ordinate sia quello delle ascisse risultano essere molto discriminanti; in particolare, la popolazione dei positivi è situata nel 1° quadrante, mentre la popolazione dei negativi è situata nel 3° quadrante. Si nota che nel semiasse negativo delle ascisse le variabili sono più raggruppate, segno di una maggiore associazione.

Il sito di Splicing donatore (SD) giace in corrispondenza del semiasse negativo delle ascisse ed è quindi verosimilmente associato alla popolazione dei negativi e risulta vicino agli esoni 4, 17, 18 e 22. Nel 2° e nel 3° quadrante, inoltre, associati alla popolazione dei negativi si ritrova l'esone 3.

In corrispondenza della popolazione dei negativi si ritrovano inoltre le modalità della variabile "Distance from Sj" da -1 a -5, anche se la modalità -3 e la modalità -5 sono più prossime alla popolazione negativa.

Per quanto concerne le altre variabili è possibile notare che sono associati alla popolazione dei negativi i nucleotidi A, T e G in posizione -1 nel sito di splicing SD, tutti e 4 i nucleotidi in posizione -2 nel sito di splicing SD, i nucleotidi A e G in posizione -3 nel sito di splicing SD, il nucleotide C in posizione 0 nel sito di splicing SD, il nucleotide T in posizione +1 nel sito di splicing SD, i nucleotidi A e G in posizione +2 nel sito di splicing SD, tutti e 4 i nucleotidi in posizione +3 nel sito di splicing SD, i nucleotidi A e C in posizione più 4 nel sito di splicing SD.

I suddetti risultati sono riassunti nella seguente tabella:

Tabella 2. *Nucleotidi presenti nelle varie posizioni con sito di splicing accettore associato alla popolazione dei positivi*

-3	-2	-1	0	1	2	3	4
A, G	A, T, C, G	A, T, G	C	T	A, G	A, T, C, G	A, C

Il sito di Splicing SA giace, invece, in corrispondenza del semiasse positivo delle *x* ed è quindi verosimilmente associato alla popolazione dei positivi. In corrispondenza del semiasse positivo delle *x* si ritrovano anche gli esoni 5, 19, 20. Inoltre, l'esone 5 si trova in posizione intermedia tra le due popolazioni. Infine, nel 1° e nel 4° quadrante, associati alla popolazione dei negativi si notano gli esoni 16 e 21.

In corrispondenza della popolazione dei positivi si osservano le modalità della variabile "Distance from Sj" da 1 a 4, anche se la modalità 2, la modalità 3 e la modalità 4 sono più prossime, in termini di distanza, alla popolazione dei positivi e quindi maggiormente associate.

Per quanto concerne le altre variabili si nota che sono associate alla popolazione dei positivi tutti e 4 i nucleotidi in posizione -17 nel sito di splicing SA, i nucleotidi C, T e G in posizione -16 nel sito di splicing SA, tutti e 4 i nucleotidi in posizione -15 nel sito di splicing SA, i nucleotidi C, T e G in posizione -14 nel sito di splicing

SA, i nucleotidi C, A e G in posizione -13 nel sito di splicing SA, i nucleotidi C e A in posizione -12 nel sito di splicing SA, i nucleotidi C, A e G in posizione -11 nel sito di splicing SA, i nucleotidi C, A e G in posizione -10 nel sito di splicing SA, i nucleotidi C, T e G in posizione -9 nel sito di splicing SA, i nucleotidi C, A e G in posizione -8 nel sito di splicing SA, tutti e 4 i nucleotidi in posizione -7 nel sito di splicing SA, tutti e 4 i nucleotidi in posizione -6 nel sito di splicing SA, tutti e 4 i nucleotidi in posizione -5 nel sito di splicing SA, il nucleotide C in posizione -4 nel sito di splicing SA, i nucleotidi C, A e T in posizione -3 nel sito di splicing SA, i nucleotidi C e T in posizione -2 nel sito di splicing SA, i nucleotidi A e G in posizione -1 nel sito di splicing SA, i nucleotidi C e G in posizione zero nel sito di splicing SA, i nucleotidi A e T in posizione +1 nel sito di splicing SA, tutti e 4 i nucleotidi in posizione +2 nel sito di splicing SA, i nucleotidi T, A e G in posizione +3 nel sito di splicing SA.

I suddetti risultati sono riassunti nella Tabella 3 seguente:

Tabella 3. *Nucleotidi presenti nelle varie posizioni nel sito di splicing donatore associato alla popolazione dei negativi.*

-17	-16	-15	-14	-13	-12	-11
A, T, C, G	T, C, G	A, T, C, G	T, C, G	A, C, G	A, C	A, C, G
-10	-9	-8	-7	-6	-5	-4
A, C, G	T, C, G	A, C, G	A, T, C, G	A, T, C, G	A, T, C, G	C
-3	-2	-1	0	1	2	3
A, T, C	T, C	A, G	C, G	A, T	A, T, C, G	A, T, C

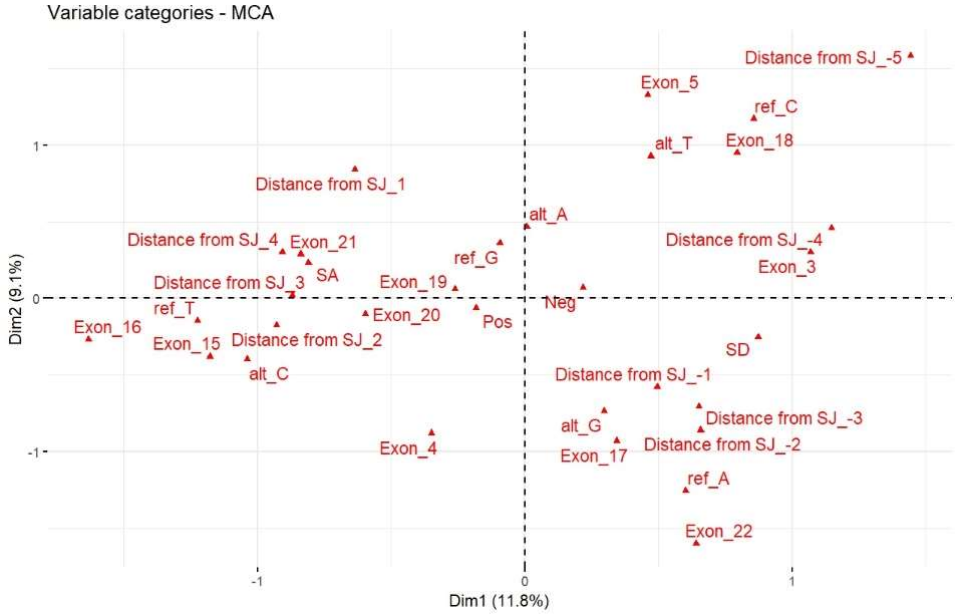
Si considerano ora solo le variabili di seguito elencate:

- Exon: esone interessato nella mutazione
- Distance from SJ: distanza dal sito di splicing espressa in nume-ro di nucleotidi

- Ref: nucleotide presente nella mutazione
- Alt: nucleotide che si trova normalmente

Il grafico dell'analisi effettuata risulta:

Figura 6. *Secondo plot delle corrispondenze.*



Considerando la Figura 6 è possibile notare come l'asse delle *y* risulta essere discriminante per la variabile popolazione; in particolare, la popolazione dei negativi è situata a destra tra il 1° e il 4° quadrante, mentre la popolazione dei positivi è situata a sinistra nel 3° quadrante, entrambi a ridosso dell'asse delle ascisse. Si osserva che nel semiasse negativo delle ascisse le variabili sono più concentrate, segno di una maggiore associazione.

Il sito di Splicing SA giace in corrispondenza del semiasse negativo delle ascisse ed è quindi verosimilmente associato alla popolazione dei positivi e risulta vicino agli esoni 19, 20 e 21; i 3 esoni, infatti, possedevano con frequenza maggiore mutazioni in un sito di splicing di tipo SA. Nel 3° quadrante, inoltre, associati alla popolazione dei positivi si ritrovano gli esoni 4, 15 e 16 che in questa popolazione erano quelli più frequentemente mutati.

Il sito di Splicing SD giace, invece, in corrispondenza del semiasse positivo delle ascisse ed è quindi verosimilmente associato alla popolazione dei negativi. Sempre

con riferimento all'asse delle ascisse, in corrispondenza del semiasse positivo si notano gli esoni 3, 5, 17 e 18.

In particolare, si osserva la formazione di due gruppi nel semiasse positivo delle ascisse: nel primo quadrante si posizionano gli esoni 3, 5 e 18 associati a una distanza dal sito di splicing donatore pari a -4 o -5 dove presentano tipicamente un nucleotide C, sostituito da un nucleotide T; nel quarto quadrante si posizionano gli esoni 17 e 22 associati a una distanza dal sito di splicing (donatore) pari a -1, -2, -3 dove presentano tipicamente un nucleotide A, sostituito da un nucleotide G.

4. Conclusioni

In conclusione, lo studio condotto ha portato a significativi risultati.

Dall'analisi esplorativa, si era dedotto che gli esoni maggiormente soggetti a errori nello splicing determinanti nello sviluppo del carcinoma mammario ereditario legato a mutazioni del gene BRCA1 erano rappresentati dagli esoni 3, 4, 16.

Dall'analisi delle corrispondenze si osserva che una mutazione che colpisce gli esoni 16, 19, 20, 21 a una distanza dal sito di splicing accettore in termini di nucleotidi pari a 1, 2, 3, 4 che presentavano come nucleotide di riferimento il nucleotide G, sostituito in conseguenza della mutazione da un nucleotide A o C, risulta essere associato a una probabile influenza sullo splicing.

Si denota inoltre, che in corrispondenza delle posizioni più prossime al sito di splicing il genoma risulta essere meno flessibile in quanto in corrispondenza della posizione 0 si posiziona esclusivamente il nucleotide C e in posizione 1 esclusivamente il nucleotide T. La presenza di nucleotidi differenti in corrispondenza delle suddette posizioni quasi certamente porta ad un'alterazione del processo di splicing.

Al contrario una mutazione negli esoni 3, 4, 17 18 e 22 a una distanza dal sito di splicing donatore in termini di nucleotidi pari a -1, -2, -3, -4 e -5 che presentavano come nucleotide di riferimento il nucleotide A o C, sostituiti in conseguenza della mutazione da un nucleotide G o T risulta essere probabilmente NON associato a una possibile influenza sullo splicing.

In merito all'esone 5 che presentava in posizione -4 con sito di Splicing di tipo SD un nucleotide di riferimento G, trascritto erroneamente come A o C e in posizione 2 con sito di Splicing SA un nucleotide di riferimento C trascritto erroneamente come A non è possibile ritenere che non sia associato a una probabile influenza sullo splicing in quanto risulta essere vicino a entrambe le due popolazioni.

Si denota inoltre che in corrispondenza delle posizioni più prossime al sito di splicing il genoma risulta essere meno flessibile in quanto in corrispondenza della posizione -4 ritroviamo il nucleotide C, in posizione -2 ritroviamo esclusivamente il nucleotide T o C, in posizione -1 il nucleotide A o G, in posizione 0 il nucleotide C o G e in posizione 1 il nucleotide A o T.

5. Bibliografia

Atkins, P. W., Jones, L., & Laverman, L. (2005). *Principi di chimica*. Zanichelli.

Becker, W. M., Kleinsmith, L. J., Hardin, J., & Raasch, J. (2002). *Il mondo della cellula*. EdiSES.

Chan, B. K. (2015). Biostatistics for epidemiology and public health using R. Springer Publishing Company.

Elston, RC, Olson, JM e Palmer, L. (a cura di). (2002). *Genetica biostatistica ed epidemiologia genetica (Vol. 1)*. John Wiley & Figli.

Pagano, M., Gauvreau, K., & Mattie, H. (2022). *Principi di biostatistica*. Chapman e Hall/CRC.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 155-170

La manna del Mezzogiorno tra normativa e mercato (XVIII-XIX secc.)

Maurizio Gangemi*

Dipartimento di Economia e Finanza, Università degli Studi di Bari Aldo Moro

Riassunto: Il vasto utilizzo della manna da frassino nella farmacopea d'età moderna e contemporanea comportò un crescente interesse del governo napoletano per la tutela della qualità e per ragioni fiscali. I primi vantaggi ottenuti dalla Calabria nel produrre e commercializzare la manna funsero poi da stimolo ad altre aree del Regno per avviare un maggiore sfruttamento e ampliamento della frassino-cultura. Anche se, per lungo tempo, la dizione 'manna Calabrina' continuò a comparire con assiduità nelle ricette degli speziali italiani ed europei, la provenienza regionale non era però più garantita. Attraverso l'impiego di una significativa bibliografia coeva e contemporanea e dei dati offerti dalla ricerca archivistica, si vuole qui ripercorrere brevemente l'iter legislativo e alcuni aspetti economici nodali inerenti questa singolare produzione del Mezzogiorno.

Keywords: manna; produzione, commercio, Regno Napoli-Sicilia, Marsiglia.

1. Introduzione

I frassini, di molteplici specie e varietà, sono presenti oggi in quasi tutti i paesi europei, anche in associazione con altri alberi come querce, carpini, castagni, faggi, pinacee, a formare boschi misti[1]. In età moderna ritroviamo frassini nel Regno di

* Autore corrispondente: maurizio.gangemi@uniba.it .

Abbreviazioni: ASCs, Archivio di Stato di Cosenza; ASCz, Archivio di Stato di Catanzaro; ASN, Archivio di Stato Napoli; ASRC, Archivio di Stato di Reggio Calabria; DS, ADBR, Déclarations de Santé, Archives Départementales des Bouches-du-Rhône (Marsiglia). Pesi e monete: 1 cantaro = 100 rotoli = 89,0997 kg; 1 rotolo = 0,890997 kg. Ducato = 10 carlini= 100 grana.

[1] Caudullo G., de Rigo D., (2016), pp. 100-101.

Napoli, per lo più in certe aree della Calabria di Capitanata e della Basilicata, in Sicilia, e anche nello Stato della Chiesa e nel Granducato di Toscana[2]. Caratteristica delle piante poste nelle zone più calde, in particolare delle specie Fraxinus ornus L. ed Excelsior, è quella di produrre naturalmente una sostanza gommosa e zuccherina che durante la stagione estiva, in parte spontaneamente ma soprattutto per incisione del tronco, solidifica a contatto con l'aria in granuli bianco-giallastri: la manna. La parte più pregiata del prodotto era detta manna 'di corpo', 'spontanea' o 'in cannolo' perché si raggruma lungo il fusto e, quasi come una colatura di candela, si asporta semplicemente staccandola; più abbondante in commercio, e ritenuta di minore qualità, quella detta manna 'forzata', di 'frasca' o, ancora, 'in sorte' che, lasciata colare sul tronco e raccolta alla sua base su foglie o pietre disposte sul terreno, presentava ovviamente non poche impurità[3]. L'estrazione e la commercializzazione della manna sono attività già ampiamente praticate in Calabria almeno dal XV secolo, anche se molte testimonianze, sia coeve sia posteriori, rifacendosi ad una convinzione ampiamente diffusa perché riportata nei testi biblici, affermano la natura "aerea" della sostanza, quella provvidenziale 'manna' che, per volere divino, piovve dal cielo per ben quarant'anni e nutrì gli ebrei in fuga dall'Egitto durante la loro permanenza nel deserto[4]. La manna, riconosciuta ancora oggi in specie per le sue proprietà dolcificanti, trovava in passato larga applicazione nella farmacopea e nell'industria tintoria[5]. Sin dal XVI secolo, quando ancora soleva distinguersi in manna di 'fronda' (che si credeva essudata dalle foglie), e quella 'di corpo' o 'forzata' (prodotta dal tronco della pianta)[6], vide le sue virtù terapeutiche - lassative, emollienti, espettoranti e sedative - ampiamente utilizzate dalla medicina ufficiale del tempo, a volte messe in dubbio con l'espandersi di pratiche tese all'adulterazione del prodotto, fenomeno che assume dimensioni tali da richiedere ripetuti interventi legislativi.

[2] Cfr. Melograni G., (1810), p. 43; Galanti G.M., (1789), p. 222; Floridia S., (1936), pp. 49-51; Di Berenger A., (1859-1863), p. 695; Intorno alla più vasta area di raccolta: Boccone P., (1697 a), pp. 79-85.

[3] Sestini D., (1777), p. 98.

[4] Si veda la rassegna di vari autori che, descrivendo le caratteristiche e le produzioni tipiche della regione, fanno riferimento alla manna in Fiore G., (1691), pp. 2-20 e Florida S., (1936), pp. 37-39. Per l'evento biblico, un'ampia trattazione in Catena B., (1831), pp. 67-82.

[5] Sulle virtù terapeutiche attribuite alla sostanza, Boccone P., (1697 b) pp. 86-91. Con riferimento all'impiego della manna per dare corpo e lucentezza ai tessuti e nella concia delle pelli: Floridia S., (1936), pp. 54-55, 85; Padula V., (1977), p. 181; Galanti G.M., (1789), p. 222; Sestini D., (1777), p. 100; Santi G., (1806), p. 89.

[6] Donzelli G., (1675), pp. 262-263.

2. Bandi e prammatiche: le norme e gli abusi

Con un primo bando del 1562 le autorità governative vietano, pena la vita, a qualunque persona di ogni "stato, grado e condizione [...] tanto nelle province di Calabria, quanto nel Monte Gargano e in altri luoghi del presente Regno", di falsificare la manna mischiando quella di fronda a quella di corpo, riducendola in polvere o aggiungendo zucchero e miele[7]. Sempre sotto pena capitale si ordina di non raccoglierla in prossimità di paludi, miniere o di acque destinate alla macerazione di lino e canapa, in quanto luoghi che "sogliono far male evaporazioni". Al Reggente della Regia Cancelleria e del Consiglio Callaterale nonché al Protomedico, è affidato il compito di giudicare sulla bontà della manna raccolta che solo dopo tale verifica può essere immessa in commercio. Ma tale provvedimento "fatto per lo governo umano, ha causato effetto contrario", tanto che a distanza di un decennio (1573), è necessario rettificare le disposizioni precedentemente impartite, perché distoglievano i "mannaroli" dalla raccolta e permettevano agli speziali di praticare tali prezzi "che i poveri non avendo avuto comodità bastante da spendere, hanno talvolta lasciato di curarsi nella forma che conveniva"[8]. Nel ribadire la proibizione di raccogliere manna dalle piante cresciute in luoghi malsani, si fissano inoltre le modalità da seguire per una corretta estrazione: "che il tronco dell'albero non sia intaccato basso verso la radice, ma sopra la radice di quattro palmi in su, e il taglio, o la intaccatura predetta sia con taglio verso basso, e che per quattro dì sia purgato l'albore, di maniera che non esca più acquaccia ma manna bianca, e pura, e non scura". Si promettono premi per coloro che denunceranno eventuali contravventori, per i quali resta confermata la pena capitale. Le tecniche per estrarre la manna seguiranno pure modalità diverse e, tra i sistemi è più usati, si affermerà anche quello di inserire foglie, fili di paglia o piccoli stecchi di legno tra i tagli del tronco per favorire la creazione di piccole stalattiti ed ottenere così artificialmente le forme dette "cannoli" o "lacrime", di maggiore purezza, più pregiate e quindi di prezzo più elevato[9]. Nel Napoletano, anche la manna è oggetto di arrendamento, grava cioè su questa produzione una gabella che viene ceduta a privati in cambio di un fitto o di un capitale. Nel 1668 è ricomprato dal Regio fisco per 17.000 ducati e a distanza di due anni, dichiarato ormai diritto proibitivo, per evitare frodi "si amministra per conto della Regia Corte"[10].

[7] Giustiniani L., (1804), p. 184.
[8] Ibidem, p. 185.
[9] Boccone, (1697 a), p. 8; Swinburne H., (1783), p. 287; Palumbo M., (1912), p. 204.
[10] Giustiniani L., (1804), 186. Ampiamente, sul tema, De Rosa L., (1958).

Nessuno può incidere orni e raccogliere manna senza aver prima ottenuto "la licenza e il bullettino da Ministri deputati per questo negozio" o da persone da questi opportunamente delegate. Tali funzionari svolgono ancora una serie di altre mansioni: ricevere il prodotto e verificarne la qualità, rilasciando ai mannaroli una cartella con l'esatto peso della manna consegnata; riscuotere il "solito diritto" per ogni vendita e quindi "darne manifesto in iscritto alle persone dei venditori"; controllare che la manna caricata su imbarcazioni o vetture e destinata al commercio sia stata registrata e in regola con i pagamenti dovuti alla Regia Corte. Ai contravventori spetta la pena di 50 once d'oro e cinque anni di relegazione se nobili o altrettanti di galea se "ignobili". È anche previsto il sequestro della manna e dei mezzi di trasporto impiegati. Si dichiara esplicitamente che nulla è dovuto ai funzionari per i compiti di pesatura e vigilanza. Tutte queste disposizioni restano in vigore fino al 1785 quando, come vedremo più avanti, l'arrendamento sarà abolito. Fino a tutto il periodo del governo austriaco (1707-1734), ad ogni modo, questo resta in possesso della Regia Corte, con proventi oscillanti tra i 2.430 e i 5.900 ducati annui (Fig.1)[11], mentre si ridà in affitto a privati con l'avvento dei Borboni, integrando il bando del 1669 con numerosi, nuovi articoli.

Interessante a proposito il bando pubblicato nel 1751 e relativo all'affitto quadriennale dell'arrendamento per le province calabresi al barone Matteo Vercillo[12]. Da tutti coloro che "anderanno a fare le rivele delle manne" l'arrendatore, o i suoi delegati, esigono un carlino per ogni libbra o, altrimenti, una pari quantità di prodotto calcolato al prezzo della "voce" di volta in volta stabilito[13]. I Maestri Portulani e i loro Luogotenenti non dovranno permettere l'estrazione *infra* o *extra regnum*, sia per mare sia per terra, se non previa verifica dell'avvenuto pagamento delle somme dovute all'arrendatore (somme che sono esatte anche in caso di donazione "sotto pretesto di elemosina"). Nessun pagamento daziario è dovuto ad alcuna dogana del Regno, sia regia sia baronale, ma solo alla Regia Dogana di Napoli, quale "maggior fundaco". All'arrendatore sono ancora concessi importanti privilegi: può nominare un Attuario "assunto per cause [che] occorrono e che possono occorrere per detto Arrendamento"; un Subdelegato in ciascuna provincia con l'incarico di vigilare sui contrabbandi; sostituire a suo piacimento qualsiasi persona addetta

[11] Di Vittorio A., (1969), p. 136.

[12] ASCz, Regia Udienza Provinciale, C. D 151, f. XI, a. 1754, "Atti civili tra il Procuratore della Camera Ducale di Monteleone con Vincenzo Bardonara dell'istessa città".

[13] Si tratta di una pratica ampiamente diffusa nel Regno e molto svantaggiosa per gli agricoltori, costretti dalle necessità economiche a impegnare i propri raccolti a un prezzo che si formava pubblicamente nei centri cittadini nel momento di massima abbondanza dei prodotti e quindi sempre tendente al ribasso, come denuncia Galanti G.M., (1789), pp. 277-280.

all'arrendamento; la facoltà per sé e per tutti costoro (sostituti, guardiani, mannaroli, intaccatori etc.) di girare armati, con armi non proibite dalla legge, per tutto il tempo del servizio, godendo dell'immunità da parte di ogni corte e tribunale per le cause civili e criminali, restando la Regal Sopraintendenza l'unico organismo responsabile in materia. La stessa Sopraintendenza potrà munire di opportune provvisioni alcuni Sostituti e Officiali designati dall'arrendatore, affinché possano pubblicare "Ordini e Banni" in qualunque terra e luogo ove si raccoglie manna, nonché procedere all'imposizione di pene, alla carcerazione di contrabbandieri e delinquenti, esercitando tutta la potestà già concessa ai precedenti arrendatori. Ai baroni, alle 'università' (i comuni) e ai privati padroni di boschi è fatto obbligo di impedire, sotto qualunque pretesto, l'incisione degli orni e la raccolta della manna sotto pena di 230 ducati a beneficio dell'arrendatore, né affittare quei boschi per un tale uso "e nemmeno alterare la solita fida", potendo esigere solo 5 carlini "a cortello" e astenendosi, infine, dal procedere per qualsivoglia motivo, al taglio di quegli alberi. Affinché non venga mai meno la necessaria manodopera, è stabilito che nei mesi di luglio e di agosto i mannaroli non sono perseguibili giuridicamente per debiti e altre cause civili, "ma debbano godere della moratoria, che si concede per le ferie estive". Nel caso si rendano renitenti, l'arrendatore e i suoi sostituti hanno la facoltà di farli "astringere etiam per capturam personarum", addebitandogli la pena di 15 ducati. È lecito all'arrendatore stabilire se erogare i pagamenti dovuti ai lavoratori in denaro o, altrimenti, in manna. Ancora, tra gli altri privilegi, quello di ricevere da ciascun paese interessato alla raccolta della manna "ogni cosa necessaria e commoda per le loro abitazioni" se, per servizio dell'arrendamento dovranno dimorarvi, ma ciò sempre dietro corresponsione di "giusta mercede". Se per motivo di peste, guerra e ogni altro caso "fortuito ed inopinato" il barone non potrà riscuotere il previsto diritto di un carlino a libbra, è esentato da qualunque pagamento in favore della Regia Corte e anzi potrà godere del rimborso di spese e interessi; ammesso che entro febbraio del 1755, termine ultimo del fitto, "per mali tempi di Mare" non gli sarà possibile effettuare le eventuali spedizioni di quantità residue di manna, tale diritto gli è accordato senza bisogno di alcuna licenza e pagamento di tratta (imposta sulle esportazioni).

Nonostante le prammatiche e gli stessi bandi d'arrendamento proibiscano espressamente e ripetutamente ai sostituti di esigere compenso alcuno per il rilascio delle cartelle indicanti il peso del prodotto consegnato dai mannaroli, gli stessi poteri e privilegi di cui i funzionari godono sono spesso usati per dar luogo a soprusi e comportamenti illeciti. La situazione si presenta con i caratteri di particolare gravità in Calabria, tant'è che nel 1758 un'apposita prammatica cerca di arginare in

qualche modo i casi di concussione - divenuti oramai troppo frequenti - diffidando i Sostituti dall'effettuare richieste di pagamenti non dovuti, sia in denaro sia in natura, né tantomeno di "accettare" regalia alcuna sotto pena di carcerazione, due anni di galea e perdita immediata dell'impiego[14]. Le estorsioni dei funzionari, così simili del resto a quelle praticate dagli addetti alla pesatura della seta[15], pur rappresentando un freno e un fattore di costante squilibrio per il settore favorendo il dilagare del contrabbando[16], non costituiscono il solo motivo di scontento per i diversi ceti sociali interessati. Da una parte i lavoratori che, almeno per un mese l'anno, devono trascurare qualsiasi altra attività perché costretti a dedicarsi alla raccolta della manna, in compenso di una ben scarsa remunerazione pari a 3 carlini per ogni rotolo consegnato[17]: dall'altra, i proprietari di boschi in cui sono presenti piante di frassino mal sopportano i limiti e le restrizioni al libero godimento dei propri beni imposti dai provvedimenti legislativi fin qui esaminati, cosi come dalla stessa prammatica del 1759 che, nel regolare l'intera materia forestale, ribadisce il divieto assoluto per chiunque di tagliare orni[18].

Galanti, nel criticare aspramente l'istituzione dell'arrendamento, denuncia come per i proprietari il possedere orni nei propri fondi e boschi fosse ormai un evento considerato alla stessa stregua di una vera e propria calamità e, più in generale, ritiene errato che per una tenue entrata fiscale pari a circa 4.000 ducati annui, si tenga "oppresso un ramo d'industria che la natura aveva denegato alle altre province d'Europa"[19]. Come nel passato, al netto delle spese i proventi dell'arrendamento erano anche inferiori a tale cifra, nonostante la consistente richiesta proveniente in particolare da Marsiglia (Tab. 1). Finalmente, tra il 1775 e il 1789, sono aboliti di-

[14] Giustiniani L., (1804), p. 188.

[15] Cfr. Grimaldi D., (1770), pp. 101-102 e Id., (1780), pp. 6 sgg. Sono spesso gli stessi mannaroli addetti alla raccolta ad occultare quote di prodotto per poi rivenderle illegalmente. Il 20 ottobre 1768, un soldato del Regio Arrendamento sequestra a un mannarolo della terra di Saracena circa tre libbre di manna che questi non aveva consegnato al delegato: solo con la fuga riesce a sottrarsi all'arresto, ASN, Arrendamenti, Fascio 487, a. 1768.

[16] Sulla diffusione del contrabbando nel Regno cfr. Villani P., (1977), pp. 261-262 e De Rosa L., (1963), pp. 93-95.

[17] Swinburne H., (1783), p. 288.

[18] Giustiniani L., (1804 a), p. 191. Eppure, oltre all'incisione dei rami per avere fronde con cui alimentare il bestiame caprino e vaccino, si tagliano frassini per reperire un tipo di legname particolarmente resistente. In diverse zone tra Laino, Papasidero e Arena, dove gli orni sono "volgarmente" chiamati anche "melie" o "milie", si rinvengono nel 1768 molte piante tagliate o mutilate dai rami: nel primo caso si tratta di alberi "lavorati per uso di legname di Massaria, o siano istrumenti rurali per essere di durata e forti"; per il taglio dei rami sono accusati alcuni pastori che avrebbero utilizzato le fronde degli alberi per sfamare il proprio bestiame, "atteso - dicono - la scarsezza di erba in detto anno", ASN, Arrendamenti, fascio 488, a. 1768-1769.

[19] In Galanti G.M., (1788) p. 155.

versi arrendamenti (del minuto, tabacco, acquavite, della seta per alcune province) e tra questi, dal luglio 1785, anche quello della manna[20]. Nell'emanare la relativa prammatica, Ferdinando IV dichiara il jus proibitivo fino allora in vigore, come "lesivo della libertà d'industria sopra un genere bastamente diffuso in molti luoghi del nostro Regno: in alternativa al gettito fiscale venuto meno, s'impongono 12 cavalli "sopra l'oncia di stima di tutt'i generi oggetti a Dazi Doganali, esclusi bensì Commestibili, Grano, ed Olio"[21].

Da questo momento, quindi, chiunque può liberamente raccogliere, vendere e commerciare manna col solo obbligo di pagare, se destinata all'estero, i diritti di tratta pari a 4 ducati a cantaio per quella "in sorte" e ducati 3 se "in cannolo". Resta però confermato il divieto di tagliare gli orni, mentre agli "assegnatari sul mentovato jus proibitivo [...] in annui ducati mille dugento per capitale di ducati trentamila" è data la facoltà di riscuotere la propria rata sull'importo delle nuove imposizioni.

3. Produzione e commercio

Il provvedimento governativo, che liberalizzando il settore ha l'obiettivo di favorirne la crescita, si rivela purtroppo tardivo per la provincia di Calabria Ultra, in quegli anni ancora profondamente provata dal disastroso sisma del 1783. Anche se, come annota Galanti, paesi quali Scilla, Bagnara, Pizzo "hanno un poco di manna", nel complesso la produzione "è molto decaduta dopo il terremoto"[22]. Più consistente e prolungata nel tempo, si dimostra invece la produzione della fascia ionica occidentale, dove il movimento tellurico non provoca gravi guasti. A Rossano, nel 1815, la raccolta della manna può calcolarsi in più migliaia di libbre[23]; è abbastanza consistente nelle zone intorno a Cariati, Calovano, Campana, dove - per buona

[20] Ibidem p. 155.

[21] Giustiniani L., (1804), pp. 188-190, prammatica IV dove, erroneamente, è riportata la data del 1775, ma di contro cfr. Galanti G.M., (1788), pp. 155, 200; De Rosa L., (1958), p. 75.

[22] Galanti G.M., (1987), p. 346. Segnali della decadenza dell'attività estrattiva e, quindi, della diffusione degli orni, vengono pure dalla topografia e dalla toponomastica: nei pressi di Reggio (Motta S. Giovanni), in contrada Fossa della Manna ormai, nel 1809, le coltivazioni più diffuse sono gelsi neri, fichi, olivi e "vigna novellina", ASRC, Regia Corte di Reggio, B. 15, f. 424. Di contro, per la Calabria Citra, sappiamo di tentativi di diffondere ulteriormente le colture di orni da destinare all'estrazione della manna. È il caso del Principe Marcantonio Borghese per la difesa S. Onofrio, in territorio di Rossano, ASCs, Regia Udienza Provinciale, Mazzo (M.) 15, f. 118, voll. I, II, III, a. 1790-1794. Anche nel cosentino, comunque, emergono situazioni di crisi locale, come quella segnalata per Cirò sul finire del XVIII secolo in Galanti G.M (1987), p. 117, dove un tempo se ne raccoglieva "in qualche quantità, oggi è pochissima". Intorno al devastante sisma che interessò parte della Sicilia e della Calabria meridionale, Placanica A., (1985).

[23] Palumbo M., (1912), p. 204; Caldora U., (1957), p. 80.

parte del XIX secolo - continua ad alimentare un limitato movimento d'esportazione verso Napoli e Trieste[24]. Per alcuni mantiene, inoltre, un certo livello qualitativo in confronto ad altre produzioni meridionali, segnatamente a quella pugliese[25]. Non mancano però giudizi contrastanti: se il Gargano "è il paese della manna" che, rispetto alla calabrese così maleodorante e nauseabonda, vanta "un grato sapore, che ha molto della natura del zucchero e del mele", quando raccolta a Vieste non teme confronti e "né più eccellente di questa si rinviene in tutto il Regno di Napoli"[26]. In effetti, al di là di giudizi meramente campanilistici, è vero che dopo un certo predominio della manna 'Calabrina', le botteghe degli speziali hanno ormai orientano i propri approvvigionamenti anche su altre provenienze. E non solo quella pugliese ha trovato ampio accoglimento, ma è cresciuta d'importanza la produzione siciliana[27]. Certo, lungo l'Ottocento, dai porti garganici di San Menaio e Rodi si registrano alcune esportazioni tanto alla volta di scali italiani come Ancona, Venezia, Trieste, quanto verso l'estero, Inghilterra, Francia e ancora la Germania intorno al periodo unitario[28]. È un flusso che lascia tracce di una persistenza di pratiche produttive e commerciali che si spingerà fin dentro il XX secolo ma che, come per la manna calabrese, è solo testimonianza di attività residuali rispetto a un mercato sempre più condizionato dai proprietari siciliani. Nel corso del '700, infatti, l'isola ha implementato lo sviluppo della frassino-coltura e il prodotto ottenuto si dimostra non solo abbondante ma anche di ottima qualità, tanto da assicurarsi un solido primato nel panorama merceologico del tempo[29].

Il cambiamento è osservabile con estrema efficacia con riferimento a quello che, come già detto, è stato a lungo uno sbocco commerciale privilegiato per la manna

[24] "Quest'industria fioriva benino in tempi non molto lontani. Ogni anno partivano per Trieste un 10 quintali, e 5 per Napoli, oltre quella che si consumava per l'interno. Ma ora la Direzione Forestale l'ha proibita nei terreni demaniali e comunali; e questa industria, costretta ad esercitarsi in pochi fondi privati, è venuta a minimi termini. Se ne fa poca, e si vende fra i 15 e i 25 grana, quando è grassa, e 3 carlini quando è a cannolo. Una volta nella sola Campana e Bocchigliero se ne raccoglievano 30.000 libbre. La Regia Corte vi aveva posto la gabella di 1.100 ducati. [...] Ricche di manna Campana, Caloveto; eccellentissima quella di Cariati", Padula V., (1977), p. 182. Riferimenti a spedizioni del secolo precedente in Prato G., (1908), p. 308, e De Rosa L., (1968), pp. 354, 362-363.

[25] "Gli orni e i frassini che vegetano verso il littorale dalla parte dell'Jonio, danno una manna migliore di quella del Gargano", Mastriani R., (1842), p. 43.

[26] Manicone M., (1807), p. 7 e (1806), p. 133; Giuliani V., (1768), p. 9.

[27] "la più accreditata nelle spezierie si è quella che raccogliesi nella Calabria e nella Puglia presso il monte di s. Angelo, che era il Gargano degli antichi; quantunque quest'ultima d'ordinario non sia troppo asciutta. In seguito viene la manna di Sicilia che è più bianca e più secca; e in fine la meno stimata è quella che viene nel territorio di Roma alla Tolfa vicino a Civita vecchia, la quale è secca, più opaca e più pesante.", Dizionario universale economico rustico (1795), p. 142.

[28] Russo S., (2022), pp. 113-114.

[29] Floridia S., (1936), pp. 53-54.

meridionale: Marsiglia. Utilizzando le dichiarazioni di sanità rese dai capitali delle navi che dal Mezzogiorno continentale e dalla Sicilia raggiungevano il porto francese tra i primi anni del XVIII secolo e la metà dell'Ottocento, è possibile registrare con precisione l'avanzata della produzione siciliana in uno dei più importanti scali del commercio internazionale[30]. Rispetto ai dati disponibili, intorno alle 21.000 rilevazioni effettuate su un arco cronologico che va dal 1710 al 1846, la manna appare per la prima volta nel 1714 raggiungendo in complesso una percentuale poco superiore al 3%. È una quota marginale rispetto ai grandi imbarchi di derrate tipiche del Mezzogiorno. Queste sono in gran parte costituite dall'olio, seppure di bassa qualità e destinato soprattutto ai saponifici marsigliesi, e poi grano, zolfo, legname - specie doghe e cerchi, elementi indispensabili alla Tonnellerie francese -, soda e cenere, fibre tessili come seta, lana e cotone[31]. L'andamento dei viaggi si presenta abbastanza contenuto e discontinuo - con 25 anni di vuoto - nel corso del Settecento, condizionato da molteplici eventi, dagli episodi di peste a Marsiglia nel 1720 e a Messina e Reggio nei primi anni '40, al terremoto che devasta le due sponde dello Stretto di Messina nel 1783, ai grandi conflitti che investono l'Europa, come la Guerra dei Sette anni, quella di Successione austriaca, la 'grande guerra francese' di fine secolo; con il Congresso di Vienna (1814-15) e l'avvio della Restaurazione, segue una fase di crescita nella prima metà dell'Ottocento (Fig. 2). E proprio in questo torno di tempo si nota chiaramente l'assoluta prevalenza della manna siciliana, ormai padrona del mercato rispetto alle altre produzioni continentali (Fig. 3). Gli imbarchi dai porti isolani, specie Palermo e Messina, sfiorano l'80% del totale mentre il resto viene ancora dal continente, con una netta prevalenza del grande scalo napoletano che concentra le produzioni anche delle altre regioni prima di distribuirle sul mercato interno e all'estero. Le registrazioni della Santè danno modo di rilevare sia la molteplicità del naviglio impiegato, dove sono i brigantini e poi pinchi, tartane, bombarde, le tipologie più utilizzate, sia la nazionalità dei capitani, con la netta prevalenza dei francesi rispetto a chi si dichiara napoletano, siciliano, genovese o sardo.

[30] Si deve a Biagio Salvemini, già ordinario di Storia moderna presso l'Università di Bari e che qui ringrazio, l'avvio di un capillare lavoro di equipe per la creazione di un corposo data-base relativo alla schedatura delle Déclarations de Santé (DS, ADBR, Marseille, 200 E 474-604), e di aver condiviso tra più studiosi di questa importante fonte documentaria in occasione di una ricerca i cui risultati possono in parte vedersi in Salvemini B. (2009).

[31] Tra le prime elaborazioni dei dati della Santè e per le varietà merceologiche qui citate, Salvemini B. - Visceglia M.A. (1991), pp. 134-163. Successivi approfondimenti in Carrino A. - Salvemini B., (2006), pp. 1-46., e in Salvemini B. (2009), dove, per quanto riguarda queste specifiche merci, vedi Blando A., (2009), pp.1-39; Buti G., (2009), pp. 41-58; Bardiot N., (2009), pp. 59-85; Ciccolella D., (2009), pp. 87-115; Gangemi M., (2009), pp. 117-151.

4. Conclusioni

Nel Cinquecento, nonostante le contrarie ed evidenti esperienze già date alle stampe, da più parti la qualità aerea della manna viene sostenuta con fermezza. Su un grande e importante mercato del tempo, quello di Venezia, come del resto in tutt'Italia, due sono le qualità che si rinvengono, la Calabrese e l'altra di Levante: la prima "è la più eccellente" ma alcuni cosentini vollero mischiarla a quella "manna celeste" che i frassini avevano attirato nei propri fusti (sic) e che essi raccolsero intaccando le cortecce, sofisticando il prodotto e incorrendo così in pesanti castighi[32]. Continuò nel tempo il dibattito intorno all'essenza della manna, ma non venne meno la preferenza accordata alla manna calabrese, così come non cessarono i sospetti di contraffazione per incrementare le quantità da immettere in commercio, una possibilità ritenuta quasi una certezza per il prodotto giunto a Marsiglia e che i mercanti e gli stessi apotecari cittadini 'moltiplicano' per soddisfare la sostenuta richiesta del mercato francese [33]. In Italia uno dei luoghi guardati con grande sospetto era Livorno che, grazie alla concessione del porto franco, rappresentava un centro nevralgico per lo smistamento delle merci europee. Mutano gli attori, non più i 'pastori' cosentini o gli avidi marsigliesi, ora "molti credono artefatta dai Giudei" livornesi una parte della tanta manna che si concentra nei magazzini[34]. Ma l'espediente più facile a cui ricorre e che da tanto ha ormai trovato ampia diffusione è quello di spacciare anche le altre manne come calabresi. Un artificio praticato non solo nel meridione ma nello stesso Granducato, tanto che la produzione ottenuta nell'area tra Siena e Piombino, normalmente "è messa in commercio col nome di Manna di Calabria, di cui ha tutte le buone qualità"[35]. Sul fronte qualitativo, però, il ricorso alla copertura di questa sorta di antico brand regionale perde infine di significato.

> *Se gli Scrittori stabilirono, che la Manna Calabrese ottenesse il primo grado di eccellenza per la sua qualità, e bontà, e che alla Siciliana il secondo posto fosse stato dato, avendo il terzo luogo la Romana, e specialmente quella della Terra di S. Felicita, e della Tolfa, bisognerà ora posporre i gradi, e dire che alla Siciliana convenga, e giustamente il primo posto, imperciocchè questa è stata sperimentata di qualità, e bontà migliore, essendo più asciutta, più secca, e non tanto grassa come la Calabrese, e in conseguenza non tanto facile a*

[32] Borgarucci P., (1566), pp. 289-290. La manna levantina rispondeva a una pluralità merceologica prodotta non dai frassini ma da diverse altre piante.
[33] Gilibert J.E., (1772), p. 287.
[34] Pivati G., (1747), p. 487.
[35] Santi G., (1806), p. 89.

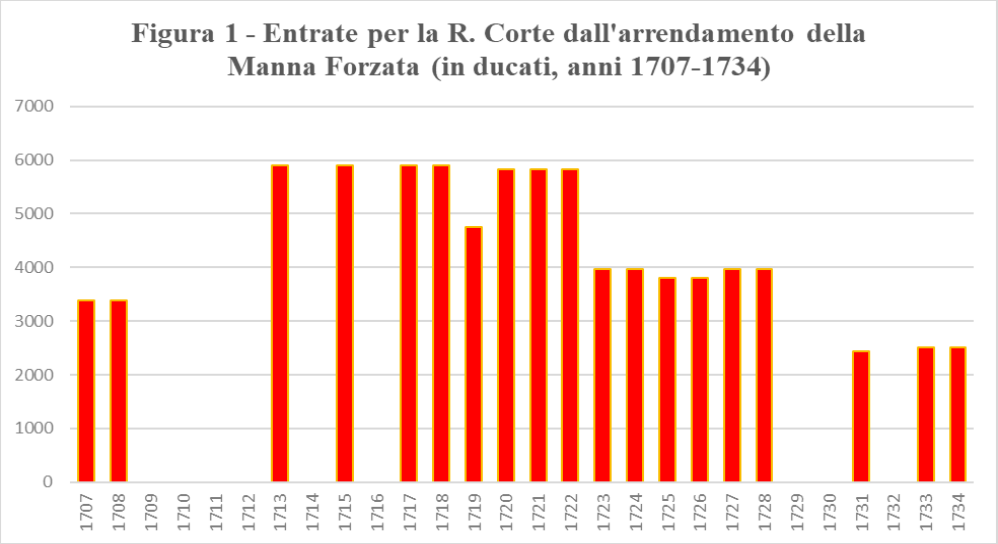
presto corrompersi, lo che reca nausea a chi ne fa uso; inoltre più ancora le si compete il primo posto per esser quella della Calabria in parte mancata, motivo per cui in Sicilia ha animato molti a piantare dei Frassini nelle loro Possessioni, e Giardini, dai quali gran vantaggio ne ricavano per il traffico vivo, che qui si fa in oggi della detta Manna, introitandosi molto danaro[36].

La convenienza economica spinse proprietari e contadini a migliorare ed estendere i frassineti che, seppur limitati a poche aree della Sicilia settentrionale, durante il XIX erano in grado di rifornire i mercati usuali ed esportare la manna locale anche verso le Isole Britanniche, il nord Europa e "per fino per l'America"[37], accarezzando così una seppur labile speranza di poter contribuire a incrinare l'atavica vocazione monocolturale isolana pervicacemente legata al grano.

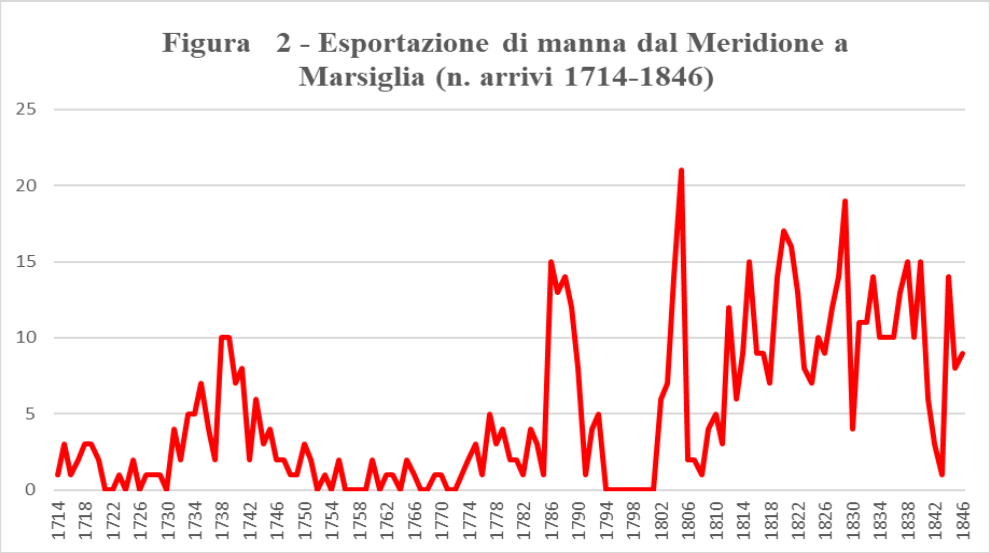
Tabella 1. *Stato dell'Arrendamento della manna nel Regno per il 1778*

Introito:	Ducati e grana
Diritti di licenze con le vendite agli speziali*:	
Basilicata	200,00
Terra di Bari	58,00
Terra di Otranto	256,00
Calabria ulteriore	240,58
Terra di Lavoro	78,00
Napoli e Casali	980,00
Vendita ai Francesi per appalto: cantara 274. 65 ¾ ordinaria a 36. 20, e cantara 2. 97 1/2 a cannolo a d. 72. 40	10.157,92
Vendita a Malta cantara 86 a cannolo a d. 97**	636,74
Riporto	12.607,24
Esito:	
Ai creditori di giustizia per il capitale di duc. 30 mila	1.200,00
Per compra della manna per d. 52 il cantaro a cannolo e l'ordinaria dove a duc. 22 e dove a duc. 26	6.817,13
Spese per la raccolta della manna	418,46
Provvisioni	1.601,40
Spese diverse	221,33
Totale	10.258,32
Netti	2.348,92
*Agli speziali si vendeva la manna a 10 carlini il rotolo, il doppio quella a cannolo. **[evidente refuso, corretto nelle edizioni successive, leggi: cant. 8,6 a duc. 79 a cant.]. Fonte: Galanti G.M., (1788), pp. 154-155.	

[36] Sestini D., (1777), pp. 98-99.
[37] Finazzo L., (1836), pp. 150-151.

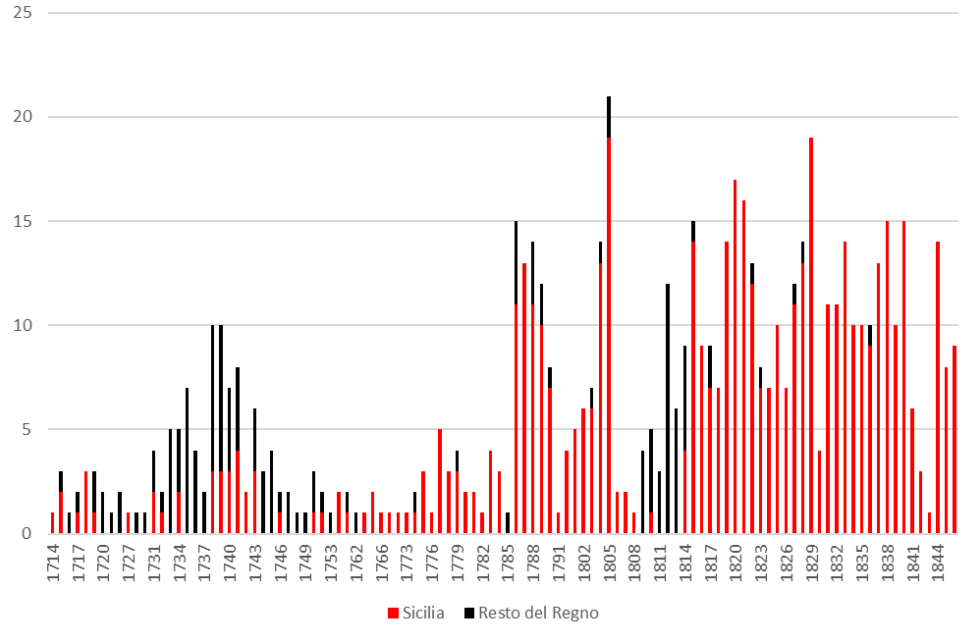


Fonte: Di Vittorio A., (1969), p. 136.



Fonte: DS, ADBR

Figura 3 - Marsiglia: provenienza della manna meridionale per grandi aree (1714-1846)



Fonte: DS, ADBR

Fonti archivistiche

ASCs, Regia Udienza Provinciale, Mazzo (M.) 15, f. 118, voll. I, II, III, a. 1790-1794. ASCz, Regia Udienza Provinciale, C. D 151, f. XI, a. 1754. ASN, Arrendamenti, Fascio 487, a. 1768; fascio 488, a. 1768-1769. ASRC, Regia Corte di Reggio, B. 15, f. 424. ADBR, Marseille, Déclarations de Santé (200 E 474-604).

Bibliografia

Bardiot N., (2009), Marseille dans la compétition industrielle au XVIIIe siècle: l'essor des soudes siciliennes après la guerre de Sept Ans, in Salvemini B. (2009).

Blando A., (2009), Da un "monopolio naturale" all'altro: il grano e lo zolfo siciliano, in Salvemini B. (2009).

Boccone P., (1697 a), Intorno la Manna Medicinale, prodotta, e raccolta in Italia nel Secolo corrente, in Id., Museo di fisica e di esperienze, Venezia, Per Io. Baptistam Zuccato.

Boccone P., (1697 b), Intorno le Proprietà, e l'uso Medicinale della Manna di Calabria, in Id., Museo di fisica e di esperienze, Venezia, Per Io. Baptistam Zuccato.

Borgarucci P., (1566), La fabrica degli spetiali, in Venetia, Appresso Vincenzo Valgriso.

Buti G., (2009), Savon marseillais et huile d'Italie méridionale au XVIIIe siècle, in Salvemini B. (2009).

Caldora U., (1957), La Statistica Murattiana del Regno di Napoli: le relazioni sulla Calabria, in "Quaderni di geografia umana per la Sicilia e la Calabria", vol. V.

Carrino A. - Salvemini B., (2006), Porti di campagna, porti di città. Traffici e insediamenti sulle coste del Regno di Napoli nella prospettiva di Marsiglia (1710-1846), in «Quaderni Storici», n. 1.

Catena B., (1831), (a cura di), Sacra Bibbia di Vence, Dissertazioni (Dissertazione sulla manna), vol. II, Milano, presso Ant. Fort. Stella e figli coi tipi di Giuseppe Bernardoni.

Caudullo G. - de Rigo D., (2016), Fraxinus ornus in Europe: distribution, habitat, usage and threats. In: San-Miguel-Ayanz J., et al. (Eds.), European Atlas of Forest Tree Species. Publ. Off. EU, Luxembourg.

Ciccolella D., (2009), Il commercio franco-meridionale di fibre tessili tra Sette e Ottocento. I dati e le dinamiche, in Salvemini B. (2009).

De Rosa L., (1958), Studi sugli arrendamenti del Regno di Napoli, aspetti della distribuzione della ricchezza mobiliare nel Mezzogiorno continentale, 1649-1806, Napoli, L'arte tipografica.

De Rosa L., (1968), Navi merci nazionalità itinerari in un porto dell'età preindustriale. Il porto di Napoli nel 1760, in Saggi e ricerche sul Settecento, Napoli, Istituto Italiano per gli Studi Storici.

Di Berenger A., (1859-1865), Studii di archeologia forestale, Treviso-Venezia, Tip. Longo.

Di Vittorio A., (1969), Gli Austriaci e il Regno di Napoli, vol. I, Le finanze pubbliche, Napoli, Giannini.

Dizionario universale economico rustico (1795), II ed., tomo XII, Roma, nella stamperia di Michele Puccinelli.

Donzelli G., (1675), Teatro farmaceutico dogmatico, e spagirico, Napoli, per G.F. Paci, G. Fasulo e M. Monaco.

Finazzo L., (1836), Sulla coltivazione dell'albero della manna, in Effemeridi scientifiche e letterarie per la Sicilia, tomo XIV, anno V, Gennajo Febbrajo e Marzo.

Fiore G., (1691), Della Calabria Illustrata, tomo I, Napoli, Parrino-Mutij.

Floridia S. (1936), Le manne e i frassini, (Fraxinus ornus-fraxinus excelsior) dal sec. XVI av. Cr. ai nostri giorni, Catania, Vincenzo Muglia.

Galanti G.M., (1788), Nuova descrizione storica e geografica delle Sicilie, tomo II, Napoli, Nel Gabinetto Letterario.

Galanti G.M., (1789), Nuova descrizione geografica e politica delle Sicilie, tomo III, Napoli, Presso i Socj del Gabinetto Letterario.

Galanti G.M., (1987), Giornale di viaggio in Calabria, in Id., Scritti sulla Calabria, ed. critica a cura di A. Placanica, Napoli, Società Editrice Napoletana.

Gangemi M., (2009), Il mercato del legname a Marsiglia: le importazioni dall'Italia meridionale tra Sette e Ottocento, in Salvemini B. (2009).

Gilibert J.E., (1772), L' anarchie médicinale, ou La medecine considérée comme nuisible a la société,premiere partie, Neuchatel, (s.e.).

Giuliani V., (1768), Memorie storiche politiche, ecclesiastiche della città di Vieste, Napoli, presso Francesco Morelli.

Giustiniani L., (1804), Nuova collezione delle prammatiche del Regno di Napoli, tomo VII, "De manna legendo", Prammatiche I, II, III, IV, Napoli, Stamperia Simoniana.

Giustiniani L., (1804 a), Nuova collezione delle prammatiche del Regno di Napoli, tomo VI, "De incisone arborum", Prammatica III, Napoli, Stamperia Simoniana.

Grimaldi D., (1770), Saggio di economia campestre per la Calabria Ultra, Napoli, V. Orsini.

Grimaldi D., (1780), Osservazioni economiche sopra la manifattura e commercio delle sete del Regno di Napoli, Napoli, G.M. Porcelli.

Manicone M., (1806), La fisica appula, tomo I, Napoli, presso Domenico Sangiacomo.

Manicone M., (1807), La fisica appula, tomo V, Napoli, presso Domenico Sangiacomo.

Mastriani R., (1842), p. 43. La Calabria (estr. dal Dizionario-Geografico-Storico-Civile del Regno delle Due Sicilie), Napoli.

Melograni G., (1810), Istruzioni fisiche ed economiche dei boschi, Napoli, A. Trani.

Padula V., (1977), Calabria prima e dopo l'Unità, (a cura di A. Marinari), vol. I, Roma-Bari, Laterza.

Palumbo M., (1912), Boschi e selve. Provvedimenti di governo, Salerno, Tip. Spadafora.

Placanica A., (1985), Il filosofo e la catastrofe. Un terremoto del Settecento, Torino, Einaudi.

Pivati G., (1747), Nuovo dizionario scientifico e curioso sacro - profano, tomo VI, in Venezia, per Benedetto Milocco.

Prato G., (1908), La vita economica in Piemonte a mezzo il secolo XVIII, Torino, Soc. Tipografico Editrice Nazionale.

Russo S., (2022), Il pino da pece e il frassino da manna nel Gargano del XIX secolo, in Dattero A. (a cura di), Il bosco. Biodiversità, diritti e culture dal medioevo al nostro tempo, Roma, Viella.

Salvemini B. - Visceglia M.A, (1991), Marsiglia e il Mezzogiorno d'Italia (1710-1846), in «Mélanges de l'École Française de Rome. Italie et Méditerranée», n.1.

Salvemini B, (2009). (a cura di), Lo spazio tirrenico nella "grande trasformazione": merci, uomini e istituzioni nel Settecento e nel primo Ottocento (atti del convegno internazionale di Bari, 17-18 novembre 2006), Bari, Edipuglia.

Santi G., (1806), Viaggio terzo per le due provincie senesi che forma il seguito del viaggio al Montamiata, Pisa, per Ranieri Prosperi.

Sestini D., (1777), Descrizione di varj prodotti dell'isola di Sicilia relativi al commercio della medesima con l'estere nazioni, Firenze, Per Gaetano Cambiagi Stamp. Granducale.

Swinburne H., (1783), Travels in the Two Sicilies in the Years 1777, 1778, 1779 and 1780, vol. I, London, P. Elmsly.

Villani P., (1977), Mezzogiorno tra riforme e rivoluzione, Roma- Bari, Laterza.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 171-191

Real World Data: la nuova sfida nell'analisi dei dati sui percorsi di cura dei pazienti

Pietro Bianco[1], Angela Maria D'Uggento[1*], Mariabeatrice Principi[2], Ernesto Toma[1].

[1]Dipartimento di Economia e Finanza, Università degli Studi di Bari Aldo Moro
[2]Dipartimento di Medicina di Precisione e Rigenerativa e Area Jonica, Sezione di Gastroenterologia, Università degli Studi di Bari Aldo Moro

Riassunto: Il presente studio illustra i risultati di una ricerca condotta su un gruppo di pazienti affetti da malattie infiammatorie croniche intestinali (IBD), la Rettocolite Ulcerosa (RCU) e il morbo di Crohn. I pazienti sono stati sottoposti a trattamento medico con anticorpi monoclonali biologici (Infliximab e Vedolizumab) con l'obiettivo di evidenziare analogie e differenze tra le due patologie per valutare l'efficacia delle cure e i miglioramenti nella qualità della vita dei pazienti. Nelle analisi sono state considerate differenti variabili demografiche, sociali e cliniche, sia con riferimento all'intero campione che nei due sottogruppi IBD, utilizzando appropriati test inferenziali. Attraverso una cluster analysis sono stati individuati quattro gruppi di pazienti di diversa ampiezza, ciascuno dei quali evidenzia aspetti clinici importanti. Accertata la presenza di strutture di clustering, si è passati ad identificare un modello probabilistico in grado di spiegare tali dati come una combinazione di distribuzioni di probabilità, attraverso un'analisi delle classi latenti (LCA). In tal modo, sono stati individuati tre sottogruppi qualitativamente diversi con ulteriori caratteristiche cliniche. Lo studio utilizza l'approccio dei Real World Data (RWD) che evidenzia come i dati del mondo reale e le evidenze cliniche possano essere impiegati per ottenere risultati generalizzabili all'intera comunità destinataria di un determinato trattamento sanitario e come la metodologia statistica possa rivelarsi efficace nel supportare la valutazione clinica del paziente.

Keywords: evidenze cliniche; morbo di Crohn; rettocolite ulcerosa; terapia biologica; cluster analysis; analisi delle classi latenti.

[*] Corresponding author: angelamaria.duggento@uniba.it
Il presente lavoro è frutto di un progetto comune, tuttavia Bianco ha provveduto alle elaborazioni e alla preparazione della bozza originale mentre gli altri Autori hanno contribuito alla revisione e alla redazione del testo finale.

1. Introduzione

Negli ultimi anni, a livello internazionale, è emersa la necessità sempre più evidente di raccogliere, gestire ed interpretare elevate quantità di dati riguardanti la salute della popolazione. Tuttavia, in ambito clinico, per poter effettuare tali analisi, è frequente operare con campioni rappresentativi di pazienti, spesso arruolati in studi multicentrici.

Tali esigenze hanno condotto allo sviluppo di due rigorosi approcci scientifici, impiegati in ambito statistico-economico, sociale e medico, in grado di valutare la qualità delle prestazioni sanitarie erogate e di supportare le decisioni di tipo clinico-assistenziale: Real World Data e Real World Evidence.

Gli obiettivi principali di questi approcci comprendono il continuo monitoraggio dello stato di salute della popolazione, la valutazione dell'efficacia ed efficienza del sistema sanitario, l'erogazione delle prestazioni effettuate in rapporto alla domanda di salute e la spesa sanitaria. Dai dataset clinici è possibile estrapolare informazioni molto importanti, come la presenza di relazioni tra due o più variabili relative ai pazienti analizzati, spesso attraverso campioni, eppure l'implementazione di un sistema dedicato ai Real World Data (RWD) risulta essere ancora estremamente costosa, complessa e richiede attività di raccolta dati molto impegnative.

La parte iniziale del lavoro fornisce alcune nozioni di base sui RWD e sul loro ruolo nelle analisi dei dati sociosanitari condotte dalle strutture ospedaliere, sia a livello locale che a livello nazionale. Dopo una panoramica generale sul fenomeno vengono forniti elementi utili alla comprensione delle specifiche patologie oggetto di analisi, attraverso l'elencazione delle principali criticità e delle metodologie di trattamento e prevenzione utilizzate per il contrasto delle malattie.

Segue una presentazione dettagliata del dataset raccolto ed analizzato, prevalentemente a scopi esplorativi e, laddove opportuno, facendo riferimento per ciascuna variabile rilevata, sia a livello complessivo che per i due sottogruppi inerenti alla singola patologia cronica intestinale. Tali dati sono sintetizzati con tabelle e rappresentazioni grafiche (boxplot, istogrammi a barre affiancate, spineplot, dendogrammi) propedeutici allo studio approfondito attraverso metodologie di analisi dei cluster gerarchiche multivariate.

2. I Real World Data e la sfida di accesso al dato

Le aziende sanitarie e farmaceutiche operano sempre più frequentemente con una elevata mole di dati clinici e genomici raccolti dalle strutture locali e dal sistema sanitario: si tratta di dati raccolti dal mondo reale, meglio noti come Real World Data (Abernethy, 2023; Castellanos, E. H. et al., 2024).

Secondo quanto recentemente riportato anche dall'ente governativo statunitense Food and Drug Administration (FDA), essi permettono di conoscere lo stato di salute del paziente ed i suoi percorsi assistenziali attraverso l'integrazione di una varietà di fonti di dati, tra cui cartelle cliniche elettroniche, attività di fatturazione, registri di prodotti e malattie, dati generati dai pazienti, informazioni fornite da un familiare o da altri caregiver. Tale mole e varietà di dati consente di osservare ciò che accade nella pratica clinica quotidiana e di effettuare analisi ottenendo evidenze comparabili a quelle prodotte dagli studi clinici randomizzati. Per tal motivo, gli operatori del settore auspicano una loro rilevante diffusione nei prossimi anni al fine di sfruttare più efficacemente le possibilità offerte dagli RWD.

Nel nostro Paese, nonostante la presenza di alcune realtà leader nella sperimentazione come Humanitas, Novartis e Roche, si fa ancora fatica ad avere una visione d'insieme: infatti, studi recenti[1] hanno dimostrato come questo strumento non venga ancora ampiamente utilizzato a causa delle fonti di dati eterogenee, spesso di difficile accesso e non ancora organizzate in opportuni database, di cartelle cliniche inadeguate, che non presentano formati standard, e principalmente per la mancata uniformità dei database amministrativi, sia per motivi tecnici legati alle strutture dei database che per difficoltà legate ai permessi di accesso relativi all'impostazione di un follow-up puntuale della malattia. Sono questi gli ostacoli che, in buona sostanza, affronta chi decida di cogliere la sfida posta dai nuovi RWD, i dati del mondo reale.

I RWD costituiscono soltanto il punto di partenza, poiché in seguito alla raccolta dei dati grezzi è necessaria una strutturazione di tutte le informazioni per giungere, infine, alla Real World Evidence (RWE), anch'essa recentemente definita dalla FDA come l'evidenza clinica relativa all'utilizzo ed ai potenziali benefici o svantaggi di un determinato prodotto medico derivato dall'analisi dei dati del mondo reale. Tale evidenza permette di delineare un predefinito ed accurato piano di ricerca, consentendo così di trasformare i dati in valore.

[1] https://www.aboutpharma.com/scienza-ricerca/la-ricerca-di-valore-deve-integrare-i-real-world-data/

Si tratta di una grande sfida se si considera che il mondo sanitario negli ultimi anni ha osservato un incremento esponenziale dei cosiddetti touch-point, ovvero dei punti di contatto con i pazienti: basti pensare ai medical device sempre più utilizzati dai pazienti.

Nel resto dell'Europa occidentale, soprattutto in Francia e Spagna, sono già vigenti diversi sistemi sanitari in cui provider, aziende sanitarie, aziende farmaceutiche ed organi di governo sono in grado di scambiarsi le informazioni in modo sicuro anche attraverso i dati. Di conseguenza, il sistema ottiene risultati sanitari più dettagliati comportando benefici notevoli quali riduzione del tasso di ospedalizzazione dei pazienti e il supporto agli stakeholder nel prendere decisioni potenzialmente salvavita in tempo reale.

Cave et al. (2019) hanno enfatizzato l'utilità di una adeguata formazione degli operatori del sistema sanitario per sfruttare l'intero potenziale dei RWD che potrebbe comportare benefici quali la riduzione di costi, complessità e tempi. A tal proposito, l'Agenzia Europea per il Farmaco (EMA, 2020) ha dichiarato, nel proprio documento *Regulatory Science to 2025*, che uno dei principali obiettivi da perseguire riguarda la promozione dell'uso dei RWD nel processo decisionale al fine di migliorare la qualità delle valutazioni. In particolare, sostiene che i dati possono essere raccolti in maniera più efficiente durante il ciclo di vita dei farmaci studiati, dallo sviluppo preclinico al loro utilizzo nel mondo reale, aggiungendo che un'adeguata analisi dei risultati d'uso aggiunge valore al processo di sviluppo clinico e di regolamentazione, con conseguente riduzione degli oneri a carico dei sistemi sanitari.

Le evidenze cliniche dei dati producono numerosi benefici per i gestori del percorso di cura, per le case farmaceutiche e per i pazienti, da un lato aiutando a monitorare la safety, dall'altro valutando con maggiore consapevolezza le linee decisionali di natura clinica. Questo conferma che il dato rappresenta l'elemento di unione tra la ricerca effettuata e i percorsi assistenziali di cura (Anderson et al., 2023).

La crescita del numero di punti di contatto ed il passaggio, in ambito sanitario, dalle logiche multicanale a quelle omnicanale ha determinato una crescita importante della mole di dati per chi si occupa della cura della salute dei pazienti e delle loro relative riabilitazioni. Per gestire queste informazioni in modo omogeneo ed organizzato è fondamentale il supporto ed utilizzo efficace di diverse moderne tecnologie (Blockchain, Intelligenza artificiale, Machine Learning) per poter lavorare su dati utili alla RWE, ma occorre anche il supporto di veri e propri professionisti del dato, come i Data Scientist (Hou et al., 2023). La tecnologia, oltre ad essere vista come abilitatore, possiede anche il ruolo di collettore: ad oggi si dispone di una

moltitudine di data silos, i quali fanno spesso riferimento alle singole strutture farmaceutiche o sanitarie, e, tuttavia, non si colgono interamente le potenzialità della tecnologia, poiché solo un dato reso affidabile diviene un elemento distintivo in grado di supportare i percorsi clinici, la ricerca e le aziende nel creare le sinergie che alimentano la medicina di precisione.

Tale aspetto è emerso anche durante la recentissima emergenza internazionale legata al Covid-19, durante la quale diversi soggetti hanno messo in pratica differenti e moderni modelli di assistenza maggiormente vicini ai cittadini, basati appunto sui servizi forniti dalle più avanzate tecnologie digitali.

3. Malattie infiammatorie croniche intestinali

Le malattie infiammatorie croniche intestinali, note con l'acronimo inglese IBD (Inflammatory Bowel Disease), consistono in infiammazioni croniche idiopatiche derivanti da una risposta immunitaria della mucosa gastrointestinale e si caratterizzano per la loro alternanza di fasi recidive e remittenti.

Tuttora le cause precise di tali patologie sono sconosciute, ma esistono evidenze cliniche che confermano potenziali anomale reazioni immunitarie innescate dalla flora intestinale negli individui caratterizzati da una predisposizione genetica multifattoriale, la quale si suppone essere fattore di alterazioni delle difese immunitarie mucosali. Tra le altre possibili cause, tuttora sotto indagine, vi sono fattori genetici, ambientali, alimentari, infettivi e psicologici.

Diversi studi (Dulai, 2019) hanno dimostrato che dal punto di vista demografico, queste patologie colpiscono soggetti di tutte le età ma in modo particolare i giovani fino ai 30 anni, dove si riscontra un picco di incidenza tra i 14 ed i 24 anni, e gli individui tra i 50 ed i 70 anni, ma con un picco meno accentuato. Dal punto di vista geografico, invece, si riscontra una maggiore predisposizione tra le popolazioni nord-europee ed anglosassoni ed un sostanziale incremento di incidenza anche tra gli afroamericani e latino-americani attualmente situati nel Nord America mentre vi è una bassa incidenza nell'Europa centro-meridionale, in Sud America, in Asia e in Africa. Inoltre, particolari ricerche (Lynch et al. 2004) hanno evidenziato delle predisposizioni croniche (dalle 2 alle 4 volte superiori alla norma) nella popolazione ebraica Ashkenazi, stabilitasi in Europa centro-orientale.

Non ci sono, invece, differenze sostanziali di genere, visto che maschi e femmine vengono colpiti dalle malattie IBD indicativamente con le stesse probabilità. Esistono anche dati interessanti riguardo la predisposizione familiare: è stato stima-

to che i parenti di primo grado dei pazienti affetti da tali patologie hanno un'incidenza dalle 4 alle 20 volte superiore rispetto agli individui senza precedenti genetici. Tale rischio assoluto sfiora il 7% e riguarda prevalentemente la malattia di Crohn, seppure la RCU non sia esente da correlazioni di tipo genetico (Bernstein, 2006).

Altri fattori di rischio, che contribuiscono al loro sviluppo o aggravamento, riguardano il consumo di sigarette, l'utilizzo dei cosiddetti farmaci antinfiammatori non steroidei (FANS) ed il consumo eccessivo nelle prime fasi di vita degli antibiotici, poiché possono eliminare batteri intestinali come l'Escherichia Coli, questi ultimi in grado di contrastare l'insorgenza di infezioni. Inoltre, altri dati ancora da approfondire indicano possibili correlazioni tra gli individui aventi uno status socio-economico elevato ed il rischio di essere affetti dalla malattia di Crohn.

Anche se entrambe trattate con agenti biologici ad infusioni ripetute ogni 8 settimane, in molti casi si osservano differenze significative tra morbo di Crohn e Rettocolite Ulcerosa.

La malattia di Crohn assume un andamento irregolare, alternando periodi di remissione e di riacutizzazione, ed è fondamentalmente localizzata nell'ultimo tratto dell'intestino tenue oppure nella parte destra del colon. Per quanto concerne il nostro Paese, si registrano annualmente circa 2 nuovi casi ogni 100 mila abitanti. In alcuni casi, può costituire un fattore che origina emorragie o megacolon. Tra le probabili cause, seppur non certificate, si segnalano: dissenteria con presenza di muco e sangue, dolori addominali, febbre, perdita di peso, squilibri psicologici, lesioni dell'ano (proctiti o fistole), astenia, anemia, disturbi extra-intestinali (artriti, uveiti e lesioni cutanee), calcolosi renale e malattie del fegato o delle vie biliari. Raramente, le lesioni anali progrediscono fino ad avere estensioni più vaste oppure vi è l'insorgenza di determinate complicazioni come acute occlusioni intestinali, ascessi intrattabili con rischi di perforazione o fistole: in circa il 70% di questi casi è necessario almeno un intervento chirurgico e, data l'elevata probabilità di recidiva del morbo, in quasi il 35% di questi viene effettuato un ulteriore intervento entro massimo 10 anni di distanza dalla precedente resezione.

Il termine rettocolite ulcerosa, invece, deriva dal greco kolon+itis, ovvero da un particolare processo infiammatorio a carico del colon sinistro. Essa si caratterizza per la presenza di ulcere sulla mucosa dell'organo colpito e per l'insorgenza di lesioni del retto, spesso coinvolto. Un fattore che influisce fortemente sul loro sviluppo è l'insufficiente apporto di sangue alle vie intestinali. Gran parte delle altre possibili cause correlate coincidono con quelle della malattia di Crohn mentre tra quelle che contraddistinguono la RCU troviamo stipsi con tenesmo, nei casi in cui

il soggetto riscontra problematiche al retto, sofferenza epatica, tachicardia ed anemia. Perforazione intestinale ed evoluzione in cancro maligno sono le due possibili complicanze che si possono riscontrare nei pazienti più gravi: tali eventi hanno maggiori probabilità di manifestarsi in coloro i quali sono affetti da rettocolite da più di 10 anni (Fumery et al., 2017).

Per quanto concerne lo stile di vita, tali patologie sono, in buona sostanza, compatibili con uno stile di vita normale: infatti, solamente in un caso su dieci si riscontrano forme invalidanti (Murthy et al., 2023).

3.1 Terapia e prevenzione delle patologie croniche intestinali

L'esame specifico per ottenere maggiori indicazioni riguardo le malattie IBD è la colonscopia della parete intestinale con biopsia. In alternativa, si fa ricorso al quadro clinico generale, ad esami radiografici, ad esami di laboratorio, opportunamente indicati dai gastroenterologi, come il clisma con doppio contrasto, e alla cosiddetta terapia medica. Quest'ultima non è risolutiva ma può essere di sostegno per controllare e prevenire eventuali riacutizzazioni della malattia.

Sono molte le classi di farmaci impiegate per il contrasto delle due patologie croniche ma le precipue caratteristiche che ne determinano l'impiego fanno sì che questi vengano trattati in maniera autonoma: in tal contesto, vengono impiegati antibiotici, acido 5-ASA, farmaci antinfiammatori corticosteroidei (prednisone, budesonide, mesalazina) o farmaci biotecnologici.

In alcuni casi è necessario ricorrere alla chirurgia che risulterà risolutiva della malattia in caso di RCU con l'asportazione del colon e del retto (proctocolectomia totale) o terapeutica in caso di morbo di Crohn complicata da stenosi, fistole o ascessi.

4. Materiali e metodi

L'obiettivo dello studio è quello di analizzare le caratteristiche di un gruppo di pazienti affetti dalle due malattie IBD, precedentemente illustrate nelle loro caratteristiche, e di evidenziarne le eventuali analogie e differenze sulla base di una serie di variabili demografiche (età, genere), comportamentali (consumo di sigaretta) e clinico-terapeutiche (trattamento biologico, linea terapeutica, durata malattia in anni, durata terapia in mesi, comorbilità, patologie reumatologiche e dermatologiche associate, intervento chirurgico, reazioni avverse, effetti collaterali).

I dati di input sono stati rilevati dai medici in servizio nelle più prestigiose unità operative di Gastroenterologia della Regione Puglia: Unità di Gastroenterologia universitaria-Ambulatorio IBD del A.O. Policlinico di Bari, UOC Gastroenterologia dell'Ospedale Di Miccoli di Barletta e UOS Gastroenterologia ed Endoscopia Digestiva dell'Ospedale Vito Fazzi di Lecce. Il campione dello studio multicentrico è costituito da 108 pazienti, rilevati nell'arco di un anno a partire dal 2022.

Ai diversi pazienti oggetto di studio, vengono somministrate per via sottocutanea due tipologie di farmaci biologici, Infliximab (IFX) e Vedolizumab (VDZ), entrambi recentemente approvati dalla Food and Drug Administration per il contrasto delle malattie IBD, seppur differenti nei loro principi attivi.

L'analisi esplorativa è utile per conoscere le caratteristiche dei pazienti e per il confronto tra i due sottocampioni che raggruppano i pazienti affetti da RCU e dalla malattia di Crohn. Per confrontare i due trattamenti biologici e capire quale influisca maggiormente sul miglioramento della qualità di vita del paziente, sono stati utilizzati il test t di Student per le variabili quantitative (età, durata malattia e durata terapia), il test U di Mann-Whitney e il test χ^2 per le variabili qualitative (Delvecchio, 2024). Nella seconda fase di studio, sulla base anche dei risultati della analisi esplorativa, è stato calcolato l'indice di Gower (Gower, 1971), che consente di condurre una cluster analysis anche in presenza di variabili quali-quantitative (Finch, 2005; Ostlund et al., 2011).

Accertata la presenza di strutture di clustering, evidenziate direttamente dai dati osservati, si è passati ad identificare un modello probabilistico in grado di spiegare tali dati come una combinazione di distribuzioni di probabilità, attraverso un'analisi delle classi latenti (LCA). Tale metodologia, infatti, risulta utile per scoprire strutture e modelli nascosti all'interno dei dati attraverso l'identificazione di un numero appropriato di diversi gruppi latenti in popolazioni che condividono specifiche caratteristiche osservabili e quindi per rilevare eterogeneità latente nel collettivo oggetto di analisi (McCutcheon, 1987; Vermunt and Magidson, 1999, Hagenaars and McCutcheon, 2002). L'applicazione di tale metodologia è ancora oggi argomento di dibattito tra i ricercatori (Rosato and Baer, 2012; Schreiber, 2017; Lythgoe et al. 2019), rispetto alla dimensione campionaria ottimale, alla selezione delle variabili predittive, alla scelta del modello finale.

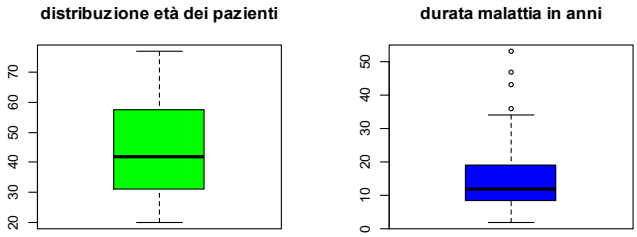
Le analisi statistiche sono state eseguite utilizzando i seguenti pacchetti di R-Studio (R Core Team, 2023;): **Readxl** (versione 1.4.2, Wickham e Bryan, 2023), **Cluster** (versione 2.1.4, Kaufman e Rousseeuw, 2023) e **poLCA** (Linzer e Lewis, 2011), per le analisi delle classi latenti con variabili politomiche codificabili in dicotomiche.

5. Risultati

5.1 Analisi esplorativa

Le caratteristiche distintive delle due malattie croniche sono sintetizzate nella Tabella 1, che illustra sia i dati dell'intero campione di pazienti che quelli dei due sottocampioni che raggruppano i pazienti affetti dalla stessa patologia. Dall'analisi descrittiva è emerso che la coorte di pazienti pugliesi analizzati presenta una prevalenza di soggetti di sesso maschile (55,6%). Inoltre, si evidenziano differenze non irrilevanti tra le età mediane dei pazienti dei due sottocampioni, con quella della rettocolite superiore di circa 4 anni rispetto a quella del morbo di Crohn. Nonostante questa differenza, è stato osservato come entrambe le patologie IBD possono colpire individui appena maggiorenni di entrambi i generi.

Figura 1. *Boxplot per l'analisi delle variabili quantitative*



Altri dati interessanti emergono analizzando i due diversi trattamenti biologici impiegati per il contrasto delle malattie. Suddividendo il campione è stato riscontrato un maggiore impiego del VDZ (60,0%) all'interno del gruppo di individui affetti da rettocolite ulcerosa e dell'IFX (72,1%) nel sottocampione degli individui affetti da morbo di Crohn. Restando sempre in ambito terapeutico, è stato possibile evidenziare un equilibrio nell'utilizzo dei due trattamenti tra i pazienti di sesso maschile ma anche un maggior impiego del VDZ sia tra le donne che tra i soggetti anziani, questi ultimi ovviamente tenuti in cura per tempi più prolungati.

Ulteriori informazioni molto utili si ricavano dal confronto tra tipologia di malattia ed abitudine al consumo di sigarette, dove sono emerse presenze rilevanti della malattia di Crohn tra i fumatori e tra coloro che ne hanno fatto uso per molto tempo ma soprattutto anche tra i pazienti non fumatori, seppur occorre sottolineare che non sono state prese in considerazione involontarie inalazioni di fumo, meglio definite come "fumo passivo".

Per quanto concerne le caratteristiche delle due malattie IBD, l'analisi dei dati dimostra che, essendo croniche, sono destinate ad accompagnare i pazienti anche

per decenni (mediamente per 12 anni, Tabella 1 e Figura 1) e, di conseguenza, sono necessarie continue ed adeguate cure in modo particolare per il morbo di Crohn.

Tabella 1. *Principali caratteristiche dei pazienti affetti da malattie croniche IBD.*

	Totale	RCU	CROHN	**P-value**
Numero di pazienti	108	65	43	
Età mediana [quartili]	42,00 [31,00 – 57,25]	44,00 [32,00 – 62,00]	40,00 [29,50 – 51,00]	0,056*
Età MAX	77	77	75	
Età MIN	20	21	20	
Genere				0,660
Pazienti M (%)	60 (55,56)	35 (53,85)	25 (58,14)	
Pazienti F (%)	48 (44,44)	30 (46,25)	18 (41,86)	
Struttura sanitaria:				
BA	77	48	29	
BAT	13	5	8	
LE	18	12	6	
Trattati con **IFX** (%)	57 (52,78)	26 (40,00)	31 (72,09)	0,002*
Trattati con **VDZ** (%)	51 (47,22)	39 (60,00)	12 (27,91)	0,002*
Consumo fumo:				0,018*
Non Fumatori (%)	69,44	76,93	58,14	
Fumatori (%)	15,74	7,69	27,91	
Ex-Fumatori (%)	14,82	15,38	13,95	
Comorbilità				
Assente (%)	62 (57,41)	30 (46,15)	32 (74,42)	0,004*
Presente (%)	46 (42,59)	35 (53,85)	11 (25,58)	
Durata malattia (anni) [quartili]	12 [8,75 – 19,00]	13 [8,00 – 20,00]	11 [9,00 – 17,50]	0,282
Durata terapia (mesi) [quartili]	36,00 [21,50 – 53,00]	35,00 [18,00 – 51,00]	41,00 [25,00 – 66,00]	0,224
Linea terapeutica				0,444
Prima linea	55	32	23	
Seconda linea	44	29	15	
Terza Linea	9	4	5	
Intervento chirurgico = Sì (%)	17 (15,74)	2 (3,08)	15 (34,88)	0,001*
Reaz.reumatologiche = Sì (%)	26 (24,07)	15 (23,08)	11 (25,58)	0,766
Reaz.dermatologiche = Sì (%)	10 (9,26)	6 (9,23)	4 (9,30)	0,990
Reazioni avverse = Sì (%)	18 (16,67)	9 (13,85)	9 (20,93)	0,334
Effetti collaterali = Sì (%)	9 (8,33)	5 (7,69)	4 (9,30)	0,767

Nota: *=p-value statisticamente significativi.

Tuttavia, tra le due malattie risultano anche delle differenze sostanziali: mentre la RCU è spesso accompagnata dalla presenza di una o più comorbilità (53,8% dei casi) il morbo di Crohn si manifesta in circa tre casi su quattro (74,4%) in assenza di patologie pregresse. Le principali patologie connesse a quelle infiammatorie in-

testinali comprendono ipertensione arteriosa, sindrome ansiosa o depressiva, obesità, dermatite atopica, psoriasi, diabete mellito di tipo II, noduli polmonari, artrite reumatoide ed asma con o senza rinite allergica.

Altre differenze significative riguardano l'eventuale scelta del medico di ricorrere ad interventi chirurgici per contrastare la progressione della malattia o per intervenire a seguito di un riscontro di reazioni locali comparse a distanza di pochi giorni dalla somministrazione del trattamento biologico: è emerso che la malattia di Crohn, in più di un terzo dei casi, porta a delicati interventi come resezione ileocecale, resezione ileocolica ed emicolectomia destra, mentre si interviene nei pazienti affetti da rettocolite solamente nel 3,1% dei casi. Al tempo stesso, però, è stato notato che nel 20,9% dei pazienti affetti da morbo di Crohn si sono verificate reazioni avverse contro il 13,8% di quelli affetti da rettocolite e, tra queste, le più comuni sono dolori intestinali, gonfiore addominale, arrossamento ed indurimenti articolari.

Per quanto riguarda le analogie, sono state riscontrate percentuali molto simili di pazienti affetti anche da problematiche di natura reumatologica (tra il 23,1 ed il 25,6%) e dermatologica (tra il 9,2% ed il 9,3%), alle quali possono sommarsi determinate reazioni sistemiche (tra il 7,7% e il 9,3%) a seguito alla somministrazione del trattamento. Le principali sintomatologie post-trattamento registrate nel breve periodo comprendono eruzioni cutanee, stanchezza o affaticamento, senso di malessere, mal di testa, dolori muscolari o mialgia e dolori articolari (solamente in rari casi ai sintomi appena elencati può seguirsi l'anafilassi (0,01%)).

Per un approfondimento di analisi, ulteriori variabili del campione sono illustrate nella Tabella 2 che descrive indici che in ambito medico sono impiegati per classificare la gravità delle patologie IBD: l'indice di Mayo Score clinico (PMS) e l'indice di Harvey-Bradshaw (HBI).

Il PMS valuta lo stadio di rettocolite ulcerosa o RCU sulla base di quattro componenti (frequenza di defecazione, sanguinamento rettale, valutazione endoscopica e giudizio complessivo del medico curante) che consentono al medico di assegnare valori generici variabili in una scala che va da 0 (remissione) a 10 (malattia in fase avanzata). L'indice HBI, invece, è stato concepito nei primi anni '80 come una versione semplificata dell'indice Crohn's Disease Activity Index (CDAI) per favorire una raccolta sistematica dei dati clinici relativi alla malattia di Crohn. Anch'esso assume differenti valori in base a specifici parametri (benessere del paziente, dolore addominale, numero di evacuazioni, massa addominale e presenza di complicanze associate) in una scala che va da 0 (remissione) a 16 (malattia in fase avanzata).

Tabella 2. *Caratteristiche del campione secondo gli indici di gravità di ciascuna malattia infiammatoria cronica intestinale*

	RCU	CROHN	Sigla nel Dataset
Numero di pazienti	65	43	
Fenotipo Crohn			
Non restrittivo (%)		16 (37,21%)	B1
Restrittivo (%)		14 (32,56%)	B2
Acuto/Perforante (%)		13 (30,23%)	B3
PMS/Partial Mayor Score: (gravità della rettocolite)			
Quasi irrilevante	54 (83,08%)		<2 (0, 1)
Poco grave	11 (16,92%)		>2 (2, 3, 4, 5)
HBI/Indice di Harvey-Bradshaw: (gravità del morbo)			
Quasi irrilevante		26 (60,47%)	<2 (0, 1)
Poco grave		12 (27,91%)	>2 e <5 (2, 3, 4)
Moderato		5 (11,62%)	>5 (5, 6)

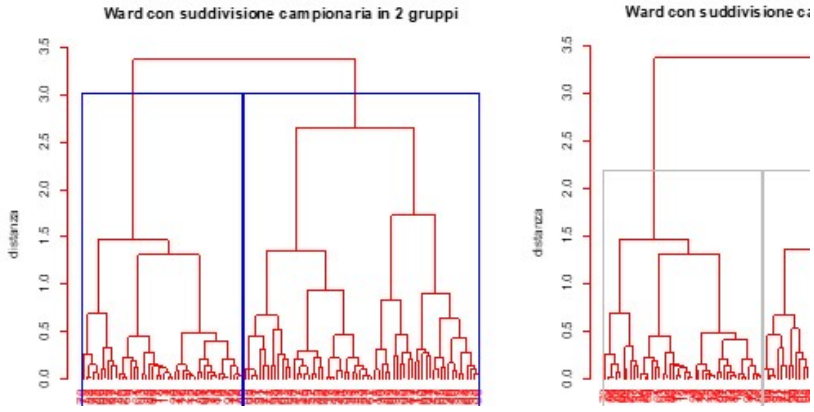
Dall'analisi dei dati è emerso che l'83,1% dei pazienti affetti da RCU ed il 60,5% dei pazienti affetti da morbo di Crohn monitorati nei reparti di Gastroenterologia pugliesi possono essere curati più efficacemente poiché colpiti da malattia di lieve. Contemporaneamente, si denota una maggiore percentuale di casi poco gravi o moderati nel sottocampione relativo ai pazienti affetti da morbo di Crohn (circa il 40%) mentre i casi più delicati del sottocampione RCU coinvolgono soltanto il 16,9% dei pazienti. È importante evidenziare che in nessuno dei due sottocampioni si registra la presenza di uno o più individui affetti da malattia terminale.

5.2 Analisi dei gruppi

Sulla base di quanto emerso nell'analisi esplorativa, è stata condotta un'analisi dei gruppi scegliendo quale metodo migliore quello di Ward (Figure 2 e 3). Tale metodo, detto anche della devianza minima, tende ad escludere le osservazioni caratterizzate da valori estremi di una o più variabili analizzate.

La Figura 2 riportata i risultati delle prime due simulazioni, partendo da quella con k=2, la quale distingueva abbastanza correttamente i pazienti in base al trattamento biologico somministrato (44 con IFX e 64 con VDZ) e, di conseguenza, alla linea terapeutica adottata dal medico (IFX come prima linea e VDZ a chi ha già precedentemente assunto un altro farmaco).

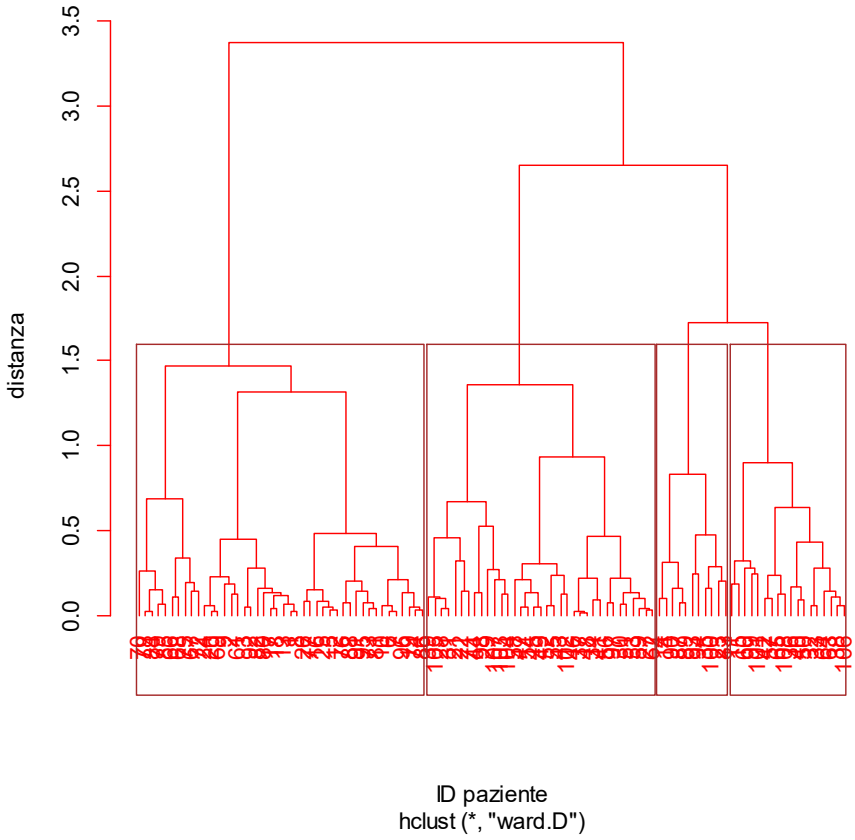
Figura 2. *Dendogramma (criterio di Ward) in due o tre gruppi, con linee di taglio per la suddivisione in base a determinate caratteristiche delle due malattie croniche*



Poiché questa suddivisione era assorbita da questa variabile e non ne coinvolgeva altre, si è successivamente operato con k=3 gruppi e, in tal caso, la distinzione era basata anche su tipologia di malattia IBD, durata della terapia e presenza o meno di reazioni avverse e/o effetti collaterali a seguito della somministrazione del trattamento indicato: il primo gruppo è rimasto identico al precedente (44 unità) mentre nel secondo (35 unità) sono stati inseriti soprattutto i pazienti affetti da RCU e trattati con VDZ e nel terzo (29 unità) i pazienti che entro i 10 giorni successivi alla somministrazione di uno dei due trattamenti biologici hanno manifestato determinate reazioni avverse e/o effetti collaterali. Questa suddivisione, come la simulazione precedente, nonostante un maggior numero di variabili del campione, ne trascurava ancora alcune fondamentali ai fini dell'analisi, pertanto è stata effettuata un'ulteriore suddivisione del campione in quattro gruppi. Tale configurazione ha mantenuto invariati i primi due gruppi (rispettivamente composti da 44 e 35 unità) ed ha scisso il terzo in due sottogruppi che, pur condividendo alcuni aspetti precedentemente elencati, si distinguono principalmente per età e malattia IBD (Figura 3).

Mentre nel terzo gruppo, costituito da 11 unità, rientrano i pazienti appena maggiorenni e di età inferiore ai 50 anni, il quarto è formato da 18 unità ed include pazienti di età compresa tra i 50 ed i 70 anni. Da questa scissione è possibile osservare che gli individui più longevi sono tendenzialmente affetti da rettocolite mentre il morbo di Crohn sorge con maggiore facilità sin dalla giovane età.

Figura 3. *Dendrogramma ottimale con Metodo di Ward con linee di taglio per la suddivisione dei cluster*



Tale configurazione finale utilizza tutte le variabili sociali, demografiche e terapeutiche del campione oggetto di analisi che, a seconda del proprio peso, hanno in qualche maniera influenzato la collocazione di ciascun paziente nel gruppo di appartenenza. La suddivisione in 4 sottogruppi consente di rilevare una maggiore dissomiglianza senza ottenere gruppi con un numero di unità eccessivamente ridotto, facendo emergere la presenza di una struttura latente di clustering all'interno dei dati.

Pertanto, per investigare in tale direzione, si è fatto ricorso ad un'analisi a classi latenti (LCA).

Analogamente al caso precedente è stata avviata la procedura per individuare il numero di classi maggiormente idoneo a identificare i profili delle determinanti della salute dei pazienti. La Tabella 3 illustra le diverse informazioni ottenute con i principali criteri di valutazione adottati per un'efficace analisi delle classi latenti

(mentre la Tabella 1 dell'Appendice riporta le 13 variabili dicotomiche incluse nell'analisi LCA). L'indicatore migliore della bontà dell'adattamento del modello ai dati è il criterio di informazione bayesiano (BIC) che, come è noto, al pari degli altri criteri utilizzati, migliora al ridursi del valor assunto: dalla Tabella 3 emerge che il modello con 3 classi si caratterizza per il valore ridotto del BIC mentre gli altri criteri suggeriscono la scelta di altri modelli (l'AIC quello con 4 classi mentre i restanti addirittura quello con 5 classi).

Tabella 3. *Risultati dell'analisi delle classi latenti per le simulazioni dei diversi modelli implementati*

Criteri di adattamento del modello					
MODELLO	LL	AIC	**BIC**	G^2	χ^2
1 Classe	-802,60	1631,21	1766,08	627,14	15027,41
2 Classi	-779,45	1612,89	1704,68	580,83	12814,00
3 Classi	-756,36	1594,72	**1685,31**	534,65	8937,24
4 Classi	-738,98	**1587,96**	1735,47	499,89	8375,51
5 Classi	**-725,42**	1588,84	1773,91	**472,77**	**4390,66**

Nota: in grassetto sono evidenziati i valori più bassi registrati per ciascun criterio, i quali suggeriscono il modello maggiormente idoneo da scegliere

Ad ulteriore conferma della scelta del modello ottimale, è stata anche misurata l'entropia (Muthén, 2008, Celeux and Soromenho, 1996). Tale misura va, comunque, letta in modo sinergico con gli altri parametri per determinare la soluzione di classe finale: la Tabella 4 mostra come tale misura, letta singolarmente, suggerisca di scegliere il modello con sole due classi latenti mentre nel modello precedentemente indicato dal BIC il valore entropico comincia a regredire evidenziando quindi che, seppure il valore dell'entropia sia superiore allo 0,7 (valore ritenuto accettabile), non costituisce la scelta ottimale.

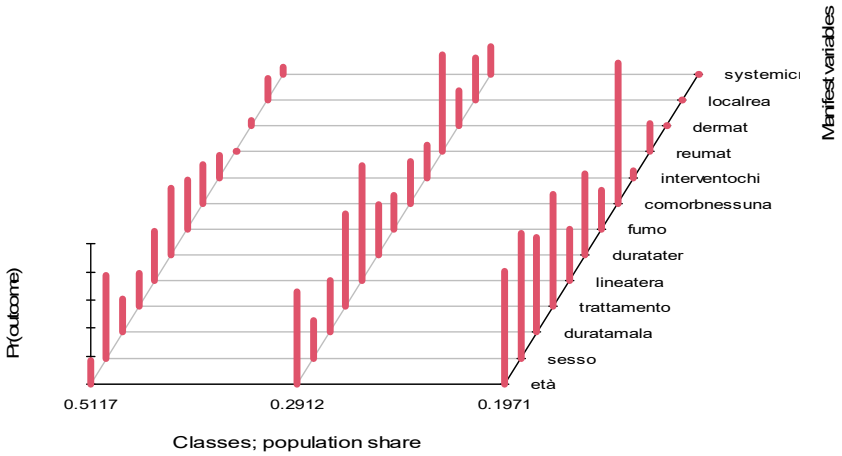
Tabella 4. *Risultati dell'analisi delle classi latenti per diversi modelli mediante l'adozione dei principali criteri diagnostici*

Criteri diagnostici					
Modello	Cluster meno numeroso (N)	Cluster meno numeroso (%)	Entropia	ALCPP	ECPP
1 Classe	108	100,00	/	/	/
2 Classi	31	28,16	**0,722**	0,750	0,718
3 Classi	10	8,63	**0,702**	0,482	0,479
4 Classi	4	3,89	0,685	0,352	0,339
5 Classi	3	2,75	0,678	0,444	0,464

Nota: in grassetto sono evidenziati i valori di entropia più elevati registrati, corrispondenti ai modelli maggiormente idonei per l'analisi.

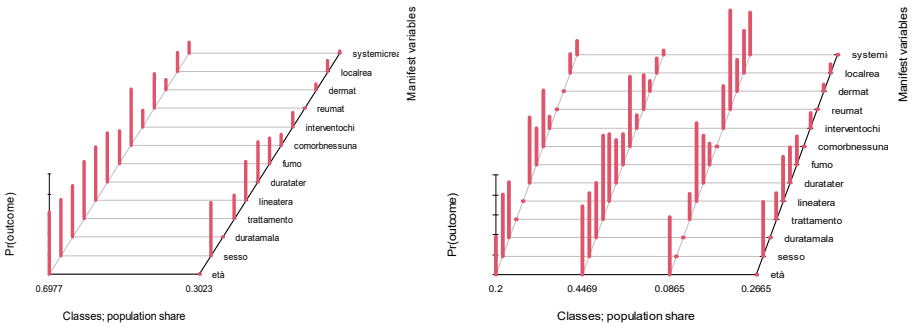
Il modello ottimale indicato dal criterio bayesiano (BIC) è stato rappresentato in Figura 4 per poter apprezzare le probabilità di appartenenza di ciascun paziente a ciascun gruppo latente: ad una maggiore altezza delle barre corrisponde una maggiore possibilità di inclusione nella classe di riferimento.

Figura 4. *Profilo latente delle caratteristiche sociali, demografici e terapeutiche dei pazienti*



Invero, come dimostrato dalla successiva Figura 5, dal modello con due classi suggerito dall'entropia sarebbero emerse informazioni insufficienti mentre nel modello a quattro classi, il numero dei gruppi è superiore a quello ottimale poiché presenta alcuni gruppi con un numero di unità troppo esiguo per essere preso in considerazione. La Figura 4 con 3 classi latenti, ovvero quello indicato dal criterio bayesiano, fornisce invece informazioni più dettagliate: innanzitutto si osserva che nel secondo gruppo sono stati inseriti i pazienti che nel post trattamento hanno manifestato reazioni avverse, come dolori addominali, gonfiore, arrossamento cutaneo ed indurimento articolare, oppure effetti collaterali, tra cui eruzione cutanea, affaticamento, malessere, mal di testa, mialgia e dolori articolari. Inoltre, negli stessi pazienti si rileva una maggiore propensione ad andare incontro alla necessità di uno o più interventi chirurgici. Nel terzo gruppo, meno rappresentativo, si nota invece un elevata correlazione tra malattia IBD e presenza di comorbilità associate: in sintesi, si osserva che alcuni fattori come invecchiamento, consumo di sigaretta, genere e durata della malattia influiscono fortemente sulla condizione del paziente e, di conseguenza, sulla terapia da somministrare. Infine, il primo gruppo latente mostra che i principali fattori che consentono di distinguere le due patologie croniche intestinali sono fondamentalmente quelle descritte negli altri due gruppi.

Figura 5. *Profili latenti dei determinanti sociali, demografici e terapeutici dei pazienti analizzati, entrambi non ottimali ai fini dello studio*



6. Conclusioni

Il presente lavoro ha messo in evidenza come, attraverso l'utilizzo di dati del mondo reale, meglio noti come RWD, e delle evidenze cliniche come solidi supporti decisionali, è possibile sopperire ai limiti specifici dei trial clinici non randomizzati, consentendo una generalizzazione dei risultati ottenuti a tutta la comunità che riceve (o riceverà) il trattamento sanitario oggetto di studio. L'approccio con i RWD si è particolarmente sviluppato in seguito alla disponibilità dei big data sanitari generati dalla digitalizzazione dei dati, fenomeno ancora poco diffuso nel nostro paese.

La vera sfida, di grande prospettiva ed interesse, è quella di conciliare i molteplici benefici della moderna tecnologia con alcuni aspetti metodologici fondamentali come attendibilità dei risultati, sicurezza e privacy.

Tale approccio è stato applicato per l'analisi di dati clinici attraverso un'analisi gerarchica dei gruppi che, a partire dal campione di dati grezzi, ha permesso di creare partizioni annidate che evidenziano le omogeneità di determinate caratteristiche all'interno di ciascuna classe.

Sebbene le procedure di analisi si distinguano per alcuni differenti criteri di applicazione, in tutti i casi è stato possibile individuare caratteri demografici e clinici utili a valutare l'efficacia dei trattamenti delle due malattie infiammatorie croniche intestinali, potendo individuare la gravità della condizione di ciascun paziente, i fattori di rischio di insorgenza delle patologie e le complicanze che interessano diverse aree dell'apparato gastrointestinale e non solo.

Da un punto di vista analitico, si può affermare come il diverso numero di classi ottenuto da ciascun metodo, fino alla scelta di quello ottimale, può rappresentare per il medico un'informazione ulteriore di supporto per la diagnosi e l'individuazione delle linee terapeutiche più appropriate: pertanto, unendo le competenze mediche teorico-pratiche degli specialisti del settore a quelle di esperti di analisi dei dati, come gli statistici, si possono estrarre dai dati informazioni utili per trarre benefici sia per i pazienti, migliorando per quanto possibile la qualità delle loro cure e di vita, sia supportare le decisioni cliniche con metodi quantitativi.

Riferimenti bibliografici

Abernethy, A. (2023) Time for real-world health data to become routine. *Nat Med* 29, 1317 (2023). https://doi.org/10.1038/s41591-023-02337.

Anderson, P., Higgins, V., Courcy, J. de, Doslikova, K., Davis, V. A., Karavali, M., Piercy, J. (2023). Real-world evidence generation from patients, their caregivers and physicians supporting clinical, regulatory and guideline decisions: an update on Disease Specific Programmes. *Current Medical Research and Opinion,* 39(12), 1707–1715. https://doi.org/10.1080/03007995.2023.2279679.

Bernstein, C. N., Rawsthorne P, Cheang M, et al. (2006). A population-based case control study of potential risk factors for IBD. *Am J Gastroenterol* 101(5):993-1002. doi: 10.1111/j.1572-0241.

Cave, A., Kurz, X., Arlett, P. (2019). Real-World Data for Regulatory Decision Making: Challenges and Possible Solutions for Europe. *Clin Pharmacol Ther*. 2019 Jul;106(1):36-39. doi: 10.1002/cpt.1426. Epub 2019 Apr 10. PMID: 30970161; PMCID: PMC6617710.

Castellanos, E. H. et al. (2024) Raising the Bar for Real-World Data in Oncology: Approaches to Quality Across Multiple Dimensions. *JCO Clinical Cancer Informatics*, 8, e2300046(2024). DOI:10.1200/CCI.23.00046.

Celeux, G., Soromenho, G. (1996). An entropy criterion for assessing the number of clusters in a mixture model. *Journal of Classification*, 13(2), 195-212. https://doi.org/10.1007/BF01246098.

Delvecchio, F. (2024). Statistica per lo studio dei fenomeni sociali. (Cap. XII, pp.257-284). Cleup sc. Padova

Dulai, P.S., Singh, S., Vande Casteele, N., et al (2019) Should we divide Crohn's disease into ileum-dominant and isolated colonic diseases? *Clin Gastroenterol Hepatol* 17(13):2634-2643, doi: 10.1016/j.cgh.2019.04.040.

European Medicine Agency - EMA (2020). Regulatory Science to 2025 - Strategic reflection.pdf.

Finch, H. (2005) Comparison of distance measures in cluster analysis with dichotomous data. *Journal of Data Science*. 2005; 3:85–100.

Fumery, M., Dulai, P.S., Meirick, P., et al. (2017) Systematic review with meta-analysis: recurrence of Crohn's disease after total colectomy with permanent ileostomy. *Aliment Pharmacol Ther* 45(3):381-390. doi: 10.1111/apt.13886.

Gower, J. (1971). A general coefficient of similarity and some of its properties. *Biometrics*, 27, 857–871.

Hagenaars, J. A., McCutcheon, A. L. (2002). *Applied latent class analysis*. Cambridge University Press.

Hou, J., Yuan, H., Pelillo, M. (2023) Towards Parameter-Free Clustering for Real-World Data, *Pattern Recognition,* 134, 2023, 109062, https://doi.org/10.1016/j.patcog.2022.109062.

Linzer, D. A., Lewis, J. (2011). poLCA: Polytomous variable latent class analysis (R package version 1.1) [Computer software]. Emory Universit http://finzi.psych.upenn.edu/library/poLCA/doc/poLCA-manual-1-4.pdf

Lynch, H.T., Brand, R.E., Locker, G.Y. (2004) Inflammatory bowel disease in Ashkenazi Jews: implications for familial colorectal cancer. *Familial Cancer,* 2004;3(3-4); pp. 229-32.

Lythgoe, D. T., Garcia-Fiñana, M., Cox, T. F. (2019). Latent class modeling with a time-to-event distal outcome: A comparison of one, two and three-step approaches. *Structural Equation Modeling: A Multidisciplinary Journal*, 26(1), 51-65. https://doi.org/10.1080/10705511.2018.1495081.

McCutcheon, A.L. *Latent class analysis*. Sage; Newbury Park, CA: 1987.

Murthy, N., Patricia Wodi, A., Cineas, S. et al. (2023). Recommended adult immunization schedule, United States, 2023. *Ann Intern Med* 176:367-380, 2023. doi: 10.7326/M23-0041.

Muthén, B. O. (2008). What is a good value of entropy? http://www.statmodel.com/discussion/messages. https://doi.org/10.1080/10705510701575396.

Ostlund, U., Kidd, L., Wengstrom, Y, Rowa-Dewar, N. (2011) Combining qualitative and quantitative research within mixed method research designs: A methodological review. *International Journal of Nursing Studies*. 48:369–383. doi: 10.1016/j.ijnurstu.2010.10.005.

R Core Team. (2023). R: A Language and Environment for Statistical Computing [Computer software manual]. Vienna, Austria. Retrieved from https://www.R-project.org/.

Rosato, N. S., Baer, J. C. (2012). Latent class analysis: A method for capturing heterogeneity. *Social Work Research*, 36(1), 61-70. https://doi.org/10.1093/swr/svs006.

Schreiber, J. (2017). Latent class analysis: An example for reporting results. *Research in Social and Administrative Pharmacy,* 13(6), 1196-1201. https://doi.org/10.1016/j.sapharm.2016.11.011

Vermunt, JK.; Magidson, J. (1999) Exploratory latent class cluster, factor, and regression analysis: the Latent GOLD approach. Paper presented at the Proceedings EMPS_99 conference, Lueneburg, Germany. 1999.

Sitografia

https://www.ema.europa.eu/en/
https://www.aboutpharma.com/scienza-ricerca/la-ricerca-di-valore-deve-integrare-i-real-world-data/
https://www.jsb-solutions.com/blog-posts/i-quattro-pilastri-della-real-world-evidence/
https://gemelligenerator.it/it/facilities/real-world-data/
https://phdlifescience.eu/real-world-evidence-la-sfida-italiana/
https://www.agendadigitale.eu/sanita/real-world-data-nuovi-orizzonti-per-il-trattamento-dei-dati-in-sanita/
https://www.humanitas.it/unita-operative/malattie-infiammatorie-croniche-dell-intestino/
https://www.farmacovigilanza.unina2.it:vedolizumab-il-primo-farmaco-biotecnologico-a-selettivita-intestinale-oggi-disponibile-in-italia
https://www.aifa.gov.it/-/vedolizumab-come-terapia-per-la-colite-ulcerosa
https://www.igibdscores.it/it/info-mayo-partial.php
https://www.igibdscores.it/it/score-hbi.php

APPENDICE

Tabella 1. *Caratteristiche del campione di pazienti pugliesi affetti da patologie infiammatorie croniche intestinali (di età compresa tra 20 e 77 anni) (N=108, variabili dicotomiche o dicotomizzate*)*

VARIABILE	Numero di pazienti	(% ponderata)
Età:		
<44 anni (media)	61	(56,5%)
>44 anni (media)	47	(43,5%)
Genere:		
Femmina	48	(44,4%)
Maschio	60	(55,6%)
Durata malattia in anni:		
<15 (media aritmetica)	69	(63,9%)
>15 (media aritmetica)	39	(36,1%)
Trattamento:		
IFX	57	(52,8%)
VDZ	51	(47,2%)
Linea terapeutica:		
Primo trattamento ricevuto	55	(50,9%)
Pazienti precedentemente trattati con altri farmaci	53	(49,1%)
Durata terapia in mesi:		
<39 (media)	58	(53,7%)
>39 (media)	50	(46,3%)
Consumo di sigarette:		
No	75	(69,4%)
Sì	33	(30,6%)
Comorbilità associate:		
No	62	(57,4%)
Sì	46	(42,6%)
Intervento chirurgico:		
No	91	(84,3%)
Sì	17	(15,7%)
Patologie reumatologiche:		
No	82	(75,9%)
Sì	26	(24,1%)
Patologie dermatologiche:		
No	98	(90,7%)
Sì	10	(9,3%)
Reazioni avverse (dopo assunzione farmaco):		
No	90	(83,3%)
Sì	18	(16,7%)
Effetti collaterali (dopo assunzione farmaco):		
No	99	(91,7%)
Sì	9	(8,3%)

**NB: Per le tre variabili quantitative sono state calcolate le medie aritmetica e non la mediana*

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 193-204

Misurare l'efficacia dei messaggi pubblicitari sui social media. Il caso della pandemia in Italia

Angela Maria D'Uggento[1], Claudia Marin[2]*, Albino Biafora[3] Margaret Antonicelli[4], Barbara Cafarelli[5]

[1]Dipartimento di Economia e Finanza, Università degli Studi di Bari Aldo Moro, [2]Dipartimento di Scienze della Formazione, Psicologia, Comunicazione, Università degli Studi di Bari Aldo Moro, [4]Department of Humanistic Studies, Faculty of Communication, IULM University, Milano, [5]Dipartimento di Economia, Management e Territorio, Università di Foggia.

Riassunto: Negli ultimi anni i ricercatori si sono sempre più interessati ai social media come preziosa fonte di dati per rilevare e analizzare le opinioni delle persone su vari argomenti. In occasione di eventi estremi, ad esempio, gli utenti della rete possono diffondere rapidamente informazioni e opinioni online, generando un impatto che può avere implicazioni sia positive che negative sulla percezione del fenomeno collettivo. Twitter è una delle piattaforme che consente alle persone di informarsi su eventi e fatti in tutto il mondo, comprese le epidemie, ed esprimere le proprie reazioni. Pertanto, i social media possono essere utilizzati da governi, aziende e altre organizzazioni per conoscere il sentiment della collettività e interagire con messaggi istituzionali o supporto emotivo. Durante la pandemia di Covid-19, molte aziende hanno utilizzato spot televisivi per infondere fiducia e speranza negli individui, in particolare nelle famiglie, promuovendo solidarietà e fratellanza, mantenendo il marchio in secondo piano. Questo articolo si propone di definire una metrica di valutazione per misurare l'efficacia del cambiamento pubblicitario di grandi marchi, utilizzando un corpus di 20.982 tweet e indicatori creati sulla base dei risultati ottenuti dall'analisi del sentiment. I nostri risultati suggeriscono che gli utenti di internet hanno sperimentato un senso di appartenenza e apprezzamento durante il lockdown, oltre a un atteggiamento positivo verso la pubblicità televisiva, precedentemente percepita come invasiva.

Keywords: analisi del sentiment, consapevolezza del brand, pandemia di Covid-19, social media.

* Autore corrispondente: claudia.marin@uniba.it

1. Introduzione

Nel 2020, il mondo ha vissuto una pandemia senza precedenti che ha cambiato radicalmente il modo in cui le persone vivevano, lavoravano, studiavano e trascorrevano il tempo libero. L'impatto economico e sociale dell'epidemia è stato devastante, causando perdita di posti di lavoro, aumento delle disuguaglianze e disagi notevoli in molti settori. Le aziende sono state costrette ad adottare nuove strategie per sopravvivere, modificando i loro processi lavorativi, riorganizzando i canali di comunicazione e anche offrendo servizi logistici alternativi.

L'epidemia di Coronavirus ha creato una situazione critica non solo dal punto di vista medico, ma anche sociale, poiché la pandemia ha avuto, fra l'altro, un impatto significativo sull'isolamento delle persone. I social media sono diventati parte integrante della vita quotidiana, offrendo nuovi modi per connettersi e comunicare [Basile et al., 2022]. In Italia, l'uso dei social media è aumentato del 21% dopo l'inizio del lockdown nel 2020 rispetto alla fine del 2019 [Basile et al., 2022], posizionando il Paese al secondo posto tra gli utilizzatori dopo la Spagna, dove l'aumento è stato del 48% [Pang and Lee, 2008].

Con l'obiettivo comune di rispettare la sensibilità di chi ha perso improvvisamente una persona cara e aumentare l'empatia con i clienti in un momento di dolore collettivo, le aziende hanno adottato diverse strategie di marketing a seconda del tipo di prodotti venduti. Le imprese, che solitamente investivano ingenti somme nella pubblicità per rafforzare l'immagine e la consapevolezza del marchio, hanno modificato il contenuto degli spot televisivi per trasmettere messaggi di fratellanza e speranza.

La consapevolezza pubblicitaria di un marchio riguarda le tracce che rimangono nella memoria dei consumatori [Tsytsarau and Palpanas, 2012]. In particolare, essa si riferisce alla capacità dei consumatori di ricordare o riconoscere un marchio [Hu et al., 2013], o alla semplice conoscenza dell'esistenza di un brand. Inoltre, è legata all'identificazione con un'azienda e influisce sull'impatto della pubblicità sulle reazioni e percezioni dei consumatori [Bhattacharya and Sen, 2003].

I nuovi paradigmi degli spot televisivi introdotti durante la pandemia miravano a suscitare sia risposte affettive che cognitive nei destinatari. Le prime riguardano l'attaccamento sentimentale a un prodotto, le seconde la percezione e la memorizzazione del contenuto pubblicitario associato al marchio. La risposta cognitiva può essere utilizzata per misurare l'efficacia di una campagna pubblicitaria, valutando la sua capacità di impressionare il pubblico, essere compresa e ricordata [15].

Gli indicatori più importanti per misurare l'efficacia della comunicazione includono il riconoscimento, il richiamo e la consapevolezza. Maggiore è la capacità di un marchio di essere immediatamente menzionato, più forte sarà la sua presenza nella memoria dei consumatori, massimizzando il "brand lift", ovvero l'aumento della percezione e consapevolezza di un prodotto o marchio nel tempo.

Durante la pandemia, il comportamento quotidiano dei cittadini di tutto il mondo è cambiato, così come il rapporto tra consumatori e brand. I consumatori hanno modificato le loro abitudini di acquisto, preferendo lo shopping online a causa del lockdown: le cene al ristorante sono state sostituite da consegne a domicilio, gli acquisti nei negozi da frequenti acquisti su e-commerce e i rapporti faccia a faccia da videochiamate e interazioni sui social media.

Le aziende e i marchi hanno dovuto ripensare sia le loro tecniche di vendita che il modo di fare pubblicità per attrarre il pubblico in un contesto economico così critico. Durante il lockdown, messaggi di incoraggiamento e vicinanza sono stati trasmessi in tutte le comunicazioni, anche pubblicitarie, enfatizzando valori come l'amore, la famiglia e la solidarietà tra le persone.

Alcune note aziende italiane hanno lanciato campagne pubblicitarie mirate al momento sociale corrente, trasmettendo messaggi di connessione tramite videochiamate, internet e intrattenimento a distanza. Anche le case automobilistiche hanno seguito questa direzione, come FCA con lo spot "Inno alla casa" e Volkswagen con l'hashtag #IoRestoInGarage. Brand di cosmetici e make-up hanno introdotto hashtag positivi come "#torneràilsorriso", accompagnati da canzoni nostalgiche e immagini di momenti felici pre-pandemia.

Questo studio analizza l'impatto del cambiamento del paradigma pubblicitario di alcuni noti brand nei settori alimentare e dei beni di consumo durante il lockdown italiano iniziale (febbraio-maggio 2020). Per raggiungere questo obiettivo sono state utilizzate tecniche di analisi del sentiment [Aggarwal and Zhai, 2002] per analizzare un vasto numero di tweet italiani raccolti online, integrando i metodi tradizionali con tecniche di analisi avanzate per valutare la capacità della pubblicità di catturare l'attenzione dei clienti.

2. Materiali e metodi

2.1 L'analisi del sentiment

L'analisi del sentiment (Sentiment Analysis, SA) è una tecnica di text mining che mira a estrarre informazioni basate sulle opinioni e a rilevare il "sentimento" pre-

sente nei testi [Pang and Lee, 2008]. Comprende una vasta gamma di tecniche, tra cui l'analisi testuale, l'estrazione di pattern e cifre stilistiche, la classificazione dei documenti, il clustering, la visualizzazione, il data mining e il machine learning [Dang and Ahmad, 2015; Aggarwal and Zhai, 2012]. In particolare, la SA è un'area di ricerca attiva nel campo dell'elaborazione del linguaggio naturale (Natural Language Processing, NLP), che utilizza pensieri, opinioni, emozioni, valutazioni, impressioni e atteggiamenti delle persone che possono essere inserite come variabili nei modelli predittivi. Grazie alla rilevanza dei social media come piattaforma di espressione, la SA trova applicazioni in ambiti economici, sociali, aziendali e di ricerca, analizzando l'enorme quantità di dati testuali disponibili online.

La SA può essere applicata su qualsiasi tipo di testo trovato in rete, sia esso strutturato o non strutturato, utilizzando approcci lessicografici o algoritmi di machine learning. L'approccio lessicografico si basa sull'analisi del punteggio di sentiment di un documento attraverso un lessico predefinito, mentre gli algoritmi di machine learning, che utilizzano metodi di classificazione supervisionata e modelli di deep learning, identificano contenuti emotivi in modo più complesso. Ricercatori autori di interessanti studi, utili per approfondire i metodi della SA, sono Liu e Zhang (2012), Tsytsarau e Palpanas (2012) e Giachanou e Crestani (2016).

2.2 Principali approcci per l'analisi del sentiment

L'approccio lessicografico, basato su tecniche di classificazione non supervisionata, analizza la polarità semantica delle parole per determinare il sentiment globale di frasi e documenti. Ogni parola nel lessico riceve un indice positivo o negativo, combinato, poi, per produrre un indice di sentiment complessivo. Questo approccio è particolarmente utile per testi tradizionali (blog, forum, recensioni di prodotti), ma meno efficace con i contenuti brevi e colloquiali di Twitter. Tra gli strumenti più utilizzati troviamo SentiStrength, migliorato da Thelwall et al. nel 2010 e 2012, e SentiCircles [Saif et al., 2016], che integra l'analisi del contesto delle parole.

Gli approcci di machine learning, distinti in apprendimento supervisionato e non supervisionato, utilizzano algoritmi di intelligenza artificiale per risolvere problemi di classificazione. Nel caso supervisionato, il sistema apprende da un set di dati etichettati; nell'approccio non supervisionato, il sistema identifica modelli comuni nei dati non etichettati.

L'approccio basato su grafi utilizza la co-occorrenza degli hashtag per classificare i sentimenti associati. È utile in assenza di dati etichettati e si basa sull'assunzione che le persone siano in grado di influenzare i sentimenti collettivi.

Le tecniche di propagazione delle etichette sono utilizzate per costruire grafi di connessione a partire da tweet, n-gram e hashtag.

Indipendentemente dall'approccio scelto, la SA permette alle aziende di comprendere il sentiment dei clienti verso prodotti, marchi o servizi, espresso nei loro feedback. Queste opinioni, raccolte tramite tweet, recensioni, email, chat e altre interazioni, rappresentano un prezioso patrimonio di conoscenza che può essere trasformato in un vantaggio competitivo per i proprietari del dato. Analizzando correttamente tali dati, le aziende possono adattare prodotti, strutture o strategie pubblicitarie alle esigenze dei consumatori.

Modelli statistici di SA valutano popolarità (positiva, negativa o neutrale), emozioni (gioia, rabbia, tristezza, ecc.) e livelli di interesse nel tempo, osservando l'effetto di nuovi prodotti o comunicati stampa sul sentiment. Inoltre, analisi in tempo reale permettono di identificare rapidamente problemi sui social media e di reagire immediatamente alle emozioni dei clienti, migliorando il rapporto tra consumatori e brand.

2.3. Fonte dei dati e preparazione

Dal suo lancio nel 2006, Twitter ha registrato una crescita esponenziale nella sua base di utenti, grazie alla sua facilità di accesso e alla capacità di caricare, pubblicare e scaricare rapidamente commenti degli utenti. È diventato uno dei più grandi archivi di dati generati dagli utenti, alimentato dall'uso di Internet e dei social network come principali strumenti di comunicazione nella vita quotidiana.

In questo studio, ci proponiamo di analizzare le opinioni degli utenti e di evidenziarne i temi principali.

Inoltre, la Twitter Sentiment Analysis (TSA), una sottocategoria dell'Analisi del Sentiment, è stata sviluppata per valutare gli stati emotivi espressi nei tweet.

Tuttavia, i tweet presentano spesso un linguaggio più informale rispetto a pagine web, blog o articoli di notizie, caratterizzato da maiuscole, parole allungate, abbreviazioni, gergo e neologismi. Tutte queste peculiarità devono essere considerate durante il processo di tokenizzazione, una fase di pulizia o filtraggio che mira a eliminare elementi irrilevanti per la classificazione. Questo passaggio riduce gli errori e rende il processo più efficiente. La tokenizzazione consiste nello "scomporre" un testo in unità più piccole, chiamate token. In questa fase, è fondamentale eliminare i cosiddetti "elementi inquinanti" senza alterare il significato del testo. Tra questi elementi rientrano: URL (ad esempio, http://...), etichette come RT (retweet), menzioni e hashtag (@, #), punteggiatura, spazi extra e numeri.

Per identificare il sentiment nei tweet raccolti, sono stati creati due distinti lessici: uno per i termini positivi e uno per quelli negativi [Kiritchenko et al., 2014]. Per l'acquisizione dei tweet, la formazione del dataset e il successivo pre-processing è stato utilizzato il linguaggio di programmazione Python.

Sebbene esistano diverse librerie Python per l'estrazione diretta di tweet, non tutte consentono di recuperare tweet più datati. A tal fine, è stata impiegata la libreria GetOldTweets3, che ha permesso di estrarre tweet dal 1° gennaio 2020 al 30 giugno 2020, utilizzando una lista di parole chiave correlate allo scopo dello studio come query di ricerca.

La lista di parole chiave è stata generata includendo nomi di marchi presenti nelle pubblicità, hashtag associati e termini più generali come "spot TV" o "spot pubblicitario coronavirus" (vedi Tabella 1 per l'elenco completo).

Sono stati raccolti i seguenti campi: data del tweet, ID del tweet, contenuto originale, parola chiave utilizzata per l'estrazione e tag di riferimento.

Il dataset finale, codificato in formato .csv con UTF-8, includeva 20.982 tweet in lingua italiana, etichettati in base a tre intervalli temporali predefiniti:

– prima del lockdown (01/01/2020 - 08/03/2020);
– durante il lockdown (09/03/2020 - 03/05/2020, "fase 1");
– dopo il lockdown (04/05/2020 - 30/06/2020).

I tweet sono stati sottoposti a pre-processing per rimuovere stop word e altri elementi irrilevanti. Il testo pulito, combinato con i metadati (ID, data e ora, parola chiave, tag di riferimento e periodo temporale), ha formato il corpus di testo utilizzato per lo studio.

Per quantificare il sentiment nei commenti dei consumatori sugli spot televisivi dei brand su Twitter, è stato utilizzato il **lessico openER** [Russo et al., 2016]. Questo strumento assegna a ciascun termine una polarità (negativa, positiva o neutra) e un indice associato. Il processo di polarizzazione dei tweet avviene tramite una funzione automatizzata denominata **"search"**, che, dato un argomento di ricerca come input (ad esempio un nome, un hashtag o un utente), genera automaticamente un dataset e fornisce i seguenti output:

1. **File .csv (_stack.csv):** include tutti i dati originali del dataset di partenza, preservandoli per eventuali analisi future.
2. **File .csv (_score.csv):** attribuisce un punteggio a ciascun tweet; tali punteggi sono utili nella fase di analisi delle correlazioni.
3. **File .csv (_opin.csv):** assegna una polarità (positiva/negativa/neutral) a ciascun tweet.

4. **Grafico scatterplot:** visualizza la polarità dei tweet in relazione a un trend storico di riferimento.

La classificazione dei tweet si basa su un sistema di pesatura o di assegnazione di punteggi. Ogni tweet, dopo essere stato sottoposto al processo di pulizia, viene suddiviso in un vettore di singole parole, ognuna delle quali rappresenta un'entità indipendente.

Per avviare questo tipo di analisi, è fondamentale definire un **lessico**, ovvero un tipo di dizionario che include termini della lingua italiana associati a un livello di positività, negatività o neutralità. Questo elenco è particolarmente utile poiché la maggior parte dei programmi di analisi del sentiment è progettata per analizzare testi in lingua inglese.

Durante l'analisi del sentiment basata su un lessico, vengono generalmente applicate funzioni di combinazione, come somma o media, per ciascun documento, tenendo conto del contesto locale delle parole, ad esempio la presenza di negazioni o intensificazioni.

I dati sono stati elaborati con i linguaggi di programmazione Python e R Studio.

3. Risultati

Per comprendere come sia effettivamente cambiata la percezione dei messaggi televisivi è stato effettuato uno studio sulla frequenza dei tweet nel periodo di tempo analizzato.

Un grafico molto intuitivo comunemente utilizzato in tali casi è la wordcloud, che consente una immediata esplorazione delle parole presenti con maggior frequenta nel testo analizzato.

La Figura 1 illustra la frequenza dei 100 termini più utilizzati nei Tweet di commento alle pubblicità durante la pandemia.

Figura 1. *Wordcloud dei 100 termini più frequentemente utilizzati nel periodo di osservazione*



La Figura 2 è, invece, riferita ai tweet del giorno 7 maggio 2020, in cui sono state scritte esattamente 32.496 parole, l'89% delle quali sono state categorizzate come relative al brand Lavazza. L'hashtag #Lavazza quel giorno ha raggiunto infatti la terza posizione tra le tendenze su Twitter in Italia (c.d. Trending Topic). La wordcloud in Fig. XX mostra le 50 parole più frequenti associate al brand Lavazza.

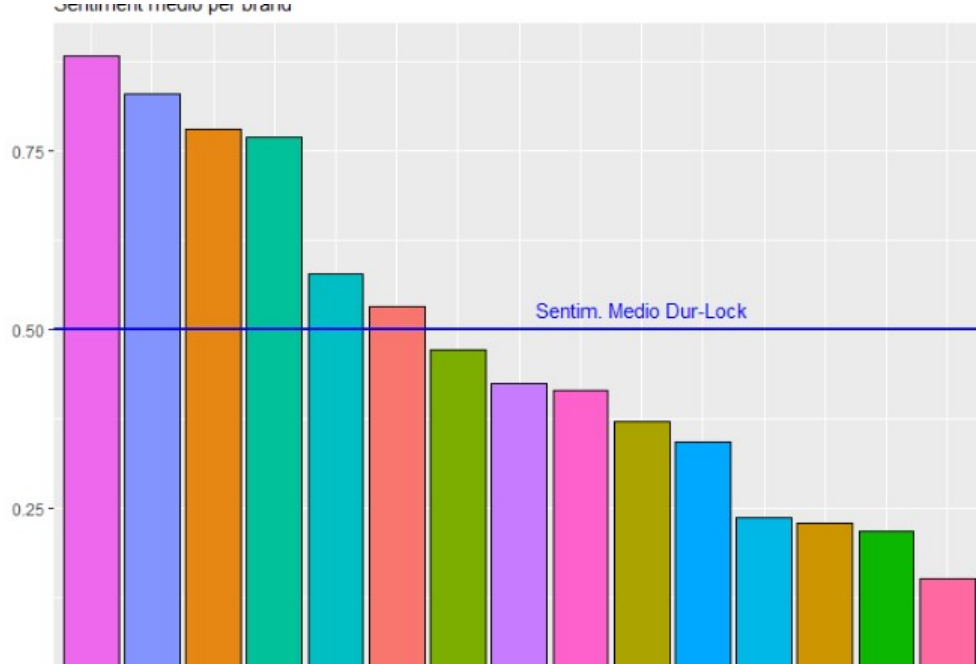
Figura 2. *WordCloud spot Lavazza nei tweet del 7 maggio 2020*



Le parole più utilizzate riguardano molti aggettivi positivi come: "bello/bella", "grande" e "bellissimo" ed altre parole di polarità negativa come "fascisti". La parola più legata al Brand è Charlie Chaplin, protagonista assoluto dello spot con il suo discorso sull'umanità, tratto dal celebre film "Il Grande Dittatore". Per comprendere la wordcloud è utile sintetizzare il contenuto dello spot Lavazza. Tale pubblicità ha suscitato ampio dibattito sui media, riscuotendo sia apprezzamento, in quanto ha suscitato sentimenti positivi per la comunità durante la crisi, ma attirando anche molte critiche perchè considerato cinicamente opportunista. In particolare, alcuni tweet hanno anche evidenziato il passaggio di Lavazza dalla clip comica nazional-popolare al messaggio emozionale sul progresso dell'umanità, evidenziando proprio il cambio di paradigma nella struttura del messaggio.

L'analisi che prende in considerazione i marchi più "twittati" può risultare interessante per comprendere quale brand abbia generato opinioni positive o negative durante il periodo del lockdown. A tale scopo è stato sommato lo score di ogni tweet riferito ad un determinato brand per poi dividere il risultato per il numero di tweet di quel brand. Si è così ottenuto il sentiment medio per brand, rappresentato in Figura 3.

Figura 3. *BarPlot del Sentiment medio per brand*



È evidente come nessun brand abbia ricevuto mediamente opinioni negative, mentre quelle positive mostrano punteggi differenziati, da quelli relativi agli spot Esselunga e WindTre, a quelli degli spot Toyota, MulinoBianco, Bauli e Famila che hanno raggiunto uno score medio di 0.75 In cima alla lista si collocano, quindi, i brand che, attraverso una scelta strategica di cambiamento del metodo di approccio negli spot pubblicitari televisivi, hanno creato maggiornamente opinioni positive sul social network Twitter.

4. Conclusioni

I primi risultati di questo studio evidenziano come il ruolo assunto dai social media nella quotidianità delle persone li abbia, di fatto, inseriti tra gli strumenti con i quali è possibile misurare l'efficacia di una campagna pubblicitaria, integrando, o in alcuni casi sostituendo, quelli tradizionali.

La pandemia è stato un evento devastante, sconosciuto e del tutto inaspettato. Durante il lockdown, con le stesse immagini terrificanti che provenivano da tutto il mondo, è stato fondamentale contrastare lo sconcerto e trasmettere fiducia e speranza. Il messaggio delle istituzioni italiane "andrà tutto bene" era onnipresente.

Le aziende hanno fatto la loro parte in quanto operatori del sistema economico.

I format tradizionali degli spot sono stati inevitabilmente adattati, suscitando reazioni nei consumatori che, in questo studio, si è cercato di misurare attraverso l'aumento del numero di tweet, il loro contenuto e le attività digitali quotidiane. I risultati delle analisi confermano che i consumatori hanno notato e apprezzato il fatto che i grandi marchi abbiano modificato la loro strategia comunicativa durante la pandemia, contribuendo, con i loro spot televisivi, a diffondere messaggi di speranza e sui principi di solidarietà.

Le tecniche dell'analisi testuale consente ai ricercatori di gestire l'esigenza di automatizzare la comprensione di dati testuali non strutturati, non solo provenienti da libri e giornali, ma anche da poster, blog, recensioni dei clienti su Internet e post sui social media.

Il presente studio si concentra su un corpus specifico di dati non strutturati, trasformandoli opportunamente per effettuare analisi di text mining e identificare pattern.

Dopo una fase accurata di estrazione e pre-elaborazione dei tweet con algoritmi di elaborazione del linguaggio naturale, è stato creato un dataset composto da

20.982 tweet analizzati in tre periodi distinti: prima del lockdown, durante il lockdown e dopo il lockdown.

La novità degli approcci pubblicitari dei brand sembra aver evocato, soprattutto durante il lockdown, un senso di gratitudine e appartenenza, meno evidente negli altri due periodi. In questi ultimi, infatti, i tweet si sono concentrati principalmente sui prodotti dei brand o su elementi percepiti come fastidiosi.

Per le ricerche future, ci si propone di affrontare i limiti imposti dai dizionari lessicali e dalle librerie computazionali (sia in R che in Python), abbondanti per la lingua inglese ma spesso inadeguate o incomplete per l'italiano.

La traduzione dei corpora italiani in inglese non è un compito semplice: richiede un lavoro preparatorio complesso, tra cui lo sviluppo di una funzione specifica di somiglianza tra stringhe, basata su un lessico composto esclusivamente da forme regolari delle parole. Inoltre, la coniugazione dei verbi rappresenta una discrepanza significativa.

L'analisi dei bigrammi e delle co-occorrenze potrebbe migliorare la costruzione di un lessico italiano adeguato e, alla luce degli obiettivi di questo studio, facilitare l'identificazione degli spot più efficaci e delle loro caratteristiche distintive.

Riferimenti bibliografici

Aggarwal C.C., Zhai C. (2012). Mining Text Data. Springer Nature. doi:10.1007/978-1-4614-3223-4.

Basile, V. Misuraca M., Spano M. (2022). Thematic analysis on online education issues during COVID-19. In: SIS2022 51st Scientific Meeting of the Italian Statistical Society. Book of the Short Papers, Balzanella A., Bini M., Cavicchia, C. Verde, R. (eds) pp. 437-445. Pearson.

Bhattacharya C.B., Sen S. (2003). Consumer– company identification: A framework for understanding consumers' relationships with companies. Journal of Marketing, 67(2), 76-88.

Dang S., Ahmad P.H. (2015). A Review of Text Mining Techniques Associated with Various Application Areas. Int J Sci Res (IJSR), 4(2), 2461-2466.

Giachanou A., Crestani F. (2016). Like it or not: a survey of Twitter Sentiment analysis methods. ACM Comput. Surv, 49(2):Article 28. doi:10.1145/2938640.

Hu X., Tang J., Gao H., Liu H. (2013). Unsupervised sentiment analysis with emotional signals. In Proceedings of the International World Wide Web Conference, pages 607–618.

Kiritchenko S., Zhu X., Mohammad S. M. (2014). Sentiment analysis of short in-

formal texts. J. Artif. Intell. Res., 50, 723–762. doi:10.1613/jair.4272.

Liu, B., Zhang L. (2012). A Survey of Opinion Mining and Sentiment Analysis. In Aggarwal C. and Zhai C. editors, Mining Text Data, Springer Nature, pp. 415-463.

Pang B., Lee L. (2008). Opinion mining and sentiment analysis. Foundation and Trends in Information Retrieval, 2(1-2), 1-135, doi:10.1561/15000000011.

Russo I. et al. (2016). OpeNER Sentiment Lexicon Italian - LMF, ILC-CNR for CLARIN-IT repository hosted at Institute for Computational Linguistics "A. Zampolli", National Research Council (CNR), Pisa. http://hdl.handle.net/20.500.11752/ILC-73.

Saif H., Bashevoy M., Taylor S., Fernandez M., Alani H. (2016). A Platform for Contextual and Conceptual Sentiment Analysis. Extended Semantic Web Conference.

Thelwall M., Buckley K., Paltoglou G., Cai D., Kappas, A. (2010), Sentiment strength detection in short informal text. J. Am. Soc. Inf. Sci., 61: 2544-2558. https://doi.org/10.1002/asi.21416.

Thelwall M., Buckley K., Paltoglou G. (2012), Sentiment strength detection for the social web1. Computer Science.

Tsytsarau M., Palpanas T. (2012). Survey on mining subjective data on the web. Data Min Knowl Disc 24(3):478-514. doi:10.1007/s10618-011-0238-6.

Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 205-220

Ramificazioni delle famiglie di curve di concentrazione *L(p)* ad una famiglia di archi di una Superellisse al variare dei parametri β e δ

Domenico Viola[1]*, Alessandro Rinaldi[2]

[1] *Dipartimento di Economia e Management e Diritto dell'Impresa*
[2] *Dottore di ricerca in Statistica, Università degli Studi di Bari Aldo Moro*

Astratto: La curva di concentrazione rappresenta il rapporto tra le frazioni relative cumulative di unità statistiche e le frazioni relative cumulative di intensità di un fenomeno trasferibile tra unità statistiche. In questo articolo la curva di Lorenz L(p) considerando il caso del modello di Dagum di tipo I dipendente da tre parametri, verrà studiata attraverso un approccio teorico matematico idealmente approssimabile ad un arco appartenente ad una particolare tipologia di supercerchi o squircle definiti per l'appunto "superellisse". Dallo studio di tale curva sarà possibile studiare tutte le possibili ramificazioni che la curva di Lorenz L(p) può assumere nell'ambito del primo quadrante di una superellisse o Supershape al variare dei parametri β e δ in maniera tale da poter dimostrare come una famiglia di curve di Lorenz sia in grado di rappresentare tutte le possibili ramificazioni di archi appartenenti ad una Supershape definita anche Squircle.

Parole chiave: curva di Lorenz; Superellisse; Squircle.

1. Introduzione

Lo strumento grafico che viene maggiormente utilizzato e impiegato per rappresentare la concentrazione e la distribuzione dei redditi è senza dubbio il diagramma di Lorenz, ma non solo per i redditi, difatti il grafico può anche essere

* Autore corrispondente: domenico.viola@uniba.it .
Il lavoro qui descritto è frutto di un progetto comune attribuibile in parti uguali ai due coautori.

utilizzato per mostrare la distribuzione del benessere, della ricchezza e delle risorse. In tale utilizzo, molti economisti lo considerano una misura della disuguaglianza totale. Il suo andamento è fortemente condizionato dal fatto di essere una curva crescente, convessa e di dover necessariamente toccare i punti di coordinate (0,0) e (1,1). Tale caratteristica purtroppo ne limita la capacità descrittiva soprattutto quando si parla di analisi della concentrazione da un punto di vista meramente puntuale (Zenga 1984, Dancelli 1989). Nel tempo sono state proposte curve di concentrazione alternative come quella Z(p) che individua nel piano cartesiano i punti (p, Z(p)) essendo:

$$Z(p) = \frac{x^*(p) - x(p)}{x^*(p)} = 1 - R(p) \quad p \in [0,1] \qquad [1]$$

dove $x^*(p)\ e\ x(p)$ rappresentano rispettivamente il quantile della popolazione e quello del reddito mentre R(p)= $x^*(p)/x(p)$ (Zenga,1984) indica l'indice di concentrazione. Zenga ha inoltre analizzato due successivi indici di concentrazione ovvero ζ (che rappresenta il valore medio di Z(p) (Zenga,1984) analizzando in maniera comparativa l'andamento della funzione Z(p) a cui ζ è correlato e quello di funzioni su cui si fondano altri indici di concentrazione fra cui vi è il famoso indice di Gini associato alla curva di Lorenz *L(p)* (Dancelli,1989).

Nel presente elaborato si focalizzerà però maggiormente l'attenzione sulla curva di Lorenz L(p).

La curva di Lorenz viene utilizzata per rappresentare graficamente la relazione stabilita tra le frazioni relative cumulative di intensità[1] $q_i=A_i/A_s$ posseduto dalle rispettive frazioni relative cumulative di unità statistiche $p_i=n_i/N$.

Se N→∞ i punti (p_i, q_i) per i quali passa la sezione di concentrazione diventano sempre più vicini tra loro, fino a quando la suddivisione assume la forma di una vera e propria curva. In questo modo si ottiene la cosiddetta "curva di Lorenz", che può assumere diverse ramificazioni a seconda di come il fenomeno risulti più o meno concentrato Fig. 1 (Cusatelli, Gallo, Rinaldi, 2021).

Il modello a 3 parametri per la distribuzione personale dei redditi indicato da C. Dagum nel 1977 (Dagum 1977, 1980; Fattorini-Lemmi,1979; Lemmi 1987; Dagum-Lemmi 1987) è caratterizzato dalla seguente seguente funzione di ripartizione:

[1] Se immaginiamo che una variabile stocastica X esprima la distribuzione delle s intensità $x_1<x_2<...<x_i<...<x_s$,, procedendo con le somme cumulative, si ha:

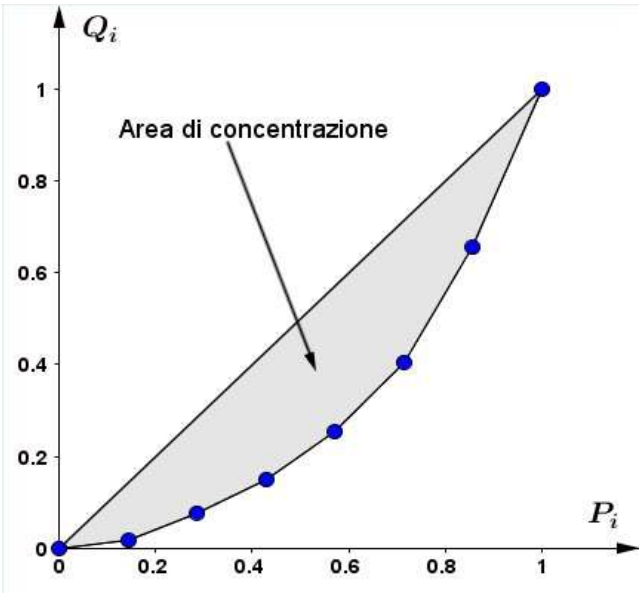
$$A_1 = x_1 \cdot n_1; A_2 = A_1 + x_2 \cdot n_2; \ldots A_i = A_{i-1} + x_i \cdot n_i; \ldots A_s = A_{s-1} + x_s \cdot n_s$$

dove: $n_1+n_2+...+n_i+...+n_s=N$.

$$F(x) = \begin{cases} (1 + \Theta^{\delta} x^{-\delta})^{-\beta} \; per \; x > 0 \\ 0 \quad altrove \end{cases} \qquad [2]$$

con (Θ, β, $\boldsymbol{\delta}$)>0 dove Θ è un parametro di scala, β e $\boldsymbol{\delta}$ sono indicatori diversi di concentrazione, in sostanza al crescere del primo il secondo diminuisce e viceversa (Dagum, 1980 pag 424; Dancelli 1986).

Figura 1. Rappresentazione grafica di una curva di Lorenz con la relativa retta di equidistribuzione e l'area di concentrazione



Lo scopo di questo articolo è quindi quello di far notare come al variare dei parametri β e $\boldsymbol{\delta}$ è possibile ottenere in termini interpolativi un'intera famiglia di curve di Lorenz approssimabili ad archi appartenenti ad una Supershape o Squircle anche da un'ottica meramente empirica.

2. Rappresentazione esplicita della funzione squircle

La Superellisse o Supershape è una forma geometrica che unisce le proprietà di un quadrato con quelle di un cerchio. Nel sistema di riferimento cartesiano il supercerchio centrato in un punto (a, b) con assi paralleli alle coordinate è descritto dall'equazione:

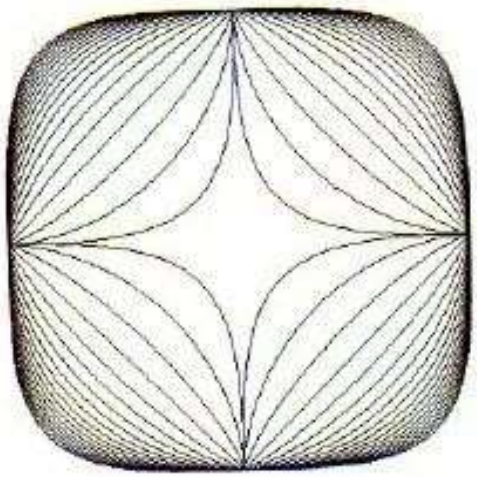
$$(x - a)^4 - (y - b)^4 = r^4 \qquad [3]$$

dove *r* sta per il raggio minimo del supercerchio.

Nella geometria euclidea, la superellisse o "curva di Lamé" (Fig. 2) rappresenta una figura geometrica che generalizza l'ellisse. In un sistema di coordinate cartesiane è descritto come il luogo dei punti (x, y) che soddisfano l'equazione:

$$\left|\frac{x}{a}\right|^n + \left|\frac{y}{b}\right|^n = 1 \qquad [4]$$

Figura 2. Ramificazione multipla di una Superellisse o Squircle o Supershape.



Nella geometria euclidea, la superellisse o "curva di Lamé" è rappresentata dalla funzione:

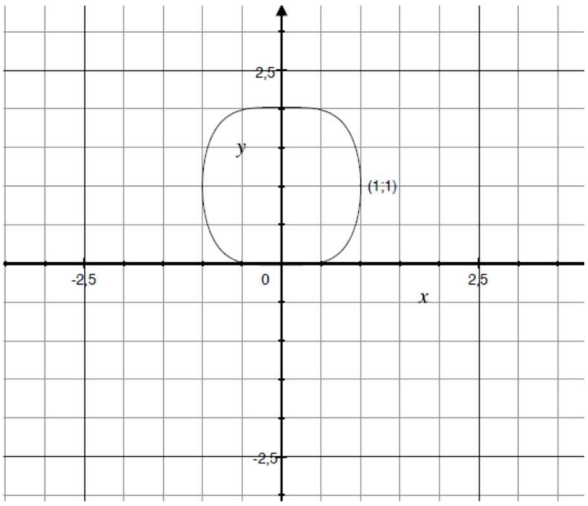
$$y = f(x) = \sqrt[4]{b^4\left(1-\frac{x^4}{a^4}\right)} \Rightarrow b \cdot \sqrt[4]{\left(1-\frac{x^4}{a^4}\right)} \qquad [5]$$

che deriva dall'equazione:

$$\frac{y^4}{b^4} = 1 - \frac{y^4}{b^4} \qquad [6]$$

nella quale ponendo a=0.45, b=0.64 si ottiene la superellisse mostrata in Fig.3 (Cusatelli, Gallo, Rinaldi, 2021)

Figura 3. *Superellisse passante per l'origine degli assi.*



3. Modello della curva di Lorenz e lunghezza dell'arco ellittico

Il modello analitico della curva di concentrazione empirica (o di Lorenz) è dato dall'espressione:

$$q = L(p,d), 0 \leq p \leq 1 \qquad [7]$$

dove $d = (d_1, d_2, \ldots, d_m)\ \epsilon\ \Theta \subseteq \mathbf{R}^m$ è il vettore dei parametri che identifica il particolare elemento nella famiglia di funzioni e Θ rappresenta il sottoinsieme dello spazio parametrico dello spazio euclideo m-dimensionale R^m (Tarsitano 1987).

Le condizioni di regolarità che trasmettono le peculiarità della curva di Lorenz empirica al modello analitico *q= L(p,d)* sono 5 (Tarsitano,1987):

1) ***positività*** (come funzione reale definita nell'intervallo chiuso [0; 1]), poiché:

$$\lim_{x\to 0^-} L(p,d) = 0 \quad e \lim_{x\to 0^+} L(p,d) = 1 \ \forall\ d\ \epsilon\ D \qquad [8]$$

2) ***non decrescenza***, perché se si hanno due punti p_1 e p_2 nell'intervallo [0,1]

$$Se\ p_1 \leq p_2 \Rightarrow L(p_1;d) \leq L(p_2;d)\ \forall\ d \in D \qquad [9]$$

3) ***convessità***, perché dati sempre i due punti p1, p2 ed α tutti in [0,1] e si supponga che $p_1<p_2$. Allora

$$L[\ \alpha p_1+(1-\alpha)\ p_2;\ d] \leq \alpha L(p_1;d) + (1-\alpha)L(p_2;d) \quad \forall d \in D \qquad [10]$$

4) unicità per equidistribuzione perché esiste uno ed un solo punto d+∈ D tale che:

$$L(p;d) = p \qquad \forall\ p \in [0,1] \qquad [11]$$

5) asimmetria. Lo spazio parametrico D può essere suddiviso nei tre sottoinsiemi D_1,D_2,D_3 tali che:

$$\bigcup_{i=1}^{3} D_i = D, \qquad \text{inoltre } D_i \cap D_j = \emptyset \quad se\ i \neq j \qquad [12]$$

In tali insiemi accade che $\forall p \in [0,1]$ si ottiene che:

$$L(1-q;d) = (1-p) \text{ per ogni } d \in D_1 \qquad [13]$$
$$L(1-q;d) < (1-p) \text{ per ogni } d \in D_2 \qquad [14]$$
$$L(1-q;d) > (1-p) \text{ per ogni } d \in D_3 \qquad [15]$$

La condizione 5 sulla base degli scritti di Tarsitano (1987), determina che la curva di Lorenz L(p;d) sia simmetrica [13] oppure presenti asimmetria destrorsa [14] ed asimmetria sinistrorsa [15] per combinazioni distinte di parametri. Tale ultima condizione facilita la comprensione del fenomeno distributivo espresso dal modello.

L'idea alla base del concetto di asimmetria adottato per la curva di Lorenz è simile a quello applicato alle distribuzioni di frequenza. Le espressioni [13] e [15] diventano più evidenti se il diagramma di Lorenz viene traslato nel sistema di coordinate

$$x = (p+q)/\sqrt{2}; \qquad y = (p-q)/\sqrt{2} \qquad [16]$$

che corrisponde sostanzialmente a considerare la curva di Lorenz in maniera speculare sulla retta di equidistribuzione (Tarsitano 1987). Alla luce di quanto asserito la curva di Lorenz avrà asimmetria destrorsa se il massimo per *y* viene ottenuto per una ascissa maggiore di quella mediana ($x=1/\sqrt{2}$) se invece il massimo è ottenuto per un'ascissa minore di quella mediana, avremo il caso contrario ovvero l'asimmetria sarà sinistrorsa (Tarsitano 1987).

In Dancelli (1989) come già ribadito in precedenza, si fa riferimento al modello della curva di Lorenz a 3 parametri per la distribuzione dei redditi personali indicato da C. Dagum (1977-1980), Fattorini - Lemmi (1979), Dagum - Lemmi (1987) e Lemmi (1987) caratterizzato dalla seguente funzione distributiva:

$$L(p) = \begin{cases} \left(1 + \Theta^{\delta} x^{-\delta}\right)^{-\beta} & if \;\; x > 0 \\ 0 & altrove \end{cases} \qquad [17]$$

Dalla formula (17) si può dedurre e ricavare l'equazione cartesiana della curva di Lorenz nelle variabili *p* e *q* (Dagum 1977-1980 e Dancelli 1986-1989):

$$L(p) = \frac{\int_0^{p^{1/\beta}} z^{\beta+1/\delta-1}(1-z)^{-1/\delta}\, dz}{\int_0^1 z^{\beta+1/\delta-1}(1-z)^{-1/\delta}\, dz}, \;\; p \in [0,1] \qquad [18]$$

con $\beta > 0 \; e \; \delta > 1$, a sua volta rappresentata dal rapporto tra la funzione beta incompleta troncata in $p^{\frac{1}{\beta}}$.

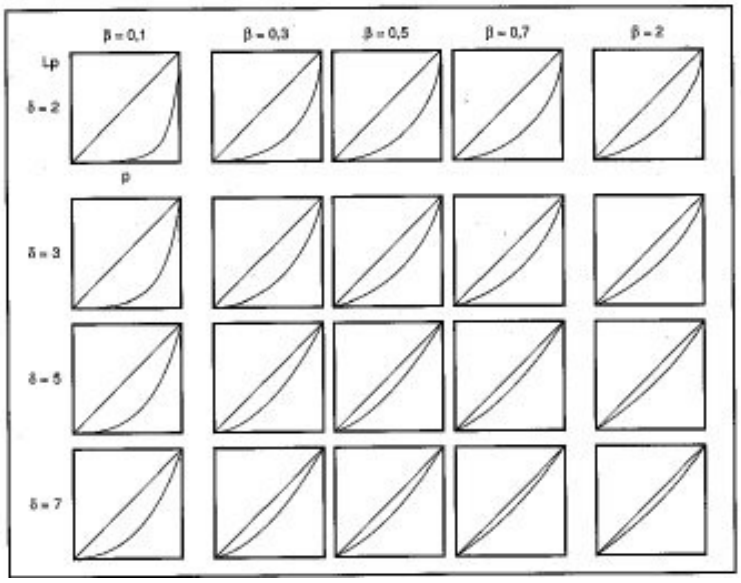
Da notare però che la curva di Lorenz L(p) essendo espletata dalla [17] e dall'equazione del momento primo incompleto, quest'ultimo può essere riscritto come:

$$Q(x) = \frac{\int_0^{z^*} z^{\beta+1/\delta-1}(1-z)^{-1/\delta}\, dz}{\int_0^1 z^{\beta+1/\delta-1}(1-z)^{-1/\delta}\, dz}, \;\; \text{con x>0} \qquad [19]$$

dove $z^* = x^{\delta}/\theta^{\delta} + x^{\delta}$, con $(\theta, \beta) > 0 \; e \; \delta > 1$ affinchè possa esistere e sussistere un valore medio (Dancelli, 1987).

Al variare dei parametri β e δ si possono evidenziare vari andamenti della curva di Lorenz riconducibili ad un arco superellittico, come mostrato nella Fig. 4 (Dancelli,1989)

Figura 4. *Andamento della curva L(p) al variare dei parametri β e δ .*



Tarsitano (1987) descrive inoltre la lunghezza della curva di Lorenz con la funzione:

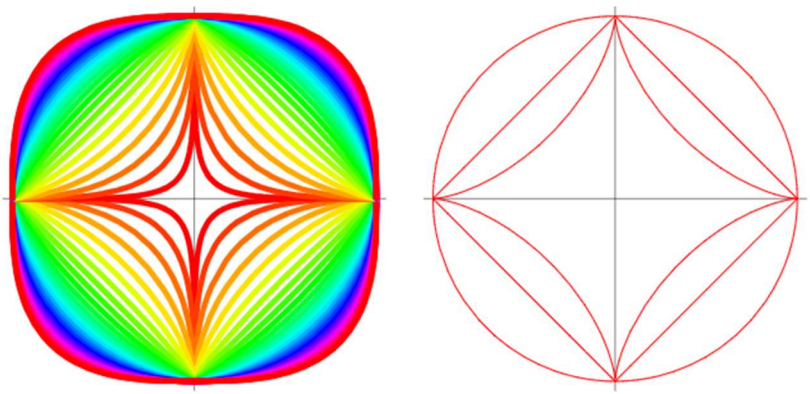
$$S = \int_0^1 \sqrt{1 + L'(p,d)^2}\,dp \qquad [20]$$

si può dedurre, sulla base della [20], che l'indice varia tra $\sqrt{2}$ (in assenza di concentrazione) e 2 (in caso di concentrazione massima).

Sulla base di quanto detto si può dedurre che il modello *L(p,d)* al variare dei due parametri β e δ può dar vita ad una vasta gamma di famiglie di curve di Lorenz che possono essere riconducibili ad intere famiglie di archi superellittici o *supershape* riferite però solo al quadrante cartesiano positivo (Cusatelli, Gallo, Rinaldi, 2021).

Obiettivo principale di questo lavoro quindi è stato quindi quello di notare da un punto di vista puramente teorico, che una curva di Lorenz altro non è che un arco di una Superellisse, osservando nel contempo a livello concettuale (ribandendo il concetto di approssimazione distributiva), come una curva di Lorenz possa essere riconducibile in maniera ideale (attraverso opportune tecniche di interpolazione), ad un'intera famiglia di archi ellittici appartenenti alla famiglia delle *Squircle* o *Supershape* nel caso di perfetta simmetria al variare dei parametri β e δ (Fig.5).

Figura 5. *Ramificazioni di una famiglia di curve di Lorenz approssimabili ad un arco superellittico*



Fonte: https://mathworld.wolfram.com/Superellipse.html

4. Tendenza alla massima e alla minima concentrazione nel modello di curva di Lorenz proposto da Dagum al variare dei parametri β e δ

Nel modello della distribuzione dei redditi proposto da Dagum (1977) è possibile giungere ad un'espressione analitica della curva di Lorenz in termini finiti ovvero (Dancelli,1986)

$$M(x) = \frac{\int_0^x t f(t) dt}{E(x)} \qquad [21]$$

che nel caso della [17] diventa:

$$M(x) = \theta^{\delta} \beta \delta \frac{\frac{\int_0^x t^{\delta\beta}}{(\theta^{\delta}+t^{\delta})^{\beta+1}} dt}{E(x)} \quad x > 0 \qquad [22]$$

con θ > 0, β > 0, δ > 0. Se nella [22] poniamo:

$$t = \theta \left(\frac{z}{1-z}\right)^{\frac{1}{\delta}}; dt = \theta \frac{1}{\delta} z^{\frac{1}{\delta}-1} (1-z)^{\frac{-1}{\delta}-1} dz \qquad [23]$$

e tenuto conto che il valor medio è dato da :

$$E(x) = \theta\beta \int_0^1 z^{\beta+\frac{1}{\delta}-1} (1-z)^{-\frac{1}{\delta}} dz \qquad [24]$$

e osservando che per *t*=*x* l'estremo superiore che compare al numeratore vale

$\frac{x^{\delta}}{\theta^{\delta}+x^{\delta}}$<1 (per 0< x < ∞) si ottiene la formula (Dancelli 1986):

$$M(x) = \frac{\int_0^{z^*} z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}}dz}{\int_0^1 z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}}dz} \quad x > 0 \qquad [25]$$

essendo

$$z^* = \frac{x^{\delta}}{\theta^{\delta}+x^{\delta}}\,. \qquad [26]$$

Adottando nella [25] questa trasformazione si perviene alla curva di concentrazione *L(p)* che diventa:

$$L(p) = \frac{\int_0^{p^{\frac{1}{\beta}}} z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}}dz}{\int_0^1 z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}}dz} \text{ con p } \in [0,1] \text{ con } \beta>1 \text{ e } \delta>1 \qquad [27]$$

Se nella [27] si pone $z = y^{\frac{1}{\beta}}$; $y = p$; $dz = \frac{1}{\beta}y^{\frac{1}{\beta}-1}dz$ si otterrebbe:

$$L(p) = \frac{\int_0^p \left(y^{\frac{1}{\beta}}-1\right)^{\frac{-1}{\delta}}dz}{\int_0^1 \left(y^{\frac{1}{\beta}}-1\right)^{\frac{-1}{\delta}}} \text{ con p } \in [0,1] \qquad [28]$$

In Dancelli (1986) viene dunque esposto come la curva di concentrazione nella distribuzione di Dagum dipende solo dai parametri β e δ; ma cosa accadrebbe se uno di tali parametri resta immutato al variare dell'altro e viceversa? In tal caso si considerano 4 differenti situazioni, tenuto conto delle definizioni di tendenza alla concentrazione nulla e massima per v.c. continue ovvero (Dancelli 1986):

Definizione A. (*Tendenza alla concentrazione nulla per v.c. continue*) Data una v.c. positiva X e dotata di funzione di densità di probabilità $f(x;\gamma_1,\gamma_2,\ldots\gamma_{k)}$ essa tende a zero per $\gamma_i \to \gamma_0$, i=1,2,..k tenuto conto che i k-1 parametri restanti siano costanti se:

$$\lim_{yi\to y0} L(p) = p \; con \; p \in [0,1) \qquad [29]$$

Definizione B. (*Tendenza alla concentrazione massima per v.c. continue*) Data una v.c. positiva X e dotata di funzione di densità di probabilità $f(x;\gamma_1,\gamma_2,\ldots\gamma_{k)}$ essa tende a ze per $\gamma_i \to \gamma_0$, i=1,2,..k tenuto conto che i k-1 parametri restanti siano

costanti se:

$$\lim_{yi \to y0} L(p) = \begin{cases} 0 & con\ p \in [0,1) \\ 1 & con\ p = 1 \end{cases} \qquad [30]$$

caso a) comportamento della curva di concentrazione per $\delta \to 1^+$, supposto β costante con $0<\beta<\infty$, considerando la formula [27] si ha che :

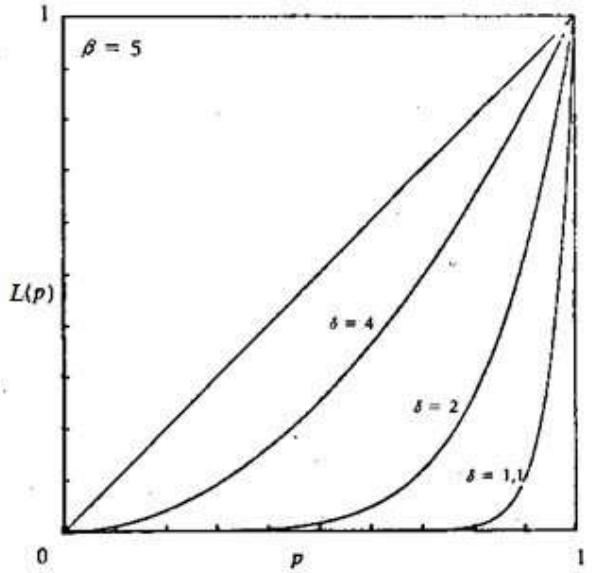
$$\lim_{\delta \to 1+} L(p) = \begin{cases} 0 & con\ p \in [0,1) \\ 1 & con\ p = 1 \end{cases} \qquad [31]$$

caso b) comportamento della curva di concentrazione per $\delta \to \infty$, supposto β costante con $0<\beta<\infty$ considerando sempre la formula [27] si ha che :

$$\lim_{\delta \to \infty} L(p) = \frac{\int_0^{p^{\frac{1}{\beta}}} z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}} dz}{\int_0^1 z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}} dz} = p \quad con\ p \in [0,1) \qquad [32]$$

I casi **a** e **b** sono raffigurati nella figura 6.

Figura 6. *Rappresentazione della curva di Lorenz L(p) con* $\delta \to 1^+$ *oppure* $\delta \to \infty$



caso c) comportamento della curva di concentrazione per $\beta \to 0^+$, supposto δ costante con $0<\delta<\infty$. Partendo sempre dalla formula [27] abbiamo:

$$\lim_{\beta \to 0+} L(p) = \begin{cases} 0 & con\ p \in [0,1) \\ 1 & con\ p = 1 \end{cases} \qquad [33]$$

caso d) comportamento della curva di concentrazione per $\beta \to \infty$, supposto δ costante con $0<\delta<\infty$. Considerando la formula [28], la curva di concentrazione può essere riscritta nella formula (Dancelli 1986):

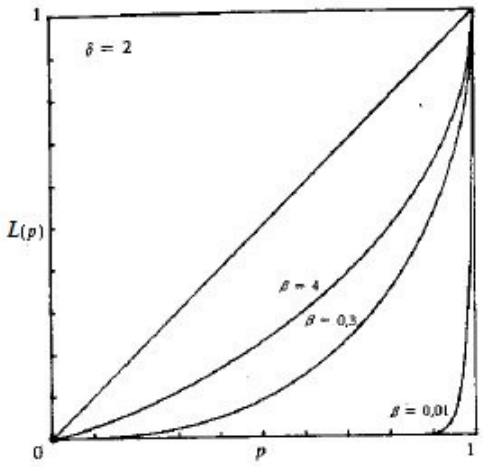
$$L(p) = \frac{\int_0^p (y^{1-\beta}-1)^{\frac{-1}{\delta}} dy}{\int_0^1 (y^{1-\beta}-1)^{\frac{-1}{\delta}} dy} \qquad [34]$$

e sviluppandola nella serie di McLaurin si otterrà che il:

$$\lim_{\beta\to\infty} L(p) = \frac{\int_0^{p^{\frac{1}{\beta}}} z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}} dz}{\int_0^1 z^{\beta+\frac{1}{\delta}-1}(1-z)^{\frac{-1}{\delta}} dz} = p \quad con\ p \in [0,1)\ . \qquad [35]$$

Il caso **c e d** sono rappresentati nella figura 7.

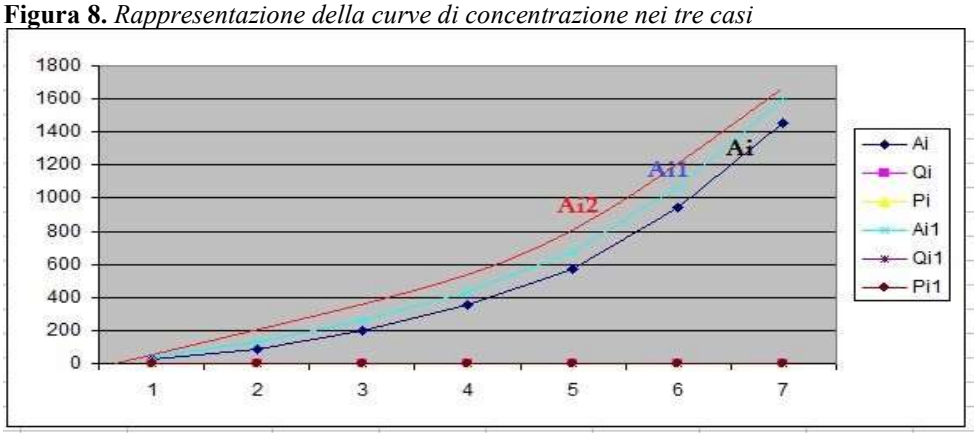
Figura 7. *Rappresentazione della curva di Lorenz L(p) con* $\beta \to 0^+$ *oppure* $\beta \to \infty$



Nel caso ad esempio si supponga che 3 capitali di una Società siano divisi fra 7 soci per un totale di 1457 euro nel primo caso, 1597 nel secondo e 1677 nel terzo caso. Le tre curve di concentrazione che ne derivano sono le seguenti (Fig.8):

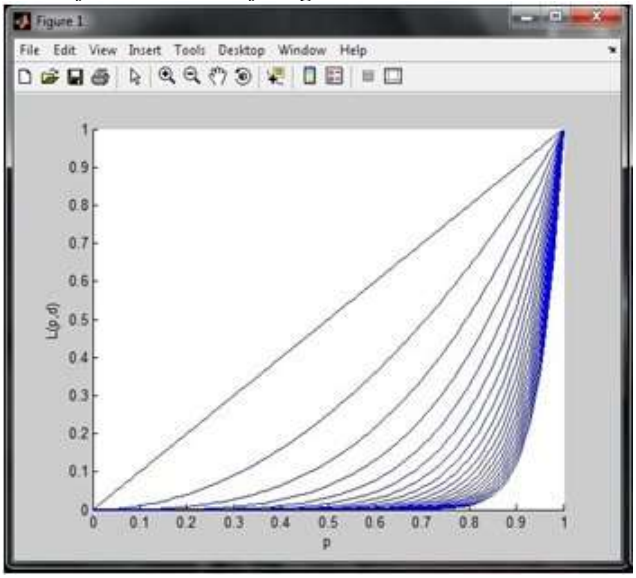
Socio	capitale	capitale 2	capitale 3	Ai	Qi	Pi	Ai1	Qi1	Pi1	Ai2	Qi2	Pi2
1	25	45	65	25	0,017158545	0,142857	45	0,028178	0,142857	65	0,03876	0,142857
2	65	85	95	90	0,061770762	0,285714	130	0,081403	0,285714	160	0,095408	0,285714
3	106	126	136	196	0,134522992	0,428571	256	0,160301	0,428571	296	0,176506	0,428571
4	155	175	185	351	0,240905971	0,571429	431	0,269881	0,571429	481	0,286822	0,571429
5	223	243	253	574	0,393960192	0,714286	674	0,422041	0,714286	734	0,437686	0,714286
6	368	388	398	942	0,646533974	0,857143	1062	0,664997	0,857143	1132	0,675015	0,857143
7	515	535	545	1457	1	1	1597	1	1	1677	1	1
TOTALE	1457	1597	1677		1,49	3		1,6268	3		1,710197	3

Figura 8. *Rappresentazione della curve di concentrazione nei tre casi*



Poiché il grafico della spezzata di Lorenz non impedisce di costruire contemporaneamente più curve essendo le quantità relative, in Matlab nel caso si dovessero rappresentate curve infinite si avrebbe una situazione di questo tipo (Fig.9)

Fig.9. *Ramificazioni di una famiglia di curve di Lorenz in Matlab*



5. Osservazioni finali

Il presente lavoro ha avuto l'obiettivo quello di illustrare l'andamento della curva di Lorenz al variare dei parametri **β** e ***δ*** mettendo in luce la peculiarità

che al mutare degli stessi, è possibile ottenere varie ramificazioni e articolazioni della stessa che possono essere comparabili e confrontabili ad una famiglia di archi superellittici appartenenti alla tipologia delle Squircle o Supershape (Cusatelli, Gallo, Rinaldi, 2021). Tale approccio è stato adottato in maniera tale da poter analizzare la curva di concentrazione non solo nell'ottica meramente deterministica-matematica, ma soprattutto da una prospettiva puramente teorico-concettuale, rendendo possibile interpolare in tal modo non solo una sola spezzata di Lorenz a casi concreti, ma intere famiglie di casi di spezzate di curve di Lorenz che potranno essere cosi analizzate e confrontate nei loro andamenti all'interno dello spazio bidimensionale. Anche in questo caso come in (Cusatelli, Gallo, Rinaldi, 2021) l'argomento è stato trattato da un punto di vista puramente teoretico e conoscitivo, evidenziando nel contempo alcune caratteristiche analitiche della curva di Lorenz, puntando anche l'attenzione dei riflettori su altre tipologie di figure geometriche che nella fattispecie sono le Superellissi definite anche *Squircle* o *Supershape*.

Riferimenti bibliografici

Carlson B. (2002). Tre miglioramenti nella riduzione e nel calcolo degli integrali ellittici. Giornale di ricerca del National Institute of Standards and Technology 107, 5, 413.

Cusatelli, Gallo, Rinaldi (2021) Distributive adaptation of the Lorenz Curve to a Squircle. Dipartimento di Economia e Finanza –Metodi e Analisi statistiche 2021 (pagg.87- 100)

Dagum C. (1977). Un nuovo modello di distribuzione del reddito personale: specificazione e stima. Applicazione economica,XXX,3,413-436.

Dagum C. (1980). La generazione e la distribuzione del reddito, la curva di Lorenz e la Ratio di Gini. Economie Appliquée, XXXIII, 2, 327-367.

Dagum C., Lemmi A. (1987). Un contributo all'analisi delle distribuzioni dei redditi e della disuguaglianza dei redditi e un caso di studio: l'Italia. Documento di ricerca n.8706, Facoltà di Scienze Sociali, Dipartimento di Economia, Università di Ottawa, presentato all'Econometric Society Meeting tenutosi a Chicago, dal 28 al 30 dicembre 1987.

Dancelli L. (1986). Tendenza alla massima ed alla minima concentrazione del modello di distribuzione personale di Dagum. Scritti in onore di Francesco

Brambilla, Vol.1, Università L. Bocconi, Milano, 249-267.

Dancelli L. (1987). In tema di relazioni e discordanze fra indici di variabilità e di concentrazione. In M. Zenga (Ed.) *Atti del Convegno La distribuzione personale del reddito: problemi di formazione, di ripartizione e di misurazione*, Vita e Pensiero, Milano

Dancelli L. (1989). Confronti fra le curve di concentrazione Z(p) e L(p) nel modello di Dagum. Statistica applicata, Vol.1, n.4, 1989.

Duclos J.-Y. (2000). Indici di Gini e redistribuzione del reddito. Fiscalità internazionale e finanza pubblica 7, 2, 141–162.

Fattorini L., Lemmi A. (1979). Proposta di un modello alternativo per l'analisi della distribuzione personale del reddito. Atti delle giornate di lavoro AIRO, Bologna, 89-117.

Fernandez Guasti M. (1992). Geometria analitica di alcune figure rettilinee. interno J. Educ. Sci. Tecnologia. 23, 895-901.

Fernández Guasti M., Meléndez Cobarrubias A., Renero Carrillo FJ, Cornejo Rodríguez A. (2005). Forma dei pixel LCD e modelli di diffrazione del campo lontano. Ottica 116, 265-269. Sloane, sequenza NJAA186642nell'Enciclopedia in linea delle sequenze intere.

Gielis J. (2003). Una trasformazione geometrica generica che unifica una vasta gamma di forme naturali e astratte. American Journal of Botany 90, 3, 333–338.

Gini C. (1931). Intorno alle curve di concentrazione. Ciao di MG Hernández.

Gini C. (1971). Variabilità e mutabilità, contributo allo studio delle distribuzioni e delle relazioni statistiche. Studi economico-giuridici della R. Università di Cagliari (1912). Recensito in: Light, RJ, Margolin, BH: An Analysis of Variance for categorical data. J. American Statistical Association 66, 534–544.

Girone G., Nannavecchia A. (2015). La distribuzione del rapporto di concentrazione per campioni provenienti da una popolazione uniforme. Matematica applicata 6, 01, 57.

Girone G., Crocetta C., Massari (2019). Statistica. Cacucci Editore.

Giurovich G. (1959). Su un indice approssimato di asimmetria della curva di concentrazione. Statistica. vol. 19, pp. 463-482.

Greenhill AG (1892). Le applicazioni delle funzioni ellittiche. Londra, New York, Macmillan.

Gridgeman NT (1970). Ovali lamé. La Gazzetta Matematica 54, 387, 31–37.

Hagerbaumer JB (1977). Il rapporto di concentrazione di Gini e il rapporto di concentrazione minore: un indice di disuguaglianza a due parametri. La revisione di economia e statistica, 377–379.

Lemmi A. (1987). Il modello kappa a tre parametri nell'analisi della distribuzione personale del reddito. Atti del convegno su: la distribuzione personale del reddito: problemi di formazione, di ripartizione e di misurazione, Brescia, 13-14 giugno

1985, a cura di M.Zenga, Vita e Pensiero, Milano, 165-189.

Hancock H. (1917). Integrali ellittici. N. 18. John Wiley & Sons, Incorporated.

Re LV (2016). Sul calcolo numerico diretto di funzioni ellittiche e integrali. Cambridge University Press.

Koshevoy G., Mosler K. (1997). Indici di Gini multivariati. Giornale di analisi multivariata 60, 2, 252–276.

Lorenz MO (1905). Metodi di misurazione della concentrazione della ricchezza. Pubblicazioni dell'associazione statistica americana 9, 70, 209–219.

Loria G. (1910). Speciali algebriche e trascendenti ebene Kurven. Lipsia: Teubner.

Martínez-Panero M., García-Lapresta JL, Meneses LC (2016). Multidistanze e misure di dispersione. Logica fuzzy e fusione delle informazioni. Springer, pp. 123-134.

Tarsitano A. (1987). L'interpolazione della spezzata di Lorenz. Statistica. Anno XLVII, N.3, pp. 437-451.

Tarsitano A. (2000). Gli indici di asimmetria della curva di Lorenz per dati raggruppati. In Atti della XL Riunione Scientifica della SIS. Firenze, 26-28 aprile 2000, 219-222.

Zanardi G. (1965). L'asimmetria statistica delle curve di concentrazione. Ricerche Economiche 19, 3-4, 355–396.

Zenga M. (1984)- Proposta per un indice di concentrazione basato sui rapporti fra quantili di popolazione e quantili di reddito *Giornale degli Economisti e Annali di Economia*, Nuova Serie, Anno 43, N. 5/6 (Maggio-Giugno 1984), pp. 301-326

Sitografia

- https://www-users.york.ac.uk/~ss44/cyc/s/superformula.htm
- https://mathworld.wolfram.com/Superellipse.html

UNIVERSITÀ DEGLI STUDI DI BARI ALDO MORO
Metodi e analisi statistiche 2024 ISBN: 978-88-6629-053-7
DIPARTIMENTO DI ECONOMIA E FINANZA p. 221-235

Spese per i servizi sociali e Strategia per le Aree Interne

Agata Maria Madia Carucci[1], Giovanni Vannella[2]*.

[1]Istat – Area Sud, [2]Università degli Studi di Bari Aldo Moro

Riassunto: La marginalità sociale ed economica di territori distanti dai servizi essenziali necessita di interventi di policy in grado di ridurre le distanze. A tal riguardo i comuni rivestono un ruolo prioritario, attraverso la redistribuzione delle risorse, garantendo un riequilibrio del benessere socio-economico della popolazione. Il presente lavoro, attraverso l'utilizzo dei dati censuari a livello comunale e dei dati sulla spesa sociale dei comuni singoli o associati rivenienti dalla "Rilevazione sugli interventi e servizi sociali dei comuni singoli o associati" (condotta in collaborazione col Ministero dell'economia e delle finanze e con le regioni e le province autonome), vuole contribuire alla disamina delle diverse caratterizzazioni delle Aree Interne con l'obiettivo di comprendere le differenze territoriali e le dinamiche che possano impattare sui differenti sviluppi dei territori.

Keywords: Spesa pubblica locale; Benessere socio-economico; Aree Interne; Previsioni demografiche.

1. Introduzione

L'Italia è una nazione storicamente e culturalmente fortemente incentrata su modelli di identità locale i quali, riferiti ad una città o ad un lontano borgo, definiscono l'Italia nei suoi usi, costumi e nel suo sviluppo sociale ed economico.

Se da una parte questa varietà è da sempre una caratteristica molto apprezzata dell'Italia, capace di offrire paesaggi, cultura e tradizioni che attirino l'interesse di

* Autore corrispondente: Giovanni Vannella giovanni.vannella@uniba.it
Sebbene il lavoro sia frutto del lavoro congiunto dei due autori, a A.M.M. Carucci sono attribuiti i paragrafi 2, 3 e 4, a G. Vannella i paragrafi 1, 5 e 6.

studiosi e visitatori, dall'altra non è esente da criticità in riferimento alla sua gestione. I comuni piccoli e piccolissimi (meno di 1.000 abitanti), che rappresentano in Italia il 25% dei comuni ed in cui vive oltre un milione di popolazione, troppo spesso sono caratterizzati da un diverso accesso ai servizi.

Nell'ultimo rapporto annuale[1], l'Istat dedica un intero capitolo ai territori, nell'ottica in cui *"Il territorio, con le sue specificità economiche, demografiche, sociali e culturali, rappresenta un momento di sintesi delle complesse trasformazioni in atto a livello nazionale e globale, evidenziando potenzialità e vincoli peculiari rispetto a quanto illustrato a livello nazionale. Il tema dell'accessibilità, intesa come possibilità di accesso per cittadini e imprese ai vari servizi, è strettamente legato a quello della perifericità dei territori e alle strategie di policy orientate alla pianificazione territoriale."*

Classificati i comuni italiani in base all'accessibilità alle principali infrastrutture di trasporto in:

- altamente accessibili
- scarsamente accessibili
- mediamente accessibili

l'Istat rileva che, nel 2022, 1milione e 300 mila italiani vivono nei 786 comuni scarsamente accessibili alle infrastrutture di trasporto (aeroporti, porti, stazioni ferroviarie e accessi alla rete autostradale). In analogia, con l'analisi dell'accessibilità ai servizi ospedalieri, misurata in funzione dei tempi di percorrenza per raggiungere l'ospedale più vicino, nel predetto rapporto l'Istat rileva che, sebbene la quasi totalità della popolazione (98,7%) risieda in comuni dai quali è possibile raggiungere una struttura ospedaliera entro mezz'ora, sussistano comunque notevoli differenze sul territorio. *"Maggiori difficoltà si rilevano laddove l'orografia e la geomorfologia dei territori rendono più complessi gli spostamenti: in Basilicata, Molise, Valle d'Aosta/Vallée d'Aoste, in Sardegna e in Calabria, dove una quota non irrilevante di popolazione (tra il 5,2 e il 20,3%) impiega oltre 30 minuti per raggiungere una struttura ospedaliera".*

L'accessibilità ai luoghi della cultura, continua l'Istat, influisce invece sull'attrattività dei territori. *"Si può ritenere che, a parità di interesse culturale, un museo, un monumento, o un sito archeologico saranno tanto più frequentati quanto più facili da raggiungere.".* Lo sviluppo, pertanto, di alcune zone del territorio più facilmente raggiungibili e l'abbandono di altre ha contribuito a causare una crescita demografica non uniforme, tale da compromettere lo sviluppo sostenibile così

[1] Rapporto annuale 2024. La situazione del Paese. ISTAT 2024

come la coesione sociale. In questo contesto si inserisce la Strategia Nazionale delle Aree Interne (SNAI)[2], innovativo strumento di politica territoriale diretto al miglioramento delle condizioni di vita della popolazione e alla riduzione delle distanze socio-economiche tra territori caratterizzato da contenuti innovativi (visione, governance e metodologia) nel quadro delle politiche di sviluppo in Italia e rispetto alla politica di coesione[3]. La Strategia Nazionale delle Aree Interne (SNAI), trova il suo riferimento normativo nel Programma Nazionale di Riforma (PNR) dell'anno 2014, è definita nell'Accordo di Partenariato 2014-2020 e confermata nel ciclo di programmazione 2021-2027[4]. Il PNRR riserva un ruolo centrale alla SNAI in quanto la coesione sociale e territoriale rappresenta uno dei pilastri fondamentali su cui poggia l'intera programmazione.

La SNAI ha messo sotto gli occhi dell'intero Paese la necessità di un riequilibrio territoriale, non solo fra gli addetti alle politiche nazionali, ma anche da parte dei sindaci, interfaccia con i cittadini, cui devono garantire servizi.[5]

In riferimento alle attività con cui i comuni "marginali", sebbene con ridotte risorse a disposizione, provino a compensare i disagi di una popolazione distante dai servizi essenziali, nel presente lavoro viene presentata una analisi delle caratteristiche socio-demografiche ed economiche dei comuni classificati secondo la SNAI, seguita da uno studio sulla distribuzione delle spese sociali dei comuni per categoria di utenti.

2. Caratteristiche socio-demografiche ed economiche dei comuni classificati secondo la SNAI, aspetti generali

La SNAI, come si diceva, rappresenta una azione diretta al sostegno della competitività territoriale sostenibile, al fine di contrastare, nel medio periodo, il declino demografico che caratterizza talune aree del Paese, definite come quelle aree più lontane dai poli di servizio essenziale primario e avanzato, ed è stata istituita con l'intento di individuare dei cluster omogenei di comuni in base

[2] https://politichecoesione.governo.it/it/politica-di-coesione/strategie-tematiche-e-territoriali/strategie-territoriali/strategia-nazionale-aree-interne-snai/

[3] Brunetta Baldi, La Strategia Nazionale delle Aree Interne: innovazione, policy transfer e ricostruzione post sismica, Rivista Italiana di Politiche Pubbliche, n. 2/2018

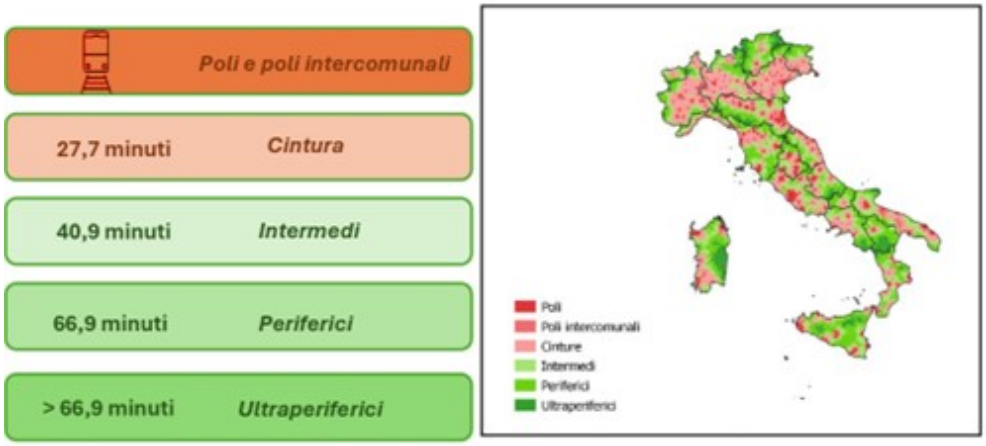
[4] Rossella Moscarelli, Anna Fera, La Strategia Nazionale Aree Interne 10 anni dopo: una proposta di analisi comparativa tra le programmazioni 2014-2020 e 2021-2027, *Scienze Regionali n. 1/2024*
Sabina Lucatelli, Francesco Monaco, Filippo Tantillo, La Strategia delle aree interne al servizio di un nuovo modello di sviluppo loca-le per l'Italia, *Rivista economica del Mezzogiorno, n. 3-4/2019*

[5] Rapporto Formez PA: La Strategia Nazionale per le Aree Interne e i nuovi aspetti istituzionali, Gangemi editore, 2022

all'accessibilità ai principali servizi di base.

I comuni che contestualmente garantiscono l'accesso ai tre servizi principali (trasporti, strutture sanitarie e scuole) sono definiti Polo e Polo intercomunale. In funzione della distanza da questi, sono individuati i comuni Cintura, Intermedi, Periferici ed Ultraperiferici (Fig. 1)[6]. I comuni Polo e Polo intercomunale, insieme ai comuni Cintura, rappresentano la macroclasse di comuni definita come Centri. Le tre classi restanti individuano invece le cosiddette Aree Interne.

Figura 1 – *Distribuzione dei comuni per SNAI e distanze dai poli*



Fonte: Agenzia per la Coesione Territoriale

3. Caratteristiche socio-demografiche dei comuni classificati secondo la SNAI

In Italia, nel 2022, i comuni delle Aree Interne rappresentano il 48,5% dei comuni totali, ospitano il 22,6% della popolazione residente e coprono infine il 58,8% del territorio. In particolare più di 5,3 milioni di abitanti, il 9% della popolazione totale, dista più di 40 minuti dai servizi essenziali, quota significativamente più alta qualora si consideri il Mezzogiorno Italia (Tabb. 1, 2 e 3).

[6] Si definisce come «Polo», o «Polo Intercomunale», quel Comune, o insieme di Comuni confinanti, in grado di offrire contemporaneamente: 1) un'offerta scolastica secondaria superiore (liceo, tecnico e professionale); 2) almeno un ospedale sede di DEA di I livello; 3) una stazione ferroviaria di tipo almeno SILVER. Tutti i Comuni sono stati classificati in base alla distanza (tempo di percorrenza) rispetto al «Polo», o «Polo Intercomunale», più vicino. In base alla propria distanza ogni Comune è stato classificato come *Cintura* – distante non più di 20 minuti dal centro (~ mediana); *Intermedio* – da 20 a 40 minuti (~ terzo quartile); *Periferico* – da 40 a 75 minuti (~ 95o percentile); *Ultraperiferico* – distante oltre 75 minuti (+ isole minori).

Tabella 1 – *Distribuzione dei comuni per SNAI. Valori assoluti e percentuali. Anno 2022*

Classificazione SNAI	Comuni	
	Valore assoluto	Incidenza percentuale
Poli	182	2,3
Poli intercomunali	59	0,7
Cintura	3.828	48,4
Intermedi	1.928	24,4
Periferici	1.524	19,3
Ultraperiferici	382	4,8
Totale	7.903	100

Fonte: elaborazione dati Istat

Tabella 2 – *Distribuzione della popolazione per SNAI. Valori assoluti e percentuali. Anno 2022*

Classificazione SNAI	Popolazione	
	Valore assoluto	Incidenza percentuale
Poli	20.332.587	34,5
Poli intercomunali	1.573.209	2,7
Cintura	23.734.444	40,2
Intermedi	8.030.611	13,6
Periferici	4.615.206	7,8
Ultraperiferici	711.144	1,2
Totale	58.997.201	100

Fonte: elaborazione dati Istat

Tabella 3 – Distribuzione della superficie per SNAI. Valori assoluti e percentuali. Anno 2022

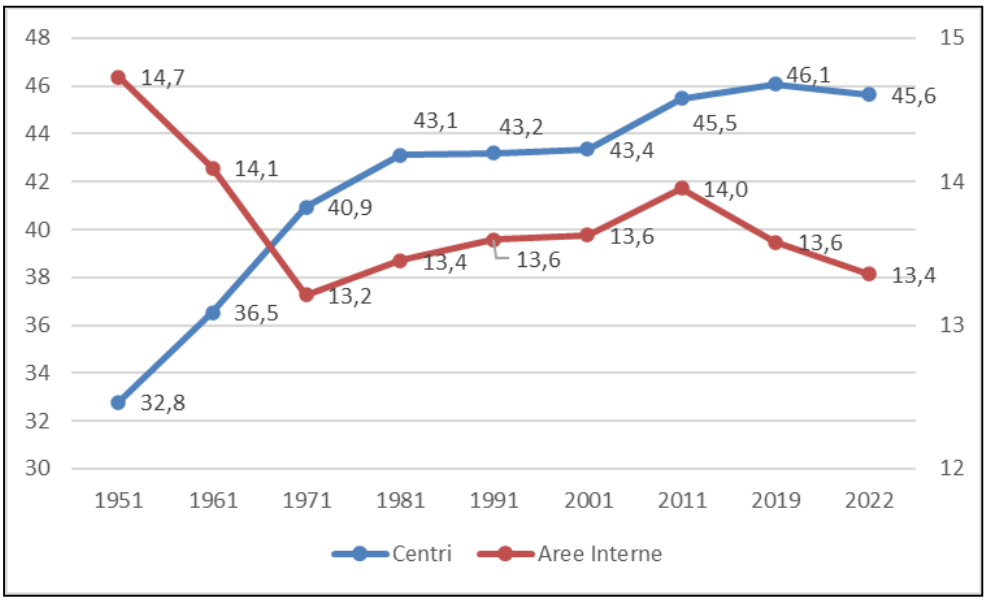
Classificazione SNAI	Superficie	
	Valore assoluto	Incidenza percentuale
Poli	24.455,0	8,1
Poli intercomunali	3.727,5	1,2
Cintura	96.344,2	31,9
Intermedi	75.837,8	25,1
Periferici	79.393,6	26,3
Ultraperiferici	22.310,1	7,4
Totale	302.068,3	100

Fonte: elaborazione dati Istat

Ciò che balza subito all'attenzione è che se tra il 1951 ed il 2022 la popolazione italiana è aumentata del 24,2%, questo aumento non si è distribuito in modo omogeneo.

Nello stesso intervallo temporale i Centri hanno registrato un incremento del 39,2 % mentre le Aree Interne hanno perso quasi 1,4 milioni abitanti pari ad un decremento del 9,2% (Fig. 2).

Figura 2 – *Popolazione ai censimenti per SNAI. Anni 1951-2022*



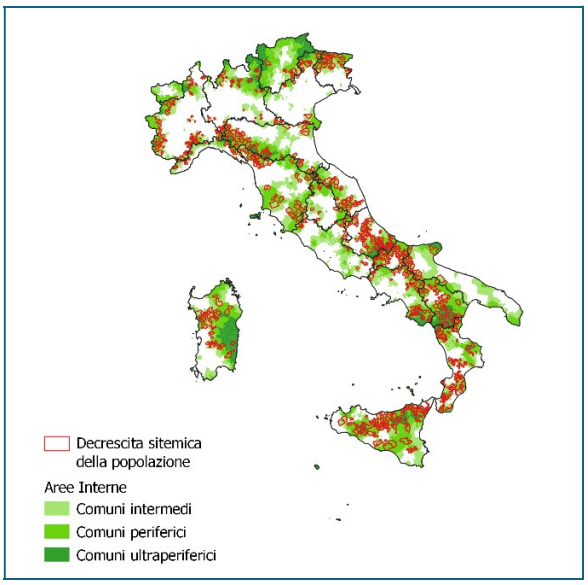
Fonte: elaborazione dati Istat

In particolare, tra il 1951 ed il 2022, un comune su quattro delle Aree Interne ha registrato un persistente calo demografico nel tempo, evidenziando quella che è notoriamente definita come decrescita sistemica, registrando infatti sempre, ad ogni censimento, una riduzione della popolazione.

Sono comuni di piccole o piccolissime dimensioni distribuiti in gran parte tra i comuni periferici e ultraperiferici collocati prevalentemente in aree non costiere e montuose (Fig. 3).

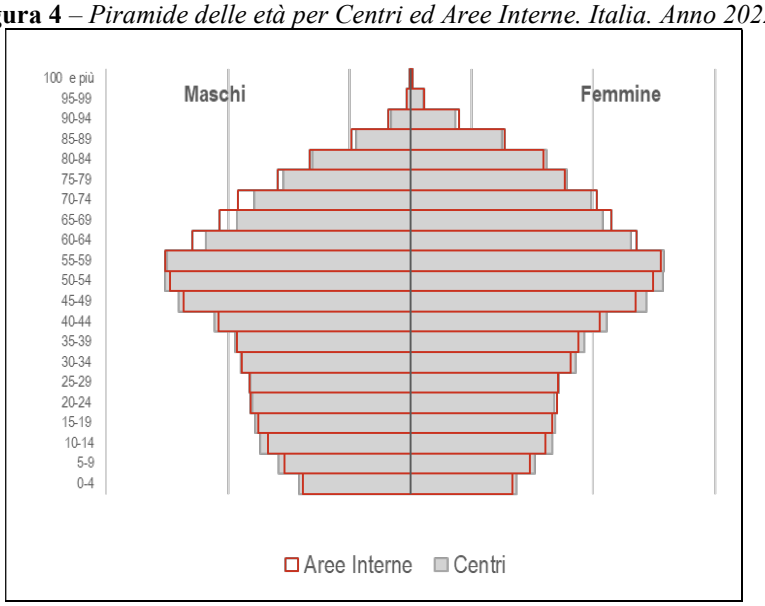
Il differente andamento demografico delle Aree Interne rispetto ai Centri si caratterizza non solo in riferimento alla sua intensità ma anche in riferimento alla sua struttura (Fig. 4).

Figura 3 – *Comuni di Aree Interne con decrescita sistemica della popolazione tra il 1951 e il 2022*



Fonte: elaborazione dati Istat

Figura 4 – *Piramide delle età per Centri ed Aree Interne. Italia. Anno 2022.*



Fonte: elaborazione dati Istat

In tal senso si può osservare come, pur se con grosse differenze a livello regionale, alla riduzione della popolazione si affianca anche un maggiore

invecchiamento della stessa

L'età media della popolazione delle Aree Interne non è particolarmente più alta rispetto a quella dei Centri (46,6 anni contro 46 anni) ma l'indice di vecchiaia risulta essere sensibilmente più alto. Si contano 201 ultrasessantacinquenni ogni 100 giovani tra 0 e 14 anni nelle Aree Interne a fronte di 183 nei Centri.

Le differenze si amplificheranno nel prossimo ventennio, con la tendenza all'abbandono delle Aree Interne soprattutto da parte dei giovani.

Nel rapporto annuale Istat 2024, si stima che, nel 2042 la popolazione italiana si ridurrà del 4,8%, i Comuni Centro perderanno il 3,6% della popolazione, mentre le Aree Interne 1,2 milioni di abitanti, registrando un decremento del 9% della popolazione di questi territori, i comuni ultraperiferici perderanno oltre il 13% della loro popolazione (Tab. 4).

Tabella 4 – Popolazione al 31 dicembre 2022 e previsioni della popolazione al 2042 per Aree SNAI. Valori assoluti e variazione percentuale

Classificazione SNAI	Popolazione 2022	Popolazione 2042	Var 2042/2022
Poli	20.332.587	19.641.982	-3,4
Poli intercomunali	1.573.209	1.489.904	-5,3
Cintura	23.734.444	22.858.024	-3,7
Intermedi	8.030.611	7.446.428	-7,3
Periferici	4.615.206	4.091.690	-11,3
Ultraperiferici	711.144	618.021	-13,1
Totale	**58.997.201**	**56.146.049**	**-4,8**
Centri	*45.640.240*	*43.989.910*	*-3,6*
Aree Interne	*13.356.961*	*12.156.139*	*-9,0*

Fonte: elaborazione dati Istat

4. Principali caratteristiche economiche delle imprese nei comuni classificati secondo la SNAI

Alla marginalità territoriale si può notare come tenda ad associarsi anche una marginalità del sistema produttivo delle aree, verificata in riferimento ai principali indicatori dimensionali ed economici.

Con riferimento alla dimensione, fermo restando che il sistema produttivo del nostro Paese si caratterizza per la presenza di imprese piccole e molto piccole, il numero medio degli addetti dipendenti per impresa dei comuni polo è pari a 3,6

(fenomeno in linea col dato nazionale) mentre il valore scende a 2,6 nei comuni ultraperiferici (Tab. 5).

Tabella 5 – *Dimensione media per aree SNAI. Anno 2022.*

Classificazione SNAI	Numero medio di dipendenti
Poli	3,6
Poli intercomunali	3,5
Cintura	3,7
Intermedi	3,2
Periferici	3,0
Ultraperiferici	2,6
Totale	**3,6**

Fonte: elaborazione dati Istat

Procedendo poi ad una prima valutazione della produttività, si osserva come gli stabilimenti produttivi dei comuni ultraperiferici presentano un valore aggiunto per addetto del 33,9% in meno rispetto a quello ottenuto nei poli, presentando quindi differenze di performance pari a quasi 20mila euro in meno (Tab. 6).

Tabella 6 – *Valore aggiunto per addetto per aree SNAI. Anno 2022.*

Classificazione SNAI	Valore Aggiunto per addetto
Poli	56.849
Poli intercomunali	46.655
Cintura	52.395
Intermedi	45.963
Periferici	40.084
Ultraperiferici	37.606
Totale	**52.613**

Fonte: elaborazione dati Istat

Differenze analoghe si notano osservando le retribuzioni medie annue per dipendente.

Gli stabilimenti produttivi dei comuni ultraperiferici pagano ai loro dipendenti una retribuzione media inferiore del 21,7% rispetto a quelle determinate nei poli, presentando quindi differenze di remunerazione media pari a quasi 6mila euro in meno annua (Tab. 7).

Tabella 7 – *Retribuzione per dipendente per aree SNAI. Anno 2022.*

Classificazione SNAI	Retribuzione media
Poli	27.564
Poli intercomunali	25.347
Cintura	27.171
Intermedi	24.326
Periferici	22.304
Ultraperiferici	21.594
Totale	**26.720**

Fonte: elaborazione dati Istat

Questa marginalità economica, se non dovesse essere corretta, comporterà necessariamente a implementare la spirale minore attrattività economica – minore crescita demografica – minore attrattività economica, con i notevoli impatti su temi ampiamente dibattuti in letteratura quali l'invecchiamento attivo[7] e i relativi costi sociali[8]. Il dualismo emerso tra Aree Interne e Centri è inoltre significativamente più accentuato nelle regioni del Mezzogiorno che già presentano importanti livelli di marginalità economica e sociale.

5. Le spese per servizi sociali

Esaminando infine le variabili socio-economiche prese in considerazione, la "Rilevazione sugli interventi e servizi sociali dei comuni singoli o associati" (condotta in collaborazione col Ministero dell'economia e delle finanze e con le regioni e le province autonome) raccoglie informazioni con cadenza annuale sulle politiche di welfare gestite a livello locale.

In particolare, si hanno a disposizione informazioni sul numero di utenti e le spese impegnate per i servizi sociali gestiti dai Comuni (singolarmente o in forma associata), dalle Province, dalle Regioni e da altri Enti territoriali che affiancano o

[7] Barslund, M.; Von Werder M.; ZAIDI, A. (2019). Inequality in active ageing: evidence from a new individual-level index for European countries. *Cambridge, Cambridge University Press*
Capellari, L., Lucifora C., Rosina A. (2018). Invecchiamento attivo, mercato del lavoro e benessere. *Analisi e politiche attive. Bologna, il Mulino*

[8] Cerea S. (2021). Le reti familiari e il senso di solitudine degli anziani, *I luoghi della cura rivista online, n. 1/2021*;
De Nardis P., Altieri L. (2012). I costi sociali dell'essere "un paese di vecchi". In Treu, T. (a cura di), *L'importanza di essere vecchi. Politiche attive per la terza età. Bologna: il Mulino -AREL*
Monteduro, G.; Bertani, M.; Nanetti S. (2021). Tra invecchiamento e fragilità, le spese per interventi e servizi sociali agli anziani, *Lavoro sociale, n. 4/2021*

sostituiscono i Comuni in questa funzione.

Dal 2011, l'Istat diffonde i dati sugli utenti e sulla spesa per interventi socio-assistenziali per singolo comune, categoria di spesa e tipologia di utente.

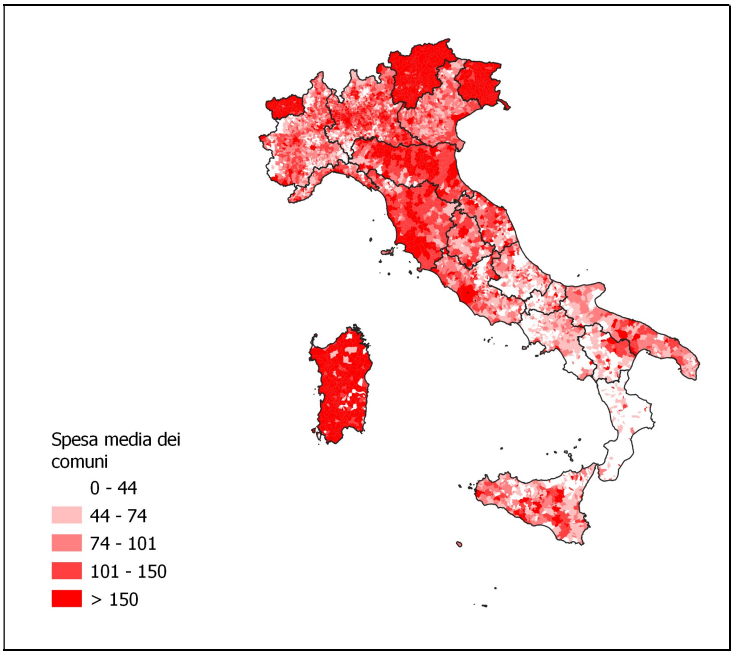
L'ultimo anno per cui sono disponibili i dati è il 2021. A causa della natura del fenomeno, occorre evidenziare come la disaggregazione dei dati a livello comunale richiede l'introduzione di una necessaria componente di stima.

Infatti il numero di utenti, le spese e le compartecipazioni relative ai vari servizi non comprendono solo l'offerta realizzata singolarmente dai Comuni, in quanto vengono opportunamente sommate a tale componente le quote aggiuntive derivanti dagli Enti associativi di appartenenza.

I dati rilevati presso gli Enti associativi vengono ripartiti tra i Comuni che vi appartengono in misura direttamente proporzionale alla popolazione di riferimento dei servizi.

Nel 2021, i comuni italiani in media destinano 140 euro per abitante ai servizi sociali, l'offerta di servizi assistenziali è caratterizzata da grandissimi divari territoriali, tanto in termini di tipologia di utenza a cui i servizi sono destinati che di risorse economiche destinate agli stessi (Fig. 5).

Figura 5 – *Distribuzione territoriale della spesa media dei comuni per servizi sociali. Italia. Anno 2021.*



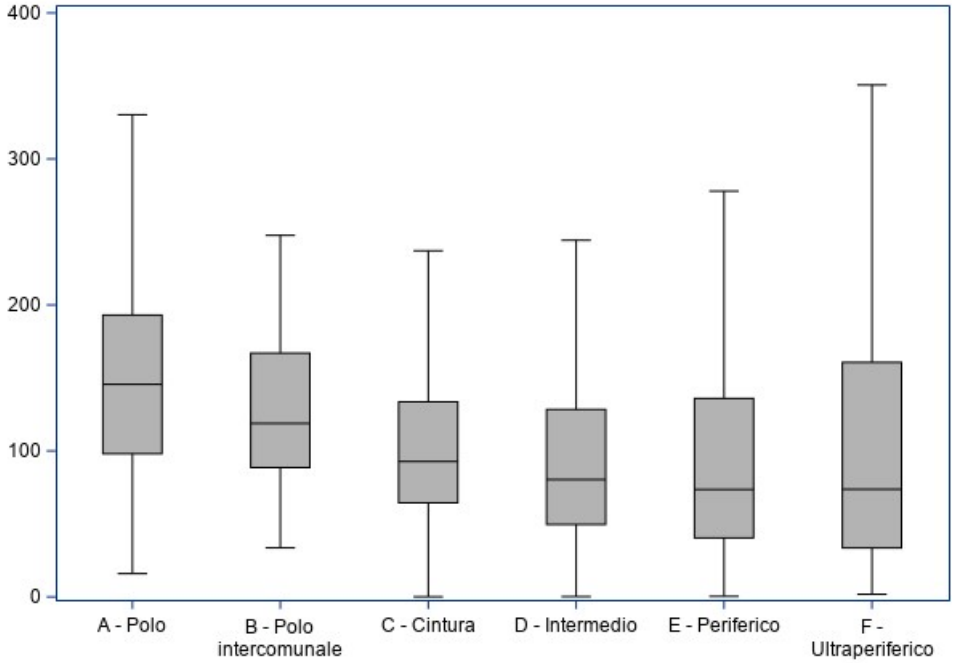
Fonte: elaborazione dati Istat

Oltre il 35% delle spese dei comuni per servizi socio-assistenziali è destinato al sostegno di famiglie e minori ed oltre il 25% agli utenti disabili e il 15% ad anziani (popolazione con 65 anni e più).

Considerando la classificazione dei comuni secondo la SNAI, i comuni appartenenti ai Centri destinano ai propri abitanti circa 150 euro per abitante mentre, i comuni più distanti dai servizi essenziali (sanità, istruzione e trasporti), riescono a determinare a tale scopo oltre il 23% in meno, destinando ciascun residente circa 115 euro (Fig. 6).

Man mano che ci si allontana dai poli, la spesa pro-capite si riduce, ad esclusione dei comuni ultraperiferici in cui necessariamente il decisore pubblico deve colmare le carenze di un territorio lontano dai servizi.

Figura 6 – Spesa sociale dei comuni per abitante per aree SNAI. *Anno 2021.*



Fonte: elaborazione dati Istat

In funzione dell'area SNAI, cambia necessariamente il peso di ciascuna categoria di utenza sul totale.

Se nei Centri oltre il 38% della spesa è destinata alle famiglie e ai minori, nelle Aree Interne questa incidenza, coerente ed in modo strettamente connesso con quanto visto in riferimento alle strutture demografiche, scende al 33% mentre è di

oltre 5 punti percentuali più alto il peso della spesa sociale per gli anziani nelle Aree Interne (circa il 20% a fronte del 14% nei Centri) (Tab. 8).

Tabella 8 – *Quota della spesa sociale per tipologia di utenza e aree SNAI. Anno 2022.*

Utenti	CENTRI	AREE INTERNE
Famiglie e minori	38,8	33,1
Disabili	26,0	27,6
Dipendenze	0,3	0,4
Anziani	14,0	19,8
Immigrati	4,4	3,1
Povertà	11,0	10,0
Multiutenza	5,6	6,0

Fonte: elaborazione dati Istat

6. Conclusioni

Già in riferimento all'intero territorio italiano, con una analisi rivolta alle differenze tra macro ripartizioni geografiche, in un precedente lavoro[9] era emerso come il forte invecchiamento della popolazione italiana stesse ridisegnando gli assetti sociali ed economici, con conseguenze che si riflettono nel campo della produzione, dei consumi, del mercato del lavoro.

Il tutto con notevole impatto sul welfare locale, con conseguenti evidenti effetti in riferimento alla spesa pubblica, effetti la cui previsione è senza dubbio estremamente complessa in quanto dipende da diversi fattori, quali: la qualità dell'invecchiamento, l'efficienza della spesa pubblica, le scelte di politica economica e la possibilità di reperire le risorse necessarie.

Aspetti questi tanto più devastanti quanto più combinazione di numerosi fattori tra cui:

- modalità di invecchiamento non omogenee per macroaree,
- differenti attenzioni e risorse che le stesse aree hanno per l'assistenza alla popolazione anziana,

il che richiede una profonda riflessione sulle conseguenze impressionanti che le diverse scelte di politica economica e di modelli di welfare potrebbero avere nel

[9] M. Carbonara, A.M.M. Carucci, G. Vannella (2023), A Forecasting model for the Italian local public demand and expenditure of services for the senior age. The impact of demographic aging, *Italian Journal of Economic, Demographic and Statistical Studies, n. 3/2023*

prossimo futuro.

Il presente lavoro in primo luogo ha permesso di constatare come, in riferimento al caso italiano, alle problematiche appena richiamate debba essere affiancata la constatazione di ulteriori caratterizzazioni del tessuto socio economico e demografico determinate dalla presenza di due realtà decisamente difformi, i Centri e le Aree Interne, che impattano in modo importante sulle differenti previsioni di bisogno di servizi e delle relative risorse necessarie.

In secondo luogo ha permesso di confermare la necessità di valutare azioni politiche che possano nel tempo tentare di ridurre i dualismi emersi.

Riferimenti bibliografici

Baldi, B. (2018). La Strategia Nazionale delle Aree Interne: innovazione, policy transfer e ricostruzione post sismica*, Rivista Italiana di Politiche* Pubbliche, n. 2/2018.

Barslund, M.; Von Werder M.; ZAIDI, A. (2019). Inequality in active ageing: evidence from a new individual-level index for European countries. *Cambridge, Cambridge University Press*.;

Capellari, L., Lucifora C., Rosina A. (2018). Invecchiamento attivo, mercato del lavoro e benessere. Analisi e politiche attive. Bologna, il Mulino

Carbonara, M.; Carucci, A.M.M.; Vannella, G. (2023), A Forecasting model for the Italian local public demand and expenditure of services for the senior age. The impact of demographic aging, *Italian Journal of Economic, Demographic and Statistical Studies, n. 3/2023*

Cerea S. (2021). Le reti familiari e il senso di solitudine degli anziani, *I luoghi della cura rivista online, n. 1/2021*;

De Nardis P., Altieri L. (2012). I costi sociali dell'essere "un paese di vecchi". In Treu, T. (a cura di), *L'importanza di essere vecchi. Politiche attive per la terza età. Bologna: il Mulino -AREL*;

Dipartimento per le politiche di coesione e per il Sud, Strategia nazionale Aree Interne – SNAI https://politichecoesione.governo.it/it/politica-di-coesione/strategie-tematiche-e-territoriali/strategie-territoriali/strategia-nazionale-aree-interne-snai/

Formez (2002). Rapporto Formez PA: La Strategia Nazionale per le Aree Interne e i nuovi aspetti istituzionali*, Gangemi editore, 2022*

Istat, Rapporto annuale 2024. La situazione del Paese. ISTAT 2024 https://www.istat.it/produzione-editoriale/rapporto-annuale-2024-la-situazione-del-paese-2/

Lucatelli S.; Monaco, F.; Filippo Tantillo, F. (2019), La Strategia delle aree interne al servizio di un nuovo modello di sviluppo locale per l'Italia, *Rivista economica del Mezzogiorno, n. 3-4/2019*

Monteduro, G.; Bertani, M.; Nanetti S. (2021). Tra invecchiamento e fragilità, le spese per interventi e servizi sociali agli anziani, *Lavoro sociale, n. 4/2021*

Moscarelli, R.; Fera, A. (2024). La Strategia Nazionale Aree Interne 10 anni dopo: una proposta di analisi comparativa tra le programmazioni 2014-2020 e 2021-2027, *Scienze Regionali, n. 1/2024*



DIPARTIMENTO DI
ECONOMIA E FINANZA

PDF finito di comporre il 28 dicembre 2024


9 788866 290537